

FMA 3TC11: Probabilités

Probability, from measure theory to the limit theorems. Assuming discrete probability (*probabilités discrètes*), the course covers measure theory and the Lebesgue integral; random variables, expectation, independence and change of variables; the characteristic function; Gaussian vectors; conditional expectation; and the limit theorems.

Prose is in English; the French terms the poly and the exams actually use are kept inline, so the vocabulary stays findable in both languages.

Contents

1	Probabilités discrètes	3
1.1	Espace de probabilité discret	3
1.2	Indépendance	4
1.3	Conditionnement	5
1.4	Variables aléatoires	7
1.5	Loi conditionnelle	8
1.6	Loi jointe, lois marginales	9
1.7	Espérance	10
1.8	Variance, covariance	12
1.9	Fonction génératrice	14
1.10	Espérance conditionnelle	16
1.11	Vecteurs aléatoires	17
1.12	Variables aléatoires indépendantes	18
2	Théorie de la mesure	19
2.1	Tribus	20
2.2	Mesures	24
2.3	Ensembles négligeables	28
2.4	Fonctions mesurables	28
3	Intégrale de Lebesgue	31
3.1	Définition	32
3.2	Monotonie	34
3.3	Linéarité	36
3.4	Ensembles négligeables	38
3.5	Convergence monotone, convergence dominée	39
3.6	Lien avec l'intégrale de Riemann	41
3.7	Mesures discrètes	43
3.8	Mesures à densité	45
3.9	Théorème de transfert	47
3.10	Changement de variable	48
3.11	Mesure produit	51
3.12	Théorème de Fubini	52
3.13	Intégrale dépendant d'un paramètre	55

4	Théorie des probabilités	57
4.1	Espace de probabilité	57
4.2	Variabes aléatoires	58
4.3	Fonction de répartition	59
4.4	Lois à densité	61
4.5	Loi jointe, lois marginales	62
4.6	Espérance	64
4.7	Variance, covariance	67
4.8	Vecteurs aléatoires	68
4.9	Variabes aléatoires indépendantes	71
4.10	Calcul de densité	72
4.11	Inégalités	75
5	Loi conditionnelle	77
5.1	Condition sur un événement non négligeable	78
5.2	Condition sur une variable aléatoire	80
5.3	Cas des lois à densité	82
5.4	Espérance conditionnelle	85
6	Fonction caractéristique	89
6.1	Définition et premières propriétés	89
6.2	Formule d'inversion	92
6.3	Calcul de moments	96
6.4	Somme de variables aléatoires indépendantes	98
6.5	Cas des vecteurs aléatoires	100
6.6	Caractérisation de l'indépendance	102
7	Vecteurs gaussiens	103
7.1	Rappels sur la loi normale	103
7.2	Premier exemple	104
7.3	Définition	105
7.4	Construction d'un vecteur gaussien	106
7.5	Un contre-exemple	107
7.6	Existence d'une densité	108
7.7	Propriétés	110
8	Théorèmes limites	114
8.1	Convergence presque sûre	115
8.2	Convergence en loi	116
8.3	Loi forte des grands nombres	119
8.4	Théorème central limite	122
8.5	Cas des vecteurs aléatoires	126
9	Annexes	127
9.1	Classe monotone	128
9.2	Lois usuelles	130
9.3	Notions de convergence	131

1 Probabilités discrètes

Definition (Expérience Aléatoire (*random experiment*)). Une **expérience aléatoire** est une expérience dont le résultat n'est pas prévisible.

Formellement, une telle expérience se décrit comme un élément ω pris dans un ensemble Ω de résultats possibles, appelé l'**univers** (*sample space*).

Lorsque l'univers Ω est un ensemble au plus dénombrable, on peut définir une théorie de la probabilités élémentaire, qui ne nécessite pas la théorie de la mesure. Chaque événement peut être affecté d'une probabilité, et les probabilités des événements sont reliées par les axiomes de Kolmogorov. Cette théorie est appelée la théorie des probabilités discrètes,

1.1 Espace de probabilité discret

On se restreint au cas où l'univers Ω est un ensemble au plus dénombrable. On note $\mathcal{P}(\Omega)$ l'**ensemble des parties** de Ω .

Definition (Événement). On appelle **événement** (*event*) tout sous-ensemble de Ω .

On dit que l'événement A est réalisé si $\omega \in A$.

The whole vocabulary of set operations carries a probabilistic reading. Comme les événements sont des ensembles, on obtient pour tous événements A et B :

- $A^c = \Omega \setminus A$: l'événement “non A ” ;
- $A \cap B$: l'événement “ A et B ” ; $A \cup B$: l'événement “ A ou B ” ;
- $A \subseteq B$: la propriété “ A implique B ” ;
- $A \cap B = \emptyset$: la propriété “ A et B incompatibles”.

Par ailleurs, les ensembles $\emptyset$ et Ω définissent des événements, respectivement impossible et certain: the two extreme cases, the **événement impossible** (*impossible event*) and the **événement certain** (*certain event*).

Definition (Mesure de probabilité). On appelle **mesure de probabilité** (*probability measure*) sur un ensemble au plus dénombrable Ω une application $\mathbb{P} : \mathcal{P}(\Omega) \rightarrow [0, 1]$ qui satisfait les deux propriétés suivantes :

- $\mathbb{P}(\Omega) = 1$;
- pour toute famille au plus dénombrable d'événements deux-à-deux disjoints $(A_i)_{i \in I}$,

$$\mathbb{P}\left(\bigcup_{i \in I} A_i\right) = \sum_{i \in I} \mathbb{P}(A_i).$$

On appelle la seconde propriété l'axiome de **σ -additivité** (*σ -additivity*).

The two hypotheses on the family matter and are often quoted loosely. The family must be at most countable — σ -additivité says nothing about an uncountable union — and the événements must be *pairwise* disjoint, not merely have empty total intersection.

Remark. Une mesure de probabilité sur un espace discret est entièrement caractérisée par ses valeurs prises sur les singletons, puisque pour tout $A \subseteq \Omega$,

$$\mathbb{P}(A) = \sum_{\omega \in A} \mathbb{P}(\{\omega\}).$$

This is the one structural simplification the discrete setting buys, and it is exactly what fails in the general case: on $\mathbb{R}$ every singleton has probability 0, yet the measure is not zero.

Proposition. Soit $\mathbb{P}$ une mesure de probabilité sur Ω . Pour tous $A, B \subseteq \Omega$,

1. $\mathbb{P}(\emptyset) = 0$;
2. $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$;
3. $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$;
4. si $A \subseteq B$, alors $\mathbb{P}(A) \leq \mathbb{P}(B)$.

Suite d'événements. Une suite d'événements $(A_n)_{n \geq 1}$ est dite *croissante* si $A_n \subseteq A_{n+1}$ pour tout n ; sa limite est alors $A = \cup_n A_n$, ce que l'on notera $A_n \uparrow A$. De même, une suite d'événements est dite *décroissante* si $A_{n+1} \subseteq A_n$ pour tout n ; sa limite est $A = \cap_n A_n$, ce que l'on notera $A_n \downarrow A$.

Proposition. Soit $\mathbb{P}$ une mesure de probabilité sur Ω et $(A_n)_{n \geq 1}$ une suite d'événements.

1. Si $A_n \uparrow A$, alors $\mathbb{P}(A) = \lim_n \mathbb{P}(A_n)$.
2. Si $A_n \downarrow A$, alors $\mathbb{P}(A) = \lim_n \mathbb{P}(A_n)$.
3. On a la **borne de l'union** (union bound) :

$$\mathbb{P}\left(\bigcup_{n \geq 1} A_n\right) \leq \sum_{n \geq 1} \mathbb{P}(A_n).$$

Remark. These are the discrete shadow of convergence monotone. The increasing case is σ -additivity after disjointification — set $B_1 = A_1$ and $B_n = A_n \setminus A_{n-1}$. For the decreasing case, by complementation, la preuve découle de la propriété précédente, en remarquant que $A_n \downarrow A$ implique $A_n^c \uparrow A^c$. The borne de l'union is finite subadditivity iterated, then passed to the limit. All three reappear in chapter 2 for a general mesure, where the decreasing case acquires a finiteness hypothesis that is automatic here.

1.2 Indépendance

Definition (Indépendance (*independence*)). Deux événements A, B sont dits **indépendants**, ce que l'on note $A \perp\!\!\!\perp B$, si

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \mathbb{P}(B).$$

La notion d'indépendance est donc liée à la mesure de probabilité: it is not a property of the sets, but of the sets *together with* the mesure. The same two subsets of the same Ω can be independent for one mesure and dependent for another, and this is why conditioning — which replaces $\mathbb{P}$ by $\mathbb{P}(\cdot \mid C)$ — can destroy or create it.

Proposition. Il y a équivalence entre $A \perp\!\!\!\perp B$, $A \perp\!\!\!\perp B^c$, $A^c \perp\!\!\!\perp B$ et $A^c \perp\!\!\!\perp B^c$.

Proposition. Un événement A tel que $\mathbb{P}(A) = 0$ ou $\mathbb{P}(A) = 1$ est indépendant de tout autre événement.

Definition (Événements indépendants (*independent events*)). Les événements d'une famille $(A_i)_{i \in I}$ sont dits **indépendants** si pour tout sous-ensemble fini $J \subseteq I$,

$$\mathbb{P}\left(\bigcap_{i \in J} A_i\right) = \prod_{i \in J} \mathbb{P}(A_i).$$

The quantifier over all finite subsets is the whole content of the definition. Checking the single identity $\mathbb{P}(\cap_{i \in I} A_i) = \prod_{i \in I} \mathbb{P}(A_i)$, or checking it only on pairs, is strictly weaker.

Example (Pairwise indépendance is not indépendance). Throw a die twice, and consider the three événements “le premier lancer est pair”, “le second lancer est pair” and “la somme des deux lancers est paire”. Each has probability $\frac{1}{2}$, and any two of them are independent: knowing the parity of one throw says nothing about the parity of the other, and the parity of the sum is equally likely either way given one throw. But the three are not independent, because the third événement is the événement that the first two *agree*: the intersection of all three has probability $\frac{1}{4}$, not $\frac{1}{8}$. Taken two at a time, though, les événements “le premier lancer est pair” et “la somme des deux lancers est paire” sont indépendants — an identity between numbers, not a fact about the experiment. Ainsi, les événements “le premier lancer est impair” et “la somme des deux lancers est impaire” sont également indépendants, by the proposition above.

1.3 Conditionnement

Definition (Probabilité conditionnelle). Pour tous événements A, B tels que $\mathbb{P}(B) > 0$, on définit la **probabilité conditionnelle** (*conditional probability*) de A sachant B par :

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

The hypothesis $\mathbb{P}(B) > 0$ is not cosmetic: the whole of chapter 5 exists to give a meaning to conditioning on an événement of probability zero, which is the generic situation once densités appear. In the discrete setting it can simply be required.

Proposition. Pour tout événement B tel que $\mathbb{P}(B) > 0$, l'application $A \mapsto \mathbb{P}(A | B)$ est une mesure de probabilité sur Ω .

Everything already proved therefore applies verbatim to $\mathbb{P}(\cdot | B)$: complementation, inclusion–exclusion, monotone limits, the borne de l'union. Tout se passe comme si l'univers, initialement Ω , était réduit à B — and renormalised.

Proposition. Deux événements A et B sont indépendants si et seulement si $\mathbb{P}(B) = 0$ ou $\mathbb{P}(A | B) = \mathbb{P}(A)$.

Proposition (Formule de Bayes (*Bayes' formula*)). Soit A, B deux événements tels que $\mathbb{P}(A) > 0$ et $\mathbb{P}(B) > 0$. Alors,

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(B | A) \mathbb{P}(A)}{\mathbb{P}(B)}.$$

Both positivity hypotheses are needed: $\mathbb{P}(B) > 0$ for the left-hand side to exist, $\mathbb{P}(A) > 0$ for the probabilité conditionnelle on the right. La formule de Bayes permet de changer l'ordre du conditionnement. La preuve est immédiate: $\mathbb{P}(A \cap B)$ can be factored two ways.

Definition (Indépendance conditionnelle (*conditional independence*)). Soit C un événement tel que $\mathbb{P}(C) > 0$. Deux événements A, B sont dits **indépendants conditionnellement à C** , ce que l'on note $A \perp\!\!\!\perp B | C$, s'ils sont indépendants pour la probabilité conditionnelle $\mathbb{P}(\cdot | C)$:

$$\mathbb{P}(A \cap B | C) = \mathbb{P}(A | C) \mathbb{P}(B | C).$$

Proposition. Soit C un événement tel que $\mathbb{P}(C) > 0$. Deux événements A et B sont indépendants conditionnellement à C si et seulement si $\mathbb{P}(B | C) = 0$ ou $\mathbb{P}(A | B \cap C) = \mathbb{P}(A | C)$.

Example (Conditioning destroys indépendance). On lance un dé deux fois. Les événements “le premier lancer est pair” et “le second lancer est pair” sont indépendants, mais *pas* conditionnellement à l'événement “la somme des deux lancers est paire”. Given that the sum is even, the two throws have the same parity, so knowing that the first is even forces the second to be. Indépendance conditionnelle is neither implied by, nor implies, indépendance.

Proposition (Formule des probabilités composées (*chain rule*)). Pour tous événements $A_1, \dots, A_n$ tels que $\mathbb{P}(A_1 \cap \dots \cap A_n) > 0$,


$$\mathbb{P}(A_1 \cap \dots \cap A_n) = \mathbb{P}(A_1) \mathbb{P}(A_2 | A_1) \cdots \mathbb{P}(A_n | A_1 \cap \dots \cap A_{n-1}).$$

The positivity hypothesis is on the *full* intersection. It is what makes every conditioning on the right-hand side legitimate at once, since each conditioning événement contains $A_1 \cap \dots \cap A_n$ and therefore has positive probability too.

Proposition (Formule des probabilités totales (*law of total probability*)). *Pour toute famille d'événements $(B_i)_{i \in I}$ formant une partition de Ω , avec $\mathbb{P}(B_i) > 0$ pour tout $i \in I$,*

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(B_i) \mathbb{P}(A | B_i).$$

Il suffit d'écrire $A = \cup_{i \in I} (A \cap B_i)$: the union is disjoint, so σ -additivité applies; the family must therefore be at most countable, like everything else here. The two formulas are usually used together: the formule des probabilités totales supplies the denominator $\mathbb{P}(B)$ that the formule de Bayes needs.



Reading the tree left to right gives the formule des probabilités totales: each path to an A leaf contributes the product of the probabilities along it, and the paths are disjoint. Reading it right to left — which branch did we come down, given that we landed on A ? — is the formule de Bayes.

Example (A screening test with a small prevalence). On dispose d'un test pour une certaine maladie. Ce test n'est pas parfait : 1% des individus sains sont positifs au test et 2% des individus malades sont négatifs au test. On suppose que la maladie touche 1% de la population. Quelle est la probabilité qu'un individu positif au test soit effectivement malade ?

Soit X l'état de l'individu et Y le résultat du test. Par la formule de Bayes,

$$\mathbb{P}(X = + | Y = +) = \frac{\mathbb{P}(X = +)}{\mathbb{P}(Y = +)} \mathbb{P}(Y = + | X = +),$$

on a $\mathbb{P}(X = +) = 1\%$ et $\mathbb{P}(Y = + | X = +) = 1 - 2\% = 98\%$. Il reste à appliquer la formule des probabilités totales — for the denominator, with the partition $\{X = +\}, \{X = -\}$ — pour obtenir :

$$\mathbb{P}(Y = +) = 99\% \times 1\% + 1\% \times 98\%.$$

Et donc

$$\mathbb{P}(X = + | Y = +) = \frac{1\% \times 98\%}{99\% \times 1\% + 1\% \times 98\%} \simeq 50\%.$$

A test that is 98% and 99% accurate identifies the ill barely better than a coin, because the prevalence and the false-positive rate are the same order of magnitude. The lesson is that $\mathbb{P}(X | Y)$ and $\mathbb{P}(Y | X)$ are different numbers, and that the prior is what separates them.


Example (Two walkers on a heptagon, as a conditioning computation). Two walkers move on the vertices of a heptagon, numbered 0 to 6. At each time n each walker moves independently and uniformly to one of the two neighbouring vertices, so that with X_n and Y_n their positions,

$$\mathbb{P}(X_{n+1} = X_n + 1 \bmod 7) = \mathbb{P}(X_{n+1} = X_n - 1 \bmod 7) = \frac{1}{2},$$

and likewise for Y_n . Let L_n be the length of the shortest path between the two walkers,

$$L_n = \min(X_n - Y_n \bmod 7, Y_n - X_n \bmod 7) \in \{0, 1, 2, 3\}.$$

Write $D_n = X_n - Y_n \bmod 7$, so that $L_n = \min(D_n, 7 - D_n)$. Each walker moves by ± 1 , so D changes by ± 2 , 0 or -2 with probabilities $\frac{1}{4}, \frac{1}{2}, \frac{1}{4}$. From $D = 0$ the gap becomes 2 or 5, both at distance 2; from $D = 1$ it becomes 3 or 6, at distances 3 and 1; from $D = 2$ it becomes 4 or 0, at distances 3 and 0; from $D = 3$ it becomes 5 or 1, at distances 2 and 1. The loi of L_{n+1} therefore depends on the past only through L_n , which is the Markov property, and the transition probabilities $\mathbb{P}(L_{n+1} = \ell' \mid L_n = \ell)$ are collected in the graph below.



The graph is connected in both directions, so the chain is irreducible, and every state carries a self-loop, so it is aperiodic; the loi of L_n therefore converges to the stationary loi π . The balance equations — each the formule des probabilités totales applied to the partition by the previous state —

$$\pi_0 = \frac{1}{2}\pi_0 + \frac{1}{4}\pi_2, \quad \pi_1 = \frac{3}{4}\pi_1 + \frac{1}{4}\pi_3, \quad \pi_2 = \frac{1}{2}\pi_0 + \frac{1}{2}\pi_2 + \frac{1}{4}\pi_3,$$

gives $\pi_1 = \pi_2 = \pi_3 = 2\pi_0$, so $\pi = \frac{1}{7}(1, 2, 2, 2)$ after normalisation. In particular $\mathbb{P}(L_n = 0) \rightarrow \frac{1}{7}$: in the long run the two walkers occupy the same vertex one seventh of the time, which is what uniformity on seven vertices should give.

1.4 Variables aléatoires

Une **variable aléatoire** (*random variable*) est une grandeur à valeurs dans un certain ensemble ; cette valeur dépend du résultat de l'expérience.

Definition (Variable aléatoire). Une **variable aléatoire** X est une fonction de Ω vers un ensemble E .

No measurability is required, because on a discrete Ω every subset is an événement — exactly the hypothesis reinstated in chapter 4. On notera

$$\mathbb{P}(X = x) = \mathbb{P}(\{\omega \in \Omega : X(\omega) = x\}) = \mathbb{P}(X^{-1}(x)).$$

Comme l'univers Ω est discret, on peut supposer l'ensemble E discret, sans perte de généralité: X is determined by its values on a countable set.

Definition (Loi d'une variable aléatoire). On appelle **loi** (*distribution*) de la variable aléatoire X la mesure de probabilité définie sur E par :

$$\forall A \subseteq E, \quad \mathbb{P}_X(A) = \mathbb{P}(X \in A).$$


Comme toute mesure de probabilité discrète, la loi est entièrement caractérisée par ses valeurs prises sur les singletons, soit $\mathbb{P}_X(x) = \mathbb{P}(X = x)$. Chapter 4 will identify $\mathbb{P}_X$ as the mesure image of $\mathbb{P}$ under X , an object chapter 2 defines.

Notation. Several letters are reused deliberately — $\mathcal{P}$, $\mathcal{B}$ and three more — and chapter 2 sets those collisions out in full; the argument in the parentheses disambiguates in every case.


Lois discrètes. Nous donnons ici quelques lois discrètes usuelles — the five the course uses, tabulated below. Their espérances, variances and fonctions génératrices are computed in the three subsections that follow.

Nom	Paramètre(s)	Notation	Support	$\mathbb{P}(X = k)$
Bernoulli	$p \in [0, 1]$	$\mathcal{B}(p)$	$\{0, 1\}$	p if $k = 1$, $1 - p$ if $k = 0$
Binomiale	$n \in \mathbb{N}$, $p \in [0, 1]$	$\mathcal{B}(n, p)$	$\{0, \dots, n\}$	$\binom{n}{k} p^k (1 - p)^{n-k}$
Poisson	$\lambda > 0$	$\mathcal{P}(\lambda)$	$\mathbb{N}$	$e^{-\lambda} \lambda^k / k!$
Géométrique	$p \in]0, 1]$	$\mathcal{G}(p)$	$\mathbb{N}^*$	$(1 - p)^{k-1} p$
Uniforme	$n \in \mathbb{N}^*$	$\mathcal{U}(1, \dots, n)$	$\{1, \dots, n\}$	$1/n$

The binomial counts the successes among n independent Bernoulli trials of the same parameter; the geometric counts the trials up to and including the first success, so its support starts at 1.



Both binomials above have $n = 20$. The mass concentrates around $np = 5$ and 12 respectively — and the spread is governed by $np(1 - p)$, which is largest at $p = \frac{1}{2}$; the right-hand loi, being nearer the symmetric case, is the wider of the two.



The two panels are the same picture: this is the **absence de mémoire** (*memorylessness*) of the loi géométrique. Since $\mathbb{P}(X > k) = (1 - p)^k$ on the support $\mathbb{N}^*$,

$$\mathbb{P}(X > n + k \mid X > n) = \frac{(1 - p)^{n+k}}{(1 - p)^n} = (1 - p)^k = \mathbb{P}(X > k).$$

Three failed trials leave the number of further trials distributed exactly as at the start. The geometric is the only discrete loi with this property; the loi exponentielle of chapter 4 is its continuous counterpart.

1.5 Loi conditionnelle

Soit X une variable aléatoire à valeurs dans E .

Definition (Loi conditionnelle). Soit A un événement tel que $\mathbb{P}(A) > 0$. On appelle **loi conditionnelle** (*conditional distribution*) de X sachant A la mesure de probabilité $\mathbb{P}_{X|A}$ définie sur E par :

$$\forall B \subseteq E, \quad \mathbb{P}_{X|A}(B) = \mathbb{P}(X \in B \mid A).$$

C'est la mesure image de la probabilité conditionnelle $\mathbb{P}(\cdot \mid A)$ par X . As before $\mathbb{P}(A) > 0$ is what makes the definition legitimate; chapter 5 removes it, at the cost of defining the loi conditionnelle only up to a négligeable set.

Example (Restricting a uniform die). Soit X une variable aléatoire de loi uniforme sur $\{1, \dots, 6\}$. La loi conditionnelle de X sachant $X \leq 3$ est une loi uniforme sur $\{1, 2, 3\}$. Each surviving value keeps the weight $\frac{1}{6}$, and renormalising by $\mathbb{P}(X \leq 3) = \frac{1}{2}$ turns it into $\frac{1}{3}$. Conditioning a loi uniforme on a subset of its support gives the loi uniforme on that subset — only because the weights were equal to begin with.

1.6 Loi jointe, lois marginales

Soit X et Y deux variables aléatoires à valeurs respectives dans E et F . Le couple (X, Y) définit une variable aléatoire sur $E \times F$.

Definition (Loi jointe, lois marginales). La loi du couple (X, Y) , notée $\mathbb{P}_{X,Y}$, est appelée la **loi jointe** (*joint distribution*) de X et Y . Les lois $\mathbb{P}_X$ et $\mathbb{P}_Y$ sont les **lois marginales** (*marginal distributions*) du couple.

La loi jointe est une mesure de probabilité discrète, entièrement caractérisée par ses valeurs sur les singletons :

$$\forall x \in E, \forall y \in F, \quad \mathbb{P}_{X,Y}(\{x\} \times \{y\}) = \mathbb{P}(X = x, Y = y),$$

et les lois marginales s'en déduisent, by summing out the other coordinate :

$$\mathbb{P}_X(x) = \sum_{y \in F} \mathbb{P}(X = x, Y = y), \quad \mathbb{P}_Y(y) = \sum_{x \in E} \mathbb{P}(X = x, Y = y).$$

The converse fails: the lois marginales do not determine the loi jointe, which is what makes the next definition non-trivial.

Definition (Indépendance de deux variables aléatoires). Deux variables aléatoires X et Y sont dites **indépendantes** si pour tous $A \subseteq E$ et $B \subseteq F$, les événements $\{X \in A\}$ et $\{Y \in B\}$ sont indépendants, soit :

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A) \mathbb{P}(Y \in B).$$

Proposition. Deux variables aléatoires X et Y sont indépendantes si et seulement si

$$\forall x \in E, \forall y \in F, \quad \mathbb{P}(X = x, Y = y) = \mathbb{P}(X = x) \mathbb{P}(Y = y).$$

Though indépendance quantifies over all pairs of subsets, la loi du couple étant une loi discrète, il suffit de vérifier cette propriété sur les singletons; summing recovers the general case. De façon équivalente, les variables aléatoires X et Y sont indépendantes si et seulement si pour tout $x \in E$ tel que $\mathbb{P}(X = x) > 0$, la loi conditionnelle de Y sachant $X = x$ est la loi de Y .

Proposition. Si les variables aléatoires X et Y sont indépendantes, alors les variables aléatoires $\phi(X)$ et $\psi(Y)$ sont indépendantes, quelles que soient les fonctions ϕ et ψ .

No hypothesis at all is needed on ϕ and ψ ; in chapter 4 they must be mesurables, which is the only change.

Example (Thinning a Poisson count by a fair coin). Une tortue donne naissance à N bébés. On suppose que N suit une loi de Poisson $\mathcal{P}(\lambda)$. Chaque bébé a une chance sur deux ($\frac{1}{2}$) d'être une femelle, independently of the others. On note F le nombre de bébés femelles.

Conditionally on $N = n$, the variable F counts the successes among n independent fair trials: sa loi conditionnelle est une loi binomiale $\mathcal{B}(n, \frac{1}{2})$. La loi jointe du couple est :

$$\forall 0 \leq k \leq n, \quad \mathbb{P}(N = n, F = k) = \mathbb{P}(N = n) \mathbb{P}(F = k \mid N = n) = e^{-\lambda} \frac{\lambda^n}{n!} \binom{n}{k} \frac{1}{2^n}.$$

Summing over $n \geq k$, and substituting $m = n - k$,

$$\mathbb{P}(F = k) = e^{-\lambda} \left(\frac{\lambda}{2}\right)^k \frac{1}{k!} \sum_{m \geq 0} \left(\frac{\lambda}{2}\right)^m \frac{1}{m!} = e^{-\lambda/2} \left(\frac{\lambda}{2}\right)^k \frac{1}{k!},$$

so F follows the loi de Poisson $\mathcal{P}(\lambda/2)$. Thinning a Poisson count keeps it Poisson and halves the parameter.

Les variables ne sont *pas* indépendantes car la loi de F sachant $N = 0$ est un Dirac en 0, qui est différente de la loi de F . Having the same family of lois is no substitute for checking the product identity.

1.7 Espérance

Soit X une variable aléatoire à valeurs réelles.

Definition (Espérance). L'**espérance** (*expectation*) de la variable aléatoire X est la valeur, éventuellement infinie,

$$\mathbb{E}(X) = \sum_{\omega \in \Omega} X(\omega) \mathbb{P}(\omega),$$

pourvu que X soit positive ou que $\mathbb{E}(|X|) < \infty$.

The proviso is the whole hypothesis. A sum over a countable index set is order-independent only when its terms are positive or the sum is absolutely convergent; without one of the two, $\mathbb{E}(X)$ is not even well-defined. Every manipulation below rests on it.

Proposition. L'espérance de la variable aléatoire X dépend uniquement de sa loi :

$$\mathbb{E}(X) = \sum_{x \in E} x \mathbb{P}(X = x),$$

pourvu que X soit positive ou que $\mathbb{E}(|X|) < \infty$.

Une variable aléatoire d'espérance nulle est dite **centrée** (*centred*).

Example (The espérance of an indicator is a probability). Soit $A \subseteq \Omega$ un événement. Alors la variable aléatoire $X = \mathbb{1}_A$ suit une loi de Bernoulli $\mathcal{B}(\mathbb{P}(A))$, de sorte que

$$\mathbb{E}(\mathbb{1}_A) = \mathbb{P}(A).$$

This one line is the bridge between counting and probability, and it is the engine of the linearity arguments below.

Example (Espérances des cinq lois). L'espérance d'une variable aléatoire $X \sim \mathcal{B}(p)$ est $\mathbb{E}(X) = \mathbb{P}(X = 1) = p$.

L'espérance d'une variable aléatoire $X \sim \mathcal{P}(\lambda)$ est

$$\mathbb{E}(X) = \sum_{k \geq 0} k e^{-\lambda} \frac{\lambda^k}{k!} = \lambda e^{-\lambda} \sum_{k \geq 1} \frac{\lambda^{k-1}}{(k-1)!} = \lambda.$$

L'espérance d'une variable aléatoire $X \sim \mathcal{U}(1, \dots, n)$ est $\mathbb{E}(X) = \frac{1+2+\dots+n}{n} = \frac{n+1}{2}$.

For $X \sim \mathcal{B}(n, p)$, writing $X = \sum_{i=1}^n X_i$ with the X_i independent $\mathcal{B}(p)$ and using linearity below, $\mathbb{E}(X) = np$. For $X \sim \mathcal{G}(p)$,

$$\mathbb{E}(X) = \sum_{k \geq 1} k(1-p)^{k-1}p = p \cdot \frac{1}{p^2} = \frac{1}{p},$$

using $\sum_{k \geq 1} kq^{k-1} = (1-q)^{-2}$ for $|q| < 1$.

Theorem (Transfert (*transfer theorem*)). *Soit X une variable aléatoire à valeurs dans E . Pour toute fonction $\phi : E \rightarrow \mathbb{R}$,*

$$\mathbb{E}(\phi(X)) = \sum_{x \in E} \phi(x) \mathbb{P}(X = x),$$

pourvu que ϕ soit positive ou que $\mathbb{E}(|\phi(X)|) < \infty$.

To compute the espérance of $\phi(X)$ one never needs Ω : the loi of X suffices, which is why a variable can be described by its loi alone. The hypothesis is again positivity *or* integrability, and it bears on $\phi(X)$, not on X : X may be integrable while X^2 is not.

Corollary (Linéarité). *Soit X, Y deux variables aléatoires réelles d'espérances finies. Alors,*

$$\forall \alpha \in \mathbb{R}, \quad \mathbb{E}(\alpha X) = \alpha \mathbb{E}(X), \quad \text{and} \quad \mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y).$$

Remark. Linearity requires *finite* espérances and nothing else: X and Y need not be independent, so $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$ holds for arbitrarily dependent variables. On raisonne en appliquant le théorème de transfert au couple (X, Y) , the absolute convergence coming from the finiteness hypothesis. Contrast the product rule below, which does need indépendance, and the variance of a sum, which does not split without it.

Proposition (Espérance d'une série). *Pour toute suite de variables aléatoires réelles $(X_n)_{n \geq 1}$,*

$$\mathbb{E} \left(\sum_{n \geq 1} X_n \right) = \sum_{n \geq 1} \mathbb{E}(X_n)$$

dès que les variables aléatoires X_n sont positives pour tout $n \geq 1$ ou que $\sum_{n \geq 1} \mathbb{E}(|X_n|) < \infty$.

This is linearity extended to a countable sum, and the discrete form of the convergence monotone and convergence dominée theorems of chapter 3. The second hypothesis bounds the *sum* of the $\mathbb{E}(|X_n|)$, not each term separately.

Proposition. *Pour toutes variables aléatoires réelles X, Y indépendantes d'espérances finies,*

$$\mathbb{E}(XY) = \mathbb{E}(X) \mathbb{E}(Y).$$

Indépendance is essential; finiteness of $\mathbb{E}(X)$ and $\mathbb{E}(Y)$ then gives $\mathbb{E}(|XY|) = \mathbb{E}(|X|) \mathbb{E}(|Y|) < \infty$, so XY is automatically integrable. The converse is false: $\mathbb{E}(XY) = \mathbb{E}(X) \mathbb{E}(Y)$ says only that X and Y are décorrélées, which is weaker than indépendance.

Example (Fixed points of a random ordering, by indicators and linearity). One object here is borrowed from chapter 4 and one is not: the variables to be sorted are continuous, and so outside this chapter, but the permutation that sorts them takes finitely many values, so it is a discrete variable aléatoire and the computation below lives entirely in the present setting.

Let $X_1, \dots, X_n$ be **indépendantes et identiquement distribuées** (*independent and identically distributed*) real variables aléatoires, abbreviated i.i.d. from here on, whose common loi has a densité — an object chapter 4 builds, quoted here only for the one fact that $\mathbb{P}(X_i = X_j) = 0$ for $i \neq j$; by the borne de l'union, $\mathbb{P}(\exists i \neq j, X_i = X_j) = 0$. There is therefore presque sûrement a unique permutation σ of $\{1, \dots, n\}$ that

sorts them, $X_{\sigma(1)} < \dots < X_{\sigma(n)}$, and σ is a variable aléatoire with values in the set of permutations.

Because the X_i are i.i.d., for every fixed permutation s ,

$$\mathbb{P}(\sigma = s) = \mathbb{P}(X_{s(1)} < \dots < X_{s(n)}) = \mathbb{P}(X_1 < \dots < X_n),$$

a quantity that does not depend on s , so σ is uniform on the $n!$ permutations. In particular $\mathbb{P}(\sigma(i) = j) = \frac{1}{n}$ for all i, j .

How many fixed points does σ have on average? Write the count as a sum of indicators and use linearity:

$$\mathbb{E} \left(\sum_{i=1}^n \mathbb{1}_{\{\sigma(i)=i\}} \right) = \sum_{i=1}^n \mathbb{E}(\mathbb{1}_{\{\sigma(i)=i\}}) = \sum_{i=1}^n \mathbb{P}(\sigma(i) = i) = n \cdot \frac{1}{n} = 1.$$

The answer is 1 for every n , and the événements $\{\sigma(i) = i\}$ are heavily dependent — knowing $n-1$ of them determines the last — which linearity does not care about. The method is the one to keep for any counting espérance: decompose into indicators, take espérances termwise, read each term as a probability.

1.8 Variance, covariance

Soit X une variable aléatoire réelle d'espérance finie.

Definition (Variance). La **variance** de la variable aléatoire X est la valeur, éventuellement infinie :

$$\text{Var}(X) = \mathbb{E}((X - \mathbb{E}(X))^2).$$

Par linéarité de l'espérance, on obtient l'expression équivalente :

$$\text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2,$$

which is the one to compute with; it comes from expanding the square.

Proposition. On a $\text{Var}(X) \geq 0$ avec $\text{Var}(X) = 0$ si et seulement si $X = \mathbb{E}(X)$ p.s.

The abbreviation *p.s.* means **presque sûrement** (*almost surely*), c'est-à-dire avec probabilité 1; it is kept in its French form. Here it says $X(\omega) = \mathbb{E}(X)$ for every ω with $\mathbb{P}(\omega) > 0$: the values of X on the null part of Ω are unconstrained, which is why the conclusion is not $X = \mathbb{E}(X)$ everywhere.

Par linéarité de l'espérance, on a :

$$\forall \alpha \in \mathbb{R}, \quad \text{Var}(\alpha X) = \alpha^2 \text{Var}(X).$$

The variance scales quadratically: the square is the entire content of the rule, and the reason the écart type $\sqrt{\text{Var}(X)}$, not the variance, is the quantity with the same units as X . In particular $\text{Var}(-X) = \text{Var}(X)$, the case $\alpha = -1$. Separately, $\text{Var}(X+c) = \text{Var}(X)$ for a constant c , which does not follow from the scaling rule but straight from the definition: adding c moves X and $\mathbb{E}(X)$ by the same amount, so $X+c-\mathbb{E}(X+c) = X-\mathbb{E}(X)$.

On considère maintenant X et Y deux variables aléatoires de variances finies.

Definition (Covariance). La **covariance** entre les variables aléatoires X et Y est la valeur :

$$\text{Cov}(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))).$$

Finiteness of the two variances is what makes this well-defined: on en déduit que $\mathbb{E}(X^2) < \infty$ et $\mathbb{E}(Y^2) < \infty$. En utilisant le fait que $|XY| \leq \frac{1}{2}(X^2 + Y^2)$, on obtient que XY est d'espérance finie. Par linéarité de l'espérance — after expanding the product — on obtient alors :

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y).$$

On note que $\text{Cov}(X, Y) = 0$ dès que X et Y sont indépendantes. La réciproque est fausse.

La covariance vérifie les propriétés suivantes :

- $\text{Cov}(X, X) = \text{Var}(X)$;
- $\text{Cov}(X, Y) = \text{Cov}(Y, X)$;
- $\text{Cov}(\alpha X, Y) = \alpha \text{Cov}(X, Y)$ pour tout $\alpha \in \mathbb{R}$;
- $\text{Cov}(X, Y + Z) = \text{Cov}(X, Y) + \text{Cov}(X, Z)$ pour toutes variables X, Y, Z de variances finies.

En particulier, la covariance est une forme bilinéaire symétrique.

Remark. La covariance n'est pas **définie positive** (*positive definite*) car $\text{Var}(X) = 0$ implique uniquement que X est p.s. constante, not zero. La covariance n'est définie positive que si l'on se restreint aux variables aléatoires centrées — identifying two that are p.s. equal. Elle définit alors un produit scalaire. That structure is the right way to see the next two results: the variance of a sum is an expansion of $\|X + Y\|^2$, and Cauchy–Schwartz is Cauchy–Schwartz.

Proposition. On a pour toutes variables aléatoires X et Y de variances finies :

$$\text{Var}(X + Y) = \text{Var}(X) + 2 \text{Cov}(X, Y) + \text{Var}(Y).$$

Corollary. Si les variables aléatoires X et Y sont indépendantes et de variances finies, alors $\text{Cov}(X, Y) = 0$ et

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y).$$

The cross term is the only place indépendance enters. Espérances add for any pair of integrable variables; variances add only when the covariance vanishes, and vanishing covariance is weaker than indépendance, so the corollary is genuinely weaker than the proposition. With the scaling rule, for independent X, Y and reals a, b ,

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y),$$

the squares again.

Proposition (Inégalité de Cauchy-Schwartz (*Cauchy–Schwartz inequality*)). On a pour toutes variables aléatoires X et Y de variances finies :


$$|\text{Cov}(X, Y)| \leq \sqrt{\text{Var}(X) \text{Var}(Y)}.$$

The name is spelled *Cauchy–Schwartz* throughout. On peut supposer les variables aléatoires X et Y centrées, quitte à considérer les variables $X - \mathbb{E}(X)$ et $Y - \mathbb{E}(Y)$, which changes neither side. Le résultat est alors une conséquence du fait que la covariance définit un produit scalaire: the inequality is Cauchy–Schwartz for the inner product of the remark above.

Definition (Coefficient de corrélation). Le **coefficient de corrélation** (*correlation coefficient*) entre deux variables aléatoires X et Y de variances finies et non nulles est la valeur :

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}}.$$

The variances must be non-zero for the quotient to exist — a p.s. constant variable has no correlation with anything. Au vu de l'inégalité de Cauchy-Schwartz, on a $\rho(X, Y) \in [-1, 1]$, avec $|\rho(X, Y)| = 1$ si et seulement si X et Y sont linéairement dépendantes, à savoir $\rho(X, Y) = 1$ si et seulement si $Y = aX + b$ avec $a > 0$, et $\rho(X, Y) = -1$ si et seulement si $Y = aX + b$ avec $a < 0$. Lorsque $\rho(X, Y) = 0$, on dit que les variables sont **décorrélées** (*uncorrelated*). The coefficient is the cosine of the “angle” between the two variables centrées. The outer panels are the extreme cases: all the mass on a line, $\rho = \pm 1$ by the slope's sign. The middle panel is the one to remember — the mass is uniform on a circle, so by symmetry $\mathbb{E}(X) = \mathbb{E}(Y) = \mathbb{E}(XY) = 0$ and the coordinates are décorréliées, yet X determines Y up to a sign. Correlation measures only the *linear* part of a dependence, so $\rho = 0$ is strictly weaker than indépendance.



Example (Uncorrelated but not independent). Soit X une variable aléatoire de loi uniforme sur $\{0, 1\}$ et Z une variable aléatoire de loi uniforme sur $\{-1, +1\}$ indépendante de X . On note $Y = XZ$. Since $\mathbb{E}(Z) = 0$ and Z is independent of X and of X^2 ,

$$\mathbb{E}(Y) = \mathbb{E}(XZ) = \mathbb{E}(X) \mathbb{E}(Z) = 0, \quad \mathbb{E}(XY) = \mathbb{E}(X^2Z) = \mathbb{E}(X^2) \mathbb{E}(Z) = 0,$$

so $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X) \mathbb{E}(Y) = 0$ and the variables are décorrélées. Par contre, $\mathbb{P}(X = 0, Y = 1) = 0$ tandis que $\mathbb{P}(X = 0) = \frac{1}{2}$ et $\mathbb{P}(Y = 1) = \frac{1}{4}$, donc les variables ne sont pas indépendantes: the product identity fails on a single pair of singletons. One pair suffices to break indépendance.

Example (Variances des cinq lois). For $X \sim \mathcal{B}(p)$, $X^2 = X$ so $\text{Var}(X) = p - p^2 = p(1 - p)$.

For $X \sim \mathcal{B}(n, p)$, write X as a sum of n independent Bernoulli variables; the covariances vanish and the variances add, giving $\text{Var}(X) = np(1 - p)$. This is the corollary above doing real work: the summands are not identically zero, but their pairwise covariances are.

For $X \sim \mathcal{P}(\lambda)$, $\mathbb{E}(X(X - 1)) = \lambda^2$, so $\mathbb{E}(X^2) = \lambda^2 + \lambda$ and $\text{Var}(X) = \lambda$: the loi de Poisson has equal mean and variance. For $X \sim \mathcal{G}(p)$, $\text{Var}(X) = \frac{1-p}{p^2}$, and for $X \sim \mathcal{U}(1, \dots, n)$, $\text{Var}(X) = \frac{n^2-1}{12}$.

1.9 Fonction génératrice

La fonction génératrice d'une variable aléatoire à valeurs entières positives permet de caractériser la loi et d'en calculer les moments.

Definition (Fonction génératrice). La **fonction génératrice** (*generating function*) d'une variable aléatoire X à valeurs dans $\mathbb{N}$ est la fonction G_X définie par :

$$\forall t \in [-1, 1], \quad G_X(t) = \mathbb{E}(t^X) = \sum_{k \geq 0} \mathbb{P}(X = k) t^k.$$

The hypothesis that X takes values in $\mathbb{N}$ is what the construction needs: t^X must be a power series in t . Il s'agit d'une série entière de rayon de convergence supérieur ou égal à 1 — the coefficients sum to 1 — et G_X est donc une fonction continue sur $[-1, 1]$ et C^∞ sur $] -1, 1[$. The endpoints are the delicate ones, and the one-sided derivative at 1 below is where the moments live.

Proposition. On a $\mathbb{P}(X = 0) = G_X(0)$ et pour tout $k \geq 1$,

$$\mathbb{P}(X = k) = \frac{1}{k!} \frac{d^k G_X}{dt^k}(0).$$

Ce résultat montre que la fonction génératrice caractérise la loi: two $\mathbb{N}$ -valued variables with the same fonction génératrice have the same loi. That is the first of its two uses.

The second is moments. La fonction génératrice a toujours une dérivée à gauche en 1, éventuellement infinie, et on a :

$$\mathbb{E}(X) = G'_X(1^-).$$

More generally the k -th **factorial moment** is read off the k -th left derivative, when that derivative is finite:

$$\mathbb{E}(X(X-1)\cdots(X-k+1)) = \frac{d^k G_X}{dt^k}(1^-).$$

The derivative is a *left* derivative at 1, since G_X is only defined on $[-1, 1]$, and it may be infinite — exactly when X has no moment of that order. From the factorial moments the ordinary ones follow: $\mathbb{E}(X^2) = G''_X(1^-) + G'_X(1^-)$, and then $\text{Var}(X) = G''_X(1^-) + G'_X(1^-) - G'_X(1^-)^2$.

Proposition. Soit X, Y deux variables aléatoires indépendantes à valeurs dans $\mathbb{N}$. Alors,

$$G_{X+Y} = G_X G_Y.$$

The proof is one line — $\mathbb{E}(t^{X+Y}) = \mathbb{E}(t^X) \mathbb{E}(t^Y)$ by indépendance — and the consequence is that a convolution of lois becomes a product of functions. Indépendance is indispensable; without it the espérance of the product does not factor.

Remark. These two properties are exactly what makes the fonction caractéristique φ_X of chapter 6 worth building: $\varphi_X(t) = \mathbb{E}(e^{itX})$ characterises the loi of *any* real variable aléatoire, its derivatives at 0 give the moments, and $\varphi_{X+Y} = \varphi_X \varphi_Y$ for independent summands. The fonction génératrice is the same idea restricted to $\mathbb{N}$ -valued variables, with t for e^{it} : cheaper, real-valued, and enough whenever the variable counts something.

Example (Fonctions génératrices des cinq lois). La fonction génératrice d'une variable aléatoire $X \sim \mathcal{B}(p)$ est $G_X(t) = 1 - p + pt$. For $X \sim \mathcal{B}(n, p)$, the binomial is a sum of n independent Bernoulli variables, so the product rule gives $G_X(t) = (1 - p + pt)^n$ at once.

La fonction génératrice d'une variable aléatoire $X \sim \mathcal{P}(\lambda)$ est

$$G_X(t) = \sum_{k \geq 0} e^{-\lambda} \frac{\lambda^k}{k!} t^k = e^{-\lambda} e^{\lambda t} = e^{\lambda(t-1)}.$$

For $X \sim \mathcal{G}(p)$, summing the geometric series, $G_X(t) = \frac{pt}{1-(1-p)t}$, which is finite for every $t \in [-1, 1]$ when $p \in]0, 1]$. For $X \sim \mathcal{U}(1, \dots, n)$, $G_X(t) = \frac{t}{n} \frac{1-t^n}{1-t}$ for $t \neq 1$, and $G_X(1) = 1$.

Example (The sum of two independent Poisson counts). Soit X, Y des variables aléatoires indépendantes suivant des lois de Poisson $\mathcal{P}(\alpha)$ et $\mathcal{P}(\beta)$. Then

$$G_{X+Y}(t) = G_X(t)G_Y(t) = e^{\alpha(t-1)}e^{\beta(t-1)} = e^{(\alpha+\beta)(t-1)},$$

which is the fonction génératrice of $\mathcal{P}(\alpha + \beta)$. Since the fonction génératrice characterises the loi, $X + Y \sim \mathcal{P}(\alpha + \beta)$. Computing the same convolution directly means summing $\sum_j \mathbb{P}(X = j) \mathbb{P}(Y = k - j)$ and recognising a binomial expansion; the fonction génératrice makes it a product of exponentials.

Loi	Support	$\mathbb{E}(X)$	$\text{Var}(X)$	$G_X(t)$
$\mathcal{B}(p)$	$\{0, 1\}$	p	$p(1-p)$	$1 - p + pt$
$\mathcal{B}(n, p)$	$\{0, \dots, n\}$	np	$np(1-p)$	$(1 - p + pt)^n$
$\mathcal{P}(\lambda)$	$\mathbb{N}$	λ	λ	$e^{\lambda(t-1)}$
$\mathcal{G}(p)$	$\mathbb{N}^*$	$\frac{1}{p}$	$\frac{1-p}{p^2}$	$\frac{pt}{1-(1-p)t}$
$\mathcal{U}(1, \dots, n)$	$\{1, \dots, n\}$	$\frac{n+1}{2}$	$\frac{n^2-1}{12}$	$\frac{t}{n} \frac{1-t^n}{1-t}$

Remark. The loi géométrique is the one to watch. This course puts its support on $\mathbb{N}^*$, counting the trials *up to and including* the first success, so $\mathbb{E}(X) = 1/p$; many computations instead use $\tau = X - 1$, the failures *before* the first success, supported on $\mathbb{N}$, with $\mathbb{E}(\tau) = (1 - p)/p$. Check which of the two is meant before quoting a mean.

Example (Surviving hatchlings, by composing fonctions génératrices). Une tortue donne naissance à N bébés. On suppose que $N \sim \mathcal{P}(\lambda)$. Chaque bébé a une probabilité de survivre $p \in]0, 1[$, indépendamment des autres bébés. On note X le nombre de bébés tortues qui survivent.

The fonction génératrice of N is $G_N(t) = e^{\lambda(t-1)}$. Conditioning on $N = n$ and using the product rule for the n independent Bernoulli survival indicators, whose common fonction génératrice is $G(t) = 1 - p + pt$,

$$G_X(t) = \sum_{n \geq 0} \mathbb{P}(N = n) \mathbb{E}(t^X \mid N = n) = \sum_{n \geq 0} \mathbb{P}(N = n) G(t)^n = G_N(G(t)).$$

Hence $G_X(t) = e^{\lambda(1-p+pt-1)} = e^{\lambda p(t-1)}$, the fonction génératrice of $\mathcal{P}(\lambda p)$, so $X \sim \mathcal{P}(\lambda p)$. The earlier computation was the case $p = \frac{1}{2}$ done by summing the loi jointe; the composition $G_N \circ G$ — the fonction génératrice of a random sum of i.i.d. variables — does it for any p , and is what a branching process is built on.

1.10 Espérance conditionnelle

Soit X une variable aléatoire à valeurs réelles.

Definition (Espérance conditionnelle). Pour tout événement A tel que $\mathbb{P}(A) > 0$, on appelle **espérance conditionnelle** (*conditional expectation*) de la variable aléatoire X sachant A la valeur :

$$\mathbb{E}(X \mid A) = \sum_{\omega \in \Omega} X(\omega) \mathbb{P}(\omega \mid A),$$

pourvu que X soit positive ou que $\mathbb{E}(|X| \mid A) < \infty$.

C'est l'espérance pour la probabilité conditionnelle $\mathbb{P}(\cdot \mid A)$. Everything proved about espérances therefore applies unchanged — linearity, the théorème de transfert, and the integrability proviso, which here is a condition under the *conditional* mesure.

Proposition. L'espérance conditionnelle de la variable aléatoire X sachant A s'obtient directement à partir de la loi conditionnelle :

$$\mathbb{E}(X \mid A) = \sum_{x \in E} x \mathbb{P}(X = x \mid A),$$

pourvu que X soit positive ou que $\mathbb{E}(|X| \mid A) < \infty$.

Proposition. L'espérance conditionnelle de la variable aléatoire X sachant A vérifie :

$$\mathbb{E}(X \mid A) = \frac{\mathbb{E}(X \mathbb{1}_A)}{\mathbb{P}(A)}.$$

This identity is the practical one: it replaces a conditional mesure by an ordinary espérance of a truncated variable. It is also the form that survives into chapter 5, where an integral identity of this shape *defines* the loi conditionnelle and the espérance conditionnelle is then read off it as an integral against that loi.

Proposition. Soit $(A_i)_{i \in I}$ une famille d'événements formant une partition de Ω , avec $\mathbb{P}(A_i) > 0$ pour tout $i \in I$. Alors,

$$\mathbb{E}(X) = \sum_{i \in I} \mathbb{P}(A_i) \mathbb{E}(X \mid A_i)$$

dès que X est positive ou $\mathbb{E}(|X|) < \infty$.

On en déduit l'équivalent de la formule des probabilités totales pour l'espérance — proved from the previous proposition together with $\sum_{i \in I} \mathbb{1}_{A_i} = 1$ and the espérance of a series. The hypotheses accumulate rather than simplify: a partition, each part of positive probability, and X positive or integrable.

Example (Averaging a die over an even outcome). Soit X une variable aléatoire de loi uniforme sur $\{1, \dots, 6\}$. L'espérance conditionnelle est donnée par $\mathbb{E}(X \mid X \text{ even}) = \sum_{k=1}^6 k \mathbb{P}(X = k \mid X \text{ even}) = \frac{2+4+6}{3} = 4$, against $\mathbb{E}(X) = 3.5$ unconditionally. Conditioning restricts the support and renormalises the weights; both effects move the mean.

Example (When to stop rolling: a threshold from espérances conditionnelles). Les règles du jeu sont les suivantes : on part d'un score nul (0). À chaque coup, on lance deux dés. Si le total vaut 7, le score retourne à 0 et la partie est terminée ; sinon, le score augmente du total obtenu et on a le droit de rejouer. Si l'on ne rejoue pas, le score est acquis et la partie est terminée. On note X le total obtenu sur un lancer, et $(X_n)_{n \geq 0}$ une suite de variables aléatoires i.i.d. de même loi que X .

The loi of X is the familiar triangle on $\{2, \dots, 12\}$, with $\mathbb{P}(X = k) = \frac{1}{36} \min(k-1, 13-k)$, and $\mathbb{E}(X) = 7$ by symmetry about 7. Soit $\tau = \inf\{n \geq 0 : X_n = 7\}$: it is the number of throws before the first 7. Since $\mathbb{P}(X = 7) = \frac{1}{6}$, the variable $\tau + 1$ is geometric $\mathcal{G}(\frac{1}{6})$, so $\mathbb{E}(\tau) = \frac{1}{1/6} - 1 = 5$.

A player who knew the next throw in advance would stop just before the 7, scoring $S = \sum_{n=0}^{\tau-1} X_n$. Conditioning on τ and using the formule des probabilités totales for espérances,

$$\mathbb{E}(S) = \sum_{t \geq 1} \mathbb{P}(\tau = t) t \mathbb{E}(X \mid X \neq 7) = \mathbb{E}(\tau) \mathbb{E}(X \mid X \neq 7) = 5 \times 7 = 35,$$

where $\mathbb{E}(X \mid X \neq 7) = \mathbb{E}(X) = 7$ because the triangle is symmetric about 7, so removing the value 7 does not move the mean.

For an ordinary player at score s , throwing again gives

$$\mathbb{E}(S_{n+1} \mid S_n = s) = \mathbb{P}(X \neq 7) (s + \mathbb{E}(X \mid X \neq 7)) = \frac{5}{6}(s + 7),$$

since with probability $\frac{1}{6}$ the score is wiped out. Throwing is worth it exactly when $\frac{5}{6}(s + 7) > s$, that is when $s < 35$. La stratégie optimale consiste à jouer tant que l'on n'a pas atteint 35, et à s'arrêter après avoir franchi ce seuil. The threshold is the clairvoyant's score again, and for the same reason: both are $\mathbb{E}(X)(1-p)/p = \mathbb{E}(X) \mathbb{E}(\tau)$ with $p = \mathbb{P}(X = 7)$.

1.11 Vecteurs aléatoires

Soit $E_1, \dots, E_n$ des ensembles au plus dénombrables.

Definition (Vecteur aléatoire). Un **vecteur aléatoire** (*random vector*) est une variable aléatoire à valeurs dans l'espace produit $E = E_1 \times \dots \times E_n$.

Ses composantes $X_1, \dots, X_n$ sont des variables aléatoires à valeurs respectives dans $E_1, \dots, E_n$. La loi du vecteur X est appelée la loi jointe des variables aléatoires $X_1, \dots, X_n$; les lois $\mathbb{P}_{X_1}, \dots, \mathbb{P}_{X_n}$ en sont les lois marginales. Elles s'en déduisent en sommant sur toutes les autres variables.

Example (Loi multinomiale). Soit X une variable aléatoire de **loi multinomiale** (*multinomial distribution*) de paramètres $(N, p_1, \dots, p_n)$ avec $p_1 + \dots + p_n = 1$:

$$\forall x \in \mathbb{N}^n \text{ with } x_1 + \dots + x_n = N, \quad \mathbb{P}(X = x) = \frac{N!}{x_1! \dots x_n!} p_1^{x_1} \dots p_n^{x_n}.$$

C'est un vecteur aléatoire. It counts how many of N independent trials fall into each of n categories. Les lois marginales sont des lois binomiales: looking at one category only turns the other $n-1$ into a single "failure" category, so $X_i \sim \mathcal{B}(N, p_i)$.

Definition (Fonction génératrice vectorielle (*vector generating function*)). La **fonction génératrice** d'un vecteur aléatoire X à valeurs dans $\mathbb{N}^n$ est la fonction G_X définie par :

$$\forall t \in [-1, 1]^n, \quad G_X(t) = \mathbb{E}(t_1^{X_1} \cdots t_n^{X_n}) = \sum_{k_1, \dots, k_n \geq 0} \mathbb{P}(X_1 = k_1, \dots, X_n = k_n) t_1^{k_1} \cdots t_n^{k_n}.$$

Comme dans le cas des variables aléatoires, la fonction génératrice caractérise la loi, et permet d'obtenir les moments par dérivations successives — *partial ones*, now including the mixed ones, which is what makes it a tool for covariances rather than just for variances.

Example (Covariance inside a multinomial, from the fonction génératrice vectorielle). For the loi multinomiale with parameters $(N, p_1, \dots, p_n)$, the multinomial theorem collapses the sum:

$$\forall t \in [-1, 1]^n, \quad G_X(t) = (p_1 t_1 + \cdots + p_n t_n)^N.$$

Differentiating at $t = (1, \dots, 1)$, where $p_1 + \cdots + p_n = 1$ makes the base equal to 1,

$$\mathbb{E}(X_i) = \frac{\partial G_X}{\partial t_i}(1) = N p_i, \quad \mathbb{E}(X_i X_j) = \frac{\partial^2 G_X}{\partial t_i \partial t_j}(1) = N(N-1) p_i p_j \quad (i \neq j),$$

the second being a mixed partial, so it returns $\mathbb{E}(X_i X_j)$ rather than a factorial moment. Hence

$$\text{Cov}(X_i, X_j) = N(N-1) p_i p_j - N^2 p_i p_j = -N p_i p_j.$$

The same derivative taken twice in t_i gives the factorial moment $\mathbb{E}(X_i(X_i - 1)) = N(N-1) p_i^2$, whence $\text{Var}(X_i) = N p_i(1 - p_i)$, consistent with the binomial loi marginale, and

$$\rho(X_i, X_j) = -\sqrt{\frac{p_i}{1-p_i} \cdot \frac{p_j}{1-p_j}}.$$

The correlation is negative for every pair, as it must be: the N trials are shared out, so a trial counted in category i is one that category j cannot have.

1.12 Variables aléatoires indépendantes

Definition (Indépendance d'une famille). Les variables aléatoires $X_1, \dots, X_n$ sont dites **indépendantes** si pour tous $A_1 \subseteq E_1, \dots, A_n \subseteq E_n$, les événements $\{X_1 \in A_1\}, \dots, \{X_n \in A_n\}$ sont indépendants.

Pour vérifier l'indépendance, il suffit donc de s'assurer que :

$$\mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) = \mathbb{P}(X_1 \in A_1) \cdots \mathbb{P}(X_n \in A_n)$$

pour tous $A_1 \subseteq E_1, \dots, A_n \subseteq E_n$. Si l'indépendance d'une famille d'événements exige de regarder tous les sous-ensembles finis de ces événements, ceci est fait de façon implicite ici grâce au choix des ensembles A_i : le choix $A_1 = E_1$ par exemple élimine le premier événement, which it makes certain and so drops from the product. Running each A_i over subsets and over E_i therefore covers all sub-families.

Proposition. Les variables aléatoires $X_1, \dots, X_n$ sont indépendantes si et seulement si :

$$\forall x_1 \in E_1, \dots, \forall x_n \in E_n, \quad \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \mathbb{P}(X_1 = x_1) \cdots \mathbb{P}(X_n = x_n).$$

Proposition. Si les variables aléatoires $X_1, \dots, X_n$ sont indépendantes, alors $\phi_1(X_1), \dots, \phi_n(X_n)$ sont indépendantes, quelles que soient les fonctions $\phi_1, \dots, \phi_n$.

Proposition (Regroupement (*grouping*)). Si les variables aléatoires $X_1, \dots, X_n$ sont indépendantes, alors pour tout entier $k = 1, \dots, n-1$, les variables aléatoires

$$X = (X_1, \dots, X_k) \quad \text{and} \quad Y = (X_{k+1}, \dots, X_n)$$

sont indépendantes.


Remark. Regroupement is the proposition that gets used without being named: it is what licenses “ $X_1 + X_2$ is independent of $X_3 + X_4$ ” from the indépendance of the four variables — group into two blocs, then apply the previous proposition with ϕ_1, ϕ_2 the two sums. It splits the family into *consecutive* blocs; any partition into disjoint blocs follows by relabelling, but the blocs must be disjoint, or the conclusion is false.

Conclusion. Three things in this chapter do not reappear later and must be taken from here. The fonction génératrice is one: chapter 6 builds the fonction caractéristique on the same two properties, but there the loi is recovered by an inversion integral, whereas here differentiating at 0 returns $\mathbb{P}(X = k)$ directly, and $G_N \circ G$ handles a random sum. The discrete espérance conditionnelle is another: chapter 5 characterises the loi conditionnelle by an integral identity, reads $\mathbb{E}(X | Y = y)$ off it as an integral against that loi and makes $\mathbb{E}(X | Y)$ a variable aléatoire, and the elementary $\mathbb{E}(X | A) = \mathbb{E}(X \mathbb{1}_A) / \mathbb{P}(A)$ is what that construction is designed to reproduce. The third is the collection of counterexamples — pairwise but not mutually independent événements, décorrélés but dependent variables, lois marginales that do not determine a loi jointe — each the reason a later hypothesis is stated the way it is.


What does *not* carry over is the ease. Every subset of a discrete Ω is an événement, every function on it is a variable aléatoire, and every mesure is determined by its values on singletons. The next two chapters exist to buy back as much of that as survives when Ω is uncountable, and the price is the tribu.

2 Théorie de la mesure


Les mathématiciens ont longtemps buté sur la bonne façon de formaliser les probabilités, la science du hasard et de l’incertain. The difficulty is not that the calculations are hard; it is that the words are empty. Un exemple typique de problèmes rencontrés est le paradoxe de Joseph Bertrand, énoncé en 1889, and it makes the point in one line. Il s’agit de calculer la probabilité qu’une corde “aléatoire” d’un cercle de rayon 1 soit de longueur supérieure à $\sqrt{3}$, la longueur des côtés d’un triangle équilatéral inscrit dans ce cercle.



(a) Extrémités aléatoires



(b) Milieu aléatoire dans le disque



(c) Milieu aléatoire sur un rayon

Three constructions, three answers. Fix one endpoint of the chord at a vertex of the inscribed triangle and draw the other endpoint uniformly on the circle: the chord beats $\sqrt{3}$ exactly when the second endpoint falls on the opposite arc, one third of the circle, so the answer is $1/3$. Draw instead the *midpoint* of the chord uniformly in the disc: the chord beats $\sqrt{3}$ exactly when its midpoint lies within $1/2$ of the centre, an area ratio of $(1/2)^2 = 1/4$. Draw a radius, then the midpoint uniformly *on that radius*: the condition is that the midpoint falls in the inner half, so the answer is $1/2$.

None of the three is wrong. Le problème est en réalité mal posé car il faut définir précisément la manière de tirer cette corde aléatoire: the three constructions are three different questions wearing the same words. Ainsi la définition précise de l’expérience aléatoire considérée est cruciale: the paradox shows that *at random* names nothing until it has been specified — which outcomes are possible, which collections of outcomes count as événements, and what number each of those collections is assigned. Those three things are the univers, the **tribu** (σ -algebra) and the mesure, and building them is what this chapter does. Le calcul des probabilités était un problème considéré si important et si difficile à l’époque que David Hilbert y consacra un problème

(le sixième) parmi sa liste de 23 problèmes présentés en 1900. Une réponse à ce problème fut donnée dans les années 1930 par Andreï Kolmogorov, avec une axiomatisation des probabilités reposant sur la théorie de la mesure et de l'intégration, développée entre-temps par Émile Borel et Henri Lebesgue, notamment.

Le terme de **mesure** (*measure*) doit être compris comme une formalisation des notions physiques de volume, d'aire ou de longueur : c'est une application qui, à un ensemble, associe un nombre positif, éventuellement infini. Si cet ensemble s'écrit comme une union de sous-ensembles disjoints, sa mesure doit être égale à la somme des mesures de ces sous-ensembles. C'est la propriété de σ -additivité, qui est au cœur de la notion de mesure. Une mesure classique sur $\mathbb{R}$ est la **mesure de Lebesgue** (*Lebesgue measure*), notée λ , qui satisfait $\lambda([a, b]) = b - a$.

Si une telle mesure semble très naturelle, sa construction est délicate, and the delicacy cannot be waved away. *Ainsi, en admettant l'axiome du choix, il n'existe pas une telle mesure de "longueur" qui s'applique à tout sous-ensemble de $\mathbb{R}$.* Some subsets of the line cannot be assigned a length at all without contradiction — the Vitali set, built by choosing one representative from each class of $[0, 1]$ modulo $\mathbb{Q}$, is one. On doit restreindre le domaine de définition de λ à certains sous-ensembles, à savoir la tribu de Borel: a family closed enough to be useful and small enough to be consistent. Everything below that looks like bureaucracy — why a tribu rather than all subsets, why a mesure is defined on a tribu and not on $\mathcal{P}(\Omega)$ — follows from that one sentence.

Notation (Five deliberate collisions). The course's notation is used throughout these notes, collisions included. Five symbols carry more than one meaning, and each time the meaning is fixed by what sits in the parentheses:

- $\mathcal{P}$ is the *ensemble des parties* $\mathcal{P}(\Omega)$ and the *loi de Poisson* $\mathcal{P}(\lambda)$;
- $\mathcal{B}$ is the *tribu de Borel* $\mathcal{B}(\mathbb{R})$, the *loi de Bernoulli* $\mathcal{B}(p)$, the *loi binomiale* $\mathcal{B}(n, p)$ and the *loi Beta* $\mathcal{B}(a, b)$;
- λ is the *mesure de Lebesgue* and the parameter of the *loi exponentielle* and the *loi de Poisson*;
- Γ is the *loi Gamma* $\Gamma(a, \lambda)$ and the *matrice de covariance* of a vecteur gaussien, $\mathcal{N}(\mu, \Gamma)$;
- $\mathcal{E}$ is a *generic tribu*, as in $(E, \mathcal{E})$, and the *loi exponentielle* $\mathcal{E}(\lambda)$.

An espace mesurable is written $(\Omega, \mathcal{F})$, an espace de probabilité $(\Omega, \mathcal{F}, \mathbb{P})$, and generic espaces mesurables $(E, \mathcal{E})$ and $(F, \mathcal{F})$. The complement of A is A^c .

Notation (Set identities used without comment). Soit A, B, C des ensembles :

- (commutativité) $A \cup B = B \cup A$, $A \cap B = B \cap A$;
- (associativité) $A \cup (B \cup C) = (A \cup B) \cup C$, $A \cap (B \cap C) = (A \cap B) \cap C$;
- (distributivité) $(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$, $(A \cap B) \cup C = (A \cup C) \cap (B \cup C)$;
- (lois de Morgan) $(A \cup B)^c = A^c \cap B^c$, $(A \cap B)^c = A^c \cup B^c$.

Ces résultats s'étendent à des familles au plus dénombrables d'ensembles. De Morgan in its countable form is what makes "stable under complement and countable union" the same condition as "stable under complement and countable intersection", and it is used silently in almost every proof below.

2.1 Tribus

Soit Ω un ensemble arbitraire.

Définition (Tribu). Une famille $\mathcal{F}$ de sous-ensembles de Ω est appelée une tribu sur Ω si elle vérifie les propriétés suivantes :

- $\Omega \in \mathcal{F}$;
- pour tout $A \in \mathcal{F}$, $A^c \in \mathcal{F}$;

- pour tous $A_1, A_2, \dots \in \mathcal{F}$, $\bigcup_{i \geq 1} A_i \in \mathcal{F}$.

Autrement dit, une tribu contient Ω , est stable par passage au complémentaire et par union dénombrable. En passant au complémentaire, on obtient qu'une tribu contient $\emptyset$ et est stable par intersection dénombrable. Countable, not merely finite, union is the essential clause: it is what puts the limit $\bigcup_n A_n$ of an increasing sequence inside $\mathcal{F}$, and every continuity and uniqueness argument below passes through such a limit.

Remark (The two evident tribus). Every Ω carries two. The **tribu grossière** (*coarse σ -algebra*) $\mathcal{F} = \{\emptyset, \Omega\}$ is the smallest, the **tribu des parties** (*power-set σ -algebra*) $\mathcal{F} = \mathcal{P}(\Omega)$ is the largest, and every tribu on Ω sits between them. On a countable Ω one takes $\mathcal{P}(\Omega)$ and loses nothing; the difficulty is the uncountable case, where $\mathcal{P}(\mathbb{R})$ is too large to carry a length.

Definition (Espace mesurable). Un espace Ω muni d'une tribu $\mathcal{F}$ s'appelle un **espace mesurable** (*measurable space*), noté $(\Omega, \mathcal{F})$.

Trace

Soit $(\Omega, \mathcal{F})$ un espace mesurable et $A \subseteq \Omega$. Nothing requires A itself to be in $\mathcal{F}$.

Definition (Trace). On appelle **trace** de $\mathcal{F}$ sur A l'ensemble :

$$\mathcal{F}_A = \{A \cap B, B \in \mathcal{F}\}.$$

Proposition. *L'ensemble $\mathcal{F}_A$ est une tribu sur A .*

Remark. Three checks, each one line. On vérifie que $A \in \mathcal{F}_A$ puisque $A = A \cap \Omega$ avec $\Omega \in \mathcal{F}$. Le complémentaire de $A \cap B$ dans A est $A \cap B^c$, qui appartient à $\mathcal{F}_A$ car $B^c \in \mathcal{F}$ — the complement is taken in A , not in Ω , which is why the trace is a tribu on A . And $\bigcup_{i \geq 1} (A \cap B_i) = A \cap \bigcup_{i \geq 1} B_i$ by distributivity. On remarque que si $A \in \mathcal{F}$ alors $\mathcal{F}_A \subseteq \mathcal{F}$.

Example (The trace of a three-point tribu). Soit $\Omega = \{1, 2, 3\}$ et $\mathcal{F} = \{\emptyset, \{1, 2\}, \{3\}, \{1, 2, 3\}\}$. Intersecting each of the four with $\{1, 2\}$ gives $\emptyset, \{1, 2\}, \emptyset, \{1, 2\}$: la trace de $\mathcal{F}$ sur $\{1, 2\}$ est la tribu grossière $\{\emptyset, \{1, 2\}\}$ de $\{1, 2\}$. A trace never distinguishes points that $\mathcal{F}$ did not distinguish.

Tribu engendrée

Nous allons définir la plus petite tribu contenant une collection d'ensembles. Nous aurons besoin du résultat préliminaire suivant :

Proposition. *Toute intersection de tribus sur Ω est une tribu sur Ω .*

Remark. Soit $(\mathcal{F}_i)_{i \in I}$ une famille de tribus et $\mathcal{F}$ leur intersection. Each clause is inherited pointwise in i : $\Omega \in \mathcal{F}_i$ pour tout i ; pour tout $A \in \mathcal{F}$, on a $A \in \mathcal{F}_i$ pour tout i , de sorte que $A^c \in \mathcal{F}_i$ pour tout i , soit $A^c \in \mathcal{F}$; same for countable unions. The index family I may be uncountable — no countability is used on it.

Definition (Tribu engendrée). Soit $\mathcal{C} \subseteq \mathcal{P}(\Omega)$ une collection de sous-ensembles de Ω . L'intersection de toutes les tribus contenant $\mathcal{C}$ est une tribu, appelée la **tribu engendrée** (*generated σ -algebra*) par $\mathcal{C}$. On la note $\sigma(\mathcal{C})$.

The intersection is over a non-empty family, since $\mathcal{P}(\Omega)$ always contains $\mathcal{C}$. By construction $\sigma(\mathcal{C})$ is the smallest tribu containing $\mathcal{C}$: any tribu containing $\mathcal{C}$ contains $\sigma(\mathcal{C})$. That is the only tool available for proving an inclusion between tribus, and it is used in every proof of this chapter.

Example (The tribu generated by one set). Soit $\mathcal{C} = \{A\}$ avec $A \subseteq \Omega$. Alors $\sigma(\mathcal{C}) = \{\emptyset, \Omega, A, A^c\}$: those four are forced, and they already form a tribu.

Example (A tribu generated by two sets). Soit $\Omega = \{1, 2, 3, 4\}$ et $\mathcal{C} = \{\{1\}, \{2, 3\}\}$. Complements give $\{2, 3, 4\}$ and $\{1, 4\}$; unions give $\{1, 2, 3\}$ and, by complement, $\{4\}$. The list closes:

$$\sigma(\mathcal{C}) = \{\emptyset, \{1\}, \{2, 3\}, \{4\}, \{1, 2, 3\}, \{1, 4\}, \{2, 3, 4\}, \Omega\}.$$

It has $2^3 = 8$ elements, as expected: $\mathcal{C}$ splits Ω into the three atoms $\{1\}$, $\{2, 3\}$, $\{4\}$, and a tribu generated by a finite partition is the set of unions of its atoms. The points 2 and 3 are never separated, so no tribu built from $\mathcal{C}$ can tell them apart.

Example (Tribu engendrée sur un intervalle). Soit $\Omega = [-1, 1]$ et $\mathcal{C} = \{\{0\}, [0, 1]\}$. Par passage au complémentaire et union, on trouve

$$\sigma(\mathcal{C}) = \{\emptyset, \{0\}, [0, 1],]0, 1], [-1, 0], [-1, 0[, [-1, 0[\cup]0, 1], \Omega\},$$

again eight sets, generated by the three atoms $[-1, 0[$, $\{0\}$ and $]0, 1]$.

Tribu de Borel sur $\mathbb{R}$

Definition (Tribu de Borel). La **tribu de Borel** (*Borel σ -algebra*) sur $\mathbb{R}$, notée $\mathcal{B}(\mathbb{R})$, est la tribu sur $\mathbb{R}$ engendrée par les intervalles $[a, b]$ avec $a < b$.

Un élément de $\mathcal{B}(\mathbb{R})$ s'appelle un **borélien** (*Borel set*). En utilisant les propriétés d'une tribu (passage au complémentaire, union et intersection dénombrables), on obtient que $\mathcal{B}(\mathbb{R})$ contient :

- les intervalles $[a, b]$ pour tous $a < b$;
- les intervalles $[a, +\infty[$ et $]-\infty, b]$;
- les intervalles $]a, b]$, $[a, b[$ et $]a, b[$;
- les singletons $\{a\}$;
- les rationnels $\mathbb{Q}$ et les irrationnels $\mathbb{R} \setminus \mathbb{Q}$.

La liste n'est pas exhaustive. En réalité, il est difficile d'exhiber un ensemble qui ne soit pas un borélien — in practice one never meets a subset of $\mathbb{R}$ that fails to be one. Cela nécessite l'axiome du choix: the Vitali set of the opening. That is the precise sense in which restricting to $\mathcal{B}(\mathbb{R})$ costs nothing in applications.

Proposition (Génération par les demi-droites). *La tribu de Borel $\mathcal{B}(\mathbb{R})$ est la tribu engendrée par les intervalles $] -\infty, b]$ pour tout $b \in \mathbb{R}$.*

Remark. Soit $\mathcal{C}$ cette collection. Each $] -\infty, b]$ is a borélien, de sorte que $\sigma(\mathcal{C}) \subseteq \mathcal{B}(\mathbb{R})$. Inversement, $\sigma(\mathcal{C})$ contient $]a, +\infty[$ par passage au complémentaire, et $]a, +\infty[= \bigcap_{n \geq 1}]a - \frac{1}{n}, +\infty[$ par intersection dénombrable ; elle contient donc également $[a, b] = [a, +\infty[\cap] -\infty, b]$ par intersection, si bien que $\mathcal{B}(\mathbb{R}) \subseteq \sigma(\mathcal{C})$. This is the generating family one actually uses: it is the reason the fonction de répartition determines a loi.

Proposition (Génération par les ouverts). *La tribu de Borel $\mathcal{B}(\mathbb{R})$ est la tribu engendrée par les ouverts de $\mathbb{R}$.*

Proof. Soit $\mathcal{O}$ la collection des ouverts de $\mathbb{R}$.

First, $\sigma(\mathcal{O}) \subseteq \mathcal{B}(\mathbb{R})$. Soit $U \in \mathcal{O}$. Pour tout $u \in U$, il existe des *rationnels* a_u, b_u tels que $u \in [a_u, b_u] \subseteq U$, because U is open and $\mathbb{Q}$ is dense. En particulier,

$$U = \bigcup_{u \in U} [a_u, b_u].$$

The union appears to be indexed by U , which is uncountable; but the intervals occurring in it have rational endpoints, and l'ensemble des intervalles à extrémités rationnelles est dénombrable. The union therefore

has at most countably many distinct terms: c'est donc un borélien, comme union dénombrable de boréliens, and $U \in \mathcal{B}(\mathbb{R})$. Comme la tribu $\mathcal{B}(\mathbb{R})$ contient tous les ouverts, elle contient la tribu engendrée par les ouverts.

Second, $\mathcal{B}(\mathbb{R}) \subseteq \sigma(\mathcal{O})$. Pour $a < b$,

$$[a, b] = \bigcap_{n \geq 1} \left] a - \frac{1}{n}, b + \frac{1}{n} \right[,$$

a countable intersection of open sets. Donc $[a, b] \in \sigma(\mathcal{O})$. Comme la tribu $\sigma(\mathcal{O})$ contient tous les intervalles $[a, b]$, elle contient la tribu de Borel $\mathcal{B}(\mathbb{R})$.

Two moves in that proof recur everywhere. Countability is smuggled in through $\mathbb{Q}$: an uncountably indexed union collapses because only countably many *distinct* sets occur in it. And a closed set is reached from open sets by a countable intersection.

Remark. La caractérisation de la tribu de Borel comme la tribu engendrée par les ouverts permet d'étendre cette notion à des espaces de dimension infinie. It makes sense on any topological space, where “interval” has no meaning — which is how one puts a tribu on a space of functions.

Tribu de Borel sur un intervalle, sur $\overline{\mathbb{R}}$ et sur $\mathbb{R}^n$

Definition (Tribu de Borel sur un intervalle). La tribu de Borel sur un intervalle $[a, b]$, notée $\mathcal{B}([a, b])$, est la trace de $\mathcal{B}(\mathbb{R})$ sur $[a, b]$.

Elle est constituée de l'ensemble des boréliens inclus dans $[a, b]$. La définition s'étend à tout intervalle, ouvert ou fermé à droite ou à gauche, infini à droite ou à gauche.

Definition (Tribu de Borel sur $\overline{\mathbb{R}}$). Soit $\overline{\mathbb{R}} = \mathbb{R} \cup \{-\infty, +\infty\}$. La tribu de Borel sur $\overline{\mathbb{R}}$, notée $\mathcal{B}(\overline{\mathbb{R}})$, est la tribu engendrée par les intervalles $[-\infty, b]$ pour tout $b \in \mathbb{R}$.

Par rapport à $\mathcal{B}(\mathbb{R})$, cette tribu contient notamment les intervalles $[-\infty, b]$ et $[a, +\infty]$ ainsi que les singletons $\{-\infty\}$ et $\{+\infty\}$.

Remark (Why $\overline{\mathbb{R}}$ is not a technicality). The two infinite points are admitted as genuine elements of the space, not as limits. That is what makes it legal to speak of a mesurable function taking the value $+\infty$ on a set of positive measure. Two things later depend on it. The suprema, infima and upper and lower limits of a sequence of mesurable functions are mesurables *as maps into* $\overline{\mathbb{R}}$, and they generally have to be: $\sup_n f_n$ need not be finite anywhere. And the intégrale de Lebesgue of a positive mesurable function is defined with values in $[0, +\infty]$, so the théorème de convergence monotone can be stated without an integrability hypothesis. Dropping $\mathcal{B}(\overline{\mathbb{R}})$ as a nicety costs both.

Definition (Tribu de Borel sur $\mathbb{R}^n$). Pour $n \geq 1$, la tribu de Borel sur $\mathbb{R}^n$, notée $\mathcal{B}(\mathbb{R}^n)$, est la tribu sur $\mathbb{R}^n$ engendrée par les **pavés** (*boxes*) $[a_1, b_1] \times \cdots \times [a_n, b_n]$ avec $a_1 < b_1, \dots, a_n < b_n$.

Les deux propositions précédentes s'étendent à ce cas : $\mathcal{B}(\mathbb{R}^n)$ is equally generated by the sets $] - \infty, b_1] \times \cdots \times] - \infty, b_n]$, and equally by the open sets of $\mathbb{R}^n$.

Tribu produit

On se donne deux espaces mesurables $(E, \mathcal{E})$ et $(F, \mathcal{F})$ et on cherche à construire une tribu sur l'espace produit $E \times F$. The obvious candidate fails.

Example (The product of two tribus is not a tribu). Soit $\Omega = \{0, 1\}$ et $\mathcal{F} = \mathcal{P}(\Omega)$. Alors $\mathcal{F} \times \mathcal{F}$, the family of rectangles $A \times B$, n'est pas une tribu de $\Omega \times \Omega$. En effet, le singleton $\{(0, 0)\}$ is the rectangle $\{0\} \times \{0\}$ and so belongs to it, mais pas son complémentaire $\{(0, 1), (1, 0), (1, 1)\}$, which is not a rectangle.

The rectangles must therefore be completed: il faut générer tous les autres ensembles permettant de constituer une tribu, par passage au complémentaire et union dénombrable — which is to say, one generates.

Definition (Tribu produit). La **tribu produit** (*product σ -algebra*), notée $\mathcal{E} \otimes \mathcal{F}$, est la tribu engendrée par $\mathcal{E} \times \mathcal{F}$.

Theorem (La tribu de Borel de $\mathbb{R}^n$ est la tribu produit).

$$\mathcal{B}(\mathbb{R}^n) = \mathcal{B}(\mathbb{R}) \otimes \cdots \otimes \mathcal{B}(\mathbb{R}) \quad (n \text{ factors}).$$

Proof Sketch. On considère le cas $n = 2$. Le cas général se montre par récurrence. The inclusion $\mathcal{B}(\mathbb{R}^2) \subseteq \mathcal{B}(\mathbb{R}) \otimes \mathcal{B}(\mathbb{R})$ is immediate, since the right-hand side contains the pavés. The other inclusion is proved by a bootstrap that is worth recognising, because the same device reappears in the théorème d'unicité and in Fubini. On considère pour tout intervalle $A \subseteq \mathbb{R}$ l'ensemble

$$\mathcal{F} = \{B \in \mathcal{B}(\mathbb{R}) : A \times B \in \mathcal{B}(\mathbb{R}^2)\}.$$

On vérifie que $\mathcal{F}$ est une tribu — $A \times B^c = (A \times \mathbb{R}) \setminus (A \times B)$ and $A \times \bigcup_i B_i = \bigcup_i (A \times B_i)$ — and it contains the intervals, so it is all of $\mathcal{B}(\mathbb{R})$. Now fix a borélien B and run the argument again on $\mathcal{G} = \{A \in \mathcal{B}(\mathbb{R}) : A \times B \in \mathcal{B}(\mathbb{R}^2)\}$, which by the first step contains the intervals and is a tribu, hence is $\mathcal{B}(\mathbb{R})$. Finalement, $A \times B \in \mathcal{B}(\mathbb{R}^2)$ pour tous boréliens A, B , and the tribu produit they generate is contained in $\mathcal{B}(\mathbb{R}^2)$.

The device: to prove a property for all pairs of boréliens, freeze one argument, show that the good values of the other form a tribu containing a generating family, then unfreeze. One variable at a time, never both at once.

2.2 Mesures


Soit $(\Omega, \mathcal{F})$ un espace mesurable.

Definition (Mesure). Une **mesure** sur $(\Omega, \mathcal{F})$ est une fonction $\mu : \mathcal{F} \rightarrow [0, +\infty]$ telle que

- $\mu(\emptyset) = 0$;
- pour toute famille au plus dénombrable $(A_i)_{i \in I}$ d'éléments de $\mathcal{F}$ deux-à-deux disjoints,

$$\mu\left(\bigcup_{i \in I} A_i\right) = \sum_{i \in I} \mu(A_i).$$

$A = \bigcup_i A_i$, the A_i pairwise disjoint



$$\mu(A) = \mu(A_1) + \mu(A_2) + \mu(A_3) + \mu(A_4) + \mu(A_5)$$

On notera que la mesure d'un ensemble est une quantité positive, éventuellement infinie; $[0, +\infty]$, not $[0, +\infty[$, is the target on purpose. Une mesure μ est dite *finie* si $\mu(\Omega) < \infty$. Additivity is required for countable families and not merely finite ones, and only for *pairwise disjoint* sets — weakening either restriction breaks the theory.

Example (Mesure de comptage). Soit Ω un ensemble. La fonction $\mu(A) = \text{card}(A)$ est une mesure sur $(\Omega, \mathcal{P}(\Omega))$, appelée la **mesure de comptage** (*counting measure*). It is finite exactly when Ω is finite.

Example (Mesure de Dirac). Soit $(\Omega, \mathcal{F})$ un espace mesurable et $a \in \Omega$. La fonction

$$\delta_a(A) = \begin{cases} 1 & \text{if } a \in A, \\ 0 & \text{otherwise,} \end{cases} \quad A \in \mathcal{F},$$

est une mesure, appelée la **mesure de Dirac** (*Dirac measure*) en a . It is a mesure de probabilité: $\delta_a(\Omega) = 1$.

On vérifie facilement que toute somme au plus dénombrable de mesures est une mesure: the check swaps two positive sums.

Example (Mesure de comptage de $\mathbb{N}$). La fonction $\mu = \sum_{n \in \mathbb{N}} \delta_n$ est une mesure sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$: $\mu(A)$ counts the integers lying in A . Elle est appelée la mesure de comptage de $\mathbb{N}$, and it is the mesure with respect to which a sum over $\mathbb{N}$ will later be read as an integral.

Definition (Mesure σ -finie). Une mesure μ sur $(\Omega, \mathcal{F})$ est dite **σ -finie** (*σ -finite*) si Ω peut être couvert par une réunion dénombrable d'ensembles de mesures finies.

Example (σ -finite but not finite). La mesure de comptage de $\mathbb{N}$ sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ est σ -finie, en remarquant que $\mathbb{R} = \bigcup_{n \geq 1} [-n, n]$ — each $[-n, n]$ carries finitely many integers. Par contre, cette mesure n'est pas finie : $\mu(\mathbb{R}) = +\infty$. The mesure de Lebesgue is σ -finie for the same covering, and also not finite.

σ -finiteness is the hypothesis that lets a statement about finite mesures be transported to an infinite one by exhausting Ω along an increasing sequence. It is close to, but weaker than, the covering hypothesis of the théorème d'unicité below — there the covering sets are required to lie in $\mathcal{C}$ itself — and it is a hypothesis of Fubini; when a result about mesures fails, the failure is usually here.

Proposition (Inclusion-exclusion et monotonie). Soit μ une mesure sur $(\Omega, \mathcal{F})$. Pour tous $A, B \in \mathcal{F}$,

1. $\mu(A \cup B) + \mu(A \cap B) = \mu(A) + \mu(B)$;
2. si $A \subseteq B$, alors $\mu(A) \leq \mu(B)$.

Remark. Both come from σ -additivité applied to a decomposition into disjoint pieces. For the first, $A \cup B = A \sqcup (B \setminus A)$ gives $\mu(A \cup B) + \mu(A \cap B) = \mu(A) + \mu(B \setminus A) + \mu(A \cap B) = \mu(A) + \mu(B)$, the last step because $B = (B \setminus A) \sqcup (A \cap B)$. For the second, $B = A \sqcup (B \setminus A)$ and $\mu(B \setminus A) \geq 0$. Notice that the first identity is stated as a sum, not as $\mu(A \cup B) = \mu(A) + \mu(B) - \mu(A \cap B)$: the subtracted form is meaningless when $\mu(A \cap B) = +\infty$. The additive form holds always.

Convergence monotone

Une suite $(A_n)_{n \geq 1}$ d'éléments de $\mathcal{F}$ est dite *croissante* si $A_n \subseteq A_{n+1}$ pour tout n ; sa limite est alors $A = \bigcup_n A_n$, ce que l'on notera $A_n \uparrow A$. De même, elle est dite *décroissante* si $A_{n+1} \subseteq A_n$ pour tout n ; sa limite est $A = \bigcap_n A_n$, ce que l'on notera $A_n \downarrow A$.

Proposition (Continuité monotone, borne de l'union). Soit μ une mesure sur $(\Omega, \mathcal{F})$ et $(A_n)_{n \geq 1}$ une suite d'éléments de $\mathcal{F}$.

1. Si $A_n \uparrow A$, alors $\mu(A) = \lim_n \mu(A_n)$.
2. Si $A_n \downarrow A$ et $\mu(A_1) < \infty$, alors $\mu(A) = \lim_n \mu(A_n)$.
3. On a la borne de l'union : $\mu\left(\bigcup_{n \geq 1} A_n\right) \leq \sum_{n \geq 1} \mu(A_n)$, for any sequence, disjoint or not.

Remark. Continuity from below is σ -additivité in disguise: write $A = A_1 \sqcup (A_2 \setminus A_1) \sqcup \dots$ and read the telescoping series as the limit of its partial sums. Continuity from above follows by passing to complements inside A_1 , which is where the finiteness enters — the step subtracts $\mu(A_n)$ from $\mu(A_1)$, and subtraction is not defined when both are $+\infty$. The borne de l'union follows from the disjointification $\bigcup_n A_n = \bigcup_n (A_n \setminus \bigcup_{k < n} A_k)$ together with monotonicity.

Example (Continuity from above fails without the finiteness hypothesis). Soit λ la mesure de Lebesgue sur $\mathbb{R}$ et $A_n = [n, +\infty[$ pour $n \geq 1$. The sequence is decreasing, and $\bigcap_{n \geq 1} A_n = \emptyset$, so $A_n \downarrow \emptyset$. Then

$$\lambda(\lim_n \downarrow A_n) = \lambda(\emptyset) = 0, \quad \text{whereas} \quad \lim_n \downarrow \lambda(A_n) = +\infty,$$

since $\lambda(A_n) = +\infty$ for every n . The two are not equal. The hypothesis $\mu(A_1) < \infty$ is violated — $\lambda(A_1) = +\infty$ — and the conclusion is false; the mass escapes to infinity rather than being destroyed. Dropping that one-line hypothesis is the classic error of the chapter, and this is the counter-example that catches it. Note that it is $\mu(A_1)$, not $\mu(A)$, that must be finite: here $\mu(A) = 0$ and the conclusion still fails.

Unicité

Lorsque la tribu est engendrée par une collection d'ensembles (comme la tribu de Borel, by the intervals), il est naturel de définir la mesure uniquement sur cette collection d'ensembles, la mesure des autres ensembles s'en déduisant par σ -additivité. Le **théorème d'unicité** (*uniqueness theorem*) permet de formaliser cette idée.

Theorem (Unicité). Soit μ une mesure sur l'espace mesurable $(\Omega, \mathcal{F})$, avec $\mathcal{F} = \sigma(\mathcal{C})$ pour une certaine collection $\mathcal{C} \subseteq \mathcal{P}(\Omega)$. On suppose que :

- $\mathcal{C}$ est **stable par intersection finie** (stable under finite intersection) — a π -system —,
- Ω peut être couvert par une union dénombrable d'éléments de $\mathcal{C}$ de mesures finies.

S'il existe une mesure ν qui coïncide avec μ sur $\mathcal{C}$ alors $\nu = \mu$.

Proof. Soit $B_n \uparrow \Omega$ une suite d'éléments de $\mathcal{C}$ telle que $\mu(B_n) < \infty$ pour tout $n \geq 1$ — an increasing sequence, which is how the covering hypothesis is used: $\mathcal{C}$ is assumed stable par intersection finie only, so the finite unions of a bare cover need not lie in $\mathcal{C}$ and the cover is taken increasing from the start — as it already is in every application below, $\mathbb{R} = \bigcup_{n \geq 1} [-n, n]$ being the model. Pour tout n fixé, soit

$$\mathcal{M} = \{A \in \mathcal{F} : \mu(A \cap B_n) = \nu(A \cap B_n)\}.$$

On vérifie que $\mathcal{M}$ est une **classe monotone** (*monotone class*) — it contains Ω , it is stable under proper difference, and it is stable under increasing limits. The lemme de classe monotone and the notion itself are carried in the reference chapter.

- $\Omega \in \mathcal{M}$: indeed $\Omega \cap B_n = B_n \in \mathcal{C}$, where μ and ν agree by hypothesis.
- Si $A, B \in \mathcal{M}$ tels que $A \subseteq B$, alors

$$\mu((B \setminus A) \cap B_n) = \mu(B \cap B_n) - \mu(A \cap B_n) = \nu(B \cap B_n) - \nu(A \cap B_n) = \nu((B \setminus A) \cap B_n),$$

si bien que $B \setminus A \in \mathcal{M}$. The two subtractions are legal only because $\mu(A \cap B_n) \leq \mu(B_n) < \infty$, and the same for ν ; this is the single place where the finite-measure half of the covering hypothesis is used, and without it the step is $\infty - \infty$.

- If $A_1, A_2, \dots \in \mathcal{M}$ with $A_k \uparrow A$, then $A_k \cap B_n \uparrow A \cap B_n$ and continuity from below gives

$$\mu(A \cap B_n) = \lim_{k \rightarrow +\infty} \mu(A_k \cap B_n) = \lim_{k \rightarrow +\infty} \nu(A_k \cap B_n) = \nu(A \cap B_n),$$

si bien que $A \in \mathcal{M}$.

Next, $\mathcal{C} \subseteq \mathcal{M}$: for $A \in \mathcal{C}$ the set $A \cap B_n$ again belongs to $\mathcal{C}$, because $\mathcal{C}$ is stable par intersection finie, and μ and ν agree on $\mathcal{C}$. Hence the classe monotone generated by $\mathcal{C}$ satisfies $\mathcal{M}(\mathcal{C}) \subseteq \mathcal{M}$. Mais par le lemme de classe monotone — whose own hypothesis is, once more, that $\mathcal{C}$ is stable par intersection finie —, $\mathcal{M}(\mathcal{C}) = \sigma(\mathcal{C}) = \mathcal{F}$. On en déduit que $\mathcal{M} = \mathcal{F}$, de sorte que

$$\forall A \in \mathcal{F}, \quad \mu(A \cap B_n) = \nu(A \cap B_n).$$

Finally let $n \rightarrow +\infty$. Since $A \cap B_n \uparrow A$, continuity from below gives $\mu(A) = \nu(A)$ pour tout $A \in \mathcal{F}$, ce qui signifie que $\mu = \nu$.

Remark (Where each hypothesis is spent). Stability of $\mathcal{C}$ under finite intersection is used twice, and both uses are essential: once to know that $A \cap B_n$ is still a set on which μ and ν are known to agree, and once inside the lemme de classe monotone, which is false without it. The finite-measure covering is used twice as well: to make the difference step a legal subtraction, and to exhaust Ω at the end. Two measures agreeing on a generating family that is *not* a π -system may differ — the theorem is not a formality, and on an exam the first thing to check is that the collection offered is closed under intersection.

Mesure de Lebesgue

Definition (Mesure de Lebesgue sur $\mathbb{R}$). La mesure de Lebesgue sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ est l'unique mesure, notée λ , telle que pour tous réels $a < b$,

$$\lambda([a, b]) = b - a.$$

La preuve de l'existence d'une telle mesure est difficile: it is obtained by building an outer mesure from countable coverings by intervals, showing that the sets splitting every test set additively form a tribu containing the boréliens, and restricting. L'unicité est une conséquence directe du théorème d'unicité. Il suffit en effet de considérer la collection $\mathcal{C}$ des intervalles $[a, b]$ avec $a \leq b$, complétée de $\emptyset$. Cette collection est stable par intersection finie, since the intersection of two such intervals is again one or is empty, and $\mathbb{R} = \bigcup_{n \geq 1} [-n, n]$ is a countable cover by elements of finite mesure. Toute autre mesure ν qui donne la mesure $b - a$ à l'intervalle $[a, b]$ est nécessairement égale à λ .

Remark (Three consequences, each a one-line computation). Pour tout $a \in \mathbb{R}$, $\lambda(\{a\}) = 0$, en utilisant le fait que $\{a\} = \bigcap_{n \geq 1} [a - \frac{1}{n}, a + \frac{1}{n}]$ — a decreasing limit with $\lambda([a - 1, a + 1]) = 2 < \infty$, so continuity from above applies and gives $\lim_n \frac{2}{n} = 0$. Then $\lambda(\mathbb{Q}) = 0$ par σ -additivité, $\mathbb{Q}$ being a countable union of singletons. And $\lambda(\mathbb{R} \setminus \mathbb{Q}) = +\infty$, since $\lambda(\mathbb{R}) = \lambda(\mathbb{Q}) + \lambda(\mathbb{R} \setminus \mathbb{Q})$ and $\lambda(\mathbb{R}) = +\infty$. A countable set is invisible to λ ; an uncountable one need not be visible either, as the ensemble de Cantor shows below.

Proposition (Invariance par translation (*translation invariance*)). Pour tout borélien A et tout $t \in \mathbb{R}$, $\lambda(A + t) = \lambda(A)$.

Remark. First, $A + t$ is a borélien whenever A is: $\{B - t : B \in \mathcal{B}(\mathbb{R})\}$ is a tribu containing the intervals, hence contains $\mathcal{B}(\mathbb{R})$. So $\lambda(A + t)$ is defined. Notons $\mu(A) = \lambda(A + t)$ pour $A \in \mathcal{B}(\mathbb{R})$. On vérifie que μ est une mesure — translation preserves disjointness and countable unions — and $\mu([a, b]) = \lambda([a + t, b + t]) = b - a$, so μ coïncide avec λ sur les intervalles. D'après le théorème d'unicité, $\mu = \lambda$. This is the standard use of the theorem: to identify two mesures, check them on a π -system and stop. Conversely, la mesure de Lebesgue est la *seule* mesure σ -finie invariante par translation sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, à une constante multiplicative près; the constant is recovered as $\alpha = \mu([0, 1])$, which is finite precisely because μ is σ -finie, and one then propagates $\mu([0, x]) = \alpha x$ from $x \in \mathbb{N}$ to $x \in \mathbb{Q}_+$ and finally to $x \in \mathbb{R}_+$ by monotone limits.

Definition (Mesure de Lebesgue sur $\mathbb{R}^n$). La mesure de Lebesgue sur $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ est l'unique mesure, que l'on notera également λ , telle que pour tous réels $a_1 < b_1, \dots, a_n < b_n$,

$$\lambda([a_1, b_1] \times \dots \times [a_n, b_n]) = (b_1 - a_1) \cdots (b_n - a_n).$$

Cette mesure est également la seule mesure σ -finie invariante par translation sur $\mathbb{R}^n$, à une constante multiplicative près. The σ -finiteness is not decoration: without it the characterisation is false, and it is what a computation of the image of λ under an invertible affine map has to check first.

Example (A mesure that is neither Lebesgue nor atomic). On $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ put $\mu = \lambda + \delta_0$, a sum of two mesures and therefore a mesure. Then

$$\mu(\{0\}) = 1, \quad \mu([0, 1]) = 2, \quad \mu([-1, 1]) = 3, \quad \mu([-1, 0]) = 1, \quad \mu(\mathbb{R}_+) = +\infty.$$

Each is the Lebesgue length plus 1 if 0 is in the set. In $\mathbb{R}^2$ with $\mu = \lambda + \delta_{(0,0)}$ the same reading gives $\mu(\{(0, 0)\}) = 1$, $\mu([0, 1]^2) = 2$, $\mu([-1, 1]^2) = 5$, $\mu([-1, 0]^2) = 1$ and $\mu(\mathbb{R}_+ \times \{0\}) = 1$, the last because that half-line has mesure de Lebesgue zero in the plane and contains the origin.

2.3 Ensembles négligeables

Soit μ une mesure sur $(\Omega, \mathcal{F})$.

Definition (Ensemble négligeable). Un ensemble $A \in \mathcal{F}$ est dit **négligeable** (*negligible*) si $\mu(A) = 0$.

Une propriété est dite vraie **presque partout** (*almost everywhere*) si sa négation correspond à un ensemble négligeable. The abbreviation p.p. is kept in its French form, and it is the primary form in these notes; the measure it refers to is always named or clear from the context.

Example (Almost every real is irrational). Presque tout réel est irrationnel pour la mesure de Lebesgue: $\lambda(\mathbb{Q}) = 0$, so the set of rationals is négligeable. There are as many rationals as integers and uncountably many reals, and λ sees only the second fact.

Remark (Negligible with respect to which measure?). Negligibility is a statement about a pair, a set *and* a measure: il faut veiller à bien spécifier la mesure considérée. Par exemple, il est faux de dire que presque tout réel est irrationnel pour la mesure $\mu = \lambda + \delta_0$: $\mu(\mathbb{Q}) \geq \mu(\{0\}) = 1 \neq 0$, so $\mathbb{Q}$ n'est pas négligeable pour μ , even though it is for λ . Two mesures on the same tribu can disagree completely about which sets are négligeables.

Example (An uncountable negligible set: the ensemble de Cantor). Let $C_0 = [0, 1]$, and let C_{n+1} be obtained from C_n by deleting the open middle third of each of its intervals, so that

$$C_1 = \left[0, \frac{1}{3}\right] \cup \left[\frac{2}{3}, 1\right], \quad C_2 = \left[0, \frac{1}{9}\right] \cup \left[\frac{2}{9}, \frac{1}{3}\right] \cup \left[\frac{2}{3}, \frac{7}{9}\right] \cup \left[\frac{8}{9}, 1\right],$$

and set $C = \bigcap_{n \geq 0} C_n$, the **ensemble de Cantor** (*Cantor set*). A real of $[0, 1]$ lies in C_n exactly when none of the first n digits of its ternary expansion is 1, so C is the set of reals whose ternary expansion uses only the digits 0 and 2. Replacing every 2 by a 1 maps C bijectively onto the binary expansions, that is onto $[0, 1]$: the ensemble de Cantor is uncountable. Yet C_n is a union of 2^n intervals of length 3^{-n} , so $\lambda(C_n) = (2/3)^n$, and $C_n \downarrow C$ with $\lambda(C_0) = 1 < \infty$, so continuity from above applies and

$$\lambda(C) = \lim_n \left(\frac{2}{3}\right)^n = 0.$$


Being négligeable is therefore not a statement about cardinality. Note that the finiteness hypothesis was available here and had to be invoked.

2.4 Fonctions mesurables

Soit $(\Omega, \mathcal{F})$ et $(E, \mathcal{E})$ deux espaces mesurables.

Definition (Fonction mesurable). Une fonction $f : \Omega \rightarrow E$ est dite **mesurable** (*measurable*) si :

$$\forall A \in \mathcal{E}, \quad f^{-1}(A) \in \mathcal{F}.$$



Measurability is a condition on *preimages*, never on images, because f^{-1} commutes with every set operation — complement, arbitrary union, arbitrary intersection — while the direct image does not commute with complement. That one algebraic fact makes the whole of this subsection work.

Example (The indicator function is measurable). Soit $A \in \mathcal{F}$. La fonction $f = \mathbb{1}_A$ est mesurable de $(\Omega, \mathcal{F})$ vers $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. En effet, pour tout borélien B ,

$$f^{-1}(B) = \begin{cases} A & \text{if } 1 \in B, 0 \notin B, \\ A^c & \text{if } 1 \notin B, 0 \in B, \\ \Omega & \text{if } 0, 1 \in B, \\ \emptyset & \text{if } 0, 1 \notin B, \end{cases}$$

and all four are in $\mathcal{F}$. Only four preimages occur because f takes only two values; measurability of $\mathbb{1}_A$ is exactly the statement $A \in \mathcal{F}$.

Remark. On remarque que si $\mathcal{F} = \mathcal{P}(\Omega)$ alors toute fonction sur Ω est mesurable, whatever the target. Measurability constrains only when the source tribu is genuinely smaller than the ensemble des parties: it measures how much information $\mathcal{F}$ carries about f .

Lemma (La mesurabilité se vérifie sur une collection génératrice). Soit $\mathcal{C} \subseteq \mathcal{P}(E)$ une collection d'ensembles telle que $\mathcal{E} = \sigma(\mathcal{C})$. Une condition suffisante pour que $f : \Omega \rightarrow E$ soit mesurable est que :

$$\forall A \in \mathcal{C}, \quad f^{-1}(A) \in \mathcal{F}.$$

Remark. Soit $\mathcal{G} = \{A \in \mathcal{E} : f^{-1}(A) \in \mathcal{F}\}$. It is a tribu, precisely because f^{-1} commutes with complement and countable union: $f^{-1}(E) = \Omega$, $f^{-1}(A^c) = f^{-1}(A)^c$ and $f^{-1}(\bigcup_i A_i) = \bigcup_i f^{-1}(A_i)$. Par hypothèse, $\mathcal{C} \subseteq \mathcal{G}$, donc $\mathcal{E} = \sigma(\mathcal{C}) \subseteq \mathcal{G}$, ce qui signifie que la fonction f est mesurable. This lemma is the workhorse of the subsection: every measurability proof below applies it to a well-chosen generating family, and for a real-valued function that family is almost always the half-lines $] - \infty, b]$.

Mesure image

Si μ est une mesure sur $(\Omega, \mathcal{F})$, toute fonction mesurable définit une nouvelle mesure, transported to the target.

Definition (Mesure image). Soit $f : \Omega \rightarrow E$ une fonction mesurable. La mesure μ_f définie par :

$$\forall A \in \mathcal{E}, \quad \mu_f(A) = \mu(f^{-1}(A))$$

est appelée la **mesure image** (*image measure*) de μ par f .

That μ_f is a measure is again the commutation of f^{-1} with the set operations: preimages of disjoint sets are disjoint, and a countable disjoint union pulls back to one. This construction later carries the whole of probability — the loi of a variable aléatoire is the image of $\mathbb{P}$ by that variable, and nothing else.

Example (Mesure image sur un espace à deux points). Soit $\Omega = \{1, 2, 3\}$ et μ la mesure de comptage sur $(\Omega, \mathcal{P}(\Omega))$, and $f = \mathbb{1}_{\{1, 2\}}$ with values in $E = \{0, 1\}$. Then $f^{-1}(\{0\}) = \{3\}$ and $f^{-1}(\{1\}) = \{1, 2\}$, so

$$\mu_f(\{0\}) = 1, \quad \mu_f(\{1\}) = 2.$$

The total mass 3 is preserved: a measure image never creates or destroys mass, it only redistributes it.

Example (Mesure de Lebesgue et fonction affine). Soit $\phi : \mathbb{R} \rightarrow \mathbb{R}$ la fonction affine $\phi(x) = \alpha x + \beta$, avec $\alpha \neq 0$. Pour $a < b$,

$$x \in \phi^{-1}([a, b]) \iff a \leq \alpha x + \beta \leq b,$$

on obtient l'intervalle $[\frac{a-\beta}{\alpha}, \frac{b-\beta}{\alpha}]$ si $\alpha > 0$ et l'intervalle $[\frac{b-\beta}{\alpha}, \frac{a-\beta}{\alpha}]$ si $\alpha < 0$; in both cases its length is $(b-a)/|\alpha|$. On en déduit $\lambda_\phi([a, b]) = (b-a)/|\alpha|$, and the two mesures λ_ϕ and $\lambda/|\alpha|$ agree on the intervals, a π -system generating $\mathcal{B}(\mathbb{R})$ along a countable cover of finite measure. By the théorème d'unicité,

$$\lambda_\phi = \frac{\lambda}{|\alpha|}.$$

The invertibility $\alpha \neq 0$ is essential: for $\alpha = 0$ the map is constant, the preimage of a set is $\emptyset$ or $\mathbb{R}$, and the measure image is not even σ -finie. In $\mathbb{R}^n$ the same statement holds for $\phi(x) = Ax + b$ with A **invertible**, and reads $\lambda_\phi = \lambda/|\det A|$; the proof reduces the general case to the diagonal, orthogonal and symmetric ones through the polar decomposition $A = QS$, and the first step is precisely the check that λ_ϕ is σ -finie and translation-invariant.

Stabilité de la mesurabilité

Proposition (Composition de fonctions). *Soit $(G, \mathcal{G})$ un espace mesurable. Si les fonctions $f : \Omega \rightarrow E$ et $g : E \rightarrow G$ sont mesurables, la fonction $g \circ f : \Omega \rightarrow G$ est mesurable.*

Remark. One line: pour tout ensemble $A \in \mathcal{G}$, on a $g^{-1}(A) \in \mathcal{E}$ because g is mesurable, donc $f^{-1}(g^{-1}(A)) \in \mathcal{F}$ because f is; and $(g \circ f)^{-1}(A) = f^{-1}(g^{-1}(A))$.

On s'intéresse maintenant aux fonctions réelles $f : \Omega \rightarrow \mathbb{R}$ ou vectorielles $f : \Omega \rightarrow \mathbb{R}^n$, les ensembles $\mathbb{R}$ et $\mathbb{R}^n$ étant munis de leur tribu de Borel.

Proposition (Continuité implique mesurabilité). *Toute fonction continue $f : \Omega \rightarrow \mathbb{R}^n$, avec $\Omega = \mathbb{R}$ ou $\mathbb{R}^m$ muni de sa tribu de Borel, est mesurable.*

Remark. Under a continuous map, l'image réciproque d'un ouvert est un ouvert, hence a borélien; la tribu de Borel de $\mathbb{R}^n$ étant engendrée par les ouverts, conclude by the generating lemma. This is the one place where the characterisation of $\mathcal{B}(\mathbb{R})$ by the open sets, rather than by the intervals, is what makes the argument work at all.

Remark (The converse is false). Il existe des fonctions mesurables qui ne sont pas continues. Par exemple, la fonction $1_{\mathbb{Q}} : \mathbb{R} \rightarrow \mathbb{R}$ est mesurable puisque $\mathbb{Q}$ est un borélien, and is continuous at no point. Measurability is much weaker than continuity, and that weakness is the point: the class of measurable functions is closed under operations — limits above all — under which the continuous functions are not.

Proposition (Mesurabilité coordonnée par coordonnée). *Soit $f = (f_1, \dots, f_n)$ une fonction de Ω vers $\mathbb{R}^n$. La fonction f est mesurable si et seulement si les fonctions $f_1, \dots, f_n$ sont mesurables.*

Remark. Forwards: $f_1^{-1}([a, b]) = f^{-1}([a, b] \times \mathbb{R} \times \dots \times \mathbb{R})$, a preimage of a borélien, so f_1 is measurable by the generating lemma, and likewise for the other coordinates. Réciproquement, pour tout pavé,

$$f^{-1}([a_1, b_1] \times \dots \times [a_n, b_n]) = f_1^{-1}([a_1, b_1]) \cap \dots \cap f_n^{-1}([a_n, b_n]),$$

a finite intersection of elements of $\mathcal{F}$; the pavés generate $\mathcal{B}(\mathbb{R}^n)$, so the generating lemma applies again.

Proposition (Opérations algébriques). *Si f et g sont des fonctions mesurables, alors les fonctions $f + g$, fg , $\max(f, g)$ et $\min(f, g)$ sont mesurables.*

Remark. Each is a composition. La fonction addition $\mathbb{R}^2 \rightarrow \mathbb{R}$, $(x, y) \mapsto x + y$, est continue donc mesurable; the pair $(f, g) : \Omega \rightarrow \mathbb{R}^2$ is measurable by coordinatewise measurability; so $f + g$ is measurable as a composition of two measurable maps. Multiplication, max and min are continuous in the same way: la preuve est identique pour les autres opérations. Note the order of the three propositions: composition, then coordinates, then operations — each uses the one before.

Example (Fonction mesurable sur $\mathbb{R}$). La fonction $f(x) = x^2 + 1_{\mathbb{R}_+}(x)$ est mesurable de $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ vers $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$: c'est la somme de deux fonctions mesurables, la fonction continue $x \mapsto x^2$, mesurable because continuous, et la fonction indicatrice du borélien $\mathbb{R}_+$, mesurable because $\mathbb{R}_+$ is a borélien. It is discontinuous at 0, which costs nothing.

Example (Fonction mesurable sur $\mathbb{R}^2$). Likewise, la fonction $f(x, y) = xy + 1_{\{(0,0)\}}(x, y)$ est mesurable de $(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2))$ vers $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$: c'est la somme de deux fonctions mesurables, la fonction continue $(x, y) \mapsto xy$ et la fonction indicatrice du singleton $\{(0, 0)\}$, which is a borélien of $\mathbb{R}^2$.

Limites de fonctions mesurables

Here the class of measurable functions shows what it is for. Nous allons maintenant considérer la limite d'une suite de fonctions mesurables, lorsqu'elle existe, et montrer qu'on obtient une fonction mesurable. C'est une différence notable avec les fonctions continues, la limite de fonctions continues n'étant pas continue en général. Nous allons travailler sur l'ensemble $\mathbb{R}$, muni de sa tribu de Borel $\mathcal{B}(\mathbb{R})$, since a supremum of real functions need not be finite.

Proposition (Supremum, infimum et limites). *Soit $(f_n)_{n \geq 1}$ une suite de fonctions mesurables de Ω vers $\overline{\mathbb{R}}$. Alors les fonctions $\inf_n f_n$, $\sup_n f_n$, $\liminf_n f_n$, $\limsup_n f_n$ et $\lim_n f_n$ (lorsque celle-ci existe) sont des fonctions mesurables de Ω vers $\overline{\mathbb{R}}$.*

Remark. Soit $f = \sup_n f_n$. On a pour tout $b \in \overline{\mathbb{R}}$:

$$f^{-1}([-\infty, b]) = \bigcap_{n \geq 1} f_n^{-1}([-\infty, b]) \in \mathcal{F},$$

because $\sup_n f_n(\omega) \leq b$ if and only if $f_n(\omega) \leq b$ for every n . Comme $\mathcal{B}(\overline{\mathbb{R}})$ est engendrée par les intervalles $[-\infty, b]$, la fonction f est mesurable by the generating lemma. On montre de la même manière que l'infimum est mesurable, $\mathcal{B}(\overline{\mathbb{R}})$ étant également engendrée par les intervalles $[a, +\infty]$. Then

$$\liminf_n f_n = \sup_n \inf_{k \geq n} f_k, \quad \limsup_n f_n = \inf_n \sup_{k \geq n} f_k,$$

so both are mesurables by two applications of what precedes. Enfin, si la limite $\lim_n f_n$ est bien définie, elle vaut $\liminf_n f_n$, which settles it.

Remark (Where $\overline{\mathbb{R}}$ was needed). Nothing forces the sequence to be bounded, so $\sup_n f_n$ may legitimately be $+\infty$ on a set of positive measure. Had the target been $\mathbb{R}$, the proposition would have needed a boundedness hypothesis and would have been useless for the next chapter's théorème de convergence monotone and lemme de Fatou, both stated for positive measurable functions with values in $[0, +\infty]$. This is why $\mathcal{B}(\overline{\mathbb{R}})$ was defined at all.


Conclusion. The chapter fixes three objects and one theorem. The objects: a *tribu*, which is the family of sets one is allowed to measure, generated in practice from a small collection — intervals, half-lines, open sets, pavés — rather than written out; a *mesure*, a σ -additive map into $[0, +\infty]$, of which λ and δ_a are the two models and all the rest are built from them; and a *mesurable function*, defined by its preimages and therefore stable under composition, algebraic operations and, decisively, pointwise limits. The theorem is uniqueness: two mesures agreeing on a π -system that generates the tribu, with a countable cover of Ω by elements of that π -system of finite measure, are equal — which is what allows every later identification of a loi to stop after checking a generating family.

Two hypotheses go missing under compression, and both were written out above: continuity from above needs $\mu(A_1) < \infty$, with $A_n = [n, +\infty[$ as the standing counter-example, and the théorème d'unicité needs $\mathcal{C}$ stable par intersection finie, used once to keep $A \cap B_n$ inside $\mathcal{C}$ and once inside the lemme de classe monotone. The next chapter builds the integral on these objects, starting with positive measurable functions valued in $[0, +\infty]$ — the reason $\mathcal{B}(\overline{\mathbb{R}})$ was defined here.


3 Intégrale de Lebesgue

The previous chapter built three objects — a tribu, a mesure, a mesurable function — and stopped just short of using them. This chapter uses them: nous allons maintenant définir une intégrale par rapport à une mesure. C'est l'**intégrale de Lebesgue** (*Lebesgue integral*), beaucoup plus générale que l'intégrale de Riemann, in two independent directions: elle permet d'intégrer beaucoup plus de fonctions, et par rapport à n'importe quelle mesure, pas uniquement la mesure "uniforme" utilisée habituellement, qui correspond à la mesure de Lebesgue.

The idea is a single change of axis. Riemann cuts the *domain* into small intervals and multiplies the width of each by a value of f on it. Lebesgue cuts the *range* into small intervals and multiplies the length of each level band by the measure of the set of points where f takes a value in that band. De manière schématique, l'intégrale de Lebesgue est définie à partir d'une discrétisation selon l'axe des ordonnées (les différentes valeurs prises par la fonction à intégrer) plutôt que selon l'axe des abscisses (l'ensemble de définition de la fonction): that is the whole of the construction; everything below is bookkeeping.



(a) Intégrale de Riemann (discrétisation selon l'axe des abscisses)



(b) Intégrale de Lebesgue (discrétisation selon l'axe des ordonnées)

The price of the change is that the level set $\{f \geq y\}$ has to be measurable for its measure to exist, which is why measurability was defined first. The reward is that the class of integrable functions becomes stable under pointwise limits, and that is what the three convergence theorems of this chapter say.

3.1 Définition

Soit $(\Omega, \mathcal{F})$ un espace mesurable.

Definition (Fonction étagée (*simple function*)). Une fonction f mesurable de $(\Omega, \mathcal{F})$ vers $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ est dite **étagée** si elle prend un nombre fini de valeurs.

Une telle fonction s'écrit :

$$f = \sum_{i=1}^n \alpha_i \mathbb{1}_{A_i},$$

où $\alpha_1, \dots, \alpha_n$ sont les valeurs distinctes et non-nulles prises par f , et pour tout i , $A_i = f^{-1}(\{\alpha_i\})$. Notons que, la fonction f étant mesurable, each A_i belongs to $\mathcal{F}$; this is the only place measurability is used, and it is what makes the next definition legal. This decomposition is called the canonical form, and it will be referred to below simply as writing f in the form above.

Example (The indicator of the rationals is simple). La fonction $\mathbb{1}_{\mathbb{Q}}$ est étagée: it takes the two values 0 and 1, and $\mathbb{Q}$ is a borélien.

On se donne une mesure μ sur $(\Omega, \mathcal{F})$.

Definition (Intégrale d'une fonction étagée positive). L'intégrale d'une fonction étagée positive f est la valeur, éventuellement infinie :

$$\int f d\mu = \sum_{i=1}^n \alpha_i \mu(A_i),$$

où les réels $\alpha_1, \dots, \alpha_n > 0$ et les ensembles $A_1, \dots, A_n$ sont définis par la forme canonique.

Example (The rationals have measure de Lebesgue zero). L'intégrale de la fonction $\mathbb{1}_{\mathbb{Q}}$ par rapport à la mesure de Lebesgue est :

$$\int \mathbb{1}_{\mathbb{Q}} d\lambda = \lambda(\mathbb{Q}) = 0.$$

Si f prend la valeur 0, il est possible de l'écrire sous cette forme en définissant $\alpha_1, \dots, \alpha_n$ comme l'ensemble des valeurs prises par f , y compris la valeur 0. Les ensembles $A_1, \dots, A_n$ forment alors une partition de Ω . L'intégrale s'écrit toujours par la même somme, à condition d'adopter la convention suivante :

$$0 \times +\infty = 0,$$

ce que nous ferons dans l'ensemble du cours. The convention is not a dodge: a set of infinite measure on which the function vanishes must contribute nothing, and without the convention the sum would be undefined rather than zero.

Example (The same integral, written over a partition). L'intégrale de la fonction $\mathbb{1}_{\mathbb{Q}}$ par rapport à la mesure de Lebesgue s'écrit aussi :

$$\int \mathbb{1}_{\mathbb{Q}} d\lambda = \lambda(\mathbb{Q}) + 0 \times \lambda(\mathbb{R} \setminus \mathbb{Q}) = 0,$$

the second term being $0 \times +\infty$.

On définit maintenant l'intégrale de toute fonction mesurable positive, by approximation from below. On permet à la fonction de prendre la valeur $+\infty$.

Definition (Intégrale d'une fonction mesurable positive). L'intégrale d'une fonction $f : \Omega \rightarrow [0, +\infty]$ mesurable positive est la valeur, éventuellement infinie :

$$\int f d\mu = \sup \left\{ \int g d\mu : 0 \leq g \leq f, g \text{ simple} \right\}.$$

On vérifie que si la fonction f est elle-même étagée, cette définition coïncide avec la précédente. C'est une conséquence du résultat suivant.

Proposition (Monotonie sur les fonctions étagées). Soit f et g deux fonctions étagées positives telles que $f \leq g$. Alors

$$\int f d\mu \leq \int g d\mu.$$

Proof. On écrit :

$$f = \sum_{i=1}^n \alpha_i \mathbb{1}_{A_i} \quad \text{and} \quad g = \sum_{j=1}^m \beta_j \mathbb{1}_{B_j},$$

où $\alpha_1, \dots, \alpha_n$ et $\beta_1, \dots, \beta_m$ sont les valeurs prises par f et g , respectivement. Les ensembles $A_1, \dots, A_n$ et $B_1, \dots, B_m$ formant des partitions de Ω , on a :

$$\int f d\mu = \sum_{i=1}^n \alpha_i \mu(A_i) = \sum_{i=1}^n \sum_{j=1}^m \alpha_i \mu(A_i \cap B_j) \leq \sum_{i=1}^n \sum_{j=1}^m \beta_j \mu(A_i \cap B_j) = \sum_{j=1}^m \beta_j \mu(B_j) = \int g d\mu,$$

où l'on a utilisé le fait que $\alpha_i \leq \beta_j$ dès que $A_i \cap B_j \neq \emptyset$ — on such a point f takes the value α_i and g the value β_j , and $f \leq g$.

Il reste à définir l'intégrale d'une fonction mesurable quelconque. Pour toute fonction mesurable $f : \Omega \rightarrow \overline{\mathbb{R}}$, on définit les fonctions mesurables positives :

$$f^+ = \max(f, 0) \quad \text{and} \quad f^- = \max(-f, 0),$$

which satisfy $f = f^+ - f^-$ and $|f| = f^+ + f^-$.

Definition (Intégrale de Lebesgue). L'intégrale d'une fonction mesurable $f : \Omega \rightarrow \overline{\mathbb{R}}$ est la valeur, éventuellement infinie :

$$\int f d\mu = \int f^+ d\mu - \int f^- d\mu,$$

qui est bien définie dès que $\int f^+ d\mu < \infty$ ou $\int f^- d\mu < \infty$.

The side condition matters: on notera que l'intégrale d'une fonction mesurable n'est pas toujours définie. Two infinities of opposite sign do not subtract.

Example (A measurable function with no integral). La fonction mesurable $\mathbb{1}_{\mathbb{R}_+} - \mathbb{1}_{\mathbb{R}_-}$ n'a pas d'intégrale par rapport à la mesure de Lebesgue: its positive and negative parts both have infinite integral.

Definition (Intégrabilité). Une fonction d'intégrale finie est dite **intégrable**.

Example (Integrable and non-integrable). La fonction $\mathbb{1}_{\mathbb{Q}}$ est intégrable par rapport à la mesure de Lebesgue, of integral 0; la fonction $\mathbb{1}_{\mathbb{R}_+}$ ne l'est pas, its integral being $+\infty$. Note the difference with the previous example: here the integral *exists* and is infinite, there it does not exist at all.

Proposition (Changement de signe). *Pour toute fonction mesurable f dont l'intégrale est définie,*

$$\int (-f) d\mu = - \int f d\mu.$$

Proof. Il suffit de remarquer que $(-f)^+ = f^-$ et $(-f)^- = f^+$, si bien que l'intégrale de $-f$ est définie et vaut :

$$\int (-f) d\mu = \int f^- d\mu - \int f^+ d\mu = - \int f d\mu.$$

Remark (Integrating over a subset). Contrairement à l'intégrale de Riemann, l'intégrale de Lebesgue est définie d'emblée sur l'ensemble Ω (par exemple $\mathbb{R}$). Lorsque l'on souhaite limiter le domaine d'intégration à un ensemble $A \in \mathcal{F}$, on utilise la notation :

$$\int_A f d\mu \equiv \int f \mathbb{1}_A d\mu.$$

On notera que la fonction $f \mathbb{1}_A$ est mesurable dès que f est mesurable, comme produit de fonctions mesurables. There is no separate theory of the integral over a subset; it is the same integral applied to a different function.

Notation. Lorsque la fonction f dépend de plusieurs variables, il peut être utile de préciser la variable d'intégration. On écrira par exemple $\int f(x) d\mu(x)$ pour préciser que la variable d'intégration est x .

3.2 Monotonie

Lemma (Monotonie). *Soit f et g deux fonctions mesurables de Ω vers $\overline{\mathbb{R}}$, dont les intégrales sont définies. Alors :*

1. $f \leq g$ implique $\int f d\mu \leq \int g d\mu$;
2. $|\int f d\mu| \leq \int |f| d\mu$.

Proof. Pour le premier point, supposons f et g mesurables positives. Si $f \leq g$ alors $\{h \text{ simple}, h \leq f\} \subseteq \{h \text{ simple}, h \leq g\}$, and the supremum over the larger set is the larger, et donc $\int f d\mu \leq \int g d\mu$. In general $f \leq g$ implique $f^+ \leq g^+$ et $f^- \geq g^-$ et, d'après ce qui précède, $\int f^+ d\mu \leq \int g^+ d\mu$ et $\int f^- d\mu \geq \int g^- d\mu$; subtracting gives the claim. Pour le second point, on a $f \leq |f|$ donc $\int f d\mu \leq \int |f| d\mu$. De même, $-f \leq |f|$ donc $\int (-f) d\mu \leq \int |f| d\mu$; by the sign-reversal proposition the left-hand side of the second inequality is $-\int f d\mu$, and the two inequalities together are the claim.

The next result is the engine of the chapter: le résultat suivant est fondamental pour calculer l'intégrale de Lebesgue et en montrer les principales propriétés.

Lemma (Convergence monotone (*monotone convergence*), sous forme de lemme). *Soit $(f_n)_{n \geq 1}$ une suite croissante de fonctions mesurables positives de limite f . Alors la fonction f est mesurable et :*

$$\lim_{n \rightarrow +\infty} \int f_n d\mu = \int f d\mu.$$

Proof. On sait que la fonction f est mesurable, by the stability of measurability under pointwise limits proved in the previous chapter. By monotonicity la suite $(\int f_n d\mu)_{n \geq 1}$ est croissante et vérifie :

$$\lim_{n \rightarrow +\infty} \int f_n d\mu \leq \int f d\mu,$$

since $f_n \leq f$ for every n . Il reste à montrer l'inégalité inverse.

Soit g une fonction étagée positive telle que $g \leq f$. On l'écrit sous la forme :

$$g = \sum_{i=1}^m \alpha_i \mathbb{1}_{A_i}, \quad \alpha_1, \dots, \alpha_m > 0.$$

Soit $\varepsilon > 0$ et $B_n = \{f_n \geq (1 - \varepsilon)g\}$, a mesurable set. Monotonicity gives

$$\begin{aligned} \int f_n d\mu &\geq \int f_n \mathbb{1}_{B_n} d\mu \\ &\geq \int (1 - \varepsilon)g \mathbb{1}_{B_n} d\mu \\ &= \int (1 - \varepsilon) \sum_{i=1}^m \alpha_i \mathbb{1}_{A_i \cap B_n} d\mu = (1 - \varepsilon) \sum_{i=1}^m \alpha_i \mu(A_i \cap B_n). \end{aligned}$$

The sequence (B_n) increases to Ω : at a point where g vanishes the inequality $f_n \geq (1 - \varepsilon)g$ holds for every n , and at a point where $g > 0$ one has $f(\omega) \geq g(\omega) > (1 - \varepsilon)g(\omega)$, so $f_n(\omega)$ eventually exceeds $(1 - \varepsilon)g(\omega)$. Continuity from below of μ therefore gives $\mu(A_i \cap B_n) \uparrow \mu(A_i)$ for each i , and

$$\lim_{n \rightarrow +\infty} \int f_n d\mu \geq (1 - \varepsilon) \sum_{i=1}^m \alpha_i \mu(A_i) = (1 - \varepsilon) \int g d\mu.$$

Cette inégalité étant vérifiée pour tout $\varepsilon > 0$, on en déduit que $\lim_n \int f_n d\mu \geq \int g d\mu$. En prenant le supremum sur l'ensemble des fonctions étagées positives $g \leq f$, on conclut que $\lim_n \int f_n d\mu \geq \int f d\mu$, which closes the proof.

Remark (Why $(1 - \varepsilon)$ and not g itself). The set $\{f_n \geq g\}$ need not increase to Ω — the sequence may approach g from strictly below at every stage and never reach it. Relaxing the target by a factor $1 - \varepsilon$ is exactly what makes the exhaustion work, and letting $\varepsilon \rightarrow 0$ at the end costs nothing because the inequality is uniform in ε .

Le lemme de convergence monotone prend tout son sens grâce au résultat suivant : toute fonction mesurable positive est limite croissante de fonctions étagées positives. Son intégrale est donc la limite croissante des intégrales de ces fonctions, which are finite sums.


Lemma (Approximation par des fonctions étagées). *Soit $f : \Omega \rightarrow [0, +\infty]$ une fonction mesurable positive. Il existe une suite croissante de fonctions étagées positives $(f_n)_{n \geq 1}$ de limite f .*

Proof. Pour tout $n \geq 1$, soit

$$f_n = \sum_{k=0}^{4^n} \frac{k}{2^n} \mathbb{1}_{A_k}, \quad A_k = \begin{cases} f^{-1} \left(\left[\frac{k}{2^n}, \frac{k+1}{2^n} \right] \right) & \text{for } k = 0, \dots, 4^n - 1, \\ f^{-1}([2^n, +\infty]) & \text{for } k = 4^n. \end{cases}$$

Each A_k is in $\mathcal{F}$ by measurability of f , so f_n is a fonction étagée positive. Refining the mesh from 2^{-n} to 2^{-n-1} , and raising the cut-off from 2^n to 2^{n+1} , can only raise the value assigned to a point, so the sequence is increasing; and $f_n(\omega) \rightarrow f(\omega)$ for every ω , the error being at most 2^{-n} once n is large enough that $f(\omega) < 2^n$, while $f_n(\omega) = 2^n \rightarrow +\infty$ where $f(\omega) = +\infty$.

The staircase takes, at each point, the largest multiple of 2^{-n} below f ; every halving of the mesh inserts a new level between two old ones, so the staircase can only rise, and it rises to f . The picture also explains the cut-off at 2^n : a fonction étagée takes finitely many values and cannot follow f up to $+\infty$, so the construction truncates and lets the truncation level escape with n .



3.3 Linéarité

Theorem (Linéarité). Soit f et g des fonctions mesurables de Ω vers $\overline{\mathbb{R}}$ dont les intégrales sont bien définies. On a :

$$\forall \alpha \in \mathbb{R}, \quad \int \alpha f \, d\mu = \alpha \int f \, d\mu,$$

et

$$\int (f + g) \, d\mu = \int f \, d\mu + \int g \, d\mu,$$

cette dernière égalité étant satisfaite dès que les fonctions f et g sont positives ou que l'une d'entre elles est intégrable.

Proof. On montre successivement les deux propriétés, each by the same ladder: étagée positive, then measurable positive by convergence monotone, then arbitrary sign by splitting into positive and negative parts.

Homogeneity. Soit $\alpha \geq 0$. Si $f = \sum_{i=1}^n \alpha_i \mathbb{1}_{A_i}$ est étagée positive, où les ensembles $A_1, \dots, A_n$ forment une partition de Ω , la fonction αf est étagée positive, de sorte que $\int \alpha f \, d\mu = \sum_i \alpha \alpha_i \mu(A_i) = \alpha \int f \, d\mu$. Si la fonction f est mesurable positive, on considère une suite croissante de fonctions étagées positives (f_n) qui tend vers f . Alors (αf_n) est une suite croissante de fonctions étagées positives qui tend vers αf , and the lemme de convergence monotone gives

$$\int \alpha f \, d\mu = \lim_n \uparrow \int \alpha f_n \, d\mu = \alpha \lim_n \uparrow \int f_n \, d\mu = \alpha \int f \, d\mu.$$

Si f est une fonction mesurable, d'intégrale bien définie, on applique le résultat précédent aux fonctions $(\alpha f)^+ = \alpha f^+$ et $(\alpha f)^- = \alpha f^-$; negative α then follows from the sign-reversal proposition.

Additivity. On considère tout d'abord le cas où les fonctions f et g sont étagées positives. On écrit :

$$f = \sum_{i=1}^n \alpha_i \mathbb{1}_{A_i} \quad \text{and} \quad g = \sum_{j=1}^m \beta_j \mathbb{1}_{B_j},$$

où les ensembles $A_1, \dots, A_n$ et $B_1, \dots, B_m$ forment des partitions de Ω . La fonction $f + g$ est étagée positive, avec :

$$f + g = \sum_{i=1}^n \sum_{j=1}^m (\alpha_i + \beta_j) \mathbb{1}_{A_i \cap B_j},$$

and therefore, on obtient :

$$\begin{aligned}
 \int (f + g) d\mu &= \sum_{i=1}^n \sum_{j=1}^m (\alpha_i + \beta_j) \mu(A_i \cap B_j) \\
 &= \sum_{i=1}^n \sum_{j=1}^m \alpha_i \mu(A_i \cap B_j) + \sum_{i=1}^n \sum_{j=1}^m \beta_j \mu(A_i \cap B_j) \\
 &= \sum_{i=1}^n \alpha_i \mu(A_i) + \sum_{j=1}^m \beta_j \mu(B_j) = \int f d\mu + \int g d\mu.
 \end{aligned}$$

Si f et g sont mesurables positives, on considère des suites croissantes de fonctions étagées positives (f_n) et (g_n) qui tendent respectivement vers f et g . Alors $(f_n + g_n)$ est une suite croissante de fonctions étagées positives qui tend vers $f + g$, and the lemme de convergence monotone gives $\int (f + g) d\mu = \lim_n \uparrow (\int f_n d\mu + \int g_n d\mu) = \int f d\mu + \int g d\mu$.

Finally, si f ou g est intégrable,

$$\int (f + g)^+ d\mu \leq \int (f^+ + g^+) d\mu = \int f^+ d\mu + \int g^+ d\mu < \infty$$

ou

$$\int (f + g)^- d\mu \leq \int (f^- + g^-) d\mu = \int f^- d\mu + \int g^- d\mu < \infty,$$

l'intégrale de $f + g$ est donc bien définie. Comme :

$$f + g = (f + g)^+ - (f + g)^- = f^+ - f^- + g^+ - g^-$$

on a :

$$(f + g)^+ + f^- + g^- = (f + g)^- + f^+ + g^+,$$

ces fonctions étant positives, the positive case applies to this identity:

$$\int (f + g)^+ d\mu + \int f^- d\mu + \int g^- d\mu = \int (f + g)^- d\mu + \int f^+ d\mu + \int g^+ d\mu,$$

and rearranging gives $\int (f + g) d\mu = \int f d\mu + \int g d\mu$.

Remark (Rearranging into positive parts, and why). The last step is the only subtle one. One cannot simply subtract $\int f^-$ from both sides of an equality between possibly infinite quantities; the rearrangement into an identity between *positive* functions is what allows the additive case already proved to be applied, and the hypothesis that one of f, g is integrable is what guarantees that the terms being moved are finite. Drop that hypothesis and the statement fails: with $f = \mathbb{1}_{\mathbb{R}_+}$ and $g = -\mathbb{1}_{\mathbb{R}_+}$ the left-hand side is 0 while the right-hand side is $\infty - \infty$.

Remark (The three-stage method). The proof just given is the pattern of the whole chapter. A statement about the integral is proved first for fonctions étagées positives, where it is a finite sum; then for positive mesurable functions, by taking an increasing sequence of fonctions étagées and applying the lemme de convergence monotone on each side; then for mesurable functions of arbitrary sign, by applying the positive case to f^+ and to f^- and subtracting, which needs one of the two to be finite. Every proof below that begins “by the three-stage method” is this argument, and only its first stage is ever written out.

Remark (The order of the chapter is not circular). It looks as though linearity has just been proved using convergence monotone, while convergence monotone is stated as a theorem only two subsections below. It is not circular, and the point is worth stating once, being the single most confusing thing in this chapter. What linearity uses is the *lemma* form: an *everywhere* increasing sequence of positive mesurable functions with everywhere pointwise limit. That lemma was proved directly from the definition of the integral as a supremum over fonctions étagées, using only monotonicity and continuity from below of the mesure, and no

linearity whatsoever. The *theorem* form below weakens the hypothesis to convergence *presque partout*, and its proof restricts to the set where convergence holds and invokes the lemma there — and that restriction is where linearity and the results on ensembles négligeables are needed. The dependency runs lemma $\rightarrow$ linearity $\rightarrow$ ensembles négligeables $\rightarrow$ theorem, with no cycle, and these notes keep that order.

Corollary (L'intégrabilité se lit sur le module). *Une fonction mesurable f est intégrable si et seulement si $\int |f| d\mu < \infty$.*

Proof. Comme $|f| = f^+ + f^-$, on a par linéarité de l'intégrale, in the positive case :

$$\int |f| d\mu = \int f^+ d\mu + \int f^- d\mu,$$

qui est finie si et seulement si $\int f^+ d\mu < \infty$ et $\int f^- d\mu < \infty$, that is, if and only if f is integrable.

Corollary (Additivité dénombrable de l'intégrale). *Pour toute suite de fonctions mesurables positives $(f_n)_{n \geq 1}$,*

$$\sum_{n \geq 1} \int f_n d\mu = \int \left(\sum_{n \geq 1} f_n \right) d\mu.$$

Proof. La suite $\left(\sum_{n=1}^k f_n \right)_{k \geq 1}$ (the partial sums) est une suite croissante de fonctions mesurables positives qui tend vers $f = \sum_{n \geq 1} f_n$, so the lemme de convergence monotone gives

$$\lim_k \uparrow \int \sum_{n=1}^k f_n d\mu = \int f d\mu,$$

while, par ailleurs, la linéarité de l'intégrale implique que

$$\lim_k \uparrow \int \sum_{n=1}^k f_n d\mu = \lim_k \uparrow \sum_{n=1}^k \int f_n d\mu = \sum_{n \geq 1} \int f_n d\mu.$$

Remark (Positivity is the whole hypothesis). Nothing is assumed about convergence: both sides may be $+\infty$, and the corollary asserts that they are infinite together. This is the interchange of a sum and an integral that costs nothing; it is used below to prove that a mesure à densité is a mesure, and again inside the construction of the mesure produit. Without positivity the interchange needs domination.

3.4 Ensembles négligeables

On rappelle qu'un ensemble $A \in \mathcal{F}$ est dit négligeable si $\mu(A) = 0$, as in the previous chapter.

Proposition (Intégrale sur un ensemble négligeable). *Soit $f : \Omega \rightarrow \mathbb{R}$ une fonction mesurable et A un ensemble négligeable. Alors*

$$\int_A f d\mu = 0.$$

Proof. By the three-stage method. Si $f = \sum_{i=1}^n \alpha_i \mathbb{1}_{A_i}$ est étagée positive, alors la fonction $f \mathbb{1}_A = \sum_{i=1}^n \alpha_i \mathbb{1}_{A_i \cap A}$ est elle-même étagée positive. On en déduit :

$$\int_A f d\mu = \sum_{i=1}^n \alpha_i \mu(A_i \cap A) \leq \sum_{i=1}^n \alpha_i \mu(A) = 0.$$

The two remaining stages use $(f \mathbb{1}_A)^+ = f^+ \mathbb{1}_A$ and $(f \mathbb{1}_A)^- = f^- \mathbb{1}_A$.

On rappelle qu'une propriété est vraie "presque partout" (ce que l'on note p.p.) si sa négation correspond à un ensemble négligeable, and that the mesure it refers to is always the one the integral is taken against.

Theorem (L'intégrale ne voit pas les ensembles négligeables). *Soit $f, g : \Omega \rightarrow \mathbb{R}$ des fonctions mesurables. Alors*

1. $f = 0$ p.p. implique $\int f d\mu = 0$;
2. $f = g$ p.p. implique $\int f d\mu = \int g d\mu$ dès que l'une de ces intégrales existe ;
3. $f \geq 0$ p.p. implique $\int f d\mu \geq 0$; si de plus $\int f d\mu = 0$ alors $f = 0$ p.p. ;
4. $f \leq g$ p.p. implique $\int f d\mu \leq \int g d\mu$ dès que ces intégrales existent ; si de plus $\int f d\mu = \int g d\mu < \infty$ alors $f = g$ p.p.

Proof. 1. L'ensemble $A = \{f \neq 0\}$ est négligeable. Comme $f = f \mathbb{1}_A$, on a par la proposition précédente $\int f d\mu = \int_A f d\mu = 0$.

2. Si f, g sont positives, on note $A = \{f = g\}$, whose complement is négligeable. Comme $f = f \mathbb{1}_A + f \mathbb{1}_{A^c}$, and likewise for g , on a par linéarité et par la proposition précédente $\int f d\mu = \int f \mathbb{1}_A d\mu + \int f \mathbb{1}_{A^c} d\mu = \int g \mathbb{1}_A d\mu + \int g \mathbb{1}_{A^c} d\mu = \int g d\mu$. In general $f^+ = g^+$ p.p. et $f^- = g^-$ p.p., so the positive case applies to each; if one of the two integrals is well defined, so is the other, and they are equal.

3. On définit $A = \{f \geq 0\}$. Comme $f = f \mathbb{1}_A$ p.p., on a par le résultat précédent $\int f d\mu \geq 0$. Si de plus $\int f d\mu = 0$, on définit $A_n = \{f \geq \frac{1}{n}\}$. Comme $f \mathbb{1}_{A_n} \leq f \mathbb{1}_A$,

$$\int f d\mu \geq \int f \mathbb{1}_{A_n} d\mu \geq \frac{1}{n} \mu(A_n),$$

on a donc $\mu(A_n) = 0$ pour tout n , et comme $A_n \uparrow \{f > 0\}$, continuity from below gives $\mu(\{f > 0\}) = 0$. On en déduit que $f = 0$ p.p.

4. Soit $A = \{f \leq g\}$, whose complement is négligeable. Comme $f \mathbb{1}_A \leq g \mathbb{1}_A$, on a $\int f d\mu \leq \int g d\mu$ by the second point. Si de plus $\int f d\mu = \int g d\mu < \infty$, alors $g - f \geq 0$ p.p. avec $\int (g - f) d\mu = 0$, ce qui implique $f = g$ p.p. d'après le résultat précédent.

Remark (Finiteness in the last statement). The finiteness $\int f d\mu = \int g d\mu < \infty$ in the fourth point is not decoration. It is what makes $\int (g - f) d\mu = 0$ legitimate: subtracting two infinite integrals says nothing. Take $f = \mathbb{1}_{\mathbb{R}_+}$ and $g = \mathbb{1}_{\mathbb{R}}$ against λ . Both integrals are defined and equal to $+\infty$, and $f \leq g$ everywhere, yet f and g differ on the whole of $]-\infty, 0[$, which is very far from négligeable. Equal infinite integrals say nothing about the two functions; only equal finite ones do. The same remark applies to the equality case of the third point, where the hypothesis is the value 0, which is finite by construction.

Theorem (Une fonction intégrable est p.p. finie). *Toute fonction intégrable est p.p. finie.*

Proof. Soit f une fonction positive intégrable. Notons $A = \{f = +\infty\}$. Pour tout $n \geq 1$, $f \geq f_n$ avec $f_n = n \mathbb{1}_A$. On en déduit :

$$\int f d\mu \geq \int f_n d\mu = n\mu(A).$$

Si $\mu(A) > 0$ alors, en faisant tendre $n \rightarrow +\infty$, on obtient $\int f d\mu = +\infty$, une contradiction. L'ensemble A est donc négligeable, ce qui signifie que f est p.p. finie. Si f est intégrable (of arbitrary sign), alors $\int f^+ d\mu < \infty$ et $\int f^- d\mu < \infty$. D'après le résultat précédent, f^+ et f^- sont p.p. finies, ce qui veut dire que f est p.p. finie.

3.5 Convergence monotone, convergence dominée

This is where the intégrale de Lebesgue earns its place. Two theorems give conditions under which a limit may be taken inside an integral, and a lemma sits between them providing an inequality that always holds.

Theorem (Convergence monotone). *Soit f une fonction mesurable et $(f_n)_{n \geq 1}$ une suite croissante de fonctions mesurables positives qui converge p.p. vers f . Alors :*

$$\lim_n \int f_n d\mu = \int f d\mu.$$

Proof. Soit $A = \{\lim_n f_n = f\}$ l'ensemble des points où il y a convergence. Its complement is négligeable, so by the lemme de convergence monotone applied to the sequence $(f_n \mathbb{1}_A)$, which increases to $f \mathbb{1}_A$ everywhere,

$$\lim_n \int f_n d\mu = \lim_n \int f_n \mathbb{1}_A d\mu = \int f \mathbb{1}_A d\mu = \int f d\mu,$$

the first and last equalities being the theorem on ensembles négligeables just proved.

Remark (The theorem is the lemma, plus p.p.). The only thing added to the lemma is the tolerance of a négligeable exceptional set, and the proof is the restriction to A that the non-circularity remark above anticipated. It is the form one actually applies, because hypotheses in practice hold only p.p.

Le théorème de convergence dominée repose sur le résultat suivant.

Lemma (Lemme de Fatou (*Fatou's lemma*)). *Pour toute suite $(f_n)_{n \geq 1}$ de fonctions mesurables positives,*

$$\int \liminf_n f_n d\mu \leq \liminf_n \int f_n d\mu.$$

Proof. The sequence $(\inf_{k \geq n} f_k)_{n \geq 1}$ is increasing and positive with limit $\liminf_n f_n$, so par convergence monotone, $\int \liminf_n f_n d\mu = \lim_n \int \inf_{k \geq n} f_k d\mu$. Comme $\inf_{k \geq n} f_k \leq f_k$ pour tout $k \geq n$, monotonicity gives $\int \inf_{k \geq n} f_k d\mu \leq \inf_{k \geq n} \int f_k d\mu$, et par passage à la limite, $\int \liminf_n f_n d\mu \leq \liminf_n \int f_n d\mu$.

Remark (Fatou gives an inequality and nothing more). Le lemme de Fatou fournit uniquement une inégalité, which can be strict. Appliqué aux fonctions $f_n = \mathbb{1}_{[n, +\infty[}$, against the mesure de Lebesgue, on a $\liminf_n f_n = 0$, si bien que

$$\int \liminf_n f_n d\lambda = 0, \quad \text{while} \quad \liminf_n \int f_n d\lambda = +\infty.$$

Mass escaping to infinity is lost in the limit but not in the integrals, and the inequality records exactly that loss.

Theorem (Convergence dominée (*dominated convergence*)). *Soit f une fonction mesurable et $(f_n)_{n \geq 1}$ une suite de fonctions mesurables qui converge p.p. vers f . S'il existe une fonction intégrable g telle que $|f_n| \leq g$ pour tout $n \geq 1$, alors la fonction f est intégrable et*

$$\lim_n \int f_n d\mu = \int f d\mu.$$

Proof. Le lemme de Fatou, applied to $(|f_n|)$, implique que

$$\int |f| d\mu = \int \liminf_n |f_n| d\mu \leq \liminf_n \int |f_n| d\mu \leq \int g d\mu < \infty,$$

de sorte que la fonction f est intégrable. Les fonctions $g - f_n$ et $g + f_n$ étant mesurables positives pour tout n , le lemme de Fatou, applied to each of the two sequences, implique également que :

$$\begin{aligned} \int g d\mu - \int f d\mu &= \int (g - f) d\mu \leq \liminf_n \int (g - f_n) d\mu = \int g d\mu - \limsup_n \int f_n d\mu, \\ \int g d\mu + \int f d\mu &= \int (g + f) d\mu \leq \liminf_n \int (g + f_n) d\mu = \int g d\mu + \liminf_n \int f_n d\mu. \end{aligned}$$

Since $\int g d\mu$ is finite it can be cancelled from both lines, and on tire de ces inégalités que

$$\int f d\mu \leq \liminf_n \int f_n d\mu \leq \limsup_n \int f_n d\mu \leq \int f d\mu,$$


d'où l'on conclut que la suite $\int f_n d\mu$ converge vers $\int f d\mu$.

Remark (Where the domination is spent). The function g is used three times: to make f integrable, to make $g - f_n$ and $g + f_n$ positive so that Fatou applies, and — decisively — to allow $\int g d\mu$ to be cancelled from both sides. That cancellation is illegal if $\int g d\mu = +\infty$, which is why the hypothesis is not that some function dominates the sequence but that an *integrable* one does, and one that works for every n simultaneously.

Example (Domination cannot be dropped). Let $f_n = n \mathbb{1}_{]0, 1/n[}$ on $\mathbb{R}$ with the measure de Lebesgue. For every x , $f_n(x) \rightarrow 0$: a fixed $x > 0$ leaves the interval as soon as $n > 1/x$, and $f_n(x) = 0$ for $x \leq 0$ throughout. Yet

$$\int f_n d\lambda = n \cdot \frac{1}{n} = 1 \quad \text{for every } n, \quad \text{while} \quad \int \lim_n f_n d\lambda = 0.$$

The limit and the integral cannot be exchanged. Any function dominating the whole sequence is at least the pointwise supremum $\sup_n f_n$, the staircase equal to k on $] \frac{1}{k+1}, \frac{1}{k} [$; it therefore exceeds $x \mapsto 1/x - 1$ on $]0, 1[$, whose integral diverges. No integrable dominating function exists — exactly as the theorem requires. Note that Fatou's inequality is satisfied, $0 \leq 1$, as it must be.



The picture is the whole counter-example: a rectangle of area 1 that becomes taller and narrower without ever losing mass, while at every fixed x it eventually disappears. Mass escapes upwards here, as it escaped sideways in the Fatou remark, and an integrable dominating function is precisely a ceiling that forbids both.

3.6 Lien avec l'intégrale de Riemann

Nous montrons ici que l'intégrale de Lebesgue généralise l'intégrale de Riemann. On se donne un intervalle $[a, b]$ de $\mathbb{R}$ avec $a < b$.

Definition (Fonction en escalier (*step function*)). Une fonction $f : [a, b] \rightarrow \mathbb{R}$ est dite **en escalier** s'il existe une subdivision $a = x_0 < x_1 < \dots < x_n = b$ de l'intervalle $[a, b]$ telle que f est constante sur chaque intervalle $]x_0, x_1[, \dots,]x_{n-1}, x_n[$.

L'intégrale de Riemann d'une fonction en escalier f est définie par :

$$\int_a^b f(x) dx = \sum_{i=0}^{n-1} \alpha_i (x_{i+1} - x_i),$$

où $\alpha_0, \dots, \alpha_{n-1}$ sont les valeurs prises par f sur les intervalles respectifs $]x_0, x_1[, \dots,]x_{n-1}, x_n[$. La fonction f étant étagée in the sense of this chapter, on vérifie aisément que c'est également l'intégrale de Lebesgue par rapport à la mesure de Lebesgue :

$$\int_{[a,b]} f d\lambda = \sum_{i=0}^{n-1} \alpha_i \lambda([x_i, x_{i+1}[) = \int_a^b f(x) dx.$$

A fonction en escalier is the elementary brick of the Riemann theory exactly as a fonction étagée is of the Lebesgue theory; the difference is that a fonction en escalier is constant on *intervals* while a fonction étagée is constant on arbitrary mesurable sets, and that single relaxation is the whole gap between the two theories.

Definition (Intégrale de Riemann (*Riemann integral*)). Une fonction bornée $f : [a, b] \rightarrow \mathbb{R}$ est **intégrable au sens de Riemann** (*Riemann-integrable*) si :

$$\sup \left\{ \int_a^b g(x) dx : g \leq f, g \text{ a step function} \right\} = \inf \left\{ \int_a^b h(x) dx : f \leq h, h \text{ a step function} \right\},$$

cette valeur étant son intégrale, notée $\int_a^b f(x) dx$.

Theorem (Intégrable au sens de Riemann implique intégrable au sens de Lebesgue). *Une fonction $f : [a, b] \rightarrow \mathbb{R}$ intégrable au sens de Riemann a une intégrale par rapport à la mesure de Lebesgue et les deux intégrales coïncident :*

$$\int_a^b f(x) dx = \int_{[a,b]} f d\lambda.$$

Proof. Soit $(g_n)_{n \geq 1}$ une suite croissante de fonctions en escalier telle que $g_n \leq f$ pour tout n et :

$$\lim_n \int_a^b g_n(x) dx = \int_a^b f(x) dx,$$

et de même, soit $(h_n)_{n \geq 1}$ une suite décroissante de fonctions en escalier telle que $h_n \geq f$ pour tout n et :

$$\lim_n \int_a^b h_n(x) dx = \int_a^b f(x) dx;$$

both exist by the definition of a fonction intégrable au sens de Riemann, replacing a maximising sequence by the running maximum of its terms in the first case and the running minimum in the second. Les limites respectives g et h de ces suites sont mesurables et bornées, f being bounded, de sorte que, par convergence dominée — the constant bound being integrable on the bounded interval $[a, b]$ — both limits of intégrales de Riemann are intégrales de Lebesgue. On a donc :

$$\int_{[a,b]} g d\lambda = \int_a^b f(x) dx = \int_{[a,b]} h d\lambda.$$

Comme $g \leq f \leq h$, the equality case in the theorem on ensembles négligeables gives $g = h$ p.p., et donc $g = f = h$ p.p., ce qui implique $\int_a^b f(x) dx = \int_{[a,b]} f d\lambda$.

Remark (Which tribu the Riemann theory really uses). Le théorème suggère que toute fonction intégrable au sens de Riemann est mesurable pour la tribu de Borel. Ce n'est pas le cas. Elle est mesurable par rapport à la **tribu de Lebesgue** (*Lebesgue σ -algebra*), définie comme la tribu de Borel complétée de tous les ensembles négligeables pour la mesure de Lebesgue (ensembles mesurables négligeables et leurs sous-ensembles). Ce détail technique ne change rien en pratique, l'intégrale de Lebesgue étant définie de la même manière sur la tribu complétée; what the proof above shows is that f agrees p.p. with the Borel function g .

Il reste à étendre le résultat aux intégrales impropres. Soit $a, b \in \overline{\mathbb{R}}$. Pour toute fonction f localement intégrable au sens de Riemann sur $]a, b[$ (c'est-à-dire dont l'intégrale de Riemann est définie sur tout compact de $]a, b[$), on définit l'intégrale de Riemann comme la limite lorsqu'elle existe des intégrales

$$\int_{a_n}^{b_n} f(x) dx$$

pour toutes suites $(a_n)_{n \geq 1}$ et $(b_n)_{n \geq 1}$ respectivement strictement décroissante et strictement croissante, de limites a et b . On note toujours cette intégrale $\int_a^b f(x) dx$.

Theorem (Intégrale de Riemann impropre d'une fonction intégrable). *Soit $a, b \in \overline{\mathbb{R}}$ et f une fonction localement intégrable au sens de Riemann sur $]a, b[$, avec*

$$\int_a^b |f(x)| dx < \infty.$$

Alors :

$$\int_a^b f(x) dx = \int_{[a,b]} f d\lambda.$$

Proof. Soit (a_n) et (b_n) des suites as above. Par le théorème précédent, $\int_{a_n}^{b_n} |f(x)| dx = \int_{[a_n, b_n]} |f| d\lambda$ pour tout n . The functions $|f| \mathbb{1}_{[a_n, b_n]}$ increase to $|f| \mathbb{1}_{[a, b]}$, so par convergence monotone,

$$\int_{[a,b]} |f| d\lambda = \lim_n \int_{a_n}^{b_n} |f(x)| dx = \int_a^b |f(x)| dx < \infty,$$

which says that f is Lebesgue-integrable on $[a, b]$. The functions $f \mathbb{1}_{[a_n, b_n]}$ are then dominated by the integrable $|f| \mathbb{1}_{[a, b]}$ and converge pointwise to $f \mathbb{1}_{[a, b]}$, so par convergence dominée, on en déduit que $\int_a^b f(x) dx = \int_{[a,b]} f d\lambda$.

Remark (The hypothesis is absolute integrability, and it is the point). Le théorème exige que la fonction soit intégrable, that is $\int_a^b |f(x)| dx < \infty$, and not merely that it have a convergent improper integral. Ainsi l'intégrale impropre

$$\int_{-\infty}^{+\infty} \frac{\sin x}{x} dx$$

est définie au sens de Riemann — the positive and negative humps cancel in the limit, and the value is π — mais pas au sens de Lebesgue, since $\int |\sin x/x| dx = +\infty$ and the Lebesgue definition subtracts two infinite parts. This is the one place where the Riemann theory reaches something the Lebesgue theory does not, and the reason is structural: the intégrale de Lebesgue is absolute by construction, since it is built from f^+ and f^- separately, while an intégrale de Riemann impropre is a limit of symmetric truncations and can exploit cancellation.

Remark (The converse fails in the other direction too). Not every Lebesgue-integrable function is intégrable au sens de Riemann. The function $\mathbb{1}_{\mathbb{Q}}$ on $[0, 1]$ has intégrale de Lebesgue 0, while every fonction en escalier below it is ≤ 0 and every fonction en escalier above it is ≥ 1 on each subinterval, so the lower Riemann sums are ≤ 0 , the upper ones ≥ 1 , and the two do not meet. Taken with the previous remark, the picture is: the two classes of functions overlap but neither contains the other, and where they overlap the two integrals agree.

Comme l'intégrale de Riemann correspond à une intégrale par rapport à la mesure de Lebesgue, on utilisera les notations

$$\int_a^b f(x) dx \quad \text{and} \quad \int_{[a,b]} f d\lambda$$

indifféremment. Les résultats classiques de l'intégrale comme le théorème fondamental de l'analyse ou l'intégration par parties s'appliquent à l'intégrale de Lebesgue, par rapport à la mesure de Lebesgue. Tous ces résultats s'étendent aux fonctions de n variables, sur l'ensemble $\mathbb{R}^n$ muni de la tribu de Borel.

3.7 Mesures discrètes

The integral has been defined against an arbitrary mesure. It is time to see what it becomes for the two mesures the previous chapter singled out. Against the mesure de Lebesgue it is the classical integral, as the preceding subsection showed. Nous allons maintenant caractériser l'intégrale de Lebesgue par rapport à une mesure discrète: it is a sum — which is what makes chapter 1, where probabilities were sums over a countable set, a special case of the theory being built here rather than a separate subject. The bridge is the following pair of results.

Proposition (Mesure somme). Soit $(\mu_i)_{i \in I}$ une famille de mesures sur $(\Omega, \mathcal{F})$. L'intégrale d'une fonction mesurable $f : \Omega \rightarrow \mathbb{R}$ par rapport à la **mesure somme** (sum measure) $\mu = \sum_{i \in I} \mu_i$ est donnée par

$$\int f d\mu = \sum_{i \in I} \int f d\mu_i,$$

si cette intégrale est bien définie, c'est-à-dire si :

$$\sum_{i \in I} \int f^+ d\mu_i < \infty \quad \text{or} \quad \sum_{i \in I} \int f^- d\mu_i < \infty.$$

Proof. By the three-stage method. Si $f = \sum_{j=1}^n \alpha_j \mathbb{1}_{A_j}$ est une fonction étagée positive, alors

$$\int f d\mu = \sum_{j=1}^n \alpha_j \sum_{i \in I} \mu_i(A_j) = \sum_{i \in I} \sum_{j=1}^n \alpha_j \mu_i(A_j) = \sum_{i \in I} \int f d\mu_i,$$

the interchange of the two sums being legitimate because all the terms are positive. The second stage applies the lemme de convergence monotone once to μ and once to each μ_i , the interchange of the limit and the sum over I being again a matter of positive terms.

L'archétype des mesures discrètes est la mesure de Dirac.

Proposition (Mesure de Dirac). Soit δ_a la mesure de Dirac en $a \in \Omega$. Toute fonction mesurable $f : \Omega \rightarrow \overline{\mathbb{R}}$ a pour intégrale :

$$\int f d\delta_a = f(a).$$

Proof. By the three-stage method. Si $f = \sum_{i=1}^n \alpha_i \mathbb{1}_{A_i}$ est une fonction étagée positive, alors $\int f d\delta_a = \sum_i \alpha_i \mathbb{1}_{A_i}(a) = f(a)$; the second stage gives $\lim_n f_n(a) = f(a)$, and the third $f^+(a) - f^-(a) = f(a)$.

On montre de la même manière que pour toute mesure $\mu = \alpha \delta_a$ avec $\alpha > 0$ et $a \in \Omega$, $\int f d\mu = \alpha f(a)$. Combining this with the mesure somme, on obtient l'intégrale d'une fonction mesurable par rapport à toute mesure discrète

$$\mu = \sum_{i \in I} \alpha_i \delta_{a_i},$$

où I est un ensemble au plus dénombrable et $\alpha_i > 0$, $a_i \in \Omega$ pour tout $i \in I$.

Theorem (L'intégrale par rapport à une mesure discrète est une somme). Toute fonction mesurable $f : \Omega \rightarrow \overline{\mathbb{R}}$ a pour intégrale :

$$\int f d\mu = \sum_{i \in I} \alpha_i f(a_i)$$

dès que

$$\sum_{i \in I} \alpha_i f^+(a_i) < \infty \quad \text{or} \quad \sum_{i \in I} \alpha_i f^-(a_i) < \infty.$$

Remark (The bridge back to the discrete chapter). This is the statement that makes the general theory contain the discrete one. A discrete probability on a countable Ω is $\mathbb{P} = \sum_{\omega \in \Omega} p(\omega) \delta_\omega$, and the theorem reads $\int f d\mathbb{P} = \sum_{\omega} p(\omega) f(\omega)$: every espérance computed in chapter 1 as a weighted sum is an intégrale de Lebesgue, and every theorem proved below for the intégrale de Lebesgue applies verbatim to those sums. In particular the countable additivity corollary above is the interchange of two sums, and convergence dominée is the interchange of a limit and a series.

Example (The mesure de comptage turns the integral into a series). Soit $\mu = \sum_{n \in \mathbb{N}} \delta_n$ la mesure de comptage de $\mathbb{N}$. L'intégrale d'une fonction mesurable $f : \mathbb{R} \rightarrow \overline{\mathbb{R}}$ est la série

$$\int f d\mu = \sum_{n=0}^{+\infty} f(n)$$

dès que $\sum_{n=0}^{+\infty} f^+(n) < \infty$ ou $\sum_{n=0}^{+\infty} f^-(n) < \infty$. For $f(x) = e^{-x}$ this gives

$$\int e^{-x} d\mu(x) = \sum_{n \geq 0} e^{-n} = \frac{1}{1 - e^{-1}} = \frac{e}{e - 1}.$$

Example (A measure with a discrete part and a continuous part). Let $\mu = \delta_0 + \lambda$ on $\mathbb{R}$. By the proposition on the measure somme,

$$\int_{\mathbb{R}_+} e^{-x} d\mu(x) = \int_{\mathbb{R}_+} e^{-x} d\delta_0(x) + \int_{\mathbb{R}_+} e^{-x} d\lambda(x) = 1 + \int_0^{+\infty} e^{-x} dx = 2.$$

Nothing in the theory forbids mixing an atom and a continuous part, and lois of this kind appear as soon as a variable aléatoire is truncated.

3.8 Mesures à densité

Integration produces new mesures. This subsection says which ones, and when every measure of a given kind arises this way.

Theorem (L'intégrale d'une fonction positive définit une mesure). *Soit ν une mesure sur $(\Omega, \mathcal{F})$ et f une fonction mesurable positive.*

1. La fonction $\mu : \mathcal{F} \rightarrow [0, +\infty]$ définie par

$$\forall A \in \mathcal{F}, \quad \mu(A) = \int_A f d\nu$$

est une mesure sur $(\Omega, \mathcal{F})$.

2. Supposons la mesure ν σ -finie. S'il existe une autre fonction mesurable positive g telle que $\mu(A) = \int_A g d\nu$ pour tout $A \in \mathcal{F}$, alors $f = g$ ν -p.p.

Proof. 1. On vérifie que $\mu(\emptyset) = 0$ et que pour toute famille au plus dénombrable $(A_i)_{i \in I}$ d'éléments deux-à-deux disjoints, $\mu(\bigcup_i A_i) = \int f \sum_i \mathbb{1}_{A_i} d\nu = \sum_i \int f \mathbb{1}_{A_i} d\nu = \sum_i \mu(A_i)$, the middle equality being the countable additivity corollary, applicable because the functions $f \mathbb{1}_{A_i}$ are positive.

2. Puisque la mesure ν est σ -finie, il existe une suite $(A_n)_{n \geq 1}$ d'éléments de $\mathcal{F}$ telle que $A_n \uparrow \Omega$ et $\nu(A_n) < \infty$ pour tout n . Soit $B_n = \{g + \frac{1}{n} \leq f \leq n\}$. On a

$$\int_{A_n \cap B_n} g d\nu = \int_{A_n \cap B_n} f d\nu \leq n\nu(A_n \cap B_n) \leq n\nu(A_n) < \infty,$$

so both integrals are finite and may be subtracted, ce qui implique :

$$\int_{A_n \cap B_n} (f - g) d\nu = 0.$$

Par ailleurs, $f - g \geq \frac{1}{n}$ on B_n , so

$$\int_{A_n \cap B_n} (f - g) d\nu \geq \frac{1}{n} \nu(A_n \cap B_n),$$

ce qui implique $\nu(A_n \cap B_n) = 0$. Comme $A_n \cap B_n \uparrow \{f > g\}$, continuity from below gives that l'ensemble $\{f > g\}$ est négligeable pour ν , ce qui veut dire que $f \leq g$ ν -p.p. Par symétrie, l'inégalité inverse est vraie ν -p.p., so $f = g$ ν -p.p.

Remark (σ -finiteness is what makes the densité unique). The truncation $\{g + \frac{1}{n} \leq f \leq n\}$ intersected with A_n exists only to make an integral finite so that a subtraction is legal, and the sets A_n come from σ -finiteness. Without it uniqueness fails: on $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ with ν the measure assigning 0 to $\emptyset$ and $+\infty$ to every non-empty set, the constant functions 1 and 2 define the same μ and differ everywhere. L'énoncé du théorème implique deux mesures, so one must also say *which* measure the p.p. refers to, and here it is ν .

Definition (Mesure à densité). Soit μ et ν deux mesures sur $(\Omega, \mathcal{F})$. On dit que μ admet une densité par rapport à ν s'il existe une fonction mesurable $f : \Omega \rightarrow \mathbb{R}_+$ telle que :

$$\forall A \in \mathcal{F}, \quad \mu(A) = \int_A f d\nu.$$

La fonction f est appelée **densité** (*density*) de μ par rapport à ν .

Toute densité est définie à un ensemble négligeable près, au sens où deux mesures de densités égales presque partout sont égales, which is the theorem on ensembles négligeables. La réciproque est vraie dès que la mesure ν est σ -finie, by the uniqueness statement just proved. Le fait que

$$\forall A \in \mathcal{F}, \quad \mu(A) = \int_A d\mu = \int_A f d\nu$$

explique la notation symbolique usuelle

$$d\mu = f d\nu, \quad \text{equivalently} \quad f = \frac{d\mu}{d\nu},$$

signifiant que μ a pour densité f par rapport à ν .

Example (A densité against the mesure de Lebesgue). Soit la fonction définie sur $\mathbb{R}$ par $f(x) = \frac{1}{1+x^2}$. La mesure μ de densité f par rapport à la mesure de Lebesgue est définie par :

$$\forall A \in \mathcal{B}(\mathbb{R}), \quad \mu(A) = \int_A \frac{dx}{1+x^2},$$

ce qui se note $d\mu = \frac{dx}{1+x^2}$. Dividing it by π gives the **loi de Cauchy** (*Cauchy distribution*).

Remark (Densités against a discrete mesure). La notion de densité s'applique aux mesures discrètes; there is nothing continuous about it. Ainsi la mesure de Dirac δ_0 a pour densité la fonction $\mathbb{1}_{\{0\}}$ par rapport à la mesure de comptage $\mu = \sum_{n \geq 0} \delta_n$, since

$$\forall A \in \mathcal{B}(\mathbb{R}), \quad \delta_0(A) = \mathbb{1}_A(0) = \int_A \mathbb{1}_{\{0\}} d\mu.$$

The weights of a discrete loi are a densité just as the densité of a continuous loi is.

By the proposition on ensembles négligeables, tout ensemble négligeable pour la mesure ν est également négligeable pour la mesure μ whenever μ has a densité with respect to ν . That property has a name.

Definition (Absolue continuité). Soit μ et ν deux mesures sur $(\Omega, \mathcal{F})$. On dit que μ est **absolument continue** (*absolutely continuous*) par rapport à ν , ce que l'on note $\mu \ll \nu$, si

$$\forall A \in \mathcal{F}, \quad \nu(A) = 0 \implies \mu(A) = 0.$$

Une mesure ayant une densité par rapport à ν est absolument continue par rapport à ν ; le **théorème de Radon-Nikodym** (*Radon-Nikodym theorem*) fournit une réciproque. La preuve est omise.

Theorem (Théorème de Radon-Nikodym). Soit μ et ν deux mesures σ -finies telles que $\mu \ll \nu$. Alors μ admet une densité par rapport à ν .

Remark (Both mesures must be σ -finite). With ν the mesure de comptage on $\mathbb{R}$, which is not σ -finie, and $\mu = \lambda$, one has $\mu \ll \nu$ — only the empty set is ν -négligeable — yet λ has no densité with respect to ν , since such a densité would vanish at every point and give $\lambda(A) = 0$ for every A . Chapter 4 invokes this theorem to say that a real variable aléatoire has a densité exactly when its loi is absolument continue with respect to λ , and chapter 5 again to build densités conditionnelles; both times the σ -finiteness is available and unremarked. L'intégrale d'une fonction par rapport à une mesure à densité s'écrit de façon très naturelle, grâce à l'écriture symbolique.

Theorem (Intégrale par rapport à une mesure à densité). Soit μ une mesure de densité f par rapport à ν . Pour toute fonction mesurable $g : \Omega \rightarrow \overline{\mathbb{R}}$,

$$\int g d\mu = \int gf d\nu$$

dès que l'une de ces intégrales est bien définie.

Proof. By the three-stage method. Supposons tout d'abord la fonction $g = \sum_{i=1}^n \alpha_i \mathbb{1}_{A_i}$ étagée positive. Alors

$$\int g d\mu = \sum_{i=1}^n \alpha_i \mu(A_i) = \sum_{i=1}^n \alpha_i \int \mathbb{1}_{A_i} f d\nu = \int gf d\nu.$$

The second stage needs the lemme de convergence monotone twice, once for (g_n) increasing to g and once for $(g_n f)$ increasing to gf .

Example (Integrating against a mesure with a densité). L'intégrale de la fonction $\mathbb{1}_{\mathbb{R}_+}$ par rapport à la mesure μ de densité $x \mapsto \frac{1}{1+x^2}$ par rapport à la mesure de Lebesgue est donnée par :

$$\int \mathbb{1}_{\mathbb{R}_+} d\mu = \int_0^{+\infty} \frac{dx}{1+x^2} = \frac{\pi}{2}.$$


Example (An exponential weighting). Soit μ la mesure de densité $x \mapsto e^{-x}$ par rapport à la mesure de Lebesgue. Then

$$\int_{\mathbb{R}_+} e^{x/2} d\mu(x) = \int_0^{+\infty} e^{x/2} e^{-x} dx = \int_0^{+\infty} e^{-x/2} dx = 2.$$

The densité is absorbed into the integrand; this is the only computation rule there is for such mesures.

3.9 Théorème de transfert

Soit μ une mesure sur $(\Omega, \mathcal{F})$. Soit $(E, \mathcal{E})$ un espace mesurable. Toute fonction mesurable $\phi : \Omega \rightarrow E$ définit une mesure sur $(E, \mathcal{E})$, appelée la mesure image de μ par ϕ et notée μ_ϕ , defined in the previous chapter by $\mu_\phi(B) = \mu(\phi^{-1}(B))$. On s'intéresse à l'intégrale de la fonction $f \circ \phi$ par rapport à la mesure μ pour une fonction mesurable $f : E \rightarrow \overline{\mathbb{R}}$.



Theorem (Transfert). Soit $f : E \rightarrow \overline{\mathbb{R}}$ une fonction mesurable. On a :

$$\int f \circ \phi d\mu = \int f d\mu_\phi$$

dès que l'une de ces deux intégrales est définie.

Proof. Supposons la fonction f étagée positive, soit :

$$f = \sum_{i=1}^n \alpha_i \mathbb{1}_{B_i},$$

où $\alpha_1, \dots, \alpha_n$ sont les valeurs prises par f . La fonction $f \circ \phi$ est elle-même étagée :

$$f \circ \phi = \sum_{i=1}^n \alpha_i \mathbb{1}_{A_i}, \quad A_i = \phi^{-1}(B_i),$$

because $\mathbb{1}_{B_i} \circ \phi = \mathbb{1}_{\phi^{-1}(B_i)}$. On obtient :

$$\int f \circ \phi d\mu = \sum_{i=1}^n \alpha_i \mu(A_i) = \sum_{i=1}^n \alpha_i \mu_\phi(B_i) = \int f d\mu_\phi,$$

the middle equality being nothing but the definition of the mesure image. Si la fonction f est mesurable positive, on choisit une suite croissante de fonctions étagées positives (f_n) qui tend vers f . La suite $(f_n \circ \phi)$ étant une suite croissante de fonctions étagées positives qui tend vers $f \circ \phi$, the lemme de convergence monotone applied on each side gives

$$\int f \circ \phi d\mu = \lim_n \uparrow \int f_n \circ \phi d\mu = \lim_n \uparrow \int f_n d\mu_\phi = \int f d\mu_\phi.$$

Enfin, si la fonction f est mesurable (of arbitrary sign), on a $(f \circ \phi)^+ = f^+ \circ \phi$ et $(f \circ \phi)^- = f^- \circ \phi$, so by the positive case

$$\int (f \circ \phi)^+ d\mu = \int f^+ d\mu_\phi \quad \text{and} \quad \int (f \circ \phi)^- d\mu = \int f^- d\mu_\phi,$$

ce qui montre l'égalité dès que l'une de ces intégrales est bien définie.

Remark (The theorem the rest of the course runs on). Read with Ω an espace de probabilité, ϕ a variable aléatoire X and μ_ϕ its loi $\mathbb{P}_X$, the identity becomes

$$\mathbb{E}(f(X)) = \int f d\mathbb{P}_X.$$

The left-hand side is an integral over an abstract space nobody ever describes; the right-hand side is an integral over the value space against an object one can write down. That is why the loi is all one ever needs to know about a variable aléatoire, and it is why this theorem is used, usually silently, in every computation of chapters 4 to 8: to compute an espérance from a loi, to define the fonction caractéristique, to identify a loi by testing it against bounded continuous functions, and to read an espérance conditionnelle as an integral against a loi conditionnelle.

3.10 Changement de variable

Le théorème de transfert permet de changer de variable d'intégration. Considérons par exemple une fonction $f : \mathbb{R} \rightarrow \overline{\mathbb{R}}$ mesurable. On souhaite intégrer la fonction $x \mapsto f(ax + b)$ par rapport à la mesure de Lebesgue, avec $a \neq 0$. La mesure image de la mesure de Lebesgue par la fonction affine $\phi : x \mapsto ax + b$ étant la mesure $\frac{\lambda}{|a|}$, le théorème de transfert s'écrit :

$$\int f(ax + b) dx = \int f(y) \frac{dy}{|a|}$$

dès que l'une de ces deux intégrales est définie. On a ainsi procédé au **changement de variable** (*change of variable*) de x vers $y = ax + b$. L'écriture symbolique de ce changement de variable est :

$$dy = |a| dx \quad \text{or} \quad dx = \frac{dy}{|a|},$$

ce qui revient à dire que la mesure image de λ par ϕ est $\frac{\lambda}{|a|}$. On note la présence de la valeur absolue, une mesure étant une application à valeurs positives: the factor relating two mesures cannot be negative.

Le résultat se généralise à tout difféomorphisme ϕ . Nous allons voir que la mesure image de la mesure de Lebesgue est alors une mesure à densité.

Definition (Difféomorphisme). On appelle **difféomorphisme** une fonction de classe C^1 bijective, dont la réciproque ϕ^{-1} est elle-même de classe C^1 .

On remarque qu'un difféomorphisme est une fonction mesurable (car continue).

Proposition (Changement de variable sur $\mathbb{R}$). Soit $\phi : \mathbb{R} \rightarrow \mathbb{R}$ un difféomorphisme. Pour toute fonction mesurable $f : \mathbb{R} \rightarrow \overline{\mathbb{R}}$, on a :

$$\int f \circ \phi(x) dx = \int f(y) \frac{dy}{|\phi'(\phi^{-1}(y))|}$$

dès que l'une de ces deux intégrales est définie.

Proof. La mesure image de la mesure de Lebesgue par ϕ vérifie :

$$\begin{aligned} \lambda_\phi([a, b]) &= \lambda(\phi^{-1}([a, b])) \\ &= |\phi^{-1}(b) - \phi^{-1}(a)| \\ &= \int_a^b |(\phi^{-1})'(y)| dy = \int_a^b \frac{dy}{|\phi'(\phi^{-1}(y))|}, \end{aligned}$$

où l'on a utilisé le fait que ϕ^{-1} est de classe C^1 et monotone — so that $\phi^{-1}([a, b])$ is the interval with endpoints $\phi^{-1}(a)$ and $\phi^{-1}(b)$ — and then the fundamental theorem of analysis. On en déduit que λ_ϕ est la mesure de densité

$$y \mapsto \frac{1}{|\phi'(\phi^{-1}(y))|}$$

par rapport à la mesure de Lebesgue, these two mesures agreeing on the intervals, which generate $\mathcal{B}(\mathbb{R})$ and are stable par intersection finie. Le résultat est une conséquence du théorème de transfert, together with the theorem on integration against a mesure à densité.

L'écriture symbolique du changement de variable $y = \phi(x)$ est :

$$dy = |\phi'(x)| dx \quad \text{or} \quad dx = \frac{dy}{|\phi'(\phi^{-1}(y))|}.$$

Comme dans le cas affine, il faut veiller à ne pas oublier la valeur absolue, toute densité étant une fonction positive.

Remark (The derivative cannot vanish). La dérivée de la fonction ϕ ne s'annule pas car ϕ est un difféomorphisme — differentiating $\phi^{-1} \circ \phi = \text{id}$ gives $(\phi^{-1})'(\phi(x))\phi'(x) = 1$. C'est d'ailleurs une condition nécessaire et suffisante pour qu'une fonction bijective de classe C^1 soit un difféomorphisme (théorème d'inversion globale).

Le résultat s'étend à tout difféomorphisme $\phi : U \rightarrow V$ avec U et V ouverts de $\mathbb{R}$, which is what licenses cutting the line into pieces when a map fails to be a diffeomorphism at isolated points.

Example (A bijection that is not a diffeomorphism). Soit la fonction définie sur $\mathbb{R}$ par $\phi(x) = x^3$. It is a C^1 bijection, but cette fonction n'est pas un difféomorphisme puisque sa dérivée s'annule en 0 — equivalently, $\phi^{-1}(y) = y^{1/3}$ is not differentiable at 0. Pour changer de variable, il faut donc exclure le point 0 et appliquer deux changements de variable successifs, sur les ouverts $] -\infty, 0[$ et $]0, +\infty[$. Excluding a single point costs nothing, since it is négligeable for the mesure de Lebesgue.

Ces résultats s'étendent à des fonctions de n variables. Il faut pour cela introduire la notion de matrice jacobienne.

Definition (Matrice jacobienne). La **matrice jacobienne** (*Jacobian matrix*) d'une fonction dérivable $\phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ est la matrice des dérivées partielles :

$$\forall x \in \mathbb{R}^n, \quad J_\phi(x) = \left(\frac{\partial \phi_i}{\partial x_j}(x) \right)_{1 \leq i, j \leq n}.$$

Le déterminant de la matrice jacobienne s'appelle le jacobien. Pour tout difféomorphisme ϕ , la fonction $\phi \circ \phi^{-1}$ est la fonction identité, de sorte que :

$$J_{\phi^{-1}} \times J_{\phi} \circ \phi^{-1} = I \quad \text{and} \quad \det J_{\phi^{-1}} = \frac{1}{(\det J_{\phi}) \circ \phi^{-1}}.$$

Comme dans le cas des fonctions réelles, une fonction bijective de classe C^1 est un difféomorphisme si et seulement si son jacobien ne s'annule pas.

Theorem (Changement de variable). *Soit $\phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ un difféomorphisme. Pour toute fonction mesurable $f : \mathbb{R}^n \rightarrow \mathbb{R}$, on a :*


$$\int f \circ \phi(x) dx = \int \frac{f(y)}{|(\det J_{\phi}) \circ \phi^{-1}(y)|} dy$$

dès que l'une de ces deux intégrales est définie.

Proof. On donne une preuve partielle, dans le cas où ϕ est une application affine bijective, soit $\phi(x) = Ax + b$ avec A matrice inversible. Le cas général se traite par une approximation locale affine de ϕ . La mesure image de la mesure de Lebesgue λ par ϕ est $\frac{\lambda}{|\det A|}$, a computation carried out in the previous chapter for the affine maps of $\mathbb{R}^n$. Comme $J_{\phi} = A$, which is constant, on obtient :

$$\lambda_{\phi} = \frac{\lambda}{|\det J_{\phi}|},$$

and le résultat est une conséquence du théorème de transfert, together with integration against a mesure à densité.



a small cell of area dx is carried to a cell of area $dy = |\det J_{\phi}(x)| dx$; the Jacobian is the local area factor, and its absolute value is what keeps the factor positive

The picture is the content of the theorem. A diffeomorphism deforms a small cell into a small parallelogram whose area is $|\det J_{\phi}(x)|$ times the original, since ϕ is locally its own derivative; summing over cells turns that local factor into the densité relating the two mesures. Le résultat s'étend à tout difféomorphisme $\phi : U \rightarrow V$ between open sets of $\mathbb{R}^n$, which is the form used in practice — polar coordinates, for instance, are a diffeomorphism from $]0, +\infty[\times]0, 2\pi[$ onto the plane minus a half-line, and the missing half-line is négligeable.

Example (Polar coordinates and the Gaussian integral). Let $\phi(r, \theta) = (r \cos \theta, r \sin \theta)$, a diffeomorphism from $]0, +\infty[\times]0, 2\pi[$ onto $\mathbb{R}^2$ minus a half-line, with $\det J_{\phi}(r, \theta) = r$. For $f(x, y) = e^{-(x^2+y^2)}$,

$$\int_{\mathbb{R}^2} e^{-(x^2+y^2)} dx dy = \int_0^{2\pi} \int_0^{+\infty} e^{-r^2} r dr d\theta = 2\pi \cdot \frac{1}{2} = \pi.$$

The left-hand side is the square of $\int_{-\infty}^{+\infty} e^{-x^2} dx$ by Fubini for positive functions, so that integral equals $\sqrt{\pi}$ — the normalisation behind every densité gaussienne in these notes.

Example (The volume of an ellipsoid). Soit $a, b, c > 0$ et

$$E = \left\{ (x, y, z) \in \mathbb{R}^3 : \frac{x^2}{a^2} + \frac{y^2}{b^2} + \frac{z^2}{c^2} \leq 1 \right\}.$$

The linear map $\phi(u, v, w) = (au, bv, cw)$ is a diffeomorphism of $\mathbb{R}^3$ carrying the unit ball onto E , with constant Jacobian abc , so

$$\lambda(E) = abc \cdot \lambda(\text{unit ball}) = \frac{4}{3}\pi abc.$$

3.11 Mesure produit

Soit μ et ν des mesures σ -finies sur les espaces mesurables respectifs $(E, \mathcal{E})$ et $(F, \mathcal{F})$. On souhaite en déduire une mesure sur l'espace produit $(E \times F, \mathcal{E} \otimes \mathcal{F})$.

Theorem (Existence et unicité du produit). *Il existe une unique mesure π sur $(E \times F, \mathcal{E} \otimes \mathcal{F})$ telle que :*

$$\forall A \in \mathcal{E}, \forall B \in \mathcal{F}, \quad \pi(A \times B) = \mu(A)\nu(B).$$

Proof. Uniqueness. The rectangles $A \times B$ are stable par intersection finie and generate $\mathcal{E} \otimes \mathcal{F}$. Les mesures μ et ν étant σ -finies, il existe des suites telles que $A_n \uparrow E$ et $B_n \uparrow F$, et $\mu(A_n) < \infty$ et $\nu(B_n) < \infty$. La suite vérifie $A_n \times B_n \uparrow E \times F$ et $\pi(A_n \times B_n) = \mu(A_n)\nu(B_n) < \infty$. On est donc dans les conditions du théorème d'unicité of the previous chapter.

Existence. On définit :

$$\forall C \in \mathcal{E} \otimes \mathcal{F}, \quad \pi(C) = \int \left(\int \mathbb{1}_C(x, y) d\nu(y) \right) d\mu(x).$$

Cette définition n'a de sens que si la fonction $y \mapsto \mathbb{1}_C(x, y)$ est mesurable pour tout x , et si la fonction $x \mapsto \int \mathbb{1}_C(x, y) d\nu(y)$ est mesurable. C'est le point technique de la preuve, and it is settled in two steps.

Pour le premier point, the collection of C for which $y \mapsto \mathbb{1}_C(x, y)$ est mesurable est une tribu. En effet, elle contient l'ensemble $E \times F$ (car alors $\mathbb{1}_C = 1$), est stable par passage au complémentaire (en utilisant le fait que $\mathbb{1}_{C^c} = 1 - \mathbb{1}_C$) et par intersection dénombrable (car $\mathbb{1}_{\bigcap_n C_n} = \prod_n \mathbb{1}_{C_n}$); and it contains every rectangle, because $\mathbb{1}_{A \times B}(x, y) = \mathbb{1}_B(y)$ for $x \in A$ and 0 otherwise. It is therefore the whole of $\mathcal{E} \otimes \mathcal{F}$.

Pour le second point, on considère une suite telle que $B_n \uparrow F$ et $\nu(B_n) < \infty$; it is enough to treat $x \mapsto \int \mathbb{1}_C(x, y) \mathbb{1}_{B_n}(y) d\nu(y)$ for each n , the general case following by an increasing passage to the limit. The collection $\mathcal{M}$ of C for which that function is mesurable est une *classe monotone*: it contains $E \times F$; for $C \subseteq D$ in $\mathcal{M}$ the integral over $D \setminus C$ is the difference of the two integrals, legitimately because $\nu(B_n) < \infty$ makes them finite, ce qui montre que $D \setminus C \in \mathcal{M}$; and for $C_k \uparrow C$ in $\mathcal{M}$, convergence monotone gives $C \in \mathcal{M}$. As $\mathcal{M}$ contains the rectangles, which are stable par intersection finie, the lemme de classe monotone gives $\mathcal{M} = \mathcal{E} \otimes \mathcal{F}$.

La suite de la preuve est plus aisée. On vérifie que $\pi(\emptyset) = 0$ et que pour toute famille au plus dénombrable $(C_i)_{i \in I}$ d'éléments deux-à-deux disjoints,

$$\pi \left(\bigcup_{i \in I} C_i \right) = \int \left(\int \sum_{i \in I} \mathbb{1}_{C_i}(x, y) d\nu(y) \right) d\mu(x) = \sum_{i \in I} \pi(C_i),$$

où les deux inversions somme-intégrale sont justifiées par the countable additivity corollary, which applies because the integrands are positive. Il ne reste plus qu'à vérifier la propriété annoncée :

$$\pi(A \times B) = \int \left(\int \mathbb{1}_B(y) d\nu(y) \right) \mathbb{1}_A(x) d\mu(x) = \mu(A)\nu(B).$$

Definition (Mesure produit). Soit μ et ν des mesures σ -finies sur les espaces mesurables respectifs $(E, \mathcal{E})$ et $(F, \mathcal{F})$. On appelle **mesure produit** (*product measure*), que l'on note $\mu \otimes \nu$, l'unique mesure sur $(E \times F, \mathcal{E} \otimes \mathcal{F})$ telle que :

$$\forall A \in \mathcal{E}, \forall B \in \mathcal{F}, \quad \mu \otimes \nu(A \times B) = \mu(A)\nu(B).$$

Example (A mesure on the plane that is not a product). La mesure $\mu = \delta_{(0,1)} + \delta_{(1,0)}$ sur $(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2))$ n'est pas une mesure produit. Supposons $\mu = \mu_1 \otimes \mu_2$. Alors $\mu(\{0\} \times \mathbb{R}) = \mu_1(\{0\})\mu_2(\mathbb{R}) = 1$ implique $\mu_1(\{0\}) > 0$, and $\mu(\mathbb{R} \times \{0\}) = \mu_1(\mathbb{R})\mu_2(\{0\}) = 1$ implique $\mu_2(\{0\}) > 0$. En particulier, $\mu(\{(0,0)\}) = \mu_1(\{0\})\mu_2(\{0\}) > 0$, alors que μ puts no mass at $(0,0)$. A mesure produit cannot charge two points off the diagonal of a rectangle without charging the two remaining corners as well.

Example (The product of two densités is a densité for the product). Soit ν_1 et ν_2 des mesures σ -finies sur les espaces mesurables $(E_1, \mathcal{E}_1)$ et $(E_2, \mathcal{E}_2)$. On note μ_1 et μ_2 des mesures de densités f_1 et f_2 with respect to them. Alors la mesure produit $\mu_1 \otimes \mu_2$ a pour densité $(x_1, x_2) \mapsto f_1(x_1)f_2(x_2)$ par rapport à la mesure produit $\nu_1 \otimes \nu_2$. On a rectangle $A_1 \times A_2$ the integrand is positive, so the integral may be computed one variable at a time — a case of the Fubini–Tonelli theorem below — and it factorises into $\mu_1(A_1)\mu_2(A_2)$. Rectangles determine the mesure produit by the uniqueness just proved, so the two mesures coincide.

Le résultat se généralise à un produit d'ordre supérieur. Soit $\mu_1, \dots, \mu_n$ des mesures σ -finies sur les espaces mesurables respectifs $(E_1, \mathcal{E}_1), \dots, (E_n, \mathcal{E}_n)$.

Theorem (Produits d'ordre n). *Il existe une unique mesure π sur $(E_1 \times \dots \times E_n, \mathcal{E}_1 \otimes \dots \otimes \mathcal{E}_n)$ telle que :*

$$\forall A_1 \in \mathcal{E}_1, \dots, \forall A_n \in \mathcal{E}_n, \quad \pi(A_1 \times \dots \times A_n) = \mu_1(A_1) \dots \mu_n(A_n).$$

On la notera $\mu_1 \otimes \dots \otimes \mu_n$.

Proof. La preuve de l'unicité est la même que celle du théorème précédent. On prouve l'existence par récurrence sur n : si la propriété est vraie au rang $n-1$, the two-factor theorem applied to the mesure it produces and to μ_n gives $\pi(A_1 \times \dots \times A_n) = \mu_1(A_1) \dots \mu_n(A_n)$.

Corollary (Mesure de Lebesgue). *La mesure de Lebesgue sur $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ est le produit des mesures de Lebesgue sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$.*

Proof. Ces mesures sont égales sur les pavés $[a_1, b_1] \times \dots \times [a_n, b_n]$, qui engendrent la tribu de Borel de $\mathbb{R}^n$ et sont stables par intersection finie. Comme $\mathbb{R}^n$ peut être couvert par une réunion croissante de pavés of finite mesure, on est dans les conditions du théorème d'unicité of the previous chapter, prouvant l'égalité de ces mesures.

Remark (Why σ -finiteness is in the definition). The mesure produit is defined only when both factors are σ -finies, and the hypothesis is used twice above: once to obtain the exhausting sequence $A_n \times B_n$ that uniqueness needs, and once inside the existence proof to make the integrals over B_n finite so that a difference could be taken. Without it there may be several mesures with the prescribed values on rectangles, and the object $\mu \otimes \nu$ would not be well defined. Every application in these notes has factors that are σ -finies — a probability is finite, and the mesure de Lebesgue is σ -finie — but that is a fact to check, not to assume.

3.12 Théorème de Fubini

Le **théorème de Fubini** (*Fubini's theorem*) permet de choisir, pour une intégrale par rapport à une mesure produit, l'ordre d'intégration des variables. Soit μ et ν des mesures σ -finies sur les espaces mesurables respectifs $(E, \mathcal{E})$ et $(F, \mathcal{F})$, throughout this subsection.

Theorem (Théorème de Fubini). *Pour toute fonction mesurable $f : E \times F \rightarrow \overline{\mathbb{R}}$,*

$$\int f(x, y) d(\mu \otimes \nu)(x, y) = \int \left(\int f(x, y) d\nu(y) \right) d\mu(x) = \int \left(\int f(x, y) d\mu(x) \right) d\nu(y)$$

dès que f est positive ou intégrable par rapport à $\mu \otimes \nu$.

Proof. On ne montre que la première égalité, l'autre s'en déduisant par symétrie. On considère tout d'abord le cas où la fonction f est positive. Pour pouvoir écrire la première égalité, il faut que les fonctions

$$y \mapsto f(x, y) \quad \text{and} \quad x \mapsto \int f(x, y) d\nu(y)$$

soient mesurables. Cela fait donc partie du résultat à démontrer.

On suppose tout d'abord que f est la fonction indicatrice $\mathbb{1}_C$ pour un ensemble $C \in \mathcal{E} \otimes \mathcal{F}$. On a vu, in the proof of the existence of the mesure produit, que les deux fonctions associées sont mesurables, et que :

$$\mu \otimes \nu(C) = \int \mathbb{1}_C(x, y) d(\mu \otimes \nu)(x, y) = \int \left(\int \mathbb{1}_C(x, y) d\nu(y) \right) d\mu(x).$$

Si f est étagée positive, c'est une combinaison linéaire positive de fonctions indicatrices. La première fonction associée est donc mesurable. Par linéarité de l'intégrale, la seconde l'est également et on a bien la première égalité.



Si f est mesurable positive, on considère une suite croissante de fonctions étagées positives (f_n) qui tend vers f . La première fonction associée est mesurable, et par convergence monotone, la seconde est limite croissante des fonctions mesurables $x \mapsto \int f_n(x, y) d\nu(y)$. Elle est donc mesurable. En appliquant à nouveau le lemme de convergence monotone to each side of the equality already known for f_n , one gets the first equality for f .

Supposons maintenant f intégrable. Les fonctions f^+ et f^- étant mesurables positives, la première fonction associée est mesurable. De plus, on a par le résultat précédent :

$$\int \left(\int f^+(x, y) d\nu(y) \right) d\mu(x) < \infty \quad \text{and} \quad \int \left(\int f^-(x, y) d\nu(y) \right) d\mu(x) < \infty.$$

By the theorem asserting that an integrable function is p.p. finite, les deux fonctions $x \mapsto \int f^\pm(x, y) d\nu(y)$ sont presque partout finies. En particulier, la seconde fonction associée est presque partout bien définie et mesurable, comme différence de fonctions mesurables. Enfin,

$$\begin{aligned} \int f(x, y) d(\mu \otimes \nu)(x, y) &= \int f^+(x, y) d(\mu \otimes \nu)(x, y) - \int f^-(x, y) d(\mu \otimes \nu)(x, y) \\ &= \int \left(\int f^+(x, y) d\nu(y) \right) d\mu(x) - \int \left(\int f^-(x, y) d\nu(y) \right) d\mu(x) \\ &= \int \left(\int f^+(x, y) d\nu(y) - \int f^-(x, y) d\nu(y) \right) d\mu(x) \\ &= \int \left(\int f(x, y) d\nu(y) \right) d\mu(x). \end{aligned}$$



On the rectangle $A \times B$ both sweeps give $\mu(A)\nu(B)$, which is the definition of the mesure produit; the théorème de Fubini says that the agreement survives for every mesurable f , under one of its two hypotheses. The two branches deserve separate names, because they are used differently.

Remark (Fubini–Tonelli and Fubini). For a *positive* mesurable f nothing further is required: the three integrals are equal in $[0, +\infty]$, all three being possibly infinite together. This branch is usually called **Fubini–Tonelli**, and it is the one that needs no verification beyond positivity. For a function of arbitrary sign, integrability with respect to $\mu \otimes \nu$ is required, and that is a genuine hypothesis to check. The standard procedure is therefore to use Tonelli on $|f|$ to establish integrability, and only then Fubini on f — two passes, never one. In both branches μ and ν must be σ -finies, without which $\mu \otimes \nu$ is not even defined.

Remark (Testing integrability). Si la fonction f n'est pas positive, on peut tester si elle est intégrable en appliquant le théorème de Fubini à la fonction $|f|$, which is positive, soit :

$$\int |f(x, y)| d(\mu \otimes \nu)(x, y) = \int \left(\int |f(x, y)| d\nu(y) \right) d\mu(x) = \int \left(\int |f(x, y)| d\mu(x) \right) d\nu(y).$$

Either iterated integral of $|f|$ may be computed, whichever is easier, and finiteness of one of them is finiteness of all three.

Remark (The inner integrals need not always exist). On prendra garde au fait, apparent dans la preuve du théorème, que les intégrales

$$x \mapsto \int f(x, y) d\nu(y) \quad \text{and} \quad y \mapsto \int f(x, y) d\mu(x)$$

ne sont pas toujours définies. Le fait qu'elles le soient *presque partout* justifie l'écriture du théorème, and it is a conclusion of the theorem rather than a hypothesis.

Example (Without integrability the two orders disagree). Let

$$f(x, y) = \frac{x^2 - y^2}{(x^2 + y^2)^2} \quad \text{on }]0, 1[^2.$$

Since $\frac{\partial}{\partial y} \left(\frac{y}{x^2 + y^2} \right) = f(x, y)$,

$$\int_0^1 f(x, y) dy = \left[\frac{y}{x^2 + y^2} \right]_0^1 = \frac{1}{1 + x^2}, \quad \text{so} \quad \int_0^1 \left(\int_0^1 f(x, y) dy \right) dx = \frac{\pi}{4}.$$

But $f(y, x) = -f(x, y)$, so exchanging the roles of the variables gives

$$\int_0^1 \left(\int_0^1 f(x, y) dx \right) dy = -\frac{\pi}{4}.$$

The two iterated integrals differ. Both mesures are σ -finies, and f is mesurable; the condition that fails is integrability. Indeed, on the triangle $0 < y < x < 1$ one has $x^2 + y^2 < 2x^2$ and therefore $f \geq \frac{x^2 - y^2}{4x^4} \geq 0$, whose integral over that triangle is

$$\int_0^1 \frac{1}{4x^4} \left(x^3 - \frac{x^3}{3} \right) dx = \frac{1}{6} \int_0^1 \frac{dx}{x} = +\infty,$$

so $\int |f| dx dy = +\infty$. The example is the reason the two-pass procedure above is not a formality: a single careless application of Fubini here returns two different numbers for the same quantity.

Le théorème de Fubini justifie la notation plus simple

$$\int f(x, y) d\mu(x) d\nu(y) \quad \text{or} \quad \int f d\mu d\nu$$

pour toute fonction mesurable f positive ou intégrable. Ces résultats se généralisent à toute fonction de n variables. Pour toutes mesures σ -finies $\mu_1, \dots, \mu_n$ sur les espaces mesurables respectifs $(E_1, \mathcal{E}_1), \dots, (E_n, \mathcal{E}_n)$, on écrira

$$\int f(x_1, \dots, x_n) d\mu_1(x_1) \dots d\mu_n(x_n) \quad \text{or} \quad \int f d\mu_1 \dots d\mu_n$$

pour toute fonction mesurable $f : E_1 \times \dots \times E_n \rightarrow \overline{\mathbb{R}}$ positive ou intégrable.

3.13 Intégrale dépendant d'un paramètre

Pour finir, on considère le cas d'une fonction f de $x \in \Omega$ dépendant d'un paramètre t . Son intégrale par rapport à une mesure μ sur $(\Omega, \mathcal{F})$ est une fonction de t . On s'intéresse à la continuité et à la dérivabilité de cette fonction. Both answers are convergence dominée in disguise, and both carry a domination hypothesis that is uniform in the parameter.

Theorem (Continuité sous le signe somme (*continuity under the integral sign*)). Soit U un ouvert de $\mathbb{R}^n$ et $f : \Omega \times U \rightarrow \mathbb{R}$ une fonction telle que :

- pour tout $t \in U$, la fonction $x \mapsto f(x, t)$ est mesurable ;
- pour presque tout $x \in \Omega$, la fonction $t \mapsto f(x, t)$ est continue ;
- il existe une fonction intégrable g telle que $|f(x, t)| \leq g(x)$ pour presque tout $x \in \Omega$ et pour tout $t \in U$.

Alors la fonction $t \mapsto \int f(x, t) d\mu(x)$ est bien définie pour tout $t \in U$ et continue.

Proof. Soit $t \in U$. Comme la fonction $x \mapsto f(x, t)$ est mesurable et que

$$\int |f(x, t)| d\mu(x) \leq \int g(x) d\mu(x) < \infty,$$

son intégrale par rapport à la mesure μ est bien définie. Pour toute suite $(t_n)_{n \geq 1}$ de U tendant vers t , la suite de fonctions $(x \mapsto f(x, t_n))_{n \geq 1}$ tend p.p. vers la fonction $x \mapsto f(x, t)$ by the continuity hypothesis, and it is dominated by g . Par convergence dominée, on a :

$$\lim_{n \rightarrow \infty} \int f(x, t_n) d\mu(x) = \int f(x, t) d\mu(x),$$

so la fonction $t \mapsto \int f(x, t) d\mu(x)$ est continue en t .

Example (Continuity of a parametrised Gaussian-type integral). Pour tout $t > 0$, la fonction

$$t \mapsto \int e^{-tx^4} dx$$

est continue. Il suffit d'appliquer le théorème sur tout ouvert $U =]\epsilon, +\infty[$ avec $\epsilon > 0$, where $e^{-tx^4} \leq e^{-\epsilon x^4}$, an integrable dominating function independent of t .

Remark (The domination must not depend on the parameter). The point of the example is the restriction to $]\epsilon, +\infty[$. On the full half-line $]0, +\infty[$ there is no integrable g dominating e^{-tx^4} for every t at once, since the integrand tends to the constant 1 as $t \rightarrow 0$. Continuity is a local property, so proving it on every $]\epsilon, +\infty[$ proves it on $]0, +\infty[$; choosing the open set is part of applying the theorem, not a detail.

Theorem (Dérivabilité sous le signe somme (*differentiability under the integral sign*)). Soit U un ouvert de $\mathbb{R}^n$ et $f : \Omega \times U \rightarrow \mathbb{R}$ une fonction telle que :

- pour tout $t \in U$, la fonction $x \mapsto f(x, t)$ est intégrable ;
- pour presque tout $x \in \Omega$, la fonction $t \mapsto f(x, t)$ est dérivable ;
- il existe une fonction intégrable g telle que $\left| \frac{\partial f}{\partial t}(x, t) \right| \leq g(x)$ pour presque tout $x \in \Omega$ et pour tout $t \in U$.

Alors la fonction $t \mapsto \int f(x, t) d\mu(x)$ est bien définie pour tout $t \in U$, dérivable, et

$$\frac{\partial}{\partial t} \int f(x, t) d\mu(x) = \int \frac{\partial f}{\partial t}(x, t) d\mu(x).$$

Proof. Soit $t \in U$. Pour toute suite $(t_n)_{n \geq 1}$ de $U \setminus \{t\}$ tendant vers t , la suite de fonctions

$$\left(x \mapsto \frac{f(x, t_n) - f(x, t)}{t_n - t} \right)_{n \geq 1}$$

tend p.p. vers la fonction $x \mapsto \frac{\partial f}{\partial t}(x, t)$, and by the mean value theorem each term is bounded in modulus by g . Par convergence dominée, on obtient :

$$\lim_{n \rightarrow \infty} \frac{\int f(x, t_n) d\mu(x) - \int f(x, t) d\mu(x)}{t_n - t} = \lim_{n \rightarrow \infty} \int \frac{f(x, t_n) - f(x, t)}{t_n - t} d\mu(x) = \int \frac{\partial f}{\partial t}(x, t) d\mu(x).$$

La fonction $t \mapsto \int f(x, t) d\mu(x)$ est donc dérivable en t , de dérivée $\int \frac{\partial f}{\partial t}(x, t) d\mu(x)$.

Remark (The domination is on the derivative, not on the function). The third hypothesis bounds $\frac{\partial f}{\partial t}$, not f — f itself is handled by the first hypothesis, which asks only that each $x \mapsto f(x, t)$ be integrable. Confusing the two is the standard error. The domination is what turns the difference quotients, which converge pointwise but need not be uniformly small, into a sequence to which convergence dominée applies; the mean value theorem is what transfers a bound on the derivative to a bound on those quotients, and it is the reason the bound has to hold for every t in U and not merely at the point of interest.

Example (Differentiating under the integral sign). Pour tout $t > 0$, la fonction

$$t \mapsto \int e^{-tx^2} dx$$

est dérivable, de dérivée :

$$- \int x^2 e^{-tx^2} dx.$$

À nouveau, il suffit d'appliquer le théorème sur tout ouvert $U =]\epsilon, +\infty[$ avec $\epsilon > 0$, where $\left| \frac{\partial}{\partial t} e^{-tx^2} \right| = x^2 e^{-tx^2} \leq x^2 e^{-\epsilon x^2}$, which is integrable and independent of t .

Remark (Where chapter 6 uses this). The fonction caractéristique of a variable aléatoire X is $\varphi_X(t) = \mathbb{E}(e^{itX})$, an integral depending on the parameter t . Continuité sous le signe somme gives its continuity with the constant 1 as dominating function, available because a probability is a finite mesure; dérivabilité sous le signe somme gives, when X is integrable, that φ_X is differentiable with $\varphi'_X(t) = \mathbb{E}(iX e^{itX})$, the dominating function being $|X|$. Iterating produces the moments of X from the derivatives of φ_X at the origin, which is what makes the fonction caractéristique useful at all.

Example (A convergence computed by domination). Consider

$$\lim_{n \rightarrow +\infty} \int_0^{+\infty} \left(1 + \frac{x}{n}\right)^n e^{-2x} dx.$$

The sequence $\left(1 + \frac{x}{n}\right)^n$ increases to e^x for every $x \geq 0$, so the integrands increase to e^{-x} ; convergence monotone applies and gives

$$\lim_{n \rightarrow +\infty} \int_0^{+\infty} \left(1 + \frac{x}{n}\right)^n e^{-2x} dx = \int_0^{+\infty} e^{-x} dx = 1.$$

Convergence dominée gives the same answer, the whole sequence being bounded by the integrable e^{-x} ; which of the two theorems one invokes is a matter of convenience, and here convergence monotone needs no dominating function at all.

Conclusion. The chapter builds one object and proves six theorems about it. The object is the integral $\int f d\mu$, defined in three stages — étagée positive, mesurable positive by a supremum, arbitrary sign by $f = f^+ - f^-$

— and every proof climbs those same three stages, which is why they are worth recognising as a single method rather than learning nine times.

The six theorems are the working tools. Convergence monotone and convergence dominée exchange a limit and an integral, the first for an increasing sequence of positive functions with no further hypothesis, the second for any sequence dominated by a *single integrable* function, with the lemme de Fatou between them giving an inequality that never fails. Transfer moves an integral from the abstract space to the value space, and is what makes a loi sufficient. The changement de variable carries the Jacobian in absolute value and requires a diffeomorphism, a C^1 bijection with non-vanishing Jacobian. Fubini exchanges the order of two integrations, needing σ -finiteness of both mesures and either positivity or integrability of the function — which is why one tests integrability with Tonelli on $|f|$ before applying Fubini to f . Continuité sous le signe somme and dérivabilité sous le signe somme are convergence dominée applied to a parametrised family, the domination being on f in the first case and on $\frac{\partial f}{\partial t}$ in the second.

The hypotheses that go missing under compression are all of one kind, a finiteness or positivity condition attached to an interchange: the integrability of the dominating function, the σ -finiteness in Fubini and in Radon–Nikodym, the absolute integrability an intégrale de Riemann impropre need not have, and the finiteness that lets one of f, g be subtracted in the additivity of the integral. Each has a one-line counter-example above. The next chapter re-reads all of this with μ a mesure de probabilité: the integral becomes the espérance, transfer becomes the passage from a variable aléatoire to its loi, and the convergence theorems become the tools of the limit theorems at the end of the course.

4 Théorie des probabilités

Modern probability is the théorie de la mesure with one extra axiom: the total mass is one. Everything in this chapter is a specialisation of chapters 2 and 3 — a probability is a mesure, a variable aléatoire is a mesurable function, an espérance is an intégrale de Lebesgue — and the work is in learning what the specialisation buys. What it buys is a vocabulary that the general theory does not have: lois, fonctions de répartition, densités, indépendance, moments, and the three inequalities that every limit theorem in chapter 8 rests on.

Les résultats présentés généralisent ceux vus au chapitre 1 dans le cas des probabilités discrètes. Certaines preuves, identiques dans les deux cas, sont omises: those that are the discrete one word for word, with a sum replaced by an integral. Where the technique is one an exam asks for, it is carried in full. Two such techniques dominate the chapter. The first is the fonction test method of computing a densité, which is the single most-used calculation in the written papers. The second is the supporting-line argument behind the inégalité de Jensen, which reappears whenever convexity is used.

4.1 Espace de probabilité

Soit $(\Omega, \mathcal{F})$ un espace mesurable.

Definition (Mesure de probabilité). On appelle **mesure de probabilité** sur $(\Omega, \mathcal{F})$ toute mesure, notée $\mathbb{P}$, telle que $\mathbb{P}(\Omega) = 1$.

On note qu'on ne pourra définir la probabilité que de certains sous-ensembles de Ω : les éléments de la tribu $\mathcal{F}$, which get their own name.

Definition (Événement). On appelle **événement** tout élément de la tribu $\mathcal{F}$.

Un événement de probabilité 1 est dit presque sûr (p.s. en abrégé). The triple $(\Omega, \mathcal{F}, \mathbb{P})$ is an **espace de probabilité** (*probability space*).

Example (Mesure de Lebesgue restreinte à l'intervalle unité). La mesure de Lebesgue λ sur l'ensemble $\Omega = [0, 1]$ muni de la tribu de Borel est une mesure de probabilité, since $\lambda([0, 1]) = 1$. This is the canonical source of a uniform variable aléatoire.

Example (A finite discrete probability). La mesure discrète

$$\mathbb{P} = \frac{1}{3} (\delta_1 + \delta_2 + \delta_3)$$

sur l'ensemble $\Omega = \{1, 2, 3\}$ muni de sa tribu des parties $\mathcal{P}(\Omega)$ est une mesure de probabilité. It puts mass $\frac{1}{3}$ on each atom.

On a les propriétés élémentaires suivantes, comme dans le cas discret; they follow from σ -additivité and from the general properties of a mesure.

Proposition. *Pour tous événements A, B :*

1. $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$;
2. $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$;
3. si $A \subseteq B$, alors $\mathbb{P}(A) \leq \mathbb{P}(B)$.

Remark. La première propriété est une conséquence de la σ -additivité, applied to the partition $\Omega = A \sqcup A^c$, which gives $\mathbb{P}(A) + \mathbb{P}(A^c) = \mathbb{P}(\Omega) = 1$; this is the only place the total mass being 1 is used. Les 2 dernières propriétés sont une transcription au cas d'une mesure de probabilité of chapter 2's inclusion–exclusion and monotonicity for a general mesure.

On a également les propriétés de convergence monotone et la borne de l'union, comme dans le cas discret.

Proposition. *Soit $(A_n)_{n \geq 1}$ une suite d'événements.*

1. Si $A_n \uparrow A$, alors $\mathbb{P}(A) = \lim_n \uparrow \mathbb{P}(A_n)$.
2. Si $A_n \downarrow A$, alors $\mathbb{P}(A) = \lim_n \downarrow \mathbb{P}(A_n)$.
3. On a la borne de l'union :

$$\mathbb{P}\left(\bigcup_{n \geq 1} A_n\right) \leq \sum_{n \geq 1} \mathbb{P}(A_n).$$

Remark. The decreasing case is the one that needs the finite total mass. For a general mesure μ , $A_n \downarrow A$ gives $\mu(A) = \lim_n \mu(A_n)$ only when some A_{n_0} has finite mesure; under a mesure de probabilité every événement has mesure at most 1, so the condition is automatic and the hypothesis disappears. The borne de l'union needs no hypothesis at all.

Les résultats sur l'indépendance et le conditionnement sont identiques au cas discret, with the same proofs: $A \perp\!\!\!\perp B$ means $\mathbb{P}(A \cap B) = \mathbb{P}(A) \mathbb{P}(B)$, and $\mathbb{P}(A | B) = \mathbb{P}(A \cap B) / \mathbb{P}(B)$ whenever $\mathbb{P}(B) > 0$. The formule de Bayes and the formule des probabilités totales carry over unchanged. What does not carry over is conditioning on an événement of probability zero, which is chapter 5's subject.

4.2 Variables aléatoires

Soit $(E, \mathcal{E})$ un espace mesurable — a second one, the space of values.

Definition (Variable aléatoire). Une **variable aléatoire** X à valeurs dans E est une fonction mesurable de $(\Omega, \mathcal{F})$ vers $(E, \mathcal{E})$.

Measurability is the whole of the definition: X is a variable aléatoire precisely when $X^{-1}(A) \in \mathcal{F}$ for every $A \in \mathcal{E}$, so that $\mathbb{P}(X \in A)$ makes sense for every A . Toute variable aléatoire définit une mesure de probabilité, appelée la loi: it pushes the mesure de probabilité forward onto its value space.

Definition (Loi d'une variable aléatoire). On appelle **loi** de la variable aléatoire X , notée $\mathbb{P}_X$, la mesure image de $\mathbb{P}$ par X :

$$\forall A \in \mathcal{E}, \quad \mathbb{P}_X(A) = \mathbb{P}(X \in A).$$

The loi is a mesure de probabilité on $(E, \mathcal{E})$: it is a mesure because preimages preserve disjoint countable unions, and its total mass is $\mathbb{P}(X \in E) = \mathbb{P}(\Omega) = 1$.

Example (A Bernoulli variable built on the unit interval). Soit $\Omega = [0, 1]$ muni de la tribu de Borel, et $\mathbb{P}$ la mesure de Lebesgue. The variable aléatoire $X = \mathbb{1}_{[0, 1/2]}$ takes the values 0 and 1, and

$$\mathbb{P}(X = 1) = \mathbb{P}\left(\left[0, \frac{1}{2}\right]\right) = \frac{1}{2},$$

so X follows the loi de Bernoulli $\mathcal{B}(\frac{1}{2})$. The same construction with $[0, p]$ produces $\mathcal{B}(p)$ for any $p \in [0, 1]$.

Remark (The espace de probabilité is almost never named). En pratique, l'espace de probabilité $(\Omega, \mathcal{F}, \mathbb{P})$ est rarement spécifié. Il s'agit d'un espace abstrait, suffisamment riche pour modéliser le problème d'intérêt, mais la plupart du temps sans lien avec la "physique" de l'expérience aléatoire considérée. La loi $\mathbb{P}_X$ de la variable aléatoire suffit pour les calculs, sans besoin de connaître l'espace de probabilité sous-jacent: every computation in this chapter and the next four is done from it, never from Ω . The example above is worth remembering only because it shows that a rich enough space exists: the unit interval under the mesure de Lebesgue already carries a variable of any prescribed loi, namely $F^{-1}(U)$ for U the identity map on $[0, 1]$ and F the desired fonction de répartition. Here F^{-1} has to be read as the generalised inverse $F^{-1}(u) = \inf\{x \in \mathbb{R} : F(x) \geq u\}$: the ordinary inverse exists only for F continuous and strictly increasing, and would already fail for the loi de Bernoulli just built.

Proposition. Deux variables aléatoires X, Y telles que $X = Y$ p.s. ont même loi.

Remark. Soit B l'événement $\{X = Y\}$, qui appartient bien à la tribu $\mathcal{F}$ car $X - Y$ est une variable aléatoire. Comme $\mathbb{P}(B) = 1$, intersecting with B changes no probability, and for every $A \in \mathcal{E}$, $\mathbb{P}_X(A) = \mathbb{P}(X^{-1}(A) \cap B) = \mathbb{P}(Y^{-1}(A) \cap B) = \mathbb{P}_Y(A)$. The converse is false, and badly so: two variables can have the same loi while being presque sûrement different, as X and $1 - X$ are for X uniform on $[0, 1]$.

4.3 Fonction de répartition

Lorsque $E = \mathbb{R}$ muni de la tribu de Borel $\mathcal{B}(\mathbb{R})$, la loi de X peut être décrite par sa fonction de répartition, a single function of a real variable.

Definition (Fonction de répartition). La **fonction de répartition** (*cumulative distribution function*) d'une variable aléatoire réelle X est la fonction F_X définie par :

$$\forall x \in \mathbb{R}, \quad F_X(x) = \mathbb{P}(X \leq x).$$

La fonction de répartition permet de caractériser la loi car $F_X(x) = \mathbb{P}_X(]-\infty, x])$. La collection des intervalles $]-\infty, x]$ avec $x \in \mathbb{R}$ étant stable par intersection finie et engendrant la tribu de Borel $\mathcal{B}(\mathbb{R})$, c'est en effet une conséquence du théorème d'unicité. That theorem of chapter 2 says that two mesures de probabilité agreeing on such a family agree on the whole tribu de Borel. This is the fact chapter 8's definition of the convergence en loi is built on, so it is worth stating as a property in its own right rather than as a passing observation.

Proposition. La fonction de répartition F_X est une fonction croissante, continue à droite, telle que :

$$\lim_{x \rightarrow -\infty} F_X(x) = 0 \quad \text{and} \quad \lim_{x \rightarrow +\infty} F_X(x) = 1.$$

Moreover F_X determines $\mathbb{P}_X$ completely: two variables aléatoires réelles with the same fonction de répartition have the same loi.

Remark. All four properties are convergence monotone for the mesure $\mathbb{P}_X$, read on nested intervals. Monotonicity is $]-\infty, x] \subseteq]-\infty, y]$ for $x \leq y$. Right-continuity is $]-\infty, x + \frac{1}{n}] \downarrow]-\infty, x]$, which needs the decreasing case of the previous section and therefore the finite total mass. The two limits are $]-\infty, x] \downarrow \emptyset$ and $]-\infty, x] \uparrow \mathbb{R}$. The last sentence is the théorème d'unicité, as above.

La fonction de répartition n'est pas toujours continue. Ses éventuels points de discontinuités correspondent aux “atomes” de la loi, c'est-à-dire aux singletons de mesure non nulle, and the size of the jump is the mass of the atom:

$$\forall x \in \mathbb{R}, \quad \mathbb{P}(X = x) = \mathbb{P}(X \leq x) - \mathbb{P}(X < x) = F_X(x) - F_X(x^-),$$

où $F_X(x^-)$ désigne la limite à gauche de F_X en x . Being non-decreasing, F_X has a left limit everywhere, so this is well defined at every point.

Definition (Loi diffuse). Une loi sans atome, c'est-à-dire dont la fonction de répartition est continue, est dite **diffuse**.

Example (The loi uniforme, a continuous staircase-free function de répartition). Une variable aléatoire X suivant une loi uniforme sur $[0, 1]$ a pour fonction de répartition :

$$F_X(x) = \begin{cases} 0 & \text{if } x < 0, \\ x & \text{if } x \in [0, 1], \\ 1 & \text{if } x \geq 1. \end{cases}$$


Cette fonction est continue, so the loi is diffuse and $\mathbb{P}(X = x) = 0$ for every x .

Example (The loi de Bernoulli, a fonction de répartition with two jumps). Une variable aléatoire $X \sim \mathcal{B}(p)$, de paramètre $p \in [0, 1]$, a pour fonction de répartition :

$$F_X(x) = \begin{cases} 0 & \text{if } x < 0, \\ 1 - p & \text{if } x \in [0, 1[, \\ 1 & \text{if } x \geq 1. \end{cases}$$

Remark. The middle value is $1 - p$: on $[0, 1[$, that is for $0 \leq x < 1$, $F(x) = \mathbb{P}(X \leq x)$ is $\mathbb{P}(X = 0) = 1 - p$. The figure below, drawn for p equal to $1/3$, puts the step at height $1 - p$.

Cette fonction est discontinue: it jumps by $1 - p$ at 0 and by p at 1, which are exactly $\mathbb{P}(X = 0)$ and $\mathbb{P}(X = 1)$.



(a) Loi uniforme sur $[0, 1]$: continuous, (b) loi de Bernoulli $\mathcal{B}(\frac{1}{3})$: two atoms, two jumps

Figure 1: A continuous fonction de répartition beside a staircase one. Every jump of a fonction de répartition is an atom of the loi, and its height is that atom's probability.

Example (A loi has at most countably many atoms). For each $n \geq 1$, the set of atoms of mass at least $1/n$ has at most n elements, since the masses of distinct atoms are the mesures of disjoint sets and sum to at most 1. The set of all atoms is the union over n of these finite sets, hence at most countable. So a fonction de répartition, however wild, has at most countably many discontinuities — and a loi whose support is uncountable must give mass zero to all but countably many of its points.

4.4 Lois à densité

On dit qu'une variable aléatoire réelle a une densité lorsque sa loi a une densité par rapport à la mesure de Lebesgue, in the sense of chapter 3.

Definition (Variable à densité). Une variable aléatoire réelle X a pour **densité** la fonction f_X si :

$$\forall A \in \mathcal{B}(\mathbb{R}), \quad \mathbb{P}_X(A) = \int_A f_X(x) dx.$$

La fonction de densité f_X est mesurable, positive, et telle que :

$$\int_{-\infty}^{+\infty} f_X(x) dx = 1,$$

which is the statement $\mathbb{P}_X(\mathbb{R}) = 1$. Conversely any measurable non-negative function integrating to 1 is the densité of some loi. Une loi à densité est diffuse puisque :

$$\forall x \in \mathbb{R}, \quad \mathbb{P}(X = x) = \mathbb{P}_X(\{x\}) = \int_{\{x\}} f_X = 0$$

— a singleton is négligeable for the mesure de Lebesgue. La fonction de répartition est donnée par :

$$\forall x \in \mathbb{R}, \quad F_X(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f_X(u) du,$$

une fonction continue, presque partout dérivable, de dérivée f_X en chaque point de dérivabilité.

Example (The three densités used constantly). Loi uniforme sur $[0, 1]$: $f_X = \mathbb{1}_{[0,1]}$.

Loi exponentielle $\mathcal{E}(\lambda)$ de paramètre $\lambda > 0$: $f_X(x) = \lambda e^{-\lambda x} \mathbb{1}_{\mathbb{R}_+}(x)$.

Loi normale (*normal distribution*) centrée réduite $\mathcal{N}(0, 1)$: $f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$.




Figure 2: For a loi à densité, a probability is an area. The shaded region is $\int_a^b f_X(x) dx = F_X(b) - F_X(a) = \mathbb{P}(a \leq X \leq b)$, and the endpoints may be included or excluded freely because the loi is diffuse.

Existence d'une densité. Une question intéressante est la réciproque : une loi dont la fonction de répartition F_X est continue et presque partout dérivable admet-elle une densité ? La réponse est non, and the counterexample below is the standard one. Il faut des conditions supplémentaires. Une condition suffisante est que la fonction de répartition F_X soit C^1 , ou continue et C^1 par morceaux. Par le théorème fondamental de l'analyse, on obtient alors :

$$\forall x \in \mathbb{R}, \quad F_X(x) = \int_{-\infty}^x F'_X(u) du,$$

où la dérivée F'_X est définie à un ensemble négligeable près. La loi a donc pour densité la fonction $f_X = F'_X$. This is worth writing down as a recipe: *if the fonction de répartition is continuous and piecewise C^1 , differentiate it, and the pieces where it is constant contribute zero.*

Example (Reading a densité off a piecewise-linear fonction de répartition). Soit

$$F(x) = \begin{cases} 0 & x \leq 0, \\ \frac{x}{4} & x \in [0, 1], \\ \frac{3x-2}{4} & x \in [1, 2], \\ 1 & x \geq 2. \end{cases}$$

This is non-decreasing (the slopes $\frac{1}{4}$ and $\frac{3}{4}$ are positive), continuous at 0, 1 and 2, and has the right limits at $\pm\infty$, so it is the fonction de répartition of some variable aléatoire réelle X . La fonction est continue et C^1 par morceaux. La loi de X a donc une densité, qui s'obtient en dérivant on each piece :

$$f(x) = \frac{1}{4} \mathbb{1}_{[0,1]}(x) + \frac{3}{4} \mathbb{1}_{[1,2]}(x).$$

The two corner points $x = 1$ and $x = 2$ are négligeables and the value assigned to them is irrelevant.

Example (A truncated exponential has no densité). Soit $X = \min(Y, 1)$, où $Y \sim \mathcal{E}(\lambda)$. For $x < 0$, $F_X(x) = 0$; for $x \in [0, 1]$, $F_X(x) = 1 - e^{-\lambda x}$; and $F_X(x) = 1$ for $x \geq 1$. The function jumps at $x = 1$ by $1 - (1 - e^{-\lambda}) = e^{-\lambda} = \mathbb{P}(Y \geq 1)$, so the loi has an atom at 1 and cannot have a densité. Continuity of the fonction de répartition is a *necessary* condition, and it is the first thing to check.

Example (The loi de Pareto, differentiated from its tail). Soit X une variable aléatoire de loi de Pareto de paramètre $a > 0$, définie par $\mathbb{P}(X > x) = x^{-a}$ pour $x \geq 1$. Then

$$F_X(x) = \begin{cases} 0 & \text{if } x \leq 1, \\ 1 - \frac{1}{x^a} & \text{otherwise,} \end{cases} \quad \text{hence} \quad f_X(x) = \begin{cases} 0 & \text{if } x \leq 1, \\ \frac{a}{x^{a+1}} & \text{otherwise.} \end{cases}$$

La fonction de répartition est une fonction C^1 par morceaux, and it is continuous at $x = 1$, which is what licenses the differentiation.

Example (The devil's staircase: continuous, diffuse, and with no densité). Soit X une variable aléatoire de loi uniforme sur l'ensemble de Cantor C . Comme cet ensemble C est en bijection avec $[0, 1]$, la loi de X est diffuse. Sa fonction de répartition est continue et presque partout dérivable, de dérivée nulle presque partout, and it is non-decreasing — it rises only on a set négligeable for the mesure de Lebesgue. Pourtant, la loi ne peut avoir de densité : $\mathbb{P}_X(C) = 1$ alors que $\lambda(C) = 0$, so no integral of a function against the mesure de Lebesgue can reproduce $\mathbb{P}_X$. This is why “continue et presque partout dérivable” is not enough.

Remark (Absolue continuité). Une condition nécessaire et suffisante d'existence d'une densité est l'absolue continuité de la fonction de répartition F_X : pour tout $\varepsilon > 0$, il doit exister $\delta > 0$ tel que pour tout ensemble fini d'intervalles disjoints, l'écart cumulé de F_X sur ces intervalles n'excède pas ε si la longueur totale de ces intervalles n'excède pas δ . C'est équivalent à dire que la loi de la variable aléatoire X est absolument continue par rapport à la mesure de Lebesgue, and the densité is then the Radon–Nikodym derivative. The devil's staircase fails this: intervals of tiny total length covering C carry the whole increase of F_X .

Unicité de la densité. Une fonction de densité est unique à un ensemble négligeable près par rapport à la mesure de Lebesgue, by chapter 3's uniqueness result for Radon–Nikodym derivatives. Pour la loi uniforme sur $[0, 1]$ par exemple, the values $f_X(0)$ and $f_X(1)$ are immaterial, and $\mathbb{1}_{[0,1]}$, $\mathbb{1}_{]0,1]}$ and $\mathbb{1}_{[0,1]}$ are the same densité. Every identity between densités below is therefore an identity p.p., and that qualification is not decoration.

4.5 Loi jointe, lois marginales

Soit X et Y deux variables aléatoires à valeurs respectives dans les ensembles E et E' , munis des tribus respectives $\mathcal{E}$ et $\mathcal{E}'$. Le couple (X, Y) définit une variable aléatoire à valeurs dans l'espace produit $E \times E'$ muni de la tribu $\mathcal{E} \otimes \mathcal{E}'$, the tribu produit. Sa loi $\mathbb{P}_{X,Y}$ est appelée la loi jointe; les lois $\mathbb{P}_X$, $\mathbb{P}_Y$ en sont les lois marginales, recovered by $\mathbb{P}_X(A) = \mathbb{P}_{X,Y}(A \times E')$.

Definition (Indépendance de deux variables aléatoires). Deux variables aléatoires X et Y sont dites **indépendantes** si pour tous $A \in \mathcal{E}$ et $B \in \mathcal{E}'$, les événements $\{X \in A\}$ et $\{Y \in B\}$ sont indépendants, soit :

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A) \mathbb{P}(Y \in B).$$

Proposition (Indépendance et mesure). *Deux variables aléatoires X et Y sont indépendantes si et seulement si leur loi jointe est la mesure produit :*

$$\mathbb{P}_{X,Y} = \mathbb{P}_X \otimes \mathbb{P}_Y.$$

Remark. The definition says exactly that the two mesures agree on rectangles $A \times B$. Rectangles are stable par intersection finie and generate the tribu produit, so the proposition is une conséquence de l'unicité de la mesure produit (chapter 3), which upgrades agreement on rectangles to equality. The lois marginales never determine the loi jointe on their own; indépendance is precisely the extra information that they do.

Fonction de répartition. Lorsque $E = E' = \mathbb{R}$ muni de la tribu de Borel, le couple (X, Y) est à valeurs dans $\mathbb{R}^2$. Comme pour les variables aléatoires réelles, sa loi peut être décrite par sa fonction de répartition, the joint one, définie par :

$$\forall x, y \in \mathbb{R}, \quad F_{X,Y}(x, y) = \mathbb{P}(X \leq x, Y \leq y).$$

Proposition (Indépendance et fonction de répartition). *Deux variables aléatoires réelles X et Y sont indépendantes si et seulement si :*

$$\forall x, y \in \mathbb{R}, \quad F_{X,Y}(x, y) = F_X(x)F_Y(y).$$

Remark. One direction is the definition applied to $A =]-\infty, x]$, $B =]-\infty, y]$. The other is again uniqueness: the quadrants $]-\infty, x] \times]-\infty, y]$ form a family stable par intersection finie and generating $\mathcal{B}(\mathbb{R}^2)$, so equality of the two mesures there is equality everywhere.

Lois à densité. Le couple (X, Y) a une densité par rapport à la mesure de Lebesgue sur $\mathbb{R}^2$ s'il existe une fonction mesurable $f_{X,Y} : \mathbb{R}^2 \rightarrow \mathbb{R}_+$ telle que :

$$\forall A, B \in \mathcal{B}(\mathbb{R}), \quad \mathbb{P}(X \in A, Y \in B) = \int_{A \times B} f_{X,Y}(x, y) dx dy,$$

sa fonction de répartition étant alors donnée par :

$$\forall x, y \in \mathbb{R}, \quad F_{X,Y}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(u, v) du dv.$$

Par le théorème de Fubini — applicable because $f_{X,Y}$ is non-negative and the mesure de Lebesgue on each factor is σ -finie — les lois marginales ont des densités, obtained by integrating out the other variable and données respectivement par :

$$\forall x \in \mathbb{R}, \quad f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x, y) dy \quad \text{and} \quad \forall y \in \mathbb{R}, \quad f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x, y) dx.$$

Proposition (Indépendance et densité). *Deux variables aléatoires réelles X et Y dont la loi jointe a une densité $f_{X,Y}$ par rapport à la mesure de Lebesgue sont indépendantes si et seulement si :*

$$\forall x, y \in \mathbb{R}, \quad f_{X,Y}(x, y) = f_X(x)f_Y(y) \quad p.p.$$

Remark. Sufficiency is a double integration: if the densité factorises then $F_{X,Y}(x, y) = F_X(x)F_Y(y)$ and the previous proposition applies. Necessity runs the other way. Pour montrer que la condition est nécessaire, on écrit, by indépendance, $F_{X,Y}(x, y) = F_X(x)F_Y(y) = \int_{-\infty}^x \int_{-\infty}^y f_X(u)f_Y(v) du dv$, ce qui montre que la loi jointe a pour densité la fonction $(x, y) \mapsto f_X(x)f_Y(y)$ — a densité of it, not necessarily the given one. Le résultat est une conséquence de l'unicité de la densité à un ensemble négligeable près. That last step is why the conclusion is stated p.p. and not pointwise.

Proposition (Existence d'une densité pour un couple). *Si X et Y sont des variables aléatoires réelles indépendantes de densités respectives f_X et f_Y , alors le couple (X, Y) a pour densité :*

$$\forall x, y \in \mathbb{R}, \quad f_{X,Y}(x, y) = f_X(x)f_Y(y).$$

Remark. Comme précédemment, c'est une conséquence du théorème de Fubini: indépendance gives $F_{X,Y} = F_X F_Y$, each factor is an integral of its densité, and Fubini turns the product of two single integrals into one double integral. Note the direction: indépendance plus marginal densités gives a joint densité. Marginal densités alone do not — see the pair (X, X) below, whose lois marginales both have densités and which has none.




Figure 3: A joint densité on $\mathbb{R}^2$, shown by its level sets, with the two lois marginales obtained by integrating out the other coordinate. The lois marginales are projections and lose the tilt of the level sets: they cannot tell this loi from the independent one with the same two lois marginales.

Example (Reading marginals off a joint densité, and testing indépendance). Let (X, Y) have densité $f_{X,Y}(x, y) = (x + y) \mathbb{1}_{[0,1]^2}(x, y)$. It is non-negative, and it is a densité because

$$\int_{\mathbb{R}^2} (x + y) \mathbb{1}_{[0,1]^2}(x, y) dx dy = \int_0^1 \int_0^1 (x + y) dx dy = 2 \int_0^1 x dx = 1,$$

where the middle step uses the symmetry of the integrand in x and y . Integrating out one coordinate,

$$f_X(x) = \int_0^1 (x + y) dy \cdot \mathbb{1}_{[0,1]}(x) = \left(x + \frac{1}{2}\right) \mathbb{1}_{[0,1]}(x), \quad f_Y(y) = \left(y + \frac{1}{2}\right) \mathbb{1}_{[0,1]}(y).$$

Since $f_X(x)f_Y(y) = (x + \frac{1}{2})(y + \frac{1}{2}) \neq x + y$ on a set of positive mesure, X and Y are *not* independent. Note also that $\mathbb{P}(X = Y) = 0$, because (X, Y) has a densité and the diagonal is négligeable for the mesure de Lebesgue in $\mathbb{R}^2$; and by the symmetry of $f_{X,Y}$ together with $\mathbb{P}(X = Y) = 0$, $\mathbb{P}(X \leq Y) = \mathbb{P}(X \geq Y) = \frac{1}{2}$.

4.6 Espérance

Soit X une variable aléatoire réelle.

Definition (Espérance). L'**espérance** de la variable aléatoire X est le nombre éventuellement infini donné par :

$$\mathbb{E}(X) = \int X d\mathbb{P} = \int_{\Omega} X(\omega) d\mathbb{P}(\omega),$$

dès que cette intégrale est bien définie.

L'espérance est donc la moyenne des valeurs prises par X lorsque ω parcourt Ω . Cela généralise la notion d'espérance introduite dans le cas discret, in chapter 1. The hypotheses are chapter 3's and must not be blurred:

- l'espérance est toujours définie si $X \geq 0$ (elle peut être infinie, $+\infty$);
- en général, elle est bien définie si et seulement si $\mathbb{E}(X^+) < \infty$ ou $\mathbb{E}(X^-) < \infty$, and it is then $\mathbb{E}(X^+) - \mathbb{E}(X^-)$;
- on dit que la variable aléatoire X est intégrable si $\mathbb{E}(|X|) < \infty$, which is the same as both parts being finite.

A variable can therefore have an espérance without being integrable (the loi de Pareto with $a \leq 1$ has espérance $+\infty$), and it can fail to have one at all (the loi de Cauchy). D'après le théorème de transfert, on a

$$\mathbb{E}(X) = \int x d\mathbb{P}_X(x),$$

and l'espérance est donc le barycentre de la loi $\mathbb{P}_X$; it depends on nothing else about X .

Example (Espérance d'une variable de Bernoulli). Une variable aléatoire $X \sim \mathcal{B}(p)$, de paramètre $p \in [0, 1]$, a pour espérance $\mathbb{E}(X) = \int x d\mathbb{P}_X(x) = \mathbb{P}(X = 1) = p$.

Example (Espérance of an indicator is a probability). Pour tout événement A , on a :

$$\mathbb{E}(\mathbb{1}_A) = \int \mathbb{1}_A d\mathbb{P} = \mathbb{P}(A).$$

On a ici utilisé la définition de l'espérance, avec une intégrale par rapport à la mesure de probabilité $\mathbb{P}$ — an integral over Ω . On obtient le même résultat en intégrant par rapport à la loi de la variable aléatoire $X = \mathbb{1}_A$, qui est une loi de Bernoulli de paramètre $\mathbb{P}(A)$ — the transfer identity in its smallest case. This identity is used constantly: it is how a probability is turned into an integral so that Fubini or a changement de variable can act on it.

L'espérance hérite des propriétés de l'intégrale de Lebesgue.

Theorem. Soit X, Y deux variables aléatoires réelles. Alors :

1. $X = 0$ p.s. implique $\mathbb{E}(X) = 0$;
2. $X = Y$ p.s. implique $\mathbb{E}(X) = \mathbb{E}(Y)$ dès que X ou Y a une espérance ;
3. $X \geq 0$ p.s. implique $\mathbb{E}(X) \geq 0$; si de plus $\mathbb{E}(X) = 0$ alors $X = 0$ p.s. ;
4. $X \leq Y$ p.s. implique $\mathbb{E}(X) \leq \mathbb{E}(Y)$ dès que X ou Y a une espérance ; si de plus $\mathbb{E}(X) = \mathbb{E}(Y)$ alors $X = Y$ p.s.

The two converse halves of items 3 and 4 are used more often than they look. “Non-negative with zero espérance forces the variable to vanish presque sûrement” is what turns an inequality between espérances into an almost-sure statement, and it is the engine of the equality case in every one of the inequalities that close this chapter.

Theorem (Linéarité). Soit X, Y deux variables aléatoires réelles. Alors,

$$\forall \alpha \in \mathbb{R}, \quad \mathbb{E}(\alpha X) = \alpha \mathbb{E}(X),$$

et

$$\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y),$$

cette dernière égalité étant satisfaite dès que les variables aléatoires X, Y sont positives ou que l'une d'elles est intégrable.

The side condition on additivity is not a technicality to be dropped. Without it the right-hand side can be $(+\infty) + (-\infty)$, and the identity is meaningless; positivity of both variables, or integrability of one of them, is exactly what rules that out.

Proposition (Espérance d'une série). *Pour toute suite $(X_n)_{n \geq 1}$ de variables aléatoires réelles,*

$$\mathbb{E} \left(\sum_{n \geq 1} X_n \right) = \sum_{n \geq 1} \mathbb{E}(X_n)$$

dès que les variables aléatoires X_n sont positives pour tout $n \geq 1$, ou que $\sum_{n \geq 1} \mathbb{E}(|X_n|) < \infty$.

Remark. These are the two standard hypotheses under which chapter 3 allows a sum and an integral to be exchanged: convergence monotone in the non-negative case, convergence dominée in the absolutely summable case. Either one alone suffices; neither can be dropped.

Example (A series of espérances that diverges). Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires telle que $X_n \sim \mathcal{B}(\frac{1}{n})$. The variables are non-negative, so the exchange is legitimate without any integrability assumption, and

$$\mathbb{E} \left(\sum_{n \geq 1} X_n \right) = \sum_{n \geq 1} \frac{1}{n} = +\infty.$$

No indépendance is needed, and the conclusion holds whatever the dependence between the X_n .

L'espérance hérite également de la propriété de transfert, from chapter 3. On considère une variable aléatoire X à valeurs dans un espace quelconque E , muni d'une tribu $\mathcal{E}$.

Theorem (Transfert). *Soit X une variable aléatoire à valeurs dans E et $\phi : E \rightarrow \mathbb{R}$ une fonction mesurable. Alors,*

$$\mathbb{E}(\phi(X)) = \int \phi(x) d\mathbb{P}_X(x)$$

dès que cette intégrale est bien définie.

This is the theorem that makes the loi sufficient. The left-hand side is an integral over the abstract space Ω ; the right-hand side is an integral over the value space against the loi. Since the loi is all one ever knows, every computation below is a use of transfer, usually without saying so.

Corollary (Espérance du produit). *Pour toutes variables aléatoires réelles X, Y indépendantes d'espérances finies,*

$$\mathbb{E}(XY) = \mathbb{E}(X) \mathbb{E}(Y).$$

Remark. Apply transfer to the pair (X, Y) , whose loi is $\mathbb{P}_X \otimes \mathbb{P}_Y$ by indépendance, and then Fubini. Run the argument first on $|xy|$, which is non-negative so Tonelli applies with no hypothesis, to get $\mathbb{E}(|XY|) = \mathbb{E}(|X|) \mathbb{E}(|Y|) < \infty$; that finiteness is what licenses Fubini on xy itself in the second pass. Skipping the first pass is the classic error — Fubini needs integrability, and here integrability of the product is a conclusion, not an assumption. The converse of the corollary is false: $\mathbb{E}(XY) = \mathbb{E}(X) \mathbb{E}(Y)$ does not imply indépendance.

Cas des lois à densité. Soit X une variable aléatoire réelle de densité f_X par rapport à la mesure de Lebesgue. On a :

$$\mathbb{E}(X) = \int x f_X(x) dx$$

dès que cette intégrale est bien définie. This is chapter 3's integration against a mesure with a densité.

Example (Espérance d'une variable exponentielle). Soit $X \sim \mathcal{E}(\lambda)$ une variable aléatoire de loi exponentielle de paramètre $\lambda > 0$. Son espérance est :

$$\mathbb{E}(X) = \int_0^{+\infty} x \lambda e^{-\lambda x} dx = \frac{1}{\lambda}.$$

Example (A Pareto variable may have infinite espérance). Soit X une variable aléatoire suivant une loi de Pareto de paramètre $a > 0$. Son espérance vaut :

$$\mathbb{E}(X) = \int_1^{+\infty} x \cdot \frac{a}{x^{a+1}} dx = \begin{cases} \frac{a}{a-1} & \text{if } a > 1, \\ +\infty & \text{otherwise.} \end{cases}$$

The espérance exists in every case, because the variable is non-negative; it is finite only for $a > 1$.

Example (A Cauchy variable has no espérance at all). Soit X une variable aléatoire suivant une loi de Cauchy, de densité $f_X(x) = \frac{1}{\pi} \frac{1}{x^2+1}$. Comme $\mathbb{E}(X^+) = \mathbb{E}(X^-) = +\infty$, son espérance n'est pas définie: the difference would be $(+\infty) - (+\infty)$. This is the distinction between “infinite espérance” and “no espérance”, and it matters: the law of large numbers has nothing to say here.

Theorem (Transfert pour les lois à densité). Soit X une variable aléatoire de densité f_X par rapport à la mesure de Lebesgue et $\phi : \mathbb{R} \rightarrow \mathbb{R}$ une fonction mesurable. Alors,

$$\mathbb{E}(\phi(X)) = \int \phi(x) f_X(x) dx$$

dès que cette intégrale est bien définie.

This is the working form of transfer and the starting point of the fonction test method below. Note what it does *not* require: nothing about ϕ beyond measurability — no continuity, no monotonicity, no invertibility. It is the absence of those requirements that makes the fonction test method universal.

4.7 Variance, covariance

Soit X une variable aléatoire réelle d'espérance finie.

Definition (Variance). La **variance** de la variable aléatoire X est la valeur, éventuellement infinie :

$$\text{Var}(X) = \mathbb{E}((X - \mathbb{E}(X))^2).$$

Expanding the square, par linéarité, on a l'expression équivalente :

$$\text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2,$$

which is the one used in computations; the definition is the one used in proofs.

Proposition. On a $\text{Var}(X) \geq 0$ avec $\text{Var}(X) = 0$ si et seulement si $X = \mathbb{E}(X)$ p.s.

Remark. C'est une conséquence directe of the theorem on the espérance above: $(X - \mathbb{E}(X))^2$ is non-negative, so its espérance is non-negative, and a non-negative variable of zero espérance vanishes presque sûrement.

Par linéarité de l'espérance, on a :

$$\forall \alpha \in \mathbb{R}, \quad \text{Var}(\alpha X) = \alpha^2 \text{Var}(X),$$

a scaling rule with the square on α — the variance is not linear, and an additive shift leaves it unchanged: $\text{Var}(X + c) = \text{Var}(X)$ for every constant c .

On considère maintenant X et Y deux variables aléatoires réelles d'espérances finies.

Definition (Covariance). La **covariance** entre les variables aléatoires X et Y est la valeur :

$$\text{Cov}(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))).$$

Par linéarité de l'espérance, on a :

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X) \mathbb{E}(Y).$$

On note que $\text{Cov}(X, Y) = 0$ dès que X et Y sont indépendantes, by the corollary on the espérance du produit. **La réciproque est fausse**, and the standard counter-example is worth carrying.

Example (Uncorrelated but dependent). Let X be uniform on $[-1, 1]$ and $Y = X^2$. Then $\mathbb{E}(X) = 0$ and $\mathbb{E}(XY) = \mathbb{E}(X^3) = 0$ by symmetry, so $\text{Cov}(X, Y) = 0$. But Y is a function of X , so the pair is as dependent as it can be: the événements $\{Y \leq \frac{1}{4}\}$ and $\{|X| \leq \frac{1}{2}\}$ are one and the same, so $\mathbb{P}(Y \leq \frac{1}{4}, |X| \leq \frac{1}{2}) = \frac{1}{2}$ while the product of the two probabilities is $\mathbb{P}(Y \leq \frac{1}{4}) \mathbb{P}(|X| \leq \frac{1}{2}) = \frac{1}{4}$: the product rule of the definition of indépendance fails outright. Zero covariance only says the best linear predictor of Y from X is constant.

La covariance vérifie les propriétés suivantes :

- $\text{Cov}(X, X) = \text{Var}(X)$;
- $\text{Cov}(X, Y) = \text{Cov}(Y, X)$;
- $\text{Cov}(\alpha X, Y) = \alpha \text{Cov}(X, Y)$ pour tout $\alpha \in \mathbb{R}$;
- $\text{Cov}(X, Y + Z) = \text{Cov}(X, Y) + \text{Cov}(X, Z)$ pour toutes variables X, Y, Z de variances finies.

La covariance est donc une forme bilinéaire symétrique on the space of variables with finite variance, and the variance is its associated quadratic form. Expanding that quadratic form gives the identity the whole of chapter 8 rests on; en particulier, on a

$$\text{Var}(X + Y) = \text{Var}(X) + 2 \text{Cov}(X, Y) + \text{Var}(Y)$$

pour toutes variables aléatoires X, Y de variances finies. Si les variables aléatoires X et Y sont indépendantes, it collapses to

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$$

On définit le coefficient de corrélation comme dans le cas discret: $\rho(X, Y) = \text{Cov}(X, Y) / \sqrt{\text{Var}(X) \text{Var}(Y)}$ when both variances are finite and non-zero; it lies in $[-1, 1]$ by the inégalité de Cauchy-Schwartz.

Example (A covariance computed by splitting on a discrete factor). Let X be uniform on $[-1, 1]$ and Y uniform on $\{1, 2\}$, independent, and set $Z = X^Y$. Conditioning on the two values of Y , each of probability $\frac{1}{2}$,

$$\mathbb{E}(Z) = \frac{1}{2} (\mathbb{E}(X) + \mathbb{E}(X^2)) = \frac{1}{2} \mathbb{E}(X^2), \quad \mathbb{E}(X^2) = \int_{-1}^1 x^2 \frac{1}{2} dx = \frac{1}{3},$$

so $\mathbb{E}(Z) = \frac{1}{6}$. The same split gives

$$\mathbb{E}(XZ) = \mathbb{E}(X^{Y+1}) = \frac{1}{2} (\mathbb{E}(X^2) + \mathbb{E}(X^3)) = \frac{1}{2} \mathbb{E}(X^2) = \frac{1}{6},$$

since $\mathbb{E}(X^3) = 0$ by symmetry. As $\mathbb{E}(X) = 0$, $\text{Cov}(X, Z) = \mathbb{E}(XZ) - \mathbb{E}(X) \mathbb{E}(Z) = \frac{1}{6}$. Two things are doing the work: indépendance of X and Y , which lets each espérance conditionnelle be computed as an unconditional one; and the symmetry of the loi uniforme on $[-1, 1]$, which kills every odd moment.

4.8 Vecteurs aléatoires

Les résultats vus jusqu'à présent se généralisent au cas des vecteurs aléatoires, from $\mathbb{R}$ to $\mathbb{R}^n$, and the generalisation is where the linear algebra enters.

Definition (Vecteur aléatoire). Un **vecteur aléatoire** X est une variable aléatoire à valeurs dans l'ensemble $\mathbb{R}^n$ muni de la tribu de Borel, pour un certain entier $n \geq 1$.

On note $X_1, \dots, X_n$ les composantes de X . Ce sont des variables aléatoires réelles. La loi de X est la loi jointe des variables aléatoires $X_1, \dots, X_n$; les lois de $X_1, \dots, X_n$ sont les lois marginales du vecteur aléatoire. Pour tous vecteurs $x, y \in \mathbb{R}^n$, on note $x \leq y$ l'inégalité composante par composante.

Définition (Fonction de répartition d'un vecteur aléatoire). La **fonction de répartition** d'un vecteur aléatoire X à valeurs dans $\mathbb{R}^n$ est la fonction F_X définie par :

$$\forall x \in \mathbb{R}^n, \quad F_X(x) = \mathbb{P}(X \leq x).$$

Comme dans le cas des variables aléatoires réelles, F_X est une fonction croissante, continue à droite, qui tend vers 0 lorsque toutes les composantes de x tendent vers $-\infty$ et vers 1 lorsque toutes les composantes tendent vers $+\infty$.

Définition (Vecteur à densité). Un vecteur aléatoire X à valeurs dans $\mathbb{R}^n$ a pour **densité** la fonction f_X par rapport à la mesure de Lebesgue si :

$$\forall A \in \mathcal{B}(\mathbb{R}^n), \quad \mathbb{P}_X(A) = \int_A f_X(x) dx.$$

La fonction de densité est mesurable, positive, et telle que $\int_{\mathbb{R}^n} f_X(x) dx = 1$. Par le théorème de Fubini, les lois marginales ont également une densité, obtenues en intégrant la densité de X sur les autres variables.

Remark (The mesure de référence). Lorsque la mesure de référence n'est pas précisée, il s'agit par convention de la mesure de Lebesgue. Les résultats s'étendent à n'importe quel produit de mesures σ -finies — that hypothesis is what Fubini needs and it is not automatic; it is satisfied by the mesure de Lebesgue on $\mathbb{R}^n$ and by the mesure de comptage on a countable set.

Proposition. Si le vecteur X a une densité, alors

$$\forall i \neq j, \quad \mathbb{P}(X_i = X_j) = 0.$$

Remark. Les ensembles $\{x \in \mathbb{R}^n : x_i = x_j\}$ pour tous $i \neq j$ — hyperplanes — étant négligeables pour la mesure de Lebesgue, c'est une conséquence du fait que la loi de X est absolument continue par rapport à la mesure de Lebesgue: it gives them mass zero. This is the quickest way to see that a vector cannot have a densité when two of its components coincide.

Exemple (Two independent uniforms never collide). Soit X un vecteur de loi uniforme sur $[0, 1]^2$. Alors $\mathbb{P}(X_1 = X_2) = 0$: the diagonal is a segment in the square, of area zero. Contrast the vector (U, U) with U uniform on $[0, 1]$, which lives entirely on that diagonal and therefore has no densité at all, even though each of its two lois marginales has one.

Espérance. La notion d'espérance se généralise aux vecteurs aléatoires réels, componentwise.

Définition (Espérance d'un vecteur aléatoire). L'**espérance** du vecteur aléatoire X est le vecteur des espérances :

$$\mathbb{E}(X) = \begin{pmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_n) \end{pmatrix}.$$

Elle est définie si et seulement si toutes les composantes du vecteur X ont une espérance.

Proposition (Linéarité de l'espérance). Soit X, Y des vecteurs aléatoires à valeurs dans $\mathbb{R}^n$ d'espérances finies. Alors, pour toute matrice A ,

$$\mathbb{E}(AX) = A \mathbb{E}(X) \quad \text{and} \quad \mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y).$$

Remark. Each coordinate of AX is a finite linear combination of the X_i : c'est une conséquence directe de la linéarité de l'espérance pour les variables aléatoires réelles, applied n times. The finiteness of the espérances is what makes those combinations legitimate — the scalar theorem's side condition, inherited.

Matrice de covariance. Les notions de variance et de covariance se généralisent également aux vecteurs aléatoires réels, and they do so together: the n^2 pairwise covariances of the components are collected into a single matrix.

Definition (Matrice de covariance). Soit X un vecteur aléatoire à valeurs dans $\mathbb{R}^n$ d'espérance finie. La **matrice de covariance** (*covariance matrix*) de X est la matrice des covariances de ses composantes :

$$\text{Cov}(X) = (\text{Cov}(X_i, X_j))_{1 \leq i, j \leq n}.$$

On notera les deux propriétés suivantes, used constantly. La diagonale de la matrice de covariance est le vecteur des variances, since $\text{Cov}(X_i, X_i) = \text{Var}(X_i)$. Si les variables aléatoires $X_1, \dots, X_n$ sont indépendantes, la matrice de covariance est diagonale — the converse being false, by the example above of décorréélées but dependent variables, except for the vecteurs gaussiens de chapter 7. En généralisant la notion d'espérance à une matrice, entrywise, on obtient l'expression matricielle :

$$\text{Cov}(X) = \mathbb{E}((X - \mathbb{E}(X))(X - \mathbb{E}(X))^T).$$

Proposition. La matrice de covariance est symétrique positive.

Remark. La matrice de covariance est symétrique car $\text{Cov}(X_i, X_j) = \text{Cov}(X_j, X_i)$. Par ailleurs, for the quadratic form, on a pour tout $a \in \mathbb{R}^n$:

$$a^T \text{Cov}(X) a = a^T \mathbb{E}((X - \mathbb{E}(X))(X - \mathbb{E}(X))^T) a = \mathbb{E}((a^T(X - \mathbb{E}(X)))^2) \geq 0,$$

the middle step being the linéarité de l'espérance applied to the constant matrix a^T on each side. “Positive” here means positive *semi*-definite: the form vanishes on a exactly when $a^T X$ is presque sûrement constant, which happens whenever the components satisfy an affine relation. Chapter 7 is where the distinction between definite and semi-definite becomes the difference between a vecteur gaussien with a densité and one without.

Definition (Matrice de covariance entre vecteurs). Soit X, Y deux vecteurs aléatoires à valeurs dans $\mathbb{R}^n$ d'espérances finies. La **matrice de covariance entre X et Y** est la matrice des covariances de leurs composantes :

$$\text{Cov}(X, Y) = (\text{Cov}(X_i, Y_j))_{1 \leq i, j \leq n}.$$

On note que $\text{Cov}(X, Y) = 0$ dès que les vecteurs X et Y sont indépendants. Par ailleurs,

$$\text{Cov}(X) = \text{Cov}(X, X), \quad \text{Cov}(Y, X) = \text{Cov}(X, Y)^T,$$

et on a l'expression matricielle :

$$\text{Cov}(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))^T).$$

Note that $\text{Cov}(X, Y)$ is not symétrique in general; only $\text{Cov}(X)$ is.

Proposition (Bilinéarité de la covariance). Soit X, Y des vecteurs aléatoires à valeurs respectives dans $\mathbb{R}^n, \mathbb{R}^m$, d'espérances finies. Pour toute matrice $A \in \mathbb{R}^{m \times n}$,

$$\text{Cov}(AX, Y) = A \text{Cov}(X, Y), \quad \text{Cov}(Y, AX) = \text{Cov}(Y, X) A^T.$$

Par ailleurs, pour tous vecteurs aléatoires X, Y, Z à valeurs dans $\mathbb{R}^n$,

$$\text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z), \quad \text{Cov}(Z, X + Y) = \text{Cov}(Z, X) + \text{Cov}(Z, Y).$$

Remark. All four identities are une conséquence directe de la linéarité de l'espérance for vectors, applied inside the matrix expression above. The transpose in the second identity is forced by the shape of the matrices and is the most common slip.

Proposition (Covariance d'une somme). *Pour tous vecteurs aléatoires X, Y sur $\mathbb{R}^n$,*

$$\text{Cov}(X + Y) = \text{Cov}(X) + \text{Cov}(Y) + \text{Cov}(X, Y) + \text{Cov}(Y, X).$$

En particulier, on a pour tous vecteurs aléatoires indépendants X, Y sur $\mathbb{R}^n$,

$$\text{Cov}(X + Y) = \text{Cov}(X) + \text{Cov}(Y).$$

This is the vector form of the scalar variance-of-a-sum identity above, and it is worth writing both out side by side, because chapter 8's normalisation of a sum is nothing but these two lines:

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y),$$

$$\text{Cov}(X + Y) = \text{Cov}(X) + \text{Cov}(Y) + \text{Cov}(X, Y) + \text{Cov}(X, Y)^T.$$

In the scalar case the two cross terms coincide and give the factor 2; in the vector case they are transposes of each other and cannot be merged. Applied to n independent variables with the same variance σ^2 , the first line gives $\text{Var}(X_1 + \dots + X_n) = n\sigma^2$, hence an écart type growing like $\sqrt{n}$ — which is exactly the normalisation the théorème central limite divides by.

4.9 Variables aléatoires indépendantes

La notion d'indépendance entre deux variables aléatoires vue précédemment se généralise au cas de n variables aléatoires, and the characterisations for two variables generalise with it. Les preuves des résultats suivants sont identiques à celles vues pour deux variables, with rectangles of two factors replaced by rectangles of n .

Definition (Indépendance de n variables aléatoires). Les variables aléatoires réelles $X_1, \dots, X_n$ sont dites **indépendantes** si pour tous $A_1, \dots, A_n \in \mathcal{B}(\mathbb{R})$, les événements $\{X_1 \in A_1\}, \dots, \{X_n \in A_n\}$ sont indépendants.

The événements being independent means every sub-family has a product probability, not merely the whole family — pairwise indépendance is strictly weaker and is not what is meant here.

Theorem (Caractérisation de l'indépendance). *Les propositions suivantes sont équivalentes :*

- les variables aléatoires réelles $X_1, \dots, X_n$ sont indépendantes ;
- leur loi jointe est le produit des lois marginales :

$$\mathbb{P}_X = \mathbb{P}_{X_1} \otimes \dots \otimes \mathbb{P}_{X_n};$$

- la fonction de répartition du vecteur X est le produit des fonctions de répartition des lois marginales :

$$\forall x \in \mathbb{R}^n, \quad F_X(x) = F_{X_1}(x_1) \dots F_{X_n}(x_n).$$

The third characterisation is the practical one: it reduces an indépendance check to an algebraic factorisation of a function of n real variables.

Theorem (Indépendance et densité). *Soit X un vecteur aléatoire à valeurs dans $\mathbb{R}^n$ de densité f_X par rapport à la mesure de Lebesgue. Les propositions suivantes sont équivalentes :*

- les variables aléatoires réelles $X_1, \dots, X_n$ sont indépendantes ;
- la densité de X est le produit des densités des lois marginales :

$$\forall x \in \mathbb{R}^n, \quad f_X(x) = f_{X_1}(x_1) \dots f_{X_n}(x_n) \quad p.p.$$

The hypothesis that X has a densité is part of the statement and cannot be dropped: without it there is nothing to factorise. Note too that the factorisation need only hold presque partout, and that it suffices to exhibit f_X as a product of a function of x_1 alone, $\dots$, a function of x_n alone — the factors are then automatically the marginal densités up to constants that multiply to one.

Example (The loi uniforme on a cube has independent coordinates). Soit X le vecteur aléatoire de loi uniforme sur $[0, 1]^n$. Its densité factorises,

$$\forall x \in \mathbb{R}^n, \quad f_X(x) = \mathbb{1}_{[0,1]^n}(x) = \mathbb{1}_{[0,1]}(x_1) \dots \mathbb{1}_{[0,1]}(x_n),$$

so ses composantes $X_1, \dots, X_n$ sont indépendantes, chacune de loi uniforme sur $[0, 1]$. The factorisation of an indicator of a product set is the most common instance of the criterion, and the reason an indicator of a non-product set — a triangle, a disc, the region $\{x < y\}$ — signals dependence at a glance.

Proposition (Existence d'une densité pour un vecteur). Soit X un vecteur aléatoire dont les composantes sont indépendantes. Si chaque loi marginale a une densité, la loi jointe a une densité, donnée par :

$$\forall x \in \mathbb{R}^n, \quad f_X(x) = f_{X_1}(x_1) \dots f_{X_n}(x_n) \quad p.p.$$

Example (Indépendance is what makes the joint densité exist). Soit X, Y des variables aléatoires indépendantes de même loi uniforme sur $[0, 1]$. Alors le vecteur aléatoire (X, Y) a une densité par rapport à la mesure de Lebesgue sur $\mathbb{R}^2$, égale à $\mathbb{1}_{[0,1]^2}$. Ce n'est pas le cas du vecteur (X, X) , by the hyperplane argument above, although its two components have exactly the same lois marginales. The lois marginales never determine the loi jointe; indépendance is one extra piece of information that does.

4.10 Calcul de densité

This section is one proposition and a procedure, and it is the most-used calculation on this syllabus. Soit X une variable aléatoire réelle ayant une densité f_X . Par le théorème de transfert, on a pour toute fonction mesurable positive ϕ :

$$\mathbb{E}(\phi(X)) = \int \phi(x) f_X(x) dx.$$

Il s'avère que cette propriété est une condition nécessaire et suffisante — not merely necessary but sufficient: it characterises the densité. La fonction ϕ , que l'on n'explicite pas, s'appelle la **fonction test** (*test function*), as in the chapter opening. Le résultat s'étend aux vecteurs aléatoires, verbatim.

Proposition (Fonction test). Une variable aléatoire réelle ou un vecteur aléatoire réel X a pour densité la fonction f_X si et seulement si pour toute fonction mesurable positive ϕ :

$$\mathbb{E}(\phi(X)) = \int \phi(x) f_X(x) dx.$$

Proof. La condition nécessaire vient du théorème de transfert pour les lois à densité. Pour la condition suffisante, il suffit d'appliquer l'égalité à la fonction indicatrice $\phi = \mathbb{1}_A$, pour tout borélien A , which is non-negative and mesurable and therefore an admissible fonction test. On obtient :

$$\mathbb{P}(X \in A) = \mathbb{E}(\mathbb{1}_A(X)) = \int_A f_X(x) dx,$$

for every A , ce qui montre que X a pour densité la fonction f_X .

The proof is three lines, and it is worth seeing why it is so short: the class of fonctions test is large enough to contain the indicators, and the indicators are already the definition of a densité. Everything else is bookkeeping.

Remark (The method, as a procedure). To find the densité of $Y = g(X)$, where the loi of X is known:

1. Take an arbitrary non-negative mesurable fonction test ϕ and write $\mathbb{E}(\phi(Y)) = \mathbb{E}(\phi(g(X)))$.

2. Expand the right-hand side by transfer, as an integral of $\phi(g(x))$ against the known densité of X .
3. Change variables — $y = g(x)$, or a diffeomorphism in the vector case — so that the integral becomes $\int \phi(y) h(y) dy$ with ϕ evaluated at the integration variable and nothing else depending on ϕ .
4. Read off $f_Y = h$. The indicator of the image domain is part of h and must be carried through the changement de variable; forgetting it is the commonest error.

If step 3 cannot be completed — if a term survives in which ϕ is evaluated at a fixed point — the loi has an atom there and no densité exists. That failure is informative, not a dead end.

Ce n'est pas la seule méthode ; on peut par exemple calculer la fonction de répartition puis la dériver lorsque c'est possible, and for a monotone g that is often quicker. Mais la méthode de la fonction test présente l'avantage d'être applicable à tous les cas, y compris vectoriels — where there is no fonction de répartition worth differentiating — and it needs no monotonicity or invertibility of g .

Example (The square of a uniform variable). Soit $X = U^2$ où U suit une loi uniforme sur $[0, 1]$. Pour toute fonction mesurable positive ϕ ,

$$\mathbb{E}(\phi(X)) = \mathbb{E}(\phi(U^2)) = \int \phi(u^2) \mathbb{1}_{]0,1[}(u) du = \int \phi(x) \frac{\mathbb{1}_{]0,1[}(x)}{2\sqrt{x}} dx,$$

substituting $x = u^2$, so $u = \sqrt{x}$ and $du = dx/(2\sqrt{x})$. Hence

$$\forall x \in \mathbb{R}, \quad f_X(x) = \frac{\mathbb{1}_{]0,1[}(x)}{2\sqrt{x}}.$$

The densité is unbounded at 0, which is perfectly legal — a densité need only be mesurable, non-negative and integrate to 1.

Example (A vector densité by a changement de variable). Soit U, V deux variables aléatoires i.i.d. de loi uniforme sur $[0, 1]$, and set

$$X = UV, \quad Y = \frac{V}{U}.$$

Take a fonction test ϕ , non-negative and mesurable on $\mathbb{R}^2$. Since (U, V) has densité $\mathbb{1}_{]0,1[^2}$,

$$\mathbb{E}(\phi(X, Y)) = \mathbb{E}\left(\phi\left(UV, \frac{V}{U}\right)\right) = \int \phi\left(uv, \frac{v}{u}\right) \mathbb{1}_{]0,1[^2}(u, v) du dv.$$

On procède au changement de variable $x = uv$, $y = v/u$, correspondant au diffeomorphisme

$$\psi :]0, 1[^2 \longrightarrow \Delta, \quad (u, v) \longmapsto \left(uv, \frac{v}{u}\right), \quad \Delta = \left\{(x, y) \in \mathbb{R}^2 : 0 < x < \min\left(y, \frac{1}{y}\right)\right\},$$

de matrice jacobienne

$$J_\psi = \begin{pmatrix} v & u \\ -\frac{v}{u^2} & \frac{1}{u} \end{pmatrix}, \quad |\det J_\psi| = \frac{v}{u} + \frac{uv}{u^2} = \frac{2v}{u} = 2y.$$

Chapter 3's changement de variable theorem then gives

$$\mathbb{E}(\phi(X, Y)) = \int \phi(x, y) \frac{\mathbb{1}_\Delta(x, y)}{2y} dx dy,$$

so

$$\forall (x, y) \in \mathbb{R}^2, \quad f_{X,Y}(x, y) = \frac{\mathbb{1}_\Delta(x, y)}{2y}.$$

The densité does not factorise — the domain Δ is not a product set — so X and Y are not independent, which one can see before computing anything else.

Example (When the method fails, it says why). Soit $X = \min(U, \frac{1}{2})$ où U suit une loi uniforme sur $[0, 1]$. Il est clair que la variable aléatoire n'a pas de densité puisque sa loi a un atome en $\frac{1}{2}$, of mass $\frac{1}{2}$. Running the method anyway: si on tente d'appliquer la méthode de la fonction test, on obtient pour toute fonction mesurable positive ϕ :

$$\mathbb{E}(\phi(X)) = \int \phi(\min(u, \frac{1}{2})) \mathbb{1}_{]0,1[}(u) du = \int \phi(u) \mathbb{1}_{]0,1/2[}(u) du + \frac{\phi(\frac{1}{2})}{2}.$$

The second term cannot be written as $\int \phi(x)h(x)dx$ for any function h , because it depends on ϕ only through its value at a single point. That surviving term *is* the atom, and its coefficient is the atom's mass.

Example (The ratio of the two pieces of a broken stick). A stick of length 1 is broken at a point U uniform on $]0, 1[$. Let R be the ratio of the shorter piece to the longer one, that is

$$R = \frac{\min(U, 1-U)}{\max(U, 1-U)} \in]0, 1[.$$

The loi of U is symétrique about $\frac{1}{2}$, so for any non-negative mesurable ϕ the two halves contribute equally and

$$\mathbb{E}(\phi(R)) = 2 \int_0^{1/2} \phi\left(\frac{u}{1-u}\right) du.$$

Substitute $r = u/(1-u)$, so that $u = r/(1+r)$ and $du = dr/(1+r)^2$, and $u \in]0, \frac{1}{2}[$ corresponds to $r \in]0, 1[$:

$$\mathbb{E}(\phi(R)) = \int \phi(r) \frac{2}{(1+r)^2} \mathbb{1}_{]0,1[}(r) dr, \quad \text{hence} \quad f_R(r) = \frac{2}{(1+r)^2} \mathbb{1}_{]0,1[}(r).$$

The espérance follows by transfer, splitting the numerator as $2r = 2(1+r) - 2$:

$$\mathbb{E}(R) = \int_0^1 \frac{2r}{(1+r)^2} dr = \int_0^1 \frac{2}{1+r} dr - \int_0^1 \frac{2}{(1+r)^2} dr = 2 \ln 2 - 1 \approx 0.386.$$

The same answer can be had by computing F_R directly and differentiating; the fonction test spares the case analysis.

Example (A densité under a linear change of coordinates). Let (X, Y) have densité $f_{X,Y}(x, y) = (x+y) \mathbb{1}_{[0,1]^2}(x, y)$, and look for the densité of the vector $(X, X+Y)$. For ϕ non-negative and mesurable on $\mathbb{R}^2$,

$$\mathbb{E}(\phi(X, X+Y)) = \int \phi(x, x+y)(x+y) \mathbb{1}_{[0,1]^2}(x, y) dx dy.$$

Substitute $z = x+y$ at fixed x , a translation whose Jacobian determinant is 1; the constraint $y \in [0, 1]$ becomes $z \in [x, x+1]$, and the integrand's factor $(x+y)$ becomes z :

$$\mathbb{E}(\phi(X, X+Y)) = \int \phi(x, z) z \mathbb{1}_{[0,1]}(x) \mathbb{1}_{[x, x+1]}(z) dx dz,$$

so

$$f_{X, X+Y}(x, z) = z \mathbb{1}_{[0,1]}(x) \mathbb{1}_{[x, x+1]}(z).$$

As a check, $\int_0^1 \int_x^{x+1} z dz dx = \int_0^1 (x + \frac{1}{2}) dx = 1$. The support is a tilted band, not a rectangle, so the two components are not independent — a linear change of coordinates that mixes the variables almost always destroys indépendance, and the indicator is where one sees it.

4.11 Inégalités

On termine ce chapitre par quelques inégalités utiles, four of them. They are short, their proofs are reusable, and between them they are the standard route to a weak law of large numbers. Chapter 8 proves the loi forte des grands nombres by a fourth-moment expansion instead, and reaches for Markov only in its exponential-bound example — but the habit of bounding a probability by a moment is the one to take from here.

Proposition (Inégalité de Markov (*Markov's inequality*)). *Soit X une variable aléatoire réelle positive. Alors,*

$$\forall a > 0, \quad \mathbb{P}(X \geq a) \leq \frac{\mathbb{E}(X)}{a}.$$

Proof. For every $a > 0$, the pointwise inequality

$$\mathbb{1}_{\{X \geq a\}} \leq \frac{X}{a}$$

holds: on $\{X \geq a\}$ the left side is 1 and the right side is at least 1; off that événement the left side is 0 and the right side is non-negative, which is where the hypothesis $X \geq 0$ is used. La preuve en découle en prenant l'espérance, which preserves the inequality by monotonicity: $\mathbb{P}(X \geq a) \leq \mathbb{E}(X)/a$.

The positivity hypothesis is not decorative. Without it the pointwise inequality fails off the événement, and the conclusion is false: a variable equal to $-M$ with probability $\frac{1}{2}$ and to a with probability $\frac{1}{2}$ has $\mathbb{P}(X \geq a) = \frac{1}{2}$ and an espérance that can be made arbitrarily negative. In practice one applies Markov not to X but to $|X|$, to $|X|^p$ or to $e^{\theta X}$ — each choice is non-negative by construction and each gives a different, and generally sharper, tail bound.



Figure 4: Inégalité de Markov. The rectangle of height a over the tail sits under the line $y = x$, so taking espérances gives $a \mathbb{P}(X \geq a) \leq \mathbb{E}(X)$. The picture is the proof, and it is also where the hypothesis $X \geq 0$ enters: for negative x the line dips below the axis and the domination fails.

Proposition (Inégalité de Tchebychev (*Tchebychev's inequality*)). *Soit X une variable aléatoire réelle intégrable. Alors,*

$$\forall a > 0, \quad \mathbb{P}(|X - \mathbb{E}(X)| \geq a) \leq \frac{\text{Var}(X)}{a^2}.$$

Proof. Il suffit d'appliquer l'inégalité de Markov à la variable aléatoire $(X - \mathbb{E}(X))^2$, which is non-negative as required, at the level $a^2 > 0$:

$$\mathbb{P}(|X - \mathbb{E}(X)| \geq a) = \mathbb{P}((X - \mathbb{E}(X))^2 \geq a^2) \leq \frac{\mathbb{E}((X - \mathbb{E}(X))^2)}{a^2} = \frac{\text{Var}(X)}{a^2}.$$

The first equality is the equivalence $|t| \geq a \iff t^2 \geq a^2$ for $a > 0$.

Integrability of X is what makes $\mathbb{E}(X)$ exist, so that the statement can be written at all; the bound is vacuously true when $\text{Var}(X) = +\infty$ and carries information only when the variance is finite. The shape

$\text{Var}(X)/a^2$ is the reason Tchebychev, not Markov, gives the weak law of large numbers: applied to an average of n independent variables, the variance in the numerator carries a factor $1/n$ and the bound goes to zero.

Example (A crude but universal bound on a Gaussian tail). Soit $X \sim \mathcal{N}(0, 1)$ une variable aléatoire suivant une loi normale centrée réduite, so $\mathbb{E}(X) = 0$ and $\text{Var}(X) = 1$. Alors,

$$\forall a > 0, \quad \mathbb{P}(|X| \geq a) \leq \frac{1}{a^2}.$$

At $a = 3$ this gives $\frac{1}{9} \approx 0.111$ against the true value ≈ 0.0027 : Tchebychev is far from sharp for a loi gaussienne, because it uses only two moments. Its value is that it uses only two moments.

Example (Comparing the two bounds on a Poisson tail). Soit $X \sim \mathcal{P}(\lambda)$ une variable aléatoire suivant une loi de Poisson, so $\mathbb{E}(X) = \text{Var}(X) = \lambda$, and fix $x > \lambda$. Markov, applicable because $X \geq 0$, gives

$$\mathbb{P}(X > x) \leq \frac{\lambda}{x}.$$

Tchebychev, noting that $X > x$ implies $|X - \lambda| > x - \lambda > 0$, gives

$$\mathbb{P}(X > x) \leq \mathbb{P}(|X - \lambda| \geq x - \lambda) \leq \frac{\lambda}{(x - \lambda)^2}.$$

La seconde borne est meilleure si et seulement si $(x - \lambda)^2 > x$, that is far out in the tail; close above λ the first wins, and the Tchebychev bound even exceeds 1 there. Neither is sharp — the true tail decays super-exponentially — and obtaining that decay needs Markov applied to $e^{\theta X}$ instead.

Theorem (Inégalité de Jensen (*Jensen's inequality*)). Soit X une variable aléatoire réelle intégrable. Pour toute fonction convexe $\phi : \mathbb{R} \rightarrow \mathbb{R}$,

$$\phi(\mathbb{E}(X)) \leq \mathbb{E}(\phi(X)).$$

Proof. Comme la fonction ϕ est convexe, it lies above each of its supporting lines: il existe pour tout $a \in \mathbb{R}$ un réel α tel que :

$$\forall x \in \mathbb{R}, \quad \phi(x) - \phi(a) \geq \alpha(x - a).$$

On choisit $a = \mathbb{E}(X)$, which is finite because X is integrable, et on applique l'inégalité à la variable aléatoire X , ce qui donne :

$$\phi(X) - \phi(\mathbb{E}(X)) \geq \alpha(X - \mathbb{E}(X)).$$

En passant à l'espérance, on obtient le résultat voulu, the right-hand side having espérance zero. Il faut juste s'assurer que la variable aléatoire $\phi(X)$ a bien une espérance, which is what the displayed inequality also delivers. Or l'inégalité implique que :

$$\phi(X)^- \leq (\phi(\mathbb{E}(X)) + \alpha(X - \mathbb{E}(X)))^- \leq |\phi(\mathbb{E}(X))| + |\alpha||X| + |\alpha||\mathbb{E}(X)|,$$

whose espérance is finite by integrability of X . Donc $\mathbb{E}(\phi(X)^-) < \infty$, ce qui implique que la variable aléatoire $\phi(X)$ a une espérance, and the inequality above may be integrated.

The last paragraph of that proof is the part most often skipped and the part worth keeping: Jensen asserts an inequality between two quantities, and one of them has to be shown to exist before the assertion means anything. The mechanism — bound the negative part by an affine function of $|X|$, then use integrability of X — is the same one used whenever an espérance must be shown to be well defined. Note also that $\mathbb{E}(\phi(X))$ may be $+\infty$, and the inequality is then trivially true.

Corollary. Soit n un entier non nul. Pour tout vecteur aléatoire X à valeurs dans $\mathbb{R}^n$ et toute norme $\|\cdot\|$ de $\mathbb{R}^n$,

$$\|\mathbb{E}(X)\| \leq \mathbb{E}(\|X\|).$$

Proof. Every norm is convex, par l'inégalité triangulaire and absolute homogeneity: $\|tx + (1-t)y\| \leq t\|x\| + (1-t)\|y\|$ for $t \in [0, 1]$. C'est une conséquence de l'inégalité de Jensen, applied to $\phi = \|\cdot\|$ in its $\mathbb{R}^n$ -valued form, with the supporting line replaced by a supporting hyperplane.

This corollary is the probabilistic triangle inequality, and it is used whenever an espérance has to be moved inside a norm — for instance to bound $\|\mathbb{E}(X) - \mathbb{E}(Y)\|$ by $\mathbb{E}(\|X - Y\|)$.

Example (The mean and the median are within one écart type). Soit X une variable aléatoire réelle dont la fonction de répartition est continue, dérivable et strictement croissante, with finite espérance and finite variance. On appelle médiane l'unique réel m tel que $F(m) = \frac{1}{2}$. Then

$$|\mathbb{E}(X) - m| = |\mathbb{E}(X - m)| \leq \mathbb{E}(|X - m|) \leq \mathbb{E}(|X - \mathbb{E}(X)|) \leq \sqrt{\mathbb{E}((X - \mathbb{E}(X))^2)} = \sqrt{\text{Var}(X)}.$$

Three steps, the outer two Jensen. The first is Jensen for the absolute value. The second is the characterisation of the median as the minimiser of $a \mapsto \mathbb{E}(|X - a|)$, applied at $a = \mathbb{E}(X)$; that characterisation is a minimisation argument in its own right, not a convexity inequality, and it is taken here on trust. The third is Jensen for the square, in the form $\mathbb{E}(|Z|)^2 \leq \mathbb{E}(Z^2)$ — which is also the inégalité de Cauchy-Schwartz against the constant 1. So the mean and the median can never be more than one écart type apart, for every loi satisfying the hypotheses above.

Conclusion. The chapter is chapters 2 and 3 with the total mass set to 1, and most of what is stated above is one of their results transcribed. What is genuinely new is the vocabulary and the four things below.

The loi $\mathbb{P}_X$ is the only object a computation ever needs, and the théorème de transfert is what licenses that: an espérance written over the abstract Ω is an integral over the value space against $\mathbb{P}_X$, so Ω can be left unnamed. A real loi is then read through its fonction de répartition, whose jumps are its atoms, or through a densité with respect to the mesure de Lebesgue — which exists only under a condition strictly stronger than continuity of F_X , the devil's staircase being the counter-example that fixes how much stronger.

The fonction test method is the calculation the written papers ask for most often. To find the densité of $Y = g(X)$: take an arbitrary non-negative mesurable ϕ , expand $\mathbb{E}(\phi(Y))$ by transfer, change variables until ϕ is evaluated at the integration variable and nothing else depends on it, then read the densité off. It needs no monotonicity and no invertibility of g , it works in the vector case where there is no fonction de répartition worth differentiating, and when it fails it fails informatively: a term surviving in $\phi(x_0)$ is an atom at x_0 of exactly that mass.

The bilinearity of the covariance is the identity the limit theorems run on. In scalar form $\text{Var}(X + Y) = \text{Var}(X) + 2\text{Cov}(X, Y) + \text{Var}(Y)$; in vector form $\text{Cov}(X + Y) = \text{Cov}(X) + \text{Cov}(Y) + \text{Cov}(X, Y) + \text{Cov}(X, Y)^T$, where the two cross terms are transposes and cannot be merged. Under indépendance both vanish, so n independent variables of common variance σ^2 give $\text{Var}(X_1 + \dots + X_n) = n\sigma^2$ and an écart type of order $\sqrt{n}$, which is the normalisation chapter 8 divides by. Zero covariance is strictly weaker than indépendance, and the uniform variable against its own square is the standing reminder.

The inequalities are what turn a moment into a tail bound: Markov for a non-negative variable, Tchebychev for its second-moment consequence, Jensen for a convex function of an integrable variable. Jensen's proof carries the step usually skipped — showing that $\mathbb{E}(\phi(X))$ exists before asserting an inequality about it — and that argument, bounding a negative part by an affine function of $|X|$, is reusable wherever an espérance has to be shown to be well defined.

5 Loi conditionnelle

Conditioning is the operation of revising a loi once part of the outcome is known. In the discrete chapter it was an elementary quotient: the probabilité conditionnelle of B given A was $\mathbb{P}(A \cap B) / \mathbb{P}(A)$, and nothing

more was needed because the événements one conditions on are atoms with positive probability. The moment variables aléatoires have densités that quotient breaks down. The événement $\{Y = y\}$ is négligeable for every y , its probability is zero, and the quotient is $0/0$; yet everyone wants to speak of the loi of X given $Y = y$, and every exam problem in this course asks for one.

This chapter builds the object that survives the degeneracy. The route is the one the intégrale de Lebesgue makes available: instead of dividing by $\mathbb{P}(Y = y)$, one observes that the map $B \mapsto \mathbb{P}_{X,Y}(A \times B)$ is dominated by $\mathbb{P}_Y$, so by the théorème de Radon-Nikodym it has a densité with respect to $\mathbb{P}_Y$, and that densité — read as a function of y — is declared to be the loi conditionnelle. The price of the construction is a qualification that never goes away: the loi conditionnelle exists and is determined only for $\mathbb{P}_Y$ -almost every y . That qualification is not decoration, and it is the reason the statements below are all phrased with an “almost every”.

The plan is three steps of increasing generality: conditioning on a single événement non négligeable, which is chapter 1 re-read with an integral in place of a sum; conditioning on a variable aléatoire, where the loi conditionnelle appears as a densité with respect to $\mathbb{P}_Y$; and the case where the loi jointe has a densité, which is the computational case the exercises live in. Espérance conditionnelle follows, defined as an integral against the loi conditionnelle, and the chapter closes on the tower property $\mathbb{E}(X) = \mathbb{E}(\mathbb{E}(X | Y))$ with its proof, the standard four-rung ladder of the course.

Remark. This course builds espérance conditionnelle *from* lois conditionnelles: $\mathbb{E}(\phi(X, Y) | Y = y)$ is by definition an integral of $\phi(\cdot, y)$ against the mesure $\mathbb{P}_{X|Y=y}$. Other treatments define espérance conditionnelle abstractly rather than from lois conditionnelles; that route is not taken here, and nothing below depends on it.

5.1 Condition sur un événement non négligeable

On commence par le cas simple où la condition porte sur un événement de probabilité non nulle. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité et $A \in \mathcal{F}$ un événement tel que :

$$\mathbb{P}(A) > 0.$$

La probabilité conditionnelle $\mathbb{P}(\cdot | A)$ définit une nouvelle mesure de probabilité sur $(\Omega, \mathcal{F})$, the same espace mesurable :

$$\forall B \in \mathcal{F}, \quad \mathbb{P}(B | A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)} = \int_B \frac{\mathbb{1}_A}{\mathbb{P}(A)} d\mathbb{P}.$$

The second form is the one that generalises. It says, of $\mathbb{P}(\cdot | A)$: c’est une mesure de densité

$$\omega \mapsto \frac{\mathbb{1}_A(\omega)}{\mathbb{P}(A)},$$

par rapport à $\mathbb{P}$, and everything in this subsection is a consequence of that single sentence read through the results of chapter 3 on mesures à densité.

Soit X une variable aléatoire à valeurs dans un espace mesurable $(E, \mathcal{E})$ — not necessarily real, at this stage.

Definition (Loi conditionnelle sachant un événement). On appelle loi conditionnelle de X sachant A la mesure de probabilité $\mathbb{P}_{X|A}$ sur $(E, \mathcal{E})$ définie par :

$$\forall B \in \mathcal{E}, \quad \mathbb{P}_{X|A}(B) = \mathbb{P}(X \in B | A).$$

C’est la mesure image de la probabilité conditionnelle $\mathbb{P}(\cdot | A)$ par X , in exactly the sense chapter 4 gives to the loi $\mathbb{P}_X$ of a variable aléatoire: replace the mesure upstairs by $\mathbb{P}(\cdot | A)$ and push it forward through X . In particular $\mathbb{P}_{X|A}$ is a mesure de probabilité on $(E, \mathcal{E})$ with no further verification needed, since the image of a mesure de probabilité is a mesure de probabilité.

On suppose maintenant que X est à valeurs réelles, for the rest of this subsection, so that an espérance can be spoken of.

Definition (Espérance conditionnelle sachant un événement). On appelle espérance conditionnelle de la variable aléatoire X sachant A la valeur :

$$\mathbb{E}(X | A) = \int X(\omega) d\mathbb{P}(\omega | A),$$

dès que cette intégrale est bien définie.

The caveat “dès que cette intégrale est bien définie” is the chapter 3 caveat and is not a formality: it excludes the case $\int X^+ d\mathbb{P}(\cdot | A) = \int X^- d\mathbb{P}(\cdot | A) = +\infty$, where no value can be assigned. C’est l’espérance de X pour la probabilité conditionnelle $\mathbb{P}(\cdot | A)$, rather than for $\mathbb{P}$. D’après le théorème de transfert, which applies verbatim, on l’obtient directement à partir de la loi conditionnelle :

$$\mathbb{E}(X | A) = \int x d\mathbb{P}_{X|A}(x).$$

Proposition (Espérance conditionnelle comme quotient). *L’espérance conditionnelle de la variable aléatoire X sachant A vérifie :*

$$\mathbb{E}(X | A) = \frac{\mathbb{E}(X \mathbb{1}_A)}{\mathbb{P}(A)}.$$

The proof is the densité in one line. Integrating against a mesure that has densité $\mathbb{1}_A / \mathbb{P}(A)$ with respect to $\mathbb{P}$ is the same as integrating against $\mathbb{P}$ after multiplying by that densité, so

$$\mathbb{E}(X | A) = \int X(\omega) d\mathbb{P}(\omega | A) = \int X(\omega) \frac{\mathbb{1}_A(\omega)}{\mathbb{P}(A)} d\mathbb{P}(\omega) = \frac{\mathbb{E}(X \mathbb{1}_A)}{\mathbb{P}(A)}.$$

The step in the middle is the chapter 3 rule for integrating against a mesure given by a densité, and it holds as soon as one of the two integrals is well defined.

On en déduit l’équivalent de la formule des probabilités totales pour l’espérance.

Proposition (Équivalent de la formule des probabilités totales pour l’espérance). *Soit $(A_i)_{i \in I}$ une famille d’événements formant une partition de Ω , avec $\mathbb{P}(A_i) > 0$ pour tout $i \in I$. Alors,*

$$\mathbb{E}(X) = \sum_{i \in I} \mathbb{P}(A_i) \mathbb{E}(X | A_i)$$

dès que la variable aléatoire X est positive ou intégrable.

Comme $\sum_{i \in I} \mathbb{1}_{A_i} = 1$ — a partition writes the constant 1 that way — one has $X = \sum_{i \in I} X \mathbb{1}_{A_i}$ pointwise. Exchanging the espérance with the sum is legitimate exactly under the stated hypothesis — the chapter 4 result on the espérance of a series asks for the terms to be positive, or for the series of the espérances of the absolute values to converge — and then each term is rewritten with the previous proposition:

$$\mathbb{E}(X) = \sum_{i \in I} \mathbb{E}(X \mathbb{1}_{A_i}) = \sum_{i \in I} \mathbb{P}(A_i) \mathbb{E}(X | A_i).$$

Remark. One hypothesis genuinely carries weight: X must be positive or integrable, since otherwise the exchange of espérance and sum has no justification and the right-hand side can fail to mean anything. Countability of the index set I is *not* an extra assumption — a partition of Ω into événements of strictly positive probability is automatically at most countable, since for each n only finitely many of them can have probability above $1/n$. That is what makes the chapter 4 result on the espérance of a *series* applicable in the first place.

Example (Splitting an espérance over the value of a first draw). A box holds two coins, one fair and one biased with $\mathbb{P}(\text{heads}) = 3/4$. A coin is drawn uniformly and tossed n times; let X be the number of heads, A_1 the événement that the fair coin was drawn and $A_2 = A_1^c$. Given A_1 the variable X has loi $\mathcal{B}(n, 1/2)$, given A_2 it has loi $\mathcal{B}(n, 3/4)$, and the formule des probabilités totales pour l’espérance gives

$$\mathbb{E}(X) = \frac{1}{2} \cdot \frac{n}{2} + \frac{1}{2} \cdot \frac{3n}{4} = \frac{5n}{8}.$$

Nothing here needs the machinery of the rest of the chapter: the conditioning événements have positive probability. This is the situation that generalises badly, and the next subsection is about what replaces it.

5.2 Condition sur une variable aléatoire

On considère maintenant deux variables aléatoires X et Y à valeurs dans les espaces mesurables respectifs $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ et $(E, \mathcal{E})$. Les résultats s'étendent au cas où X est un vecteur aléatoire, à valeurs dans $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$, without change; only the notation gets heavier. On souhaite définir la loi conditionnelle de X sachant $Y = y$, pour une certaine valeur $y \in E$, même si l'événement associé, $\{Y = y\}$, est de probabilité nulle.

Example (The smaller of two uniform draws, given the larger). Soit $X = \min(U, V)$ et $Y = \max(U, V)$, avec U, V des variables aléatoires i.i.d. de loi uniforme sur $[0, 1]$. L'événement $\{Y = \frac{1}{2}\}$ est de probabilité nulle, so no quotient defines a loi of X given it. Nevertheless there is an answer, and it is the one intuition expects: la loi conditionnelle de X sachant $Y = \frac{1}{2}$ est une loi uniforme sur $[0, \frac{1}{2}]$. The rest of this chapter is what makes that sentence mean something, and the computation appears in the next subsection.

Remark. Lorsque $Y = \mathbb{1}_A$ et $y = 1$, où $A \in \mathcal{F}$ est un événement non négligeable, on retrouve le cas considéré précédemment. The construction below must — and will — agree with the previous subsection on that overlap.

The observation that unlocks everything is a comparison of masses. For every borélien A and every $B \in \mathcal{E}$,

$$\mathbb{P}_{X,Y}(A \times B) = \mathbb{P}(X \in A, Y \in B) \leq \mathbb{P}(Y \in B) = \mathbb{P}_Y(B).$$

Fix the borélien A and read this as a statement about the set function $B \mapsto \mathbb{P}_{X,Y}(A \times B)$ on $(E, \mathcal{E})$: it is a mesure, and it vanishes on every B with $\mathbb{P}_Y(B) = 0$. It is therefore absolument continue par rapport à la mesure $\mathbb{P}_Y$, et ce quel que soit le borélien A . Both mesures are finite — they are bounded by 1 — hence σ -finies, which is the hypothesis the théorème de Radon-Nikodym of chapter 3 requires. Par le théorème de Radon-Nikodym, la mesure $B \mapsto \mathbb{P}_{X,Y}(A \times B)$ admet une densité par rapport à la mesure $\mathbb{P}_Y$, que l'on définit comme la loi conditionnelle de X par rapport à Y . Because a densité is determined only up to a négligeable set, and the relevant négligeable sets here are the $\mathbb{P}_Y$ -négligeable ones, elle est unique à un ensemble négligeable près pour la mesure $\mathbb{P}_Y$.

Definition (Loi conditionnelle sachant une variable aléatoire). Pour $\mathbb{P}_Y$ -presque tout y , on définit la loi conditionnelle de X sachant $Y = y$ comme une mesure de probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, notée $\mathbb{P}_{X|Y=y}$, telle que :

$$\forall A \in \mathcal{B}(\mathbb{R}), \quad \forall B \in \mathcal{E}, \quad \mathbb{P}_{X,Y}(A \times B) = \int_B \mathbb{P}_{X|Y=y}(A) d\mathbb{P}_Y(y).$$

Remark. The “ $\mathbb{P}_Y$ -presque tout y ” is not a technical nicety that a careful reader may drop. The loi conditionnelle is defined by an integral identity that must hold for every borélien A : elle est définie à un ensemble négligeable près — a $\mathbb{P}_Y$ -négligeable exceptional set — qui dépend du borélien A considéré. Nothing in the théorème de Radon-Nikodym says these exceptional sets can be chosen inside a single négligeable set, uniformly in A , and there are uncountably many A to union over. So l'existence d'une telle mesure $\mathbb{P}_{X|Y=y}$ — one that works simultaneously for all A , for $\mathbb{P}_Y$ -almost every y — n'est pas immédiate: it is a genuine theorem and not a corollary. C'est le **théorème de Jirina** (*Jirina's theorem*), which this course states and does not prove.

Proposition (La loi conditionnelle est une mesure de probabilité). Pour $\mathbb{P}_Y$ -presque tout y , $\mathbb{P}_{X|Y=y}$ est une mesure de probabilité.

Both defining properties are checked by the p.p. uniqueness of a densité, the chapter 3 statement that two positive mesurable functions integrating to the same value on every mesurable set are equal ν -p.p. when ν is σ -finie — and $\mathbb{P}_Y$, being a mesure de probabilité, is. For the total mass, take $A = \mathbb{R}$:

$$\forall B \in \mathcal{E}, \quad \mathbb{P}_{X,Y}(\mathbb{R} \times B) = \int_B \mathbb{P}_{X|Y=y}(\mathbb{R}) d\mathbb{P}_Y(y) = \int_B d\mathbb{P}_Y(y),$$

the last equality because $\mathbb{P}_{X,Y}(\mathbb{R} \times B) = \mathbb{P}_Y(B)$. Uniqueness applies, ce qui montre que $\mathbb{P}_{X|Y=y}(\mathbb{R}) = 1$ pour $\mathbb{P}_Y$ -presque tout y . For countable additivity: pour toute famille au plus dénombrable de boréliens

deux-à-deux disjoints $(A_i)_{i \in I}$,

$$\begin{aligned} \forall B \in \mathcal{E}, \quad \mathbb{P}_{X,Y} \left(\bigcup_{i \in I} A_i \times B \right) &= \sum_{i \in I} \mathbb{P}_{X,Y}(A_i \times B) \\ &= \sum_{i \in I} \int_B \mathbb{P}_{X|Y=y}(A_i) d\mathbb{P}_Y(y) \\ &= \int_B \sum_{i \in I} \mathbb{P}_{X|Y=y}(A_i) d\mathbb{P}_Y(y), \end{aligned}$$

the exchange of sum and integral being legitimate because the terms are positive. Uniqueness applies again, ce qui montre que $\mathbb{P}_{X|Y=y}(\cup_{i \in I} A_i) = \sum_{i \in I} \mathbb{P}_{X|Y=y}(A_i)$ pour $\mathbb{P}_Y$ -presque tout y .

Remark. Notice that the exceptional set produced by this argument depends on the family (A_i) chosen. This is exactly the difficulty the previous remark described, and exactly what the théorème de Jirina repairs.

On vérifie que la définition coïncide avec celle vue précédemment, lorsque la condition porte sur un événement $A \in \mathcal{F}$ de probabilité non nulle, $\mathbb{P}(A) > 0$. En prenant $Y = \mathbb{1}_A$, so that E is $\{0, 1\}$ and $\mathbb{P}_Y(\{1\}) = \mathbb{P}(A) > 0$, and $B = \{1\}$ in the defining identity, on obtient :

$$\forall B' \in \mathcal{B}(\mathbb{R}), \quad \mathbb{P}_{X,Y}(B' \times \{1\}) = \mathbb{P}_{X|Y=1}(B') \mathbb{P}_Y(\{1\}),$$

si bien que :

$$\forall B' \in \mathcal{B}(\mathbb{R}), \quad \mathbb{P}_{X|Y=1}(B') = \frac{\mathbb{P}(X \in B', Y = 1)}{\mathbb{P}(Y = 1)} = \mathbb{P}(X \in B' \mid A).$$

The new loi conditionnelle is the old one. Note that here the “presque tout y ” costs nothing: E has two points, both of positive mass when $\mathbb{P}(A) \in (0, 1)$, so “ $\mathbb{P}_Y$ -presque tout y ” means every y .

Proposition (Loi jointe). *La loi jointe des variables aléatoires X et Y vérifie :*

$$\forall C \in \mathcal{B}(\mathbb{R}) \otimes \mathcal{E}, \quad \mathbb{P}_{X,Y}(C) = \int \left(\int \mathbb{1}_C(x, y) d\mathbb{P}_{X|Y=y}(x) \right) d\mathbb{P}_Y(y).$$

L'égalité est vérifiée pour tout ensemble produit $C = A \times B$ par définition — the definition of the loi conditionnelle, and nothing else. The extension to the whole tribu produit is the théorème d'unicité of chapter 2: the two sides are mesures de probabilité on $\mathcal{B}(\mathbb{R}) \otimes \mathcal{E}$, they agree on the collection of product sets $A \times B$, that collection is stable par intersection finie — the intersection of two rectangles is a rectangle — it generates the tribu produit by definition, and $\mathbb{R} \times E$ is itself a rectangle of finite mesure, so the covering condition holds. Hence the two mesures coincide everywhere.

Remark. This proposition is the one to keep in mind, because it is the statement that a loi jointe *factorises*. A pair (X, Y) can be specified in two stages: give the loi marginale $\mathbb{P}_Y$, then give, for $\mathbb{P}_Y$ -almost every y , a loi conditionnelle $\mathbb{P}_{X|Y=y}$. The proposition says that these two ingredients determine $\mathbb{P}_{X,Y}$ completely. Almost every model in the exercises is written this way — “ Y is exponential, and given $Y = y$ the variable X is Poisson of parameter y ” — and the proposition is what turns such a sentence into a loi jointe one can integrate against.


The tree is the picture of the proposition. A point is produced in two stages, and the probability of a set C is obtained by integrating, over the first stage, the probabilité conditionnelle computed at the second — which with $\phi = \mathbb{1}_C$ is the displayed identity, and with a general ϕ is the tower property of the last subsection.

Proposition (Indépendance). *Les variables aléatoires X et Y sont indépendantes si et seulement si la loi conditionnelle de X sachant $Y = y$ est la loi de X pour $\mathbb{P}_Y$ -presque tout y .*

Les variables aléatoires X et Y sont indépendantes si et seulement si $\mathbb{P}_{X,Y}(A \times B) = \mathbb{P}_X(A) \mathbb{P}_Y(B)$ for every borélien A and every $B \in \mathcal{E}$, ce qui est équivalent — by the definition of the loi conditionnelle — à :

$$\forall A \in \mathcal{B}(\mathbb{R}), \quad \forall B \in \mathcal{E}, \quad \int_B \mathbb{P}_{X|Y=y}(A) d\mathbb{P}_Y(y) = \int_B \mathbb{P}_X(A) d\mathbb{P}_Y(y),$$

and p.p. uniqueness of densités turns the equality of the integrals into $\mathbb{P}_{X|Y=y}(A) = \mathbb{P}_X(A)$ for $\mathbb{P}_Y$ -almost every y . So indépendance is exactly the statement that conditioning on Y teaches nothing about X .



Proposition (Condition sur une variable qui détermine l'autre). *Si $X = \phi(Y)$ pour une certaine fonction mesurable ϕ , alors la loi conditionnelle de X sachant $Y = y$ est la mesure de Dirac en $\phi(y)$ pour $\mathbb{P}_Y$ -presque tout y .*

Indeed, for every borélien A and every $B \in \mathcal{E}$,

$$\mathbb{P}_{X,Y}(A \times B) = \mathbb{P}(\phi(Y) \in A, Y \in B) = \int_B \mathbb{1}_A(\phi(y)) d\mathbb{P}_Y(y),$$

on en déduit que pour $\mathbb{P}_Y$ -presque tout y , $\mathbb{P}_{X|Y=y}(A) = \mathbb{1}_A(\phi(y)) = \delta_{\phi(y)}(A)$. The two propositions are the two extremes of the same scale: knowing Y tells nothing about X (indépendance, the loi conditionnelle is the unconditional one), or knowing Y tells everything (the loi conditionnelle is a point mass).

Example (The square of a uniform variable, given the variable). Soit X une variable aléatoire de loi uniforme sur $[0, 1]$. Pour presque tout $x \in [0, 1]$, la loi conditionnelle de X^2 sachant $X = x$ est une mesure de Dirac en x^2 . There is no randomness left to describe once X is known, and the loi conditionnelle records that by collapsing to a point.

5.3 Cas des lois à densité

The general construction is not a recipe. It becomes one as soon as the loi jointe has a densité, and that is the situation of every computation in this course. On considère maintenant le cas de variables aléatoires réelles X, Y dont la loi jointe a une densité $f_{X,Y}$ par rapport à la mesure de Lebesgue de $\mathbb{R}^2$. Les variables aléatoires X et Y ont donc des densités par rapport à la mesure de Lebesgue sur $\mathbb{R}$, each obtained as usual by integrating out the other variable.

Definition (Densité conditionnelle). Pour tout réel y tel que $f_Y(y) > 0$, on définit la **densité conditionnelle** (*conditional density*) de la variable aléatoire X par rapport à $Y = y$ comme la fonction $f_{X|Y=y}$ définie par :

$$\forall x \in \mathbb{R}, \quad f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)}.$$

The condition $f_Y(y) > 0$ is part of the definition and not a side remark: at a y where the marginal densité vanishes the quotient is $0/0$ and no densité conditionnelle is defined there. This is the trace, at the level

of densités, of the “ $\mathbb{P}_Y$ -presque tout y ” of the previous subsection, since $\{f_Y = 0\}$ carries no $\mathbb{P}_Y$ -mass. On vérifie que la loi conditionnelle a bien pour densité cette fonction par rapport à la mesure de Lebesgue — a short verification. For all $A, B \in \mathcal{B}(\mathbb{R})$,

$$\begin{aligned}\mathbb{P}_{X,Y}(A \times B) &= \int_{A \times B} f_{X,Y}(x, y) dx dy \\ &= \int_{A \times B} f_{X|Y=y}(x) f_Y(y) dx dy \\ &= \int_B \left(\int_A f_{X|Y=y}(x) dx \right) f_Y(y) dy,\end{aligned}$$

where the middle line is legitimate because on $\{f_Y = 0\}$ one has $\int f_{X,Y}(x, y) dx = f_Y(y) = 0$, so that set of y contributes nothing to either side of the identity, and the last line is Tonelli, applicable because the integrand is positive. Comparing with the defining identity of the loi conditionnelle gives, pour $\mathbb{P}_Y$ -presque tout y ,

$$\forall A \in \mathcal{B}(\mathbb{R}), \quad \mathbb{P}_{X|Y=y}(A) = \int_A f_{X|Y=y}(x) dx.$$

Remark. Two extensions come free and both are used constantly. Les résultats s’étendent sans difficulté au cas où la loi jointe a une densité par rapport à une mesure *produit* quelconque, not only Lebesgue $\otimes$ Lebesgue (par exemple, le produit de la mesure de Lebesgue sur $\mathbb{R}$ et d’une mesure discrète — the important case being the mesure de comptage $\mu = \sum_{n \in \mathbb{N}} \delta_n$ on $\mathbb{N}$, which is what one needs when one variable is discrete and the other continuous), ainsi qu’au cas où X et Y sont des vecteurs aléatoires. The formula $f_{X|Y=y} = f_{X,Y}/f_Y$ is unchanged in both cases; only the reference mesure changes, and with it the meaning of “densité”.

Remark. A practical consequence: at fixed y , $f_{X|Y=y}$ is proportional to $f_{X,Y}(\cdot, y)$, the constant being whatever makes it integrate to 1. So one writes $f_{X|Y=y}(x) \propto f_{X,Y}(x, y)$, recognises the shape of a standard loi in x , and reads its normalisation off a table rather than computing f_Y . Most solutions below are obtained this way.

Example (The smaller of two uniform draws, given the larger). Return to $X = \min(U, V)$ and $Y = \max(U, V)$ with U, V independent uniform on $[0, 1]$. Pour toute fonction mesurable positive ϕ — a fonction test —

$$\mathbb{E}(\phi(X, Y)) = \int \phi(\min(u, v), \max(u, v)) \mathbb{1}_{]0,1[}(u) \mathbb{1}_{]0,1[}(v) du dv = 2 \int \phi(x, y) \mathbb{1}_{\Delta}(x, y) dx dy$$

avec $\Delta = \{(x, y) \in [0, 1]^2 : x \leq y\}$, the factor 2 coming from the two orderings of the pair. So la loi jointe a pour densité :

$$f_{X,Y}(x, y) = 2 \times \mathbb{1}_{\Delta}(x, y),$$


la loi de Y a pour densité $f_Y(y) = 2y \mathbb{1}_{[0,1]}(y)$, and for every $y \in]0, 1]$

$$f_{X|Y=y}(x) = \frac{\mathbb{1}_{\Delta}(x, y)}{y},$$

c’est une loi uniforme sur $[0, y]$. The guess made when the example was introduced is confirmed, and $y = 0$ — the single point where f_Y vanishes — is excluded, as the definition requires.

The figure is the whole of this subsection in one image. Conditioning on $Y = y$ means cutting the joint densité along the horizontal line at height y and reading the profile of the cut as a function of x ; that profile is $f_{X,Y}(\cdot, y)$, not a probability densité, since it integrates to $f_Y(y)$ rather than 1. Dividing by $f_Y(y)$ renormalises it. The picture also makes the restriction $f_Y(y) > 0$ visible: where the cut meets the support in a set of mesure zero there is nothing to renormalise.

Proposition (Indépendance pour un couple à densité). *Deux variables aléatoires X, Y dont la loi jointe a une densité sont indépendantes si et seulement si la densité conditionnelle $f_{X|Y=y}$ est égale à la densité f_X , pour tout y tel que $f_Y(y) > 0$.*



By the chapter 4 criterion, a pair with a joint densité is independent if and only if $f_{X,Y}(x, y) = f_X(x)f_Y(y)$ p.p., which is to say

$$f_{X|Y=y}(x)f_Y(y) = f_X(x)f_Y(y)$$

for Lebesgue-almost every x , at almost every y with $f_Y(y) > 0$. Dividing by $f_Y(y)$, which is legitimate exactly on that set of y , gives the claim. A densité is only defined up to a set of mesure zero, so “pour tout y ” is to be read for a suitable choice of the densities; for an arbitrary choice the equality holds p.p. in y on the set where $f_Y(y) > 0$.

Example (A point drawn uniformly in the unit disc). Soit A un point choisi de manière aléatoire et uniforme dans le disque unité D , centré at the origin. On note (X, Y) ses coordonnées cartésiennes. La densité du vecteur est donnée par $f_{X,Y} = \frac{1}{\pi} \mathbb{1}_D$, so for $x \in]-1, 1[$,

$$f_{Y|X=x}(y) \propto \mathbb{1}_D(x, y) = \mathbb{1}_{]-\sqrt{1-x^2}, \sqrt{1-x^2}[}(y),$$

c’est une loi uniforme sur $]-\sqrt{1-x^2}, \sqrt{1-x^2}[$. The coordinates are not independent: the loi conditionnelle depends on x , and the proposition above says that is already enough to rule indépendance out. Espérance conditionnelle of a non-linear function is read off the same loi: by symmetry

$$\mathbb{E}(Y^2 | X = x) = \int_0^{\sqrt{1-x^2}} y^2 \frac{dy}{\sqrt{1-x^2}} = \frac{1-x^2}{3},$$

so the disc centred at the origin and passing through A has mean area

$$\mathbb{E}(\pi(X^2 + Y^2) | X = x) = \pi x^2 + \pi \frac{1-x^2}{3} = \frac{\pi}{3}(1 + 2x^2).$$

Example (A uniform variable given its product with another). Soit U et V deux variables aléatoires i.i.d. de loi uniforme sur $]0, 1[$, and set $T = UV$. Pour toute fonction mesurable positive ϕ , the changement de variable $t = uv$ at fixed u gives

$$\mathbb{E}(\phi(U, T)) = \int \phi(u, uv) \mathbb{1}_{]0,1[}(u) \mathbb{1}_{]0,1[}(v) du dv = \int \phi(u, t) \mathbb{1}_\Delta(u, t) \frac{du}{u} dt$$

avec $\Delta = \{(u, t) : 0 < t < u < 1\}$. On en déduit la densité $f_{U,T}(u, t) = \mathbb{1}_\Delta(u, t)/u$. Hence, for $t \in]0, 1[$,

$$f_{U|T=t}(u) \propto \frac{\mathbb{1}_{]t,1[}(u)}{u}, \quad \int \frac{\mathbb{1}_{]t,1[}(u)}{u} du = -\ln t, \quad \text{so} \quad f_{U|T=t}(u) = -\frac{\mathbb{1}_{]t,1[}(u)}{u \ln t}.$$

The loi conditionnelle is not uniform, which is worth seeing once: conditioning on a smooth function of the pair does not in general leave a loi from the standard tables. Integrating gives $\mathbb{E}(U | UV = \frac{1}{2}) = 1/(2 \ln 2)$.

5.4 Espérance conditionnelle

On étend la définition de l'espérance conditionnelle à une condition sur une variable aléatoire, in place of the condition on an événement of the first subsection. Cette généralisation n'est pas immédiate car la loi conditionnelle $\mathbb{P}_{X|Y=y}$ est une mesure de probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ et non sur l'espace de probabilité $(\Omega, \mathcal{F})$, où sont définies les variables aléatoires X et Y — a mismatch of spaces — so $\int X d\mathbb{P}_{X|Y=y}$ is not a well-formed expression and the first definition cannot simply be copied. On peut par contre calculer l'espérance de toute fonction mesurable de X et Y : integrate it against the loi conditionnelle, in the variable x , at a fixed y .

Definition (Espérance conditionnelle sachant $Y = y$). Pour $\mathbb{P}_Y$ -presque tout y , on définit l'espérance conditionnelle de $\phi(X, Y)$ sachant $Y = y$ comme :

$$\mathbb{E}(\phi(X, Y) | Y = y) = \int \phi(x, y) d\mathbb{P}_{X|Y=y}(x),$$

dès que cette intégrale est bien définie.

Two qualifications travel with this definition and neither is decorative. The $\mathbb{P}_Y$ -presque tout y is inherited from the loi conditionnelle, which is itself only defined $\mathbb{P}_Y$ -presque partout. And “dès que cette intégrale est bien définie” is the chapter 3 caveat again: the integral must not be an $\infty - \infty$.

The bridge back to the first subsection closes here. On retrouve bien l'espérance conditionnelle lorsque la condition porte sur un événement $A \in \mathcal{F}$ de probabilité non nulle, $\mathbb{P}(A) > 0$. Avec $Y = \mathbb{1}_A$ — and $\phi(x, y) = x$ — on obtient en effet :

$$\mathbb{E}(X | A) = \mathbb{E}(X | Y = 1) = \int x d\mathbb{P}_{X|A}(x),$$

which is exactly the form the théorème de transfert gives to the espérance conditionnelle given an événement. So the general definition restricts correctly, and the discrete espérance conditionnelle of chapter 1 is a special case of a special case.

Theorem (Calcul d'espérance par conditionnement). On a :

$$\mathbb{E}(\phi(X, Y)) = \int \mathbb{E}(\phi(X, Y) | Y = y) d\mathbb{P}_Y(y),$$

pour toute fonction mesurable ϕ positive ou telle que $\mathbb{E}(|\phi(X, Y)|) < \infty$.

Proof. The argument is the standard four-rung ladder of this course — indicator, étagée, positive mesurable, general — the same one that carried the théorème de transfert and the integration of a mesure à densité in chapter 3. Only the bottom rung contains anything specific to conditioning.

Fonctions indicatrices. Soit $\phi = \mathbb{1}_C$ avec $C \in \mathcal{B}(\mathbb{R}) \otimes \mathcal{E}$. By the proposition on the loi jointe,

$$\begin{aligned} \mathbb{E}(\phi(X, Y)) &= \mathbb{P}_{X,Y}(C) \\ &= \int \left(\int \mathbb{1}_C(x, y) d\mathbb{P}_{X|Y=y}(x) \right) d\mathbb{P}_Y(y) \\ &= \int \mathbb{E}(\phi(X, Y) | Y = y) d\mathbb{P}_Y(y), \end{aligned}$$

the last line being the definition of the espérance conditionnelle read backwards.

Fonctions étagées positives. A fonction étagée positive is a finite positive combination $\phi = \sum_k a_k \mathbb{1}_{C_k}$, and both sides of the identity are linear in ϕ — the left by linearity of the espérance, the right by linearity of both integrals — so le résultat s'étend à toute fonction étagée positive par linéarité.

Fonctions mesurables positives. Any positive mesurable ϕ is the increasing limit of a sequence of fonctions étagées positives, and le résultat s'étend à toute fonction mesurable positive par convergence monotone: it

applies on the left, and twice on the right — once in x for each fixed y , once in y — so the identity passes to the limit.

Le cas général. For ϕ with $\mathbb{E}(|\phi(X, Y)|) < \infty$, on applique le résultat aux fonctions ϕ^+ et ϕ^- , separately, and subtract. The integrability hypothesis is what makes the subtraction legitimate: both terms are finite, so no $\infty - \infty$ arises.

Remark. The hypothesis “positive ou telle que $\mathbb{E}(|\phi(X, Y)|) < \infty$ ” is the same dichotomy that runs through every convergence and exchange statement of chapter 3, and it is not weakenable. Drop it and the two sides can both fail to be defined. Note also that the integrability is asked of $\phi(X, Y)$ — a statement about the loi jointe — and not of the espérance conditionnelle.

Remark. The function $y \mapsto \mathbb{E}(\phi(X, Y) \mid Y = y)$ can be shown to be mesurable. This course states the fact and does not prove it; the proof is of a piece with the théorème de Jirina, since a mesurable choice of the loi conditionnelle is what makes a mesurable espérance conditionnelle available. Everything below rests on it: without it, substituting $Y(\omega)$ for y would not produce a variable aléatoire and the concise form of the theorem could not be written.

Comme l’espérance conditionnelle $\mathbb{E}(\phi(X, Y) \mid Y = y)$ est une fonction de y , dont on peut montrer qu’elle est mesurable — the fact just granted — on peut en faire une variable aléatoire, notée $\mathbb{E}(\phi(X, Y) \mid Y)$, en remplaçant y par $Y(\omega)$, une fonction de $\omega \in \Omega$. Le théorème précédent s’écrit alors de manière concise comme suit :

$$\mathbb{E}(\phi(X, Y)) = \mathbb{E}(\mathbb{E}(\phi(X, Y) \mid Y)),$$

and in particular, taking $\phi(x, y) = x$,

$$\mathbb{E}(X) = \mathbb{E}(\mathbb{E}(X \mid Y))$$

dès que la variable aléatoire X est positive ou intégrable. This is the **tower property**, and it is the single most used identity of the chapter: it computes an espérance by first conditioning on whatever makes the problem easy, then averaging the answer.

Remark. Notice the type discipline. $\mathbb{E}(X \mid A)$ is a number; $\mathbb{E}(X \mid Y = y)$ is a number for each fixed y ; $\mathbb{E}(X \mid Y)$ is a *variable aléatoire*, the composition of the function $y \mapsto \mathbb{E}(X \mid Y = y)$ with Y . Only the third can be put inside an outer espérance, and mixing the three is the most common way of writing a false line in this chapter.

Example (Recovering the espérance of a minimum by conditioning). With $X = \min(U, V)$ and $Y = \max(U, V)$ as before, la loi de X sachant $Y = y$ étant uniforme sur $[0, y]$, on a $\mathbb{E}(X \mid Y = y) = y/2$, d’où $\mathbb{E}(X \mid Y) = Y/2$ as a variable aléatoire. Since $f_Y(y) = 2y \mathbb{1}_{[0,1]}(y)$ gives $\mathbb{E}(Y) = 2/3$, the tower property yields

$$\mathbb{E}(X) = \mathbb{E}(\mathbb{E}(X \mid Y)) = \mathbb{E}\left(\frac{Y}{2}\right) = \frac{1}{3},$$

which is indeed the espérance of the minimum, since $f_X(x) = 2(1-x) \mathbb{1}_{]0,1[}(x)$. The same loi conditionnelle answers questions that are not espérances: for instance $\mathbb{P}(X + Y \leq 1 \mid Y = \frac{3}{4}) = \mathbb{P}(X \leq \frac{1}{4} \mid Y = \frac{3}{4}) = \frac{1}{3}$, by measuring $[0, \frac{1}{4}]$ under the loi uniforme on $[0, \frac{3}{4}]$.

Remark. Le théorème généralise l’équivalent de la formule des probabilités totales pour l’espérance, seen in the first subsection, which it contains as a special case. Soit $(A_i)_{i \in I}$ une famille d’événements formant une partition de Ω , avec $\mathbb{P}(A_i) > 0$ pour tout i et $I \subseteq \mathbb{N}$. En définissant $Y = \sum_{i \in I} i \mathbb{1}_{A_i}$, the variable aléatoire that reports which block of the partition occurred, so that $\{Y = i\} = A_i$, on obtient :

$$\mathbb{E}(X) = \mathbb{E}(\mathbb{E}(X \mid Y)) = \sum_{i \in I} \mathbb{P}(Y = i) \mathbb{E}(X \mid Y = i) = \sum_{i \in I} \mathbb{P}(A_i) \mathbb{E}(X \mid A_i),$$

the middle equality because the loi of Y is the discrete mesure $\sum_i \mathbb{P}(A_i) \delta_i$, so an integral against $\mathbb{P}_Y$ is a sum.

Dans le cas où la loi jointe de X et Y a une densité par rapport à la mesure de Lebesgue, le théorème s'écrit, in the form one actually computes with :

$$\mathbb{E}(\phi(X, Y)) = \int \left(\int \phi(x, y) f_{X|Y=y}(x) dx \right) f_Y(y) dy$$

pour toute fonction mesurable ϕ positive ou telle que $\mathbb{E}(|\phi(X, Y)|) < \infty$. The inner integral is $\mathbb{E}(\phi(X, Y) | Y = y)$; the outer one averages it over y . As with the densité conditionnelle itself, the formula survives the replacement of the mesure de Lebesgue by any mesure produit, with sums replacing integrals in the discrete directions.

Example (A power of a uniform variable with a Bernoulli exponent). Soit $X \sim \mathcal{B}(p)$, une variable aléatoire suivant une loi de Bernoulli de paramètre $p \in]0, 1[$, et Y une variable aléatoire suivant une loi uniforme sur $[0, 1]$, indépendante de X . Conditioning on X — a variable with two atoms, so the elementary case — gives

$$\mathbb{E}(Y^X | X = 0) = \mathbb{E}(1) = 1, \quad \mathbb{E}(Y^X | X = 1) = \mathbb{E}(Y) = \frac{1}{2},$$

where the indépendance of X and Y is what allows $\mathbb{P}_{Y|X=x}$ to be replaced by $\mathbb{P}_Y$. The tower property then gives

$$\mathbb{E}(Y^X) = (1 - p) \cdot 1 + p \cdot \frac{1}{2} = 1 - \frac{p}{2},$$

and as a variable aléatoire $\mathbb{E}(Y^X | X) = 1 - X + \frac{X}{2} = 1 - \frac{X}{2}$, a function of X as the type discipline demands.

Example (Conditioning inside a triangle). Soit (X, Y) le vecteur aléatoire réel de densité $f_{X,Y} = 2 \times \mathbb{1}_\Delta$ avec $\Delta = \{(x, y) \in \mathbb{R}_+^2 : x + y \leq 1\}$. For $x \in]0, 1[$,

$$f_{Y|X=x}(y) \propto \mathbb{1}_\Delta(x, y) \propto \mathbb{1}_{]0, 1-x[}(y), \quad \text{so} \quad f_{Y|X=x}(y) = \frac{\mathbb{1}_{]0, 1-x[}(y)}{1 - x},$$

c'est une loi uniforme sur $]0, 1 - x[$, whence $\mathbb{E}(Y | X = x) = (1 - x)/2$. The normalising constant was read off from the shape of the indicator without ever computing f_X , which is the working method of the previous remark.

Example (A win rate inferred from a run of games). La fréquence de gain à un jeu, notée X , est supposée être une variable aléatoire de loi uniforme sur $[0, 1]$. Soit N le nombre de parties gagnées sur n tentatives: la loi de N sachant $X = x$ suit une loi binomiale $\mathcal{B}(n, x)$, soit :

$$\mathbb{P}(N = k | X = x) = \binom{n}{k} x^k (1 - x)^{n-k}.$$

C'est la densité conditionnelle de N sachant $X = x$ par rapport à la mesure de comptage $\mu = \sum_{k \in \mathbb{N}} \delta_k$. Le couple (X, N) a donc pour densité :

$$f_{X,N}(x, k) = \mathbb{1}_{[0,1]}(x) \binom{n}{k} x^k (1 - x)^{n-k}$$

par rapport à la mesure produit $\lambda \otimes \mu$. Reading the quotient in the other direction,

$$f_{X|N=k}(x) \propto \mathbb{1}_{[0,1]}(x) x^k (1 - x)^{n-k},$$

on reconnaît une loi Beta $\mathcal{B}(k + 1, n - k + 1)$. Conditioning has been reversed: the model was specified as “ X , then N given X ”, and what is wanted is “ X given N ”. The joint densité, which does not care which variable came first, is the object that permits the reversal.

Example (A geometric count paired with an exponential time). Fix $a > 0$ and $b > 0$ and let (X, Y) take values in $\mathbb{N} \times \mathbb{R}_+$ with loi characterised by

$$\forall n \in \mathbb{N}, \forall t \in \mathbb{R}_+, \quad \mathbb{P}(X = n, Y \leq t) = b \int_0^t \frac{(ay)^n}{n!} e^{-(a+b)y} dy.$$

The pair has densité $f_{X,Y}(n, t) = b \frac{(at)^n}{n!} e^{-(a+b)t} \mathbb{1}_{\mathbb{R}_+}(t)$ with respect to $\mu \otimes \lambda$, where $\mu = \sum_{n \in \mathbb{N}} \delta_n$ is the mesure de comptage on $\mathbb{N}$ and λ is the mesure de Lebesgue. Integrating out t gives the marginal of X ,

$$\mathbb{P}(X = n) = \frac{b}{a+b} \left(\frac{a}{a+b} \right)^n,$$

a loi géométrique on $\mathbb{N}$ of parameter $b/(a+b)$, and summing over n gives $f_Y(t) = be^{-bt} \mathbb{1}_{\mathbb{R}_+}(t)$, a loi $\mathcal{E}(b)$. Both conditionings are now quotients. In one direction,

$$f_{Y|X=n}(t) = \frac{(a+b)^{n+1}}{n!} t^n e^{-(a+b)t} \mathbb{1}_{\mathbb{R}_+}(t),$$

a loi Gamma $\Gamma(n+1, a+b)$, so that

$$\mathbb{E}(Y | X = n) = \frac{n+1}{a+b}, \quad \mathbb{E}\left(\frac{Y}{X+1} \mid X = n\right) = \frac{1}{n+1} \mathbb{E}(Y | X = n) = \frac{1}{a+b},$$

the factor $1/(n+1)$ coming out of the integral because it is constant once X is fixed at n , the variable of integration being the value of Y . The espérance conditionnelle being the same constant for every n , the tower property gives $\mathbb{E}(Y/(X+1)) = 1/(a+b)$ without any further integration. In the other direction,

$$\mathbb{P}(X = n | Y = t) = \frac{(at)^n}{n!} e^{-at},$$

a loi de Poisson $\mathcal{P}(at)$, and therefore $\mathbb{E}(X | Y = t) = at$.

Example (Splitting an exponential sum into a proportion and a total). Let $U \sim \mathcal{E}(\lambda)$ and $V \sim \mathcal{E}(\mu)$ be independent, and set $X = U + V$ and $Y = U/(U + V)$. The changement de variable $u = xy$, $v = x(1 - y)$, a diffeomorphism of $]0, +\infty[\times]0, 1[$ onto $]0, +\infty[^2$ with Jacobian determinant of absolute value x , gives

$$f_{X,Y}(x, y) = \lambda \mu x e^{-\mu x} e^{-(\lambda - \mu)xy} \mathbb{1}_{]0, +\infty[}(x) \mathbb{1}_{]0, 1[}(y).$$

When $\lambda = \mu$ the exponential in y disappears, the densité factorises as $\lambda^2 x e^{-\lambda x} \mathbb{1}_{]0, +\infty[}(x) \cdot \mathbb{1}_{]0, 1[}(y)$, and the two variables are independent: X follows $\Gamma(2, \lambda)$ and Y is uniform on $[0, 1]$, so $f_{Y|X=x} = f_Y$ as the indépendance criterion predicts. When $\lambda \neq \mu$ the marginal of X is

$$f_X(x) = \lambda \mu \frac{e^{-\lambda x} - e^{-\mu x}}{\mu - \lambda} \mathbb{1}_{]0, +\infty[}(x),$$

and dividing,

$$f_{Y|X=x}(y) = x(\mu - \lambda) \frac{e^{(\mu - \lambda)xy}}{e^{(\mu - \lambda)x} - 1} \mathbb{1}_{]0, 1[}(y), \quad x > 0,$$

which depends on x , so the variables are not independent. Integrating this densité conditionnelle over $]0, \frac{1}{2}[$ gives

$$\mathbb{P}\left(Y \leq \frac{1}{2} \mid X = x\right) = \frac{e^{(\mu - \lambda)x/2} - 1}{e^{(\mu - \lambda)x} - 1} \xrightarrow{x \rightarrow +\infty} \begin{cases} 0 & \text{if } \lambda < \mu, \\ 1 & \text{if } \lambda > \mu, \end{cases}$$

with the value $\frac{1}{2}$ for every x in the case $\lambda = \mu$. The interpretation is clean: conditionally on a very large total $U + V$, the slower-decaying component — the one with the smaller rate, hence the heavier tail — is the one that must have been large, so the proportion Y concentrates at 0 or at 1 according to which rate is bigger.

Conclusion. A loi conditionnelle given an événement non négligeable is a mesure image and behaves like any other loi. A loi conditionnelle given a variable aléatoire is a densité of $B \mapsto \mathbb{P}_{X,Y}(A \times B)$ with respect to $\mathbb{P}_Y$ — the one the théorème de Radon-Nikodym provides — defined for $\mathbb{P}_Y$ -almost every y , and existing simultaneously in A only by the théorème de Jirina. When the loi jointe has a densité with respect to a mesure produit, the densité conditionnelle is the joint divided by the marginal wherever the marginal is strictly positive, and every computation reduces to reading a proportionality in x at fixed y and normalising. Espérance conditionnelle is an integral against the loi conditionnelle, and the tower property $\mathbb{E}(X) = \mathbb{E}(\mathbb{E}(X | Y))$ turns conditioning into a method for computing espérances, valid for X positive or integrable.

6 Fonction caractéristique

Chapter 1 introduced the fonction génératrice $G_X(t) = \mathbb{E}(t^X)$ for two things: reading moments off derivatives, and turning the loi of a sum of independent variables into a product. Both were bought at a price — G_X is defined only for a variable with values in $\mathbb{N}$, and its moment formula needs a left derivative at 1 that may be infinite.

The **fonction caractéristique** (*characteristic function*) buys the same two uses at no price at all: it is defined for every real variable aléatoire, with no integrability hypothesis and no restriction on the support, because e^{itX} has modulus 1 and a bounded complex variable aléatoire always has an espérance. That single fact makes this chapter the hinge of the second half of the course. It defines φ_X , proves by the formule d'inversion that it determines the loi, extracts moments from its derivatives at 0, proves that it turns sums of independent variables into products, transposes all of this to vecteurs aléatoires, and closes with the criterion chapter 7 runs on: the components of a vecteur aléatoire are independent exactly when the joint fonction caractéristique factorises. Chapter 8 proves the théorème central limite by computing one limit of fonctions caractéristiques.

6.1 Définition et premières propriétés

Definition (Fonction caractéristique). La **fonction caractéristique** d'une variable aléatoire réelle X est la fonction $\varphi_X: \mathbb{R} \rightarrow \mathbb{C}$ définie par :

$$\forall t \in \mathbb{R}, \quad \varphi_X(t) = \mathbb{E}(e^{itX}).$$

La fonction caractéristique est donc l'espérance d'une variable aléatoire *complexe*. En identifiant une variable aléatoire complexe comme un vecteur aléatoire de dimension 2, on en définit l'espérance comme le complexe formé des espérances de ses parties réelles et imaginaires :

$$\mathbb{E}(e^{itX}) = \mathbb{E}(\cos(tX)) + i \mathbb{E}(\sin(tX)).$$

Remark. No hypothesis is needed for φ_X to exist. Whatever the loi of X — heavy-tailed, without espérance, without variance — la fonction caractéristique est toujours bien définie, both of the two real integrals above converging absolutely, car :

$$\forall t \in \mathbb{R}, \quad \mathbb{E}(|\cos(tX)|) \leq 1 \quad \text{and} \quad \mathbb{E}(|\sin(tX)|) \leq 1,$$

a bounded measurable function of X being integrable under any mesure de probabilité. Equivalently, $|e^{itX}| = 1$ pointwise. This is the contrast with the fonction génératrice of chapter 1, which needs X to take values in $\mathbb{N}$ and whose derivatives at 1 may be infinite. The fonction caractéristique of the loi de Cauchy, which has no espérance at all, appears later in this chapter and is perfectly well behaved.

Proposition (Premières propriétés). La fonction caractéristique est continue, telle que $\varphi_X(0) = 1$ et

$$\forall t \in \mathbb{R}, \quad |\varphi_X(t)| \leq 1.$$

Remark. Three separate facts, each one line. For each fixed x , les fonctions $t \mapsto \cos(tx)$ et $t \mapsto \sin(tx)$ étant continues en t et bornées — both are dominated by the constant 1, which is integrable because $\mathbb{P}$ is finite —, la continuité est une conséquence du théorème de continuité sous le signe somme of chapter 3. The value at 0 is $\mathbb{E}(e^0) = \mathbb{E}(1) = 1$. L'inégalité vient de chapter 4's probabilistic triangle inequality, read on $\mathbb{C} = \mathbb{R}^2$ with the modulus as the norm, so that $|\mathbb{E}(Z)| \leq \mathbb{E}(|Z|)$ for an integrable complex Z — applied to $Z = e^{itX}$: $|\varphi_X(t)| \leq \mathbb{E}(|e^{itX}|) = 1$. So the curve $t \mapsto \varphi_X(t)$ lives in the closed unit disc of $\mathbb{C}$ and passes through the point 1 at $t = 0$.

Remark. The converse is false. Toute fonction satisfaisant les conditions de la proposition — continuous, equal to 1 at 0 and bounded by 1 in modulus — n'est pas nécessairement la fonction caractéristique d'une variable aléatoire réelle. Il faut en plus s'assurer que cette fonction soit définie positive, and with that hypothesis the characterisation is exact. C'est le **théorème de Bochner** (*Bochner's theorem*). It is used below only to assert that a given function *is* a fonction caractéristique without exhibiting the loi.

Two structural remarks follow from the definition alone. First, replacing X by $-X$ conjugates:

$$\forall t \in \mathbb{R}, \quad \varphi_{-X}(t) = \mathbb{E}(e^{-itX}) = \overline{\varphi_X(t)}.$$

Hence la fonction caractéristique d'une variable aléatoire X dont la loi est **symétrique** (*symmetric*), au sens où $\mathbb{P}_X = \mathbb{P}_{-X}$, est à valeurs réelles, since then $\varphi_X = \overline{\varphi_X}$ — a quick sanity check on any computation. Second, when X has a densité, φ_X is a Fourier transform.

Remark (Transformée de Fourier). Si X a une densité f_X par rapport à la mesure de Lebesgue λ , alors sa fonction caractéristique est la transformée de Fourier de cette densité: by the théorème de transfert of chapter 3, $\varphi_X(t) = \int e^{itx} f_X(x) dx$ for every $t \in \mathbb{R}$, which is the Fourier transform of f_X in the convention that puts no constant in front and no minus sign in the exponent. Everything here is therefore Fourier analysis in probabilistic clothing, and the formule d'inversion of the next subsection is the Fourier inversion theorem.

Les cinq lois discrètes

The five discrete lois of chapter 1 all have fonctions caractéristiques that come straight from the definition and the théorème de transfert, which for a discrete loi reduces the espérance to a sum:

$$\varphi_X(t) = \sum_{k \in S} \mathbb{P}(X = k) e^{itk}, \quad S \text{ the support.}$$

The computations below are the ones chapter 9's table states.

Example (Loi de Bernoulli). For $X \sim \mathcal{B}(p)$ with $p \in [0, 1]$, the support is $\{0, 1\}$ and

$$\forall t \in \mathbb{R}, \quad \varphi_X(t) = (1 - p) e^{i \cdot 0 \cdot t} + p e^{i \cdot 1 \cdot t} = 1 - p + p e^{it}.$$

At $t = 0$ this is 1, as it must be, and its modulus is at most 1 because it is a convex combination of two points of the unit circle.

Example (Loi binomiale). For $X \sim \mathcal{B}(n, p)$ with $n \in \mathbb{N}$ and $p \in [0, 1]$, the binomial theorem gives

$$\varphi_X(t) = \sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} e^{itk} = \sum_{k=0}^n \binom{n}{k} (pe^{it})^k (1-p)^{n-k} = (1 - p + p e^{it})^n.$$

The answer is the Bernoulli fonction caractéristique raised to the power n , which is no accident: it is the product rule for sums of independent variables, proved below, applied to n independent Bernoulli variables.

Example (Loi de Poisson). For $X \sim \mathcal{P}(\lambda)$ with $\lambda > 0$, the support is $\mathbb{N}$ and the exponential series sums the result in closed form:

$$\varphi_X(t) = \sum_{k \geq 0} e^{-\lambda} \frac{\lambda^k}{k!} e^{itk} = e^{-\lambda} \sum_{k \geq 0} \frac{(\lambda e^{it})^k}{k!} = e^{-\lambda} e^{\lambda e^{it}} = \exp(\lambda (e^{it} - 1)).$$

The series converges absolutely for every t because $|\lambda e^{it}| = \lambda$.

Example (Loi géométrique). For $X \sim \mathcal{G}(p)$ with $p \in]0, 1]$, the support is $\mathbb{N}^*$ and $\mathbb{P}(X = k) = (1 - p)^{k-1} p$. Factoring out one term and summing the geometric series,

$$\varphi_X(t) = \sum_{k \geq 1} (1 - p)^{k-1} p e^{itk} = p e^{it} \sum_{j \geq 0} ((1 - p) e^{it})^j = \frac{p e^{it}}{1 - (1 - p) e^{it}}.$$

The geometric series converges because $|(1 - p) e^{it}| = 1 - p < 1$ for $p \in]0, 1[$; for $p = 1$ the variable is the constant 1 and the formula degenerates correctly to $\varphi_X(t) = e^{it}$.

Example (Loi uniforme discrète). For $X \sim \mathcal{U}(1, \dots, n)$ with $n \in \mathbb{N}^*$, each of the n points carries mass $1/n$ and the sum is a finite geometric one. For $t \notin 2\pi\mathbb{Z}$,

$$\varphi_X(t) = \frac{1}{n} \sum_{k=1}^n e^{itk} = \frac{1}{n} e^{it} \frac{e^{int} - 1}{e^{it} - 1} = e^{i(n+1)t/2} \frac{\sin(nt/2)}{n \sin(t/2)},$$

the second form obtained by factoring $e^{int/2}$ out of the numerator and $e^{it/2}$ out of the denominator. For $t \in 2\pi\mathbb{Z}$ every term of the sum is 1 and $\varphi_X(t) = 1$; the excluded points are exactly the zeros of the denominator, and the function extends continuously across them.

Les quatre lois à densité

For a loi with a densité the théorème de transfert turns the espérance into an intégrale de Lebesgue, and the four lois of the densité table are computed below. Three have elementary closed forms; the fourth deliberately does not, and saying so is part of the run.

Example (Loi exponentielle). For $X \sim \mathcal{E}(\lambda)$ with $\lambda > 0$, the densité is $\lambda e^{-\lambda x} \mathbb{1}_{\mathbb{R}_+}(x)$ and

$$\varphi_X(t) = \int_0^{+\infty} e^{itx} \lambda e^{-\lambda x} dx = \lambda \int_0^{+\infty} e^{-(\lambda - it)x} dx = \frac{\lambda}{\lambda - it}.$$

The improper integral converges because $|e^{-(\lambda - it)x}| = e^{-\lambda x}$ with $\lambda > 0$, and $\lambda - it$ never vanishes for the same reason, so no case distinction is needed. The loi is not symétrique and the answer is genuinely complex.

Example (Loi Gamma). For $X \sim \Gamma(a, \lambda)$ with $a, \lambda > 0$, the densité is $\frac{\lambda^a}{\Gamma(a)} x^{a-1} e^{-\lambda x} \mathbb{1}_{\mathbb{R}_+}(x)$. The computation is the exponential one with a normalisation trick: multiply and divide so that what remains under the integral is again a gamma densité, this time with parameter $\lambda - it$ in place of λ .

$$\begin{aligned} \varphi_X(t) &= \int_0^{+\infty} e^{itx} \frac{\lambda^a}{\Gamma(a)} x^{a-1} e^{-\lambda x} dx = \int_0^{+\infty} \frac{\lambda^a}{\Gamma(a)} x^{a-1} e^{-(\lambda - it)x} dx \\ &= \left(\frac{\lambda}{\lambda - it} \right)^a \int_0^{+\infty} \frac{(\lambda - it)^a}{\Gamma(a)} x^{a-1} e^{-(\lambda - it)x} dx = \left(\frac{\lambda}{\lambda - it} \right)^a, \end{aligned}$$

the last integral being 1 because its integrand is the analytic continuation of a gamma densité and $\operatorname{Re}(\lambda - it) = \lambda > 0$. The power is the principal branch, continuous in t and equal to 1 at $t = 0$. Setting $a = 1$ recovers the loi exponentielle, as it must.

Example (Loi uniforme continue). For $X \sim \mathcal{U}([a, b])$ with $a < b$, the densité is $\frac{1}{b-a} \mathbb{1}_{[a, b]}(x)$ and, for $t \neq 0$,

$$\varphi_X(t) = \int_a^b e^{itx} \frac{dx}{b-a} = \frac{e^{itb} - e^{ita}}{it(b-a)},$$

while $\varphi_X(0) = 1$. The case distinction at $t = 0$ is genuine — the written expression is $0/0$ there — and the extension is by continuity. Two specialisations recur. On $[-1, 1]$ the loi is symétrique and the answer collapses to the real function

$$\varphi_X(t) = \frac{e^{it} - e^{-it}}{2it} = \frac{\sin t}{t}, \quad t \neq 0,$$

the **cardinal sine**; and on $[0, 1]$ it is $(e^{it} - 1)/(it)$, which the moment subsection expands.

Example (Loi Beta). For $X \sim \mathcal{B}(a, b)$ with $a, b > 0$, the densité is $\frac{1}{B(a, b)} x^{a-1} (1-x)^{b-1} \mathbb{1}_{[0, 1]}(x)$ and there is no closed form in elementary functions. What there is instead is a convergent series, obtained by expanding e^{itx} and integrating term by term — legitimate by convergence dominée, the partial sums being dominated by $e^{|t|}$ times the densité on the bounded support $[0, 1]$. Since $\mathbb{E}(X^k) = B(a+k, b)/B(a, b) = \prod_{r=0}^{k-1} \frac{a+r}{a+b+r}$,

$$\varphi_X(t) = \sum_{k \geq 0} \frac{(it)^k}{k!} \mathbb{E}(X^k) = \sum_{k \geq 0} \left(\prod_{r=0}^{k-1} \frac{a+r}{a+b+r} \right) \frac{(it)^k}{k!},$$

which is the confluent hypergeometric function $M(a, a + b, it)$. Every moment exists because the support is bounded, so the series is the Taylor series at 0 in the strongest sense and the moment theorem below applies at every order. Chapter 9's table records the series and not a closed form, because there is none to record.

Example (Loi normale centrée réduite, par une équation différentielle). For $X \sim \mathcal{N}(0, 1)$ the direct integral is not elementary, and the way in is en dérivant sous le signe somme, puis en intégrant par parties. Write

$$\varphi_X(t) = \int e^{itx} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx.$$

The partial derivative in t of the integrand is $ixe^{itx} \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$, dominated in modulus by $|x| \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$, which is integrable and does not depend on t ; the théorème de dérivabilité sous le signe somme of chapter 3 therefore applies and gives

$$\varphi'_X(t) = i \int x e^{itx} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = -i \int e^{itx} \frac{1}{\sqrt{2\pi}} \frac{d}{dx} (e^{-x^2/2}) dx = i \int (it) e^{itx} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = -t \varphi_X(t),$$

using $xe^{-x^2/2} = -\frac{d}{dx} e^{-x^2/2}$ and then an integration by parts in which the bracketed term vanishes at $\pm\infty$. So φ_X vérifie l'équation différentielle $\varphi'_X(t) = -t \varphi_X(t)$, which is linear, with $\varphi_X(0) = 1$, and since the loi is symétrique, φ_X est une fonction réelle. That Cauchy problem has the unique solution

$$\forall t \in \mathbb{R}, \quad \varphi_X(t) = e^{-t^2/2}.$$

The loi normale centrée réduite is thus its own Fourier transform up to normalisation — the fact chapter 7 builds vecteurs gaussiens on and chapter 8's théorème central limite identifies as its limit.




Figure 5: Fonctions caractéristiques de trois lois on a shared axis. The two lois symétriques give real-valued curves; the exponential, which is not symétrique, needs both a real and an imaginary part. All four curves pass through or below the level 1, and the two real ones take the value 1 at $t = 0$.

6.2 Formule d'inversion

La **formule d'inversion** (*inversion formula*) permet d'exprimer la loi d'une variable aléatoire réelle à partir de sa fonction caractéristique. Avant d'énoncer ce résultat, on montre comment obtenir les atomes de la loi — by the same technique, worth seeing first because the whole proof of the formule d'inversion is that computation with a better kernel.

Proposition (Atomes de la loi). *Soit X une variable aléatoire réelle. Alors,*

$$\forall x \in \mathbb{R}, \quad \mathbb{P}(X = x) = \lim_{T \rightarrow +\infty} \frac{1}{2T} \int_{-T}^T e^{-itx} \varphi_X(t) dt.$$




Figure 6: The bound $|\varphi_X(t)| \leq 1 = \varphi_X(0)$, drawn in the complex plane. Whatever the loi, the trajectory $t \mapsto \varphi_X(t)$ stays inside the closed unit disc and touches its boundary at $t = 0$. For $\mathcal{E}(1)$ the trajectory is exactly the circle of centre $1/2$ and radius $1/2$, tangent to the unit circle at 1 ; for the loi symétrique $\mathcal{U}([-1, 1])$ it is a real segment, $\sin t/t$ ranging over $[-0.2172\dots, 1]$.

Remark. The mechanism is a Dirichlet-kernel computation followed by an exchange of limit, espérance and integral. On fixe x . Pour tout $y \neq x$,

$$\frac{1}{2T} \int_{-T}^T e^{-itx} e^{ity} dt = \frac{1}{2T} \frac{e^{iT(y-x)} - e^{-iT(y-x)}}{i(y-x)} = \frac{\sin(T(y-x))}{T(y-x)},$$

which tends to 0 as $T \rightarrow +\infty$; for $y = x$ the integrand is 1 and the average is 1 for every T . En remplaçant y par la variable aléatoire X et en prenant l'espérance, the limit inside is $\mathbb{1}_{\{X=x\}}$. On conclut par le théorème de convergence dominée et le théorème de Fubini, which move the limit and the espérance past the integral. Les conditions de ces théorèmes sont bien réunies — both are licensed by the same one-line bound — puisque :

$$\left| \frac{1}{2T} \int_{-T}^T e^{-itx} e^{itX} dt \right| \leq \frac{1}{2T} \int_{-T}^T |e^{-itx} e^{itX}| dt = 1,$$

a constant, which is integrable because $\mathbb{P}$ is a finite mesure.

Theorem (Formule d'inversion). *Soit X une variable aléatoire réelle de fonction de répartition F_X . Alors pour tous points de continuité a, b de F_X , avec $a < b$,*

$$F_X(b) - F_X(a) = \lim_{T \rightarrow +\infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} \varphi_X(t) dt.$$

The hypothesis that a and b be continuity points of F_X is not decoration. The proof below produces, for arbitrary $a < b$, the quantity $\mathbb{P}(a < X < b) + \frac{1}{2} \mathbb{P}(X = a) + \frac{1}{2} \mathbb{P}(X = b)$, which equals $F_X(b) - F_X(a)$ as soon as neither endpoint is an atom. The half weights at the endpoints are the signature of a Dirichlet kernel and they are exactly what the continuity hypothesis kills.

Proof. On fixe $a < b$. Pour tout $T > 0$, soit :

$$I_T = \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} e^{itx} dt,$$

which is well defined: la fonction à intégrer, once extended by continuity, est continue sur $[-T, T]$ — near $t = 0$ the numerator vanishes to first order and cancels the it in the denominator.

Step 1: reduce I_T to Dirichlet integrals. Splitting the range at 0 and substituting $t \mapsto -t$ on the negative half,

$$\begin{aligned} I_T &= \int_0^T \frac{e^{-ita} - e^{-itb}}{it} e^{itx} dt + \int_0^T \frac{e^{ita} - e^{itb}}{-it} e^{-itx} dt \\ &= \int_0^T \frac{e^{it(x-a)} - e^{-it(x-a)}}{it} dt - \int_0^T \frac{e^{it(x-b)} - e^{-it(x-b)}}{it} dt \\ &= 2 \left(\int_0^T \frac{\sin(t(x-a))}{t} dt - \int_0^T \frac{\sin(t(x-b))}{t} dt \right) = 2 \left(\int_0^{T(x-a)} \frac{\sin u}{u} du - \int_0^{T(x-b)} \frac{\sin u}{u} du \right), \end{aligned}$$

the last equality by the changement de variable $u = t(x-a)$ in the first integral and $u = t(x-b)$ in the second, valid with the sign conventions because $u \mapsto \sin u/u$ is even.

Step 2: take $T \rightarrow +\infty$ using the Dirichlet integral. The classical Dirichlet integral — quoted here as an intégrale de Riemann impropre, chapter 3 recording its value π over the whole line together with the warning that it is improper-Riemann and not Lebesgue — states

$$\int_0^{+\infty} \frac{\sin u}{u} du = \frac{\pi}{2}.$$

Applying it to each of the two terms of Step 1, according to the signs of $x-a$ and $x-b$, gives

$$\lim_{T \rightarrow +\infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} e^{itx} dt = \begin{cases} 1 & \text{if } x \in]a, b[, \\ \frac{1}{2} & \text{if } x \in \{a, b\}, \\ 0 & \text{otherwise.} \end{cases}$$

En remplaçant x par la variable aléatoire X et en prenant l'espérance of this limit,

$$\mathbb{E} \left(\lim_{T \rightarrow +\infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} e^{itX} dt \right) = \mathbb{P}(a < X < b) + \frac{1}{2} \mathbb{P}(X = a) + \frac{1}{2} \mathbb{P}(X = b).$$

Step 3: exchange the limit and the espérance. Par le théorème de convergence dominée, the limit comes out of the espérance:

$$\lim_{T \rightarrow +\infty} \frac{1}{2\pi} \mathbb{E} \left(\int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} e^{itX} dt \right) = \mathbb{P}(a < X < b) + \frac{1}{2} \mathbb{P}(X = a) + \frac{1}{2} \mathbb{P}(X = b).$$

Les conditions d'application du théorème sont bien satisfaites car Step 1 has already bounded the integral, uniformly in T and in X , by a finite constant:

$$\forall T \geq 0, \quad \left| \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} e^{itX} dt \right| \leq 4 \sup_{s \geq 0} \left| \int_0^s \frac{\sin u}{u} du \right| < \infty,$$

the supremum being finite because $s \mapsto \int_0^s \sin u/u du$ is continuous with a finite limit at $+\infty$. A constant is integrable under a mesure de probabilité, so convergence dominée applies.

Step 4: exchange the espérance and the dt integral. Le théorème de Fubini donne :

$$\mathbb{E} \left(\int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} e^{itX} dt \right) = \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} \mathbb{E}(e^{itX}) dt = \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} \varphi_X(t) dt.$$

Fubini needs the mesure produit to be σ -finie — it is, $\mathbb{P}$ being finite and the mesure de Lebesgue on the bounded interval $[-T, T]$ being finite too — and needs the integrand to be integrable for the mesure produit. À nouveau, les conditions d'application du théorème sont bien satisfaites car, for every real x ,

$$\left| \frac{e^{-ita} - e^{-itb}}{it} e^{itx} \right| = \left| \frac{e^{it(b-a)/2} - e^{-it(b-a)/2}}{t} \right| = \left| \frac{2 \sin(t(b-a)/2)}{t} \right| \leq b-a,$$

de sorte que

$$\mathbb{E} \left(\left| \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} e^{itX} dt \right| \right) \leq 2T(b-a) < \infty.$$

Step 5: conclude. Finalement, combining Steps 3 and 4,

$$\lim_{T \rightarrow +\infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} \varphi_X(t) dt = \mathbb{P}(a < X < b) + \frac{1}{2} \mathbb{P}(X = a) + \frac{1}{2} \mathbb{P}(X = b).$$

Lorsque a et b sont des points de continuité de F_X , the two atoms vanish and the right-hand side is $\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a)$: on obtient le résultat annoncé.

Remark. Each exchange in the proof is justified by its own explicit bound — $4 \sup_s \left| \int_0^s \sin u/u \right|$ for convergence dominée, $b-a$ for Fubini — and that is the shape of every serious computation here: write the kernel, bound it by something integrable that does not depend on the parameter being sent to a limit, then exchange. The bound $|\sin(cs)/s| \leq |c|$ is used twice and is worth remembering separately.

Corollary (Caractérisation de la loi). *Pour toutes variables aléatoires réelles X, Y , on a*

$$\mathbb{P}_X = \mathbb{P}_Y \iff \varphi_X = \varphi_Y.$$

Remark. La condition nécessaire est immédiate, par le théorème de transfert: equal lois give equal espérances of every bounded mesurable function, in particular of $x \mapsto e^{itx}$. The converse is the formule d'inversion plus one countability argument. Soit A et B les ensembles des atomes of the two lois; ces ensembles étant au plus dénombrables, c'est également le cas de $A \cup B$, whose complement is therefore dense and unbounded below. Pour tout $b \notin A \cup B$, la formule d'inversion donne $F_X(b) - F_X(a) = F_Y(b) - F_Y(a)$ for every $a \notin A \cup B$, and letting $a \rightarrow -\infty$ en dehors de $A \cup B$ yields $F_X(b) = F_Y(b)$; par ailleurs, pour tout $b \in A \cup B$, right continuity gives $F_X(b) = \lim_{a \downarrow b} F_X(a)$, the limit again taken en dehors de $A \cup B$, and the same for Y . On a finalement $F_X = F_Y$, si bien que $\mathbb{P}_X = \mathbb{P}_Y$.

La fonction caractéristique porte bien son nom, au sens où elle caractérise la loi, and this is what every later use rests on: to identify the loi of a complicated variable aléatoire, compute its fonction caractéristique and recognise the answer. Chapters 7 and 8 both identify a loi that way.

Corollary (Formule d'inversion pour une loi à densité). *Soit X une variable aléatoire réelle dont la fonction caractéristique est intégrable sur $\mathbb{R}$. Alors X a pour densité la fonction :*

$$\forall x \in \mathbb{R}, \quad f_X(x) = \frac{1}{2\pi} \int e^{-itx} \varphi_X(t) dt.$$

Remark. The integrability of φ_X over the whole line is the hypothesis that makes this work and it cannot be weakened to the boundedness the first proposition of the chapter gives for free. It does two jobs. First it kills the atoms — la loi n'a pas d'atome — by the atom formula,

$$\left| \frac{1}{2T} \int_{-T}^T e^{-itx} \varphi_X(t) dt \right| \leq \frac{1}{2T} \int_{-T}^T |\varphi_X(t)| dt \leq \frac{1}{2T} \int |\varphi_X(t)| dt \xrightarrow{T \rightarrow +\infty} 0,$$

so $\mathbb{P}(X = x) = 0$ for every x and the half-weight terms of the formule d'inversion drop. Second it licenses a Fubini and a convergence dominée in the computation

$$\mathbb{P}(a < X < b) = \lim_{T \rightarrow +\infty} \frac{1}{2\pi} \int_{-T}^T \left(\int_a^b e^{-itx} dx \right) \varphi_X(t) dt = \int_a^b \left(\frac{1}{2\pi} \int e^{-itx} \varphi_X(t) dt \right) dx,$$

which exhibits the bracketed function as a densité of X on every interval, hence — the intervals generating $\mathcal{B}(\mathbb{R})$ — as a densité. Note the asymmetry of the two formulas: φ_X is an integral of e^{itx} against the loi, and f_X an integral of e^{-itx} against φ_X , divided by 2π .

Example (Recovering the Cauchy densité from its fonction caractéristique). Let $\varphi_X(t) = e^{-|t|}$. By the théorème de Bochner, cette fonction est la fonction caractéristique d'une certaine variable aléatoire réelle X — it is continuous, equal to 1 at 0 and bounded by 1, and it is définie positive, which is the extra hypothesis the théorème de Bochner asks for and which is not checked here — and it is integrable on $\mathbb{R}$, with $\int e^{-|t|} dt = 2$. The formule d'inversion pour une loi à densité therefore applies and gives

$$\begin{aligned} f_X(x) &= \frac{1}{2\pi} \int e^{-itx} e^{-|t|} dt = \frac{1}{2\pi} \left(\int_{-\infty}^0 e^{-itx} e^t dt + \int_0^{+\infty} e^{-itx} e^{-t} dt \right) \\ &= \frac{1}{2\pi} \left(\frac{1}{1-ix} + \frac{1}{1+ix} \right) = \frac{1}{2\pi} \cdot \frac{2}{1+x^2} = \frac{1}{\pi(1+x^2)}. \end{aligned}$$

Il s'agit de la loi de Cauchy. The example is instructive twice over: it is a loi produced from a fonction caractéristique rather than the other way round, and it is the standard counter-example of the next subsection, having no espérance at all.

6.3 Calcul de moments

The second use of the fonction caractéristique is the one chapter 1 had for the fonction génératrice: derivatives at a point return moments. Here the point is 0 rather than 1^- , and the derivatives are two-sided.

Definition (Moment). Soit k un entier non nul. On appelle **moment d'ordre k** (*moment of order k*) d'une variable aléatoire réelle X la valeur $\mathbb{E}(X^k)$, lorsqu'elle est bien définie. On dit que X **admet un moment d'ordre k** si cette valeur est finie.

Lemma. Une variable aléatoire X qui admet un moment d'ordre k admet des moments jusqu'à l'ordre k (au moins).

Remark. One line of algebra. On a pour tout $j = 1, \dots, k$,

$$|X|^j \leq \max(|X|^k, 1) \leq |X|^k + 1,$$

the first inequality because $u \mapsto u^j$ is below $\max(u^k, 1)$ on $\mathbb{R}_+$ for $j \leq k$. En appliquant l'espérance, $\mathbb{E}(|X|^j)$ is finite whenever $\mathbb{E}(|X|^k)$ is, and $\mathbb{E}(1) = 1 < \infty$ because $\mathbb{P}$ is a mesure de probabilité. The lemma is what lets the moment theorem differentiate k times rather than only once.

Theorem (Calcul de moments). Si la variable aléatoire X admet un moment d'ordre k , alors sa fonction caractéristique φ_X est k fois dérivable en 0 et

$$\varphi_X^{(k)}(0) = i^k \mathbb{E}(X^k).$$

Réciproquement, si la fonction caractéristique φ_X est k fois dérivable en 0, avec k pair, alors la variable aléatoire X admet des moments jusqu'à l'ordre k et ceux-ci sont donnés par la formule précédente.

Both hypotheses are load-bearing and neither may be dropped. The direct implication needs X to admit a moment d'ordre k — without it there is nothing to dominate the k -th derivative of the integrand and the conclusion itself fails — φ_X need not even be differentiable at 0 — as the loi de Cauchy shows below. The converse needs k even because the proof does: the sign identity $-\varphi_X''(0) = |\varphi_X''(0)|$, and the induction step behind it, rest on the positivity of $X^{2p}(1 - \cos(tX))$. The caveat stated separately below — that φ_X being of class C^1 does not make X integrable — is the same restriction at the first order.

Remark. **The direct implication.** Pour tout x réel, on a :

$$\frac{\partial^k}{\partial t^k} e^{itx} = i^k x^k e^{itx}, \quad \text{hence} \quad \left| \frac{\partial^k}{\partial t^k} e^{itX} \right| = |X|^k,$$

a dominating function that does not depend on t and is integrable exactly because X admet un moment d'ordre k . The lemma above supplies the same for every intermediate order $j \leq k$, so **le théorème de**

dérivabilité sous le signe somme of chapter 3 may be applied k times in succession — that theorem is the dependency, and it is what the hypothesis on the moment is there to feed. Evaluating at $t = 0$, on en déduit que :

$$\varphi_X^{(k)}(0) = \frac{\partial^k}{\partial t^k} \mathbb{E}(e^{itX}) \Big|_{t=0} = i^k \mathbb{E}(X^k).$$

Remark. The converse. A Taylor expansion at 0 turned into an inequality by the lemme de Fatou, run at $k = 2$ and then by induction on p for $k = 2p$. Two-fold differentiability at 0 and the identity $\varphi_X(t) + \varphi_X(-t) = 2 \mathbb{E}(\cos(tX))$ give

$$\lim_{t \rightarrow 0} \frac{2}{t^2} \mathbb{E}(1 - \cos(tX)) = -\varphi_X''(0) = |\varphi_X''(0)|,$$

la dernière égalité venant du fait que le terme de gauche est positif, $1 - \cos \geq 0$ — which is exactly where the parity of k enters. Along any $t_n \rightarrow 0$ the integrand tends to X^2 , so, par le lemme de Fatou, $\mathbb{E}(X^2)$ is bounded by $|\varphi_X''(0)| < \infty$. The induction step repeats this with $\varphi_X^{(2p)}$ in place of φ_X , using the induction hypothesis $\varphi_X^{(2p)}(0) = (-1)^p \mathbb{E}(X^{2p})$ and differentiating the same cosine identity $2p$ times under the integral sign, to bound $\mathbb{E}(X^{2p+2})$ by $|\varphi_X^{(2p+2)}(0)| < \infty$.

Remark. A caveat that is easy to lose: il n'est **pas** suffisant que la fonction caractéristique φ_X soit de classe C^1 pour que la variable aléatoire X soit intégrable. Une condition suffisante est que φ_X soit de classe C^2 . This is the same parity phenomenon as in the theorem, stated for the weakest case: one derivative buys nothing, two buy a first and a second moment.

In practice the theorem is almost never applied by differentiating k times. It is applied by expanding φ_X in a Taylor series at 0 and reading the coefficients: once φ_X is known to be k times differentiable at 0, the theorem fixes its Taylor coefficients as the $i^j \mathbb{E}(X^j)/j!$, so matching any expansion against $\sum_{j \leq k} i^j \mathbb{E}(X^j) t^j/j! + o(t^k)$ reads the moments off. The expansion alone is weaker than the differentiability the theorem asks for, so it is a way of applying the theorem and not a restatement of it. Three examples show the pattern, and one shows the failure.

Example (Moments de la loi exponentielle). For $X \sim \mathcal{E}(\lambda)$ the fonction caractéristique $\varphi_X(t) = \lambda/(\lambda - it)$ expands as a geometric series in it/λ :

$$\varphi_X(t) = \frac{1}{1 - it/\lambda} = 1 + \frac{it}{\lambda} + \left(\frac{it}{\lambda}\right)^2 + o(t^2) = 1 + \frac{it}{\lambda} - \frac{t^2}{\lambda^2} + o(t^2).$$

Matching against $1 + i \mathbb{E}(X)t - \mathbb{E}(X^2)t^2/2 + o(t^2)$ gives

$$\mathbb{E}(X) = \frac{1}{\lambda}, \quad \mathbb{E}(X^2) = \frac{2}{\lambda^2}, \quad \text{Var}(X) = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}.$$

Example (Moments de la loi uniforme sur $[0, 1]$). For $X \sim \mathcal{U}([0, 1])$, $\varphi_X(t) = (e^{it} - 1)/(it)$ for $t \neq 0$. Comme $e^{it} = 1 + it - t^2/2 - it^3/6 + o(t^3)$, on obtient, dividing by it :

$$\varphi_X(t) = 1 + \frac{it}{2} - \frac{t^2}{6} + o(t^2),$$

on en déduit

$$\mathbb{E}(X) = \frac{1}{2}, \quad \mathbb{E}(X^2) = \frac{1}{3}, \quad \text{Var}(X) = \frac{1}{3} - \frac{1}{4} = \frac{1}{12}.$$

Example (Moments de la loi Gamma). For $X \sim \Gamma(a, \lambda)$, $\varphi_X(t) = (1 - it/\lambda)^{-a}$, and the binomial series $(1 - u)^{-a} = 1 + au + a(a+1)u^2/2 + o(u^2)$ with $u = it/\lambda$ gives

$$\varphi_X(t) = 1 + \frac{ia t}{\lambda} - \frac{a(a+1)}{2} \frac{t^2}{\lambda^2} + o(t^2),$$

so that

$$\mathbb{E}(X) = \frac{a}{\lambda}, \quad \mathbb{E}(X^2) = \frac{a(a+1)}{\lambda^2}, \quad \text{Var}(X) = \frac{a(a+1) - a^2}{\lambda^2} = \frac{a}{\lambda^2}.$$

Setting $a = 1$ recovers the exponential line above, as a check.

Example (Les quatre premiers moments de la loi normale centrée réduite). For $X \sim \mathcal{N}(0, 1)$, $\varphi_X(t) = e^{-t^2/2}$, and expanding the exponential to two terms,

$$\varphi_X(t) = 1 - \frac{t^2}{2} + \frac{t^4}{8} + o(t^4).$$

The odd powers are absent, which is the symmetry of the loi reappearing. Matching coefficients against $\sum_{j \leq 4} i^j \mathbb{E}(X^j) t^j / j!$ gives

$$\mathbb{E}(X) = 0, \quad \mathbb{E}(X^2) = 1, \quad \mathbb{E}(X^3) = 0, \quad \mathbb{E}(X^4) = 3.$$

The fourth moment being 3 rather than 1 is the value worth memorising, and it is read straight off the t^4 coefficient of $e^{-t^2/2}$.

Example (A loi whose fonction caractéristique is not differentiable at zero). La loi de Cauchy n'a pas d'espérance: $\int |x|/(\pi(1+x^2)) dx$ diverges logarithmically. Its fonction caractéristique is $\varphi_X(t) = e^{-|t|}$, which is continuous everywhere, of modulus at most 1, equal to 1 at 0 — and cette fonction n'est *pas* dérivable en 0, the left and right derivatives being +1 and -1. The theorem's direct implication is therefore consistent: a loi with no moment d'ordre 1 may not have a differentiable fonction caractéristique at 0. This is the example to reach for whenever the hypothesis “ X admet un moment d'ordre k ” looks removable.

6.4 Somme de variables aléatoires indépendantes

The third use — and the one chapter 8 runs on — is that the fonction caractéristique converts the convolution of lois into an ordinary product of functions.

Proposition. Soit X et Y deux variables aléatoires réelles indépendantes. La fonction caractéristique de leur somme est donnée par :

$$\forall t \in \mathbb{R}, \quad \varphi_{X+Y}(t) = \varphi_X(t) \varphi_Y(t).$$

Proof. Fix $t \in \mathbb{R}$. Since $X \perp\!\!\!\perp Y$, the variables aléatoires e^{itX} and e^{itY} are independent as well, being mesurable functions of X and of Y respectively; both are bounded, hence integrable, so the product rule for espérances of independent integrable variables applies:

$$\varphi_{X+Y}(t) = \mathbb{E}\left(e^{it(X+Y)}\right) = \mathbb{E}\left(e^{itX} e^{itY}\right) = \mathbb{E}\left(e^{itX}\right) \mathbb{E}\left(e^{itY}\right) = \varphi_X(t) \varphi_Y(t).$$

Remark. One line, and it is worth noticing what does *not* appear in it. There is no integrability hypothesis on X or Y , because e^{itX} and e^{itY} are bounded whatever the lois; there is no hypothesis of a densité, so the result covers discrete and continuous lois at once; and there is no convolution integral to compute. Combined with the corollary that the fonction caractéristique determines the loi, the proposition is a complete method for finding the loi of a sum of independent variables: multiply, then recognise. By induction it extends immediately to n independent summands, and for n i.i.d. summands it reads $\varphi_{S_n} = \varphi_{X_1}^n$ — which is the identity the théorème central limite is proved from in chapter 8.

Example (A normal variable with general parameters). Soit $Z \sim \mathcal{N}(0, 1)$. La variable aléatoire $X = \sigma Z + \mu$ suit une loi normale $\mathcal{N}(\mu, \sigma^2)$. An affine changement de variable inside the espérance gives

$$\forall t \in \mathbb{R}, \quad \varphi_X(t) = \mathbb{E}\left(e^{it(\sigma Z + \mu)}\right) = e^{i\mu t} \varphi_Z(\sigma t) = e^{i\mu t} e^{-\sigma^2 t^2/2}.$$

The two operations used — $\varphi_{aX+b}(t) = e^{ibt} \varphi_X(at)$ — are worth isolating, since they are needed again in chapter 8 to normalise a sum.




Figure 7: The product rule, drawn. On the left, two $\mathcal{E}(1)$ densités and their convolution, the $\Gamma(2, 1)$ densité xe^{-x} ; on the right, the real parts of the corresponding fonctions caractéristiques, the product $(1/(1-it))^2$ having real part $(1-t^2)/(1+t^2)^2$. The convolution on the left costs an integral; the product on the right costs a multiplication.

Example (The sum of two independent normal variables is normal). Let $X \sim \mathcal{N}(\mu_1, \sigma_1^2)$ and $Y \sim \mathcal{N}(\mu_2, \sigma_2^2)$ be independent. Multiplying the fonctions caractéristiques of the previous example,

$$\varphi_{X+Y}(t) = e^{i\mu_1 t} e^{-\sigma_1^2 t^2/2} e^{i\mu_2 t} e^{-\sigma_2^2 t^2/2} = e^{i(\mu_1+\mu_2)t} e^{-(\sigma_1^2+\sigma_2^2)t^2/2},$$

which is the fonction caractéristique of $\mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$. Since the fonction caractéristique determines the loi, the sum follows that loi: la somme de deux variables aléatoires indépendantes suivant des lois normales suit une loi normale, d'espérance la somme des espérances et de variance la somme des variances. The indépendance hypothesis is essential — without it only the means add.

Example (A sum of independent exponential variables is a gamma variable). Soit $X_1, \dots, X_n$ des variables aléatoires i.i.d. de loi $\mathcal{E}(\lambda)$ et $S = X_1 + \dots + X_n$ leur somme. The product rule and the exponential computation give

$$\varphi_S(t) = \varphi_{X_1}(t) \cdots \varphi_{X_n}(t) = (\varphi_{X_1}(t))^n = \left(\frac{\lambda}{\lambda - it} \right)^n,$$

which is la fonction caractéristique d'une loi $\Gamma(n, \lambda)$. Hence $S \sim \Gamma(n, \lambda)$. Computing the same convolution directly would mean $n - 1$ nested integrals.

Example (The gamma family is stable in its first parameter). Soit $X \sim \Gamma(a, \lambda)$ et $Y \sim \Gamma(b, \lambda)$ indépendantes, with the *same* second parameter λ . Then

$$\forall t \in \mathbb{R}, \quad \varphi_{X+Y}(t) = \left(\frac{\lambda}{\lambda - it} \right)^a \left(\frac{\lambda}{\lambda - it} \right)^b = \left(\frac{\lambda}{\lambda - it} \right)^{a+b},$$

so $X + Y \sim \Gamma(a + b, \lambda)$. The equality of the two λ 's is what makes the exponents add; with different rate parameters the product is not of gamma form and the sum is not a gamma variable.

Example (The loi du χ^2 as a loi Gamma). For $Z \sim \mathcal{N}(0, 1)$, combining the two exponents and rescaling the Gaussian integral — legitimate for a complex parameter of positive real part — gives

$$\varphi_{Z^2}(t) = \mathbb{E}(e^{itZ^2}) = \int e^{itz^2} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = \int e^{-\frac{1}{2}(1-2it)z^2} \frac{1}{\sqrt{2\pi}} dz = \frac{1}{\sqrt{1-2it}},$$

which is $(\frac{1}{2}/(\frac{1}{2} - it))^{1/2}$, la fonction caractéristique d'une loi $\Gamma(\frac{1}{2}, \frac{1}{2})$. By definition, la **loi du χ^2 à n degrés de liberté** (*chi-squared distribution with n degrees of freedom*) est une loi Gamma $\Gamma(\frac{n}{2}, \frac{1}{2})$, so the previous example gives at once that la somme des carrés de n variables aléatoires normales centrées réduites indépendantes suit une loi du χ^2 à n degrés de liberté, and that la somme de deux variables indépendantes de lois du χ^2 à n et m degrés de liberté follows a loi du χ^2 à $n + m$ degrés de liberté.

Example (A geometric number of exponential summands). Soit $X_1, X_2, \dots$ une suite de variables aléatoires i.i.d. de loi $\mathcal{E}(\lambda)$, et N une variable aléatoire de loi géométrique $\mathcal{G}(p)$ de paramètre $p \in]0, 1[$, indépendante de cette suite. On note $S = \sum_{i=1}^N X_i$, a sum with a *random* number of terms. Conditioning on N and using the previous computation for a fixed number of summands,

$$\varphi_S(t) = \sum_{n \geq 1} \mathbb{P}(N = n) \mathbb{E}(e^{itS} \mid N = n) = \sum_{n \geq 1} (1-p)^{n-1} p \left(\frac{\lambda}{\lambda - it} \right)^n = \frac{p\lambda}{p\lambda - it},$$

the last step being the geometric sum $\sum_{n \geq 1} (1-p)^{n-1} p z^n = pz/(1 - (1-p)z)$ with $z = \lambda/(\lambda - it)$. So $S \sim \mathcal{E}(p\lambda)$: a geometric number of independent exponential waiting times is again an exponential waiting time, with the rate thinned by p . The conditioning step is the discrete espérance conditionnelle of chapter 1, and the interchange of the sum and the espérance is convergence dominée, the partial sums being bounded by 1.

Example (The loi de Cauchy is stable under averaging). Soit $X_1, \dots, X_n$ des variables aléatoires i.i.d. suivant la loi de Cauchy, so $\varphi_{X_1}(t) = e^{-|t|}$. The fonction caractéristique of the arithmetic mean is

$$\varphi_{\frac{1}{n}(X_1 + \dots + X_n)}(t) = \varphi_{X_1 + \dots + X_n}\left(\frac{t}{n}\right) = \left(\varphi_{X_1}\left(\frac{t}{n}\right)\right)^n = \left(e^{-|t|/n}\right)^n = e^{-|t|},$$

so la moyenne arithmétique of n i.i.d. Cauchy variables suit une loi de Cauchy — the same one, whatever n . Averaging buys nothing, and neither does averaging in the other sense: the inverse of a Cauchy variable is again a Cauchy variable, so the $1/X_i$ are i.i.d. with the loi de Cauchy, their arithmetic mean is Cauchy by the computation just made, and la moyenne harmonique $n/(1/X_1 + \dots + 1/X_n)$, being the inverse of that arithmetic mean, suit également une loi de Cauchy. This is the standard illustration that the loi forte des grands nombres and the théorème central limite of chapter 8 genuinely need their moment hypotheses, which the loi de Cauchy fails at the first order.

Remark (The parallel with the fonction génératrice of chapter 1). The two transforms of the course have the same two uses and differ in one respect only.

- **Moments by differentiation.** G_X gives factorial moments from left derivatives at 1, when those are finite, and φ_X gives ordinary moments from two-sided derivatives at 0, when the moment exists:

$$\mathbb{E}(X(X-1)\cdots(X-k+1)) = G_X^{(k)}(1^-), \quad \varphi_X^{(k)}(0) = i^k \mathbb{E}(X^k).$$

- **Products for sums of independents.** $G_{X+Y} = G_X G_Y$ and $\varphi_{X+Y} = \varphi_X \varphi_Y$, proved by exactly the same line: the exponential turns a sum into a product and indépendance splits the espérance.
- **The difference.** $G_X(t) = \mathbb{E}(t^X)$ requires X to take values in $\mathbb{N}$ and requires $|t| \leq 1$ for the series to converge, and even then its derivative at 1 may be infinite. φ_X requires nothing at all: it is defined for every real variable aléatoire and every real t , because $|e^{itX}| = 1$. That is the whole of the advantage, and it is why the fonction caractéristique and not the fonction génératrice is the tool of chapters 7 and 8.

Both transforms characterise the loi — G_X through $\mathbb{P}(X = k) = G_X^{(k)}(0)/k!$, φ_X through the formule d'inversion — so the choice between them is a matter of which is easier to compute, and for an $\mathbb{N}$ -valued variable that is often G_X .

6.5 Cas des vecteurs aléatoires

Les résultats précédents se généralisent à des vecteurs aléatoires réels. The scalar results are deliberately restated below rather than generalised in place, in compressed form: the statements come first and the remark that follows says which of them are word-for-word transpositions and which are genuinely different.

Definition (Fonction caractéristique d'un vecteur aléatoire). La **fonction caractéristique** d'un vecteur aléatoire réel X de dimension n est la fonction $\varphi_X : \mathbb{R}^n \rightarrow \mathbb{C}$ définie par :

$$\forall t \in \mathbb{R}^n, \quad \varphi_X(t) = \mathbb{E}\left(e^{it^T X}\right),$$

where $t^T X = t_1 X_1 + \dots + t_n X_n$.

As in dimension 1, la fonction caractéristique est continue, telle que $\varphi_X(0) = 1$ et

$$\forall t \in \mathbb{R}^n, \quad |\varphi_X(t)| \leq 1,$$

for the same three reasons: continuité sous le signe somme with the constant 1 as dominating function, the value of the integrand at $t = 0$, and the modulus inequality applied to a variable of modulus 1.

Theorem (Formule d'inversion pour un vecteur aléatoire). Soit X un vecteur aléatoire réel de fonction de répartition F_X . Alors pour tous points de continuité a, b de F_X , avec $a < b$ composante par composante,

$$F_X(b) - F_X(a) = \lim_{T_1 \rightarrow +\infty} \dots \lim_{T_n \rightarrow +\infty} \frac{1}{(2\pi)^n} \int_{-T_1}^{T_1} \dots \int_{-T_n}^{T_n} \prod_{j=1}^n \frac{e^{-it_j a_j} - e^{-it_j b_j}}{it_j} \varphi_X(t) dt.$$

Corollary (Caractérisation de la loi). Pour tous vecteurs aléatoires réels X, Y , on a

$$\mathbb{P}_X = \mathbb{P}_Y \iff \varphi_X = \varphi_Y.$$

Corollary (Formule d'inversion pour une loi à densité). Soit X un vecteur aléatoire réel dont la fonction caractéristique est intégrable sur $\mathbb{R}^n$. Alors X a pour densité la fonction :

$$\forall x \in \mathbb{R}^n, \quad f_X(x) = \frac{1}{(2\pi)^n} \int e^{-it^T x} \varphi_X(t) dt.$$

Definition (Moment d'un vecteur aléatoire). Soit k un entier non nul. On appelle **moment d'ordre k** d'un vecteur aléatoire réel X le vecteur $\mathbb{E}(X^k)$, lorsqu'il est bien défini. On dit que X admet un moment d'ordre k si ce vecteur est fini.

Lemma. Soit X un vecteur aléatoire réel qui admet un moment d'ordre k . Alors pour tous entiers naturels $j_1, \dots, j_n$ de somme inférieure ou égale à k ,

$$\mathbb{E}\left(|X_1^{j_1} \dots X_n^{j_n}|\right) < \infty.$$

Remark. The same algebraic line as in dimension 1, with a maximum over the components in place of a maximum over the orders:

$$\left|X_1^{j_1} \dots X_n^{j_n}\right| \leq \max(|X_1|^k, \dots, |X_n|^k, 1) \leq |X_1|^k + \dots + |X_n|^k + 1,$$

and en appliquant l'espérance, on obtient le résultat annoncé, each term on the right being finite by hypothesis. What the lemma controls is a *mixed* moment, which has no counterpart in dimension 1.

Theorem (Calcul de moments d'un vecteur aléatoire). Si le vecteur aléatoire X admet un moment d'ordre k , alors sa fonction caractéristique φ_X est k fois dérivable en 0 et pour tous entiers naturels $j_1, \dots, j_n$ de somme égale à k ,

$$\frac{\partial^{j_1} \dots \partial^{j_n}}{\partial t_1^{j_1} \dots \partial t_n^{j_n}} \varphi_X(0) = i^k \mathbb{E}\left(X_1^{j_1} \dots X_n^{j_n}\right).$$

Réciproquement, si la fonction caractéristique φ_X est k fois dérivable en 0, avec k pair, alors les variables aléatoires $X_1^{j_1} \dots X_n^{j_n}$ sont d'espérances finies, données par la formule précédente, pour tous entiers naturels $j_1, \dots, j_n$ de somme inférieure ou égale à k .

Remark. La première partie du théorème se prouve exactly as in dimension 1, differentiating under the integral sign, with the vector lemma above supplying the dominating function $|X_1^{j_1} \dots X_n^{j_n}|$ in place of $|X|^k$. The converse reduces to the scalar theorem by a projection: pour tout $j = 1, \dots, n$, la fonction caractéristique de la variable aléatoire X_j est donnée par $\varphi_{X_j}(t) = \varphi_X(te_j)$ pour tout $t \in \mathbb{R}$, où e_j désigne le vecteur unitaire sur la composante j . Cette fonction caractéristique étant k fois dérivable en 0, avec k pair, the scalar theorem gives X_j a moment d'ordre k ; le vecteur aléatoire X admet donc un moment d'ordre k , and the direct implication finishes.

Remark (Which of these are verbatim transpositions, and which are not). Worth separating, because reading the six statements as a block hides the two that carry new content.

- **Verbatim transpositions**, with $t^T x$ in place of tx and $\mathbb{R}^n$ in place of $\mathbb{R}$: the definition of φ_X , the continuity and the bounds $\varphi_X(0) = 1$ and $|\varphi_X| \leq 1$, and the corollary that the fonction caractéristique characterises the loi. Nothing in their proofs changes.
- **Transpositions that change shape**. The formule d'inversion becomes an *iterated* limit, one T_j per coordinate, over a product of n scalar kernels and with $(2\pi)^n$ in the denominator; its hypothesis is that $a < b$ hold componentwise, which is strictly stronger than $a < b$ for vectors read any other way. The formule d'inversion pour une loi à densité keeps the same shape but with $(2\pi)^n$ and the scalar product in the exponent, and its hypothesis is integrability over the whole of $\mathbb{R}^n$.
- **Genuinely different statements**. The lemma is about *mixed* moments $\mathbb{E}(|X_1^{j_1} \dots X_n^{j_n}|)$ with $j_1 + \dots + j_n \leq k$, where the scalar lemma was about lower-order moments $\mathbb{E}(|X|^j)$ with $j \leq k$; and the moment theorem returns *mixed partial* derivatives, one formula for each multi-index of total order k , where the scalar theorem returned one number per order. The converse also changes method, going through the projections $\varphi_{X_j}(t) = \varphi_X(te_j)$ rather than repeating the Fatou argument in n dimensions.

The product rule for sums of independent *vectors* holds too, by the same one-line proof, and is used in chapter 7 to add independent vecteurs gaussiens.

6.6 Caractérisation de l'indépendance

The last result of the chapter is the one chapter 7 is built on. It says that indépendance of the components of a vecteur aléatoire is not merely implied by a factorisation of the joint fonction caractéristique — it is equivalent to it.

Proposition (Caractérisation de l'indépendance). *Soit X un vecteur aléatoire de dimension n . Les composantes $X_1, \dots, X_n$ du vecteur X sont indépendantes si et seulement si*

$$\forall t \in \mathbb{R}^n, \quad \varphi_X(t) = \varphi_{X_1}(t_1) \dots \varphi_{X_n}(t_n).$$

Remark. **La condition nécessaire** est immédiate: if the components are independent then so are the bounded variables $e^{it_1 X_1}, \dots, e^{it_n X_n}$, and the espérance of their product splits,

$$\varphi_X(t) = \mathbb{E}(e^{i t^T X}) = \mathbb{E}(e^{it_1 X_1}) \dots \mathbb{E}(e^{it_n X_n}) = \varphi_{X_1}(t_1) \dots \varphi_{X_n}(t_n).$$

The sufficient condition is the interesting direction and it is a one-trick argument: build a comparison vector and appeal to uniqueness. On considère un vecteur Y dont les composantes sont indépendantes, de mêmes lois marginales que le vecteur X — such a Y exists, on a product space, by the mesure produit construction of chapter 3. By the direction just proved,

$$\forall t \in \mathbb{R}^n, \quad \varphi_Y(t) = \varphi_{Y_1}(t_1) \dots \varphi_{Y_n}(t_n) = \varphi_{X_1}(t_1) \dots \varphi_{X_n}(t_n) = \varphi_X(t),$$

the middle equality because Y_j and X_j have the same loi and hence the same fonction caractéristique, and the last by hypothesis. The vector corollary that the fonction caractéristique characterises the loi then gives $\mathbb{P}_X = \mathbb{P}_Y$; indépendance of the components being a property of the loi jointe alone, the components of X are independent.

Remark. The criterion is a genuine strengthening of what the definition of indépendance gives. Verifying indépendance from the definition means checking $\mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) = \prod_j \mathbb{P}(X_j \in A_j)$ for all boréliens $A_1, \dots, A_n$ — an uncountable family of conditions on sets. The criterion replaces it by one functional identity between two explicit functions on $\mathbb{R}^n$, both of which are usually written down in closed form. Chapter 7 uses it in exactly that way: the fonction caractéristique of a vecteur gaussien of matrice de covariance Γ is $\varphi_X(t) = \exp(it^T \mu - \frac{1}{2} t^T \Gamma t)$, and that expression factorises into a product of n scalar Gaussian fonctions caractéristiques exactly when the quadratic form $t^T \Gamma t$ has no cross terms, that is, exactly when Γ is diagonal. So for a vecteur gaussien — and only because the criterion is an equivalence — décorrélées components are independent components.

Conclusion. The fonction caractéristique $\varphi_X(t) = \mathbb{E}(e^{itX})$ exists for every real variable aléatoire, with no hypothesis, because $|e^{itX}| = 1$; it is continuous, equals 1 at 0 and is bounded by 1 in modulus. The formule d'inversion recovers F_X from φ_X at every pair of continuity points, and therefore φ_X determines the loi; when φ_X is integrable over $\mathbb{R}$ the same formula produces a densité. The k -th derivative at 0 returns $i^k \mathbb{E}(X^k)$ when the moment d'ordre k exists, and conversely a derivative of even order k at 0 forces the moments up to order k to exist. For independent variables $\varphi_{X+Y} = \varphi_X \varphi_Y$, which turns convolutions into products. All of this transposes to vecteurs aléatoires, the formule d'inversion becoming an iterated limit and the moment theorem returning mixed partial derivatives, and the transposition yields the criterion the next chapter needs: the components of a vecteur aléatoire are independent exactly when the joint fonction caractéristique factorises into the product of the marginal ones.

7 Vecteurs gaussiens

Vecteurs gaussiens are the one family of multivariate lois this course handles in closed form, and two facts make that possible. The loi of a vecteur gaussien is determined by two objects only, a mean vector and a matrice de covariance, so every question about it reduces to linear algebra; and the family is stable under every affine map, so the answer to such a question is again a vecteur gaussien. What follows is the consequence of those two facts, together with one counter-example showing that the definition which makes them true cannot be weakened to the one a reader expects. Les vecteurs gaussiens apparaissent également dans le théorème central limite, présenté au chapitre suivant, as its limit.

7.1 Rappels sur la loi normale

Nous commençons par revoir les principales propriétés de la loi normale — the one-dimensional case, which chapter 4 introduced as a loi with a densité and which this chapter needs in the sharper form of its fonction caractéristique.

Definition (Loi normale). Une variable aléatoire réelle X suit une loi normale d'espérance μ et de variance σ^2 , ce que l'on note $X \sim \mathcal{N}(\mu, \sigma^2)$, si elle a pour densité :

$$\forall x \in \mathbb{R}, \quad f_X(x) = \frac{1}{\sqrt{2\pi} \sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

Le paramètre $\sigma > 0$ est l'**écart type** (*standard deviation*) de X . La loi normale est également appelée **loi gaussienne** (*Gaussian distribution*), and the two names are used interchangeably throughout.

Notation. Par convention, on inclut dans les lois normales les mesures de Dirac. Ainsi une mesure de Dirac en μ sera vue comme une loi normale d'espérance μ et d'écart type $\sigma = 0$. Cette loi n'a évidemment pas de densité par rapport à la mesure de Lebesgue, and the definition above does not cover it — it is a convention, not a theorem. It is kept because without it the statements later in this chapter would each need a separate clause for the dégénéré case: an affine image of a vecteur gaussien can be constant, a vecteur gaussien with a singular matrice de covariance has components that are constant along some direction, and in both cases the convention lets the result be stated without an exception.

Si Z est une variable aléatoire suivant une loi normale centrée réduite, soit $Z \sim \mathcal{N}(0, 1)$, alors la variable aléatoire

$$X = \sigma Z + \mu$$

suit une loi normale d'espérance μ et de variance σ^2 . This is the changement de variable computation of chapter 4, and it is the form in which the loi normale is used here: everything Gaussian in this chapter is built as an affine image of something centré réduit.

Proposition (Fonction caractéristique de la loi normale). *La fonction caractéristique d'une variable aléatoire réelle X suivant une loi normale d'espérance μ et de variance σ^2 est donnée par :*

$$\forall t \in \mathbb{R}, \quad \varphi_X(t) = e^{i\mu t} e^{-\frac{\sigma^2 t^2}{2}}.$$

Remark. The loi normale centrée réduite case $\varphi_Z(t) = e^{-t^2/2}$ is the differential-equation computation of chapter 6 — differentiating under the integral sign and integrating by parts shows that φ_Z solves $\varphi'_Z(t) = -t\varphi_Z(t)$ with $\varphi_Z(0) = 1$ — and everything else is the affine rule of that same chapter: writing $X = \sigma Z + \mu$ gives $\varphi_X(t) = \mathbb{E}(e^{it(\sigma Z + \mu)}) = e^{i\mu t} \varphi_Z(\sigma t) = e^{i\mu t} e^{-\sigma^2 t^2/2}$. The formula is also consistent with the Dirac convention: at $\sigma = 0$ it reduces to $\varphi_X(t) = e^{i\mu t}$, which is the fonction caractéristique of δ_μ .

Two consequences are used constantly below. By chapter 6's Caractérisation de la loi, a real variable is normal as soon as its fonction caractéristique has the shape above — one never has to produce a densité. And the exponent is a quadratic polynomial in t , which makes the multivariate generalisation of the next sections a matter of replacing $\sigma^2 t^2$ by a quadratic form.

7.2 Premier exemple

Before any definition, one example says what the whole chapter is about.

Soit X, Y deux variables aléatoires indépendantes suivant la loi normale centrée réduite. Le vecteur aléatoire (X, Y) a pour densité, by indépendance, the product of the marginal densités:

$$\forall x, y \in \mathbb{R}, \quad f_{X,Y}(x, y) = f_X(x)f_Y(y) = \frac{1}{2\pi} e^{-\frac{x^2+y^2}{2}}.$$

Sa fonction caractéristique est donnée par the product of the marginal fonctions caractéristiques, again by indépendance:


$$\forall s, t \in \mathbb{R}, \quad \varphi_{X,Y}(s, t) = \varphi_X(s)\varphi_Y(t) = e^{-\frac{s^2+t^2}{2}}.$$

On s'intéresse à la projection orthogonale du vecteur aléatoire (X, Y) sur le vecteur unitaire $(\cos \theta, \sin \theta)$, avec $\theta \in [0, 2\pi]$. On note $S = X \cos \theta + Y \sin \theta$ leur produit scalaire. C'est une variable aléatoire de fonction caractéristique, read off the joint one :

$$\forall t \in \mathbb{R}, \quad \varphi_S(t) = \mathbb{E}\left(e^{it(X \cos \theta + Y \sin \theta)}\right) = \varphi_{X,Y}(t \cos \theta, t \sin \theta) = e^{-\frac{t^2(\cos^2 \theta + \sin^2 \theta)}{2}} = e^{-\frac{t^2}{2}}.$$

On en déduit que S suit une loi normale — the loi normale centrée réduite, for every θ . Ainsi la projection orthogonale du vecteur aléatoire (X, Y) sur n'importe quel vecteur (même non unitaire) suit une loi normale: onto any direction first, then, by scaling, onto any vector at all. That invariance is not an accident of this pair: c'est une caractéristique des vecteurs gaussiens, and the next section turns it into the definition.

The densité above depends on (x, y) only through $x^2 + y^2$, so its level sets are circles. The figure below shows what happens to those level sets when the two coordinates stop being independent and equally scaled: they become ellipses, axis-aligned while the matrice de covariance is diagonal and rotated as soon as the off-diagonal term is non-zero. Nothing else changes — the level sets of a bivariate Gaussian densité are always ellipses, which is what a quadratic form in the exponent means.



Level sets of a centrée bivariate Gaussian density at three matrices de covariance. The axes of the ellipses are the eigenvectors of Γ and their half-lengths are proportional to the square roots of its eigenvalues; the dashed line in the third panel is the direction of largest variance, which rotates away from the coordinate axes exactly when the off-diagonal term is non-zero.

7.3 Définition

Soit $n \geq 1$ un entier.

Definition (Vecteur gaussien). Un vecteur aléatoire X de dimension n est un **vecteur gaussien** (*Gaussian vector*) si pour tout $a \in \mathbb{R}^n$, la variable aléatoire réelle $a^T X$ suit une loi gaussienne.

Read that once more, because it is the whole chapter. The condition is on *every* linear combination of the components, not on the components. It is not the definition a reader expects, which would be:

(wrong) X is a vecteur gaussien when each component $X_1, \dots, X_n$ follows a loi normale.

That condition is strictly weaker. It is implied by the real definition — take a to be the i -th unit vector and $a^T X = X_i$ — but it does not imply it, and the counter-example below exhibits a pair of variables of loi normale centrée réduite whose loi jointe is not Gaussian. Everything this chapter proves is false under the weaker condition, so the distinction is not pedantry: it is the hypothesis every theorem below is checked against.

Un vecteur gaussien a nécessairement une espérance et une matrice de covariance. Il suffit de prendre pour a les vecteurs unitaires de $\mathbb{R}^n$: that makes each component a normal variable, and a normal variable has moments of every order, so no integrability hypothesis ever has to be added to a statement about vecteurs gaussiens. Si X est un vecteur gaussien d'espérance μ et de matrice de covariance Γ , alors pour tout $a \in \mathbb{R}^n$, la variable aléatoire $a^T X$ suit une loi gaussienne d'espérance et de variance :

$$\mathbb{E}(a^T X) = a^T \mu, \quad \text{Var}(a^T X) = \text{Cov}(a^T X, a^T X) = a^T \text{Cov}(X) a = a^T \Gamma a.$$

In particular $a^T \Gamma a \geq 0$ for every a : the matrice de covariance of a vecteur gaussien is symétrique and positive semi-definite, as any matrice de covariance is. It need not be invertible, and the densité section below is about what invertibility buys.

Theorem (Fonction caractéristique d'un vecteur gaussien). *Un vecteur gaussien X d'espérance μ et de matrice de covariance Γ a pour fonction caractéristique :*

$$\forall t \in \mathbb{R}^n, \quad \varphi_X(t) = e^{it^T \mu} e^{-\frac{t^T \Gamma t}{2}}.$$

Remark. One line, and it is the reason the definition is stated over all linear combinations. Pour tout $t \in \mathbb{R}^n$, la variable aléatoire $t^T X$ suit une loi gaussienne d'espérance $t^T \mu$ et de variance $t^T \Gamma t$, by definition, so evaluating its one-dimensional fonction caractéristique at the single point 1 gives

$$\varphi_X(t) = \mathbb{E}\left(e^{it^T X}\right) = \varphi_{t^T X}(1) = e^{it^T \mu} e^{-\frac{t^T \Gamma t}{2}},$$

the last equality being the proposition above on the fonction caractéristique de la loi normale. A definition by lois marginales would give this at the n unit vectors only, which is not enough to know the joint fonction caractéristique.

Notation. Since the fonction caractéristique determines the loi, la loi d'un vecteur gaussien est entièrement caractérisée par son espérance et sa matrice de covariance. On notera $X \sim \mathcal{N}(\mu, \Gamma)$ un vecteur gaussien d'espérance μ et de matrice de covariance Γ . The reuse of the symbol Γ here is one of the deliberate collisions chapter 2 sets out.

This is the practical content of the chapter. To identify the loi of anything built from a vecteur gaussien, it suffices to check that the thing is Gaussian and then to compute two objects, a mean vector and a matrice de covariance. No densité, no integral, no convolution.

Example (Reading off the loi of a projection). Soit X un vecteur gaussien, with

$$\mu = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad \Gamma = \begin{pmatrix} 2 & -1 \\ -1 & 3 \end{pmatrix}, \quad a = \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

The variable $a^T X = X_1 - X_2$ est une variable aléatoire de loi gaussienne, comme projection d'un vecteur gaussien — by definition — so only its two parameters are left to compute:

$$\mathbb{E}(a^T X) = a^T \mu = 2 - 1 = 1, \quad \text{Var}(a^T X) = a^T \Gamma a = 2 - (-1) - (-1) + 3 = 7.$$

Hence $a^T X \sim \mathcal{N}(1, 7)$. The whole computation is the expansion $a^T \Gamma a = \Gamma_{11} - \Gamma_{12} - \Gamma_{21} + \Gamma_{22}$, and the two off-diagonal terms are counted twice precisely because Γ is symétrique.

7.4 Construction d'un vecteur gaussien

Soit Z un vecteur aléatoire dont les composantes sont n variables aléatoires i.i.d. de loi normale centrée réduite. Il est facile de voir que Z est un vecteur gaussien, by indépendance :

$$\forall t \in \mathbb{R}^n, \quad \varphi_Z(t) = \mathbb{E}\left(e^{it^T Z}\right) = \varphi_{Z_1}(t_1) \dots \varphi_{Z_n}(t_n) = e^{-\frac{\|t\|^2}{2}},$$

which is the fonction caractéristique of the previous section with $\mu = 0$ and $\Gamma = I_n$. L'espérance de Z est nulle et sa matrice de covariance est la matrice identité : sa loi est dite **centrée réduite** (*standard*). Les transformations affines de Z permettent de construire n'importe quel vecteur gaussien.

Proposition. Pour toute matrice A de taille $n \times n$ et tout vecteur μ de dimension n , le vecteur aléatoire $X = AZ + \mu$ est un vecteur gaussien d'espérance μ et de matrice de covariance $\Gamma = AA^T$.

Remark. Pour tout $a \in \mathbb{R}^n$, la variable aléatoire $a^T X = (A^T a)^T Z + a^T \mu$, qui est la projection d'un vecteur gaussien, suivie d'une translation, suit une loi gaussienne. Le vecteur aléatoire X est donc gaussien, by definition. Son espérance et sa matrice de covariance sont données par $\mathbb{E}(X) = A \mathbb{E}(Z) + \mu = \mu$ and $\text{Cov}(X) = \text{Cov}(AZ) = A \text{Cov}(Z) A^T = AA^T$, by linearity of the espérance and bilinearity of the covariance.

Remark. The construction reaches every vecteur gaussien, not just some. A matrice de covariance Γ is symétrique and positive semi-definite, so it has a spectral decomposition $\Gamma = UDU^T$ with U orthogonal and D diagonal with non-negative entries; taking $A = UD^{1/2}$ gives $AA^T = \Gamma$. So for every μ and every symétrique positive semi-definite Γ there is a vecteur gaussien $\mathcal{N}(\mu, \Gamma)$, and it can always be realised as $AZ + \mu$ with Z centré réduit. Positive semi-definiteness is the whole condition — a symétrique matrix that fails it is not the matrice de covariance of anything.

Example (Which matrices de covariance are admissible). Soit X un vecteur gaussien centré de dimension 2 et de matrice de covariance

$$\Gamma = \begin{pmatrix} 1 & 1 \\ 1 & \alpha \end{pmatrix}.$$

For Γ to be a matrice de covariance, la matrice doit être semi-définie positive. A symétrique 2×2 matrix is positive semi-definite exactly when its two diagonal entries and its determinant are all non-negative. Here those three quantities are $\Gamma_{11} = 1$, $\Gamma_{22} = \alpha$ and $\det \Gamma = \alpha - 1$, so the conditions read $\alpha \geq 0$ together with $\alpha \geq 1$, and il faut et il suffit d'avoir $\alpha \geq 1$ — the determinant condition is the binding one and it subsumes the condition on the second diagonal entry. The boundary case $\alpha = 1$ is the dégénéré one: there $\det \Gamma = 0$, the vector is carried by a line, and the densité theorem below says it has no densité. For $\alpha > 1$ it does, and les composantes ne sont pas indépendantes, whatever α is, since the off-diagonal entry is $1 \neq 0$ — leur coefficient de corrélation est $1/(\sqrt{1}\sqrt{\alpha}) = 1/\sqrt{\alpha}$, which tends to 0 but never reaches it.

7.5 Un contre-exemple

Les composantes d'un vecteur gaussien suivent des lois gaussiennes : il suffit de projeter le vecteur sur chaque vecteur unitaire de $\mathbb{R}^n$. La réciproque n'est pas vraie. Nous donnons ici un exemple de vecteur aléatoire dont les composantes suivent des lois gaussiennes mais qui n'est pas gaussien. It is the reason the definition above is stated over all linear combinations, and it is worth carrying with its computation rather than as an assertion, because the computation is short and because the same shape recurs.

Soit Z une variable aléatoire suivant une loi normale centrée réduite et Y une variable aléatoire discrète, indépendante de Z , qui vaut 1 avec probabilité $\frac{1}{2}$ et -1 sinon. On vérifie facilement que YZ suit une loi gaussienne. Conditioning on the two values of Y and using indépendance,

$$\forall t \in \mathbb{R}, \quad \varphi_{YZ}(t) = \mathbb{E}(e^{iYZt}) = \frac{1}{2} \mathbb{E}(e^{iZt}) + \frac{1}{2} \mathbb{E}(e^{-iZt}) = \frac{1}{2} \varphi_Z(t) + \frac{1}{2} \varphi_Z(-t) = \varphi_Z(t),$$

the last equality because $\varphi_Z(t) = e^{-t^2/2}$ is even. By injectivity of the fonction caractéristique, $YZ \sim \mathcal{N}(0, 1)$.

Le vecteur $X = (Z, YZ)$, dont les composantes suivent des lois gaussiennes (both of them the loi normale centrée réduite), n'est pas gaussien. En effet, sa projection sur le vecteur $a = (1, 1)$ — the variable $a^T X = Z + YZ$ — satisfies

$$\mathbb{P}(Z + YZ = 0) = \mathbb{P}(Y = -1) = \frac{1}{2},$$


since $Z + YZ = 0$ on the événement $\{Y = -1\}$. A loi normale can put mass $\frac{1}{2}$ on a single point only if it is a Dirac mass, that is only if $\sigma = 0$ under the Dirac convention above; and $Z + YZ$ is not presque sûrement 0, because on the événement $\{Y = 1\}$, of probability $\frac{1}{2}$, it equals $2Z \sim \mathcal{N}(0, 4)$. So $Z + YZ$ is neither a variable with a normal densité nor a Dirac mass, hence not normal, hence X is not a vecteur gaussien.

Pour qu'un vecteur aléatoire dont les composantes suivent des lois gaussiennes soit gaussien, il faut des conditions supplémentaires, comme l'indépendance de ses composantes, as the concatenation corollary below shows.

Remark. The same pair says something sharper, and it is the reason to keep it in view when reading the indépendance theorem below. The two components are *décorrélées*:

$$\text{Cov}(Z, YZ) = \mathbb{E}(Z \cdot YZ) - \mathbb{E}(Z) \mathbb{E}(YZ) = \mathbb{E}(Y) \mathbb{E}(Z^2) - 0 = 0,$$

using the indépendance of Y and Z and $\mathbb{E}(Y) = 0$. They are very far from independent, since $|YZ| = |Z|$ makes each one a function of the other's absolute value. Two variables of loi normale centrée réduite, décorrélées, not independent. Nothing is wrong: the indépendance theorem below, the one that turns zero covariance into indépendance, has the hypothesis that the pair is a vecteur gaussien, and this pair is not.



The counter-example. Both lois marginales are the bell curve of the loi normale centrée réduite, yet the loi jointe sits on the union of the two diagonals and is visibly not elliptical — it is carried by a set négligeable pour la mesure de Lebesgue, so it has no densité at all. The dashed circles show the level sets the loi jointe would have had if the pair were a vecteur gaussien with these lois marginales and zero covariance.

7.6 Existence d'une densité

A vecteur gaussien always has a loi, a fonction caractéristique and moments of every order. Whether it has a *densité* is a separate question, and the answer is a single linear-algebra condition.

Theorem (Densité d'un vecteur gaussien). *Un vecteur gaussien X d'espérance μ et de matrice de covariance Γ a une densité par rapport à la mesure de Lebesgue si et seulement si Γ est inversible. Cette densité est alors donnée par :*

$$\forall x \in \mathbb{R}^n, \quad f_X(x) = \frac{1}{(2\pi)^{\frac{n}{2}} \sqrt{\det \Gamma}} e^{-\frac{1}{2}(x-\mu)^T \Gamma^{-1}(x-\mu)}.$$

Proof. Comme Γ est symétrique et positive, il existe une matrice A de taille $n \times n$ telle que $\Gamma = AA^T$. By the previous section, on peut donc écrire $X = AZ + \mu$ avec Z un vecteur gaussien centré réduit de dimension n . Ce vecteur a pour densité :

$$\forall z \in \mathbb{R}^n, \quad f_Z(z) = \frac{1}{(2\pi)^{\frac{n}{2}}} e^{-\frac{\|z\|^2}{2}}.$$

By the théorème de transfert, pour toute fonction mesurable positive ϕ , on a :

$$\mathbb{E}(\phi(X)) = \mathbb{E}(\phi(AZ + \mu)) = \int \phi(Az + \mu) \frac{1}{(2\pi)^{\frac{n}{2}}} e^{-\frac{\|z\|^2}{2}} dz.$$

Si Γ est inversible, A l'est aussi, since $\det \Gamma = (\det A)^2$, et l'application $z \mapsto Az + \mu$ est un difféomorphisme de $\mathbb{R}^n$ onto itself, de matrice jacobienne A , which is constant. On obtient par changement de variable $x = Az + \mu$, whose inverse is $z = A^{-1}(x - \mu)$ and whose Jacobian factor is $|\det A|$:

$$\mathbb{E}(\phi(X)) = \int \phi(x) \frac{1}{(2\pi)^{\frac{n}{2}}} e^{-\frac{1}{2}(x-\mu)^T (A^{-1})^T A^{-1}(x-\mu)} \frac{dx}{|\det A|}.$$


Now $(A^{-1})^T A^{-1} = (AA^T)^{-1} = \Gamma^{-1}$ and $|\det A| = \sqrt{\det \Gamma}$; on en déduit le résultat attendu — the integrand is the announced densité and X has that densité, the function ϕ being an arbitrary positive measurable fonction test.

Si Γ n'est pas inversible, A ne l'est pas non plus et il existe un vecteur $u \in \mathbb{R}^n$ non nul tel que $u^T A = 0$. For that u ,

$$u^T(X - \mu) = u^T AZ = 0 \quad \text{almost surely,} \quad \text{hence} \quad \mathbb{P}(u^T(X - \mu) = 0) = 1.$$

L'hyperplan $\{x \in \mathbb{R}^n : u^T(x - \mu) = 0\}$ de $\mathbb{R}^n$ est négligeable pour la mesure de Lebesgue. A vecteur aléatoire with a densité gives probability zero to every set négligeable pour la mesure de Lebesgue, so le vecteur X ne peut avoir de densité.

The second half of the proof is not a technicality to be skipped, and the vectors it describes are not error cases. When Γ is singular of rank $r < n$, the vector X is carried by the affine subspace $\mu + \text{im}(A)$ of dimension r : it is a genuine vecteur gaussien, its fonction caractéristique is still $e^{it^T \mu} e^{-t^T \Gamma t/2}$, its loi is still determined by μ and Γ , and along the $n - r$ directions in the kernel it is deterministic. Such a vector is called **dégénéré** (*degenerate*). It simply has no densité on $\mathbb{R}^n$ — though it does have one on the subspace that carries it, once that subspace is identified with $\mathbb{R}^r$. Vecteurs gaussiens dégénérés turn up on their own in exam problems, most often as a residual vector after a projection, so the right reflex on being asked for a densité is to compute $\det \Gamma$ first.



A vecteur gaussien dégénéré in $\mathbb{R}^2$: all its mass lies on the line $x_1 + x_2 = 2$, which is négligeable pour la mesure de Lebesgue, so there is no densité on the plane. The loi is still Gaussian, still determined by μ and Γ , and on the line itself it is a one-dimensional $\mathcal{N}(0, 2)$ about μ .

Example (Two vectors built from one normal variable). Soit $W \sim \mathcal{N}(0, 1)$ une variable aléatoire de loi normale centrée réduite — a single one. The vector $(W, 2W, 3W)$ is Gaussian: any linear combination $a_1 W + 2a_2 W + 3a_3 W = (a_1 + 2a_2 + 3a_3)W$ is a scalar multiple of W , hence normal — including the case where the scalar vanishes, which is the Dirac mass at 0 and is normal by convention. Its mean is 0 and its matrice de covariance is

$$\Gamma = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 3 & 6 & 9 \end{pmatrix},$$

of rank 1, hence singular: no densité. The vector lives on the line spanned by $(1, 2, 3)$, which is what rank 1 says.

The vector $(W + 1, 1 - W)$ is Gaussian for the same reason, with mean $(1, 1)$ and matrice de covariance

$$\Gamma = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}, \quad \det \Gamma = 0.$$

Again no densité: the two components sum to 2 presque sûrement, so the vector is carried by the line $x_1 + x_2 = 2$. This is the vector drawn in the figure above.

Example (Recognising a vecteur gaussien from its densité). Soit (X, Y) un vecteur aléatoire de densité :

$$\forall x, y \in \mathbb{R}, \quad f_{X,Y}(x, y) = c \exp\left(-\frac{1}{8}(3x^2 + 2xy + 3y^2)\right),$$

avec c une constante strictement positive. The exponent is a negative definite quadratic form with no linear part, so the theorem above identifies the loi by matching coefficients: the vector is a vecteur gaussien centré with

$$\frac{1}{2} \begin{pmatrix} x \\ y \end{pmatrix}^T \Gamma^{-1} \begin{pmatrix} x \\ y \end{pmatrix} = \frac{1}{8} (3x^2 + 2xy + 3y^2) \implies \Gamma^{-1} = \frac{1}{4} \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix},$$

the off-diagonal entries of Γ^{-1} each carrying half of the cross term $2xy$ because the form is symétrique. Inverting,

$$\Gamma = 4 \cdot \frac{1}{8} \begin{pmatrix} 3 & -1 \\ -1 & 3 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} 3 & -1 \\ -1 & 3 \end{pmatrix}, \quad \det \Gamma = \frac{9-1}{4} = 2,$$

so the normalising constant is forced: $c = 1 / (2\pi\sqrt{\det \Gamma}) = 1 / (2\pi\sqrt{2})$. The lois marginales are read off the diagonal, $X \sim \mathcal{N}(0, \frac{3}{2})$ and $Y \sim \mathcal{N}(0, \frac{3}{2})$, and the components are not independent since Γ is not diagonal — their coefficient de corrélation is $(-\frac{1}{2}) / (\frac{3}{2}) = -\frac{1}{3}$.

7.7 Propriétés

Nous terminons par quelques propriétés utiles des vecteurs gaussiens — the properties that do the work in practice. The first is the one almost every exercise on this chapter starts from.

Theorem (Transformation affine). *Toute transformation affine d'un vecteur gaussien est un vecteur gaussien. Precisely, if $X \sim \mathcal{N}(\mu, \Gamma)$ has dimension n , avec A matrice de taille $m \times n$ et b vecteur de dimension m , then*

$$Y = AX + b \sim \mathcal{N}(A\mu + b, A\Gamma A^T).$$

Remark. The fonction caractéristique computes itself, and the computation is where the transformed parameters come from:

$$\varphi_Y(t) = \mathbb{E}\left(e^{it^T(AX+b)}\right) = e^{it^T b} \varphi_X(A^T t) = e^{it^T(A\mu+b)} e^{-\frac{1}{2}t^T A\Gamma A^T t},$$

for $t \in \mathbb{R}^m$. Il s'agit de la fonction caractéristique d'un vecteur gaussien d'espérance $A\mu + b$ et de matrice de covariance $A\Gamma A^T$. Note that A need not be square and need not have full rank: m may exceed n or fall short of it, and $A\Gamma A^T$ is then very often singular. That is fine, and it is why the dégénéré case of the densité section had to be kept.

This theorem is the workhorse. Any question of the form “what is the loi of this linear combination, this projection, this residual” is answered by writing the object as $AX + b$ and computing $A\mu + b$ and $A\Gamma A^T$.

Theorem (Indépendance des composantes). *Les composantes d'un vecteur gaussien sont indépendantes si et seulement si la matrice de covariance de ce vecteur est diagonale.*

Remark. By the fonction caractéristique theorem above, un vecteur gaussien X d'espérance μ et de matrice de covariance Γ a pour fonction caractéristique $\varphi_X(t) = e^{it^T \mu} e^{-\frac{1}{2}t^T \Gamma t}$. Chapter 6's criterion says les composantes sont indépendantes si et seulement si cette fonction s'écrit comme un produit of functions of the individual t_i . The linear part $e^{it^T \mu}$ always factorises; the quadratic part $t^T \Gamma t = \sum_{j,k} \Gamma_{jk} t_j t_k$ factorises exactly when it has no cross term, that is exactly when Γ is diagonal.

Remark. Deux composantes d'un vecteur gaussien sont indépendantes si et seulement si leur covariance est nulle. Il suffit en effet d'appliquer le résultat précédent au vecteur aléatoire formé par ces deux composantes, qui est lui-même gaussien by the affine transformation theorem — extracting two coordinates is a linear map.

Remark. The same computation covers **blocs** (*blocks*), which is the form used in the examples below. Split a vecteur gaussien X into blocs $X^{(1)}, \dots, X^{(p)}$ of dimensions $n_1, \dots, n_p$ and split t the same way. If Γ is diagonal by blocs for that split, with diagonal blocs $\Gamma^{(1)}, \dots, \Gamma^{(p)}$ — the diagonal blocs themselves being arbitrary — then $t^T \mu = \sum_k (t^{(k)})^T \mu^{(k)}$ and $t^T \Gamma t = \sum_k (t^{(k)})^T \Gamma^{(k)} t^{(k)}$, so

$$\varphi_X(t) = \prod_{k=1}^p e^{i(t^{(k)})^T \mu^{(k)}} e^{-\frac{1}{2}(t^{(k)})^T \Gamma^{(k)} t^{(k)}} = \prod_{k=1}^p \varphi_{X^{(k)}}(t^{(k)}),$$

each factor being the fonction caractéristique of the bloc $X^{(k)}$, which is Gaussian with mean $\mu^{(k)}$ and matrice de covariance $\Gamma^{(k)}$ by the affine transformation theorem. Chapter 6's comparison-vector argument for the characterisation of indépendance never uses that the pieces are scalar: run it with blocs in place of components and this factorisation gives that $X^{(1)}, \dots, X^{(p)}$ are independent. The converse is the same computation read backwards. So two blocs of a vecteur gaussien are independent as soon as the cross-covariance bloc between them vanishes, and this **bloc form** of the theorem is what is meant below whenever a cross bloc is computed and found to be zero. The componentwise statement is the case where every bloc has size one.

Remark. This is the one place in the whole course where a zero covariance gives indépendance, and it is worth saying loudly because the temptation to reuse it is permanent. In general, being décorrélées does not mean being independent: chapter 1's correlation figure shows two variables with covariance zero and an obvious functional dependence between them, and the counter-example above gives a second instance with both lois marginales centrées réduites. The hypothesis that rescues the implication here is not that the components are normal — the counter-example's components are normal — but that the *vector* is Gaussian, that is that every linear combination of the components is normal. Check that hypothesis before using this theorem; it is the single most common way to go wrong on this chapter.

Example (Independent and dependent pairs of linear combinations). Soit X et Y deux variables aléatoires indépendantes de même loi normale centrée réduite. The vector (X, Y) is Gaussian — independent normal components, by the corollary below — and so is every linear image of it. Les vecteurs associés étant gaussiens, il suffit de regarder la corrélation: each question is a covariance computation.

For $X + Y$ and $X - Y$: the pair is a linear image of (X, Y) , hence a vecteur gaussien, and $\text{Cov}(X + Y, X - Y) = \text{Var}(X) - \text{Var}(Y) = 1 - 1 = 0$, donc indépendantes.

For $X + 2Y$ and $X - Y$: again a vecteur gaussien, but $\text{Cov}(X + 2Y, X - Y) = \text{Var}(X) - 2\text{Var}(Y) = 1 - 2 = -1 \neq 0$, donc dépendantes. Note that both variables are normal in both cases; it is the covariance, not the lois marginales, that decides.

Theorem (Somme). *La somme de vecteurs gaussiens indépendants est un vecteur gaussien. Precisely, soit $X^{(1)}, \dots, X^{(m)}$ des vecteurs gaussiens indépendants de dimension n . Write $\mu^{(k)}$ for the mean and $\Gamma^{(k)}$ for the matrice de covariance of $X^{(k)}$. Then leur somme X est un vecteur gaussien d'espérance $\mu^{(1)} + \dots + \mu^{(m)}$ et de matrice de covariance $\Gamma^{(1)} + \dots + \Gamma^{(m)}$.*

Remark. By indépendance the fonction caractéristique of the sum is the product of the fonctions caractéristiques, and multiplying the exponentials adds the means in the linear part and adds the matrices de covariance in the quadratic part:

$$\varphi_X(t) = \varphi_{X^{(1)}}(t) \dots \varphi_{X^{(m)}}(t) = e^{it^T(\mu^{(1)} + \dots + \mu^{(m)})} e^{-\frac{1}{2}t^T(\Gamma^{(1)} + \dots + \Gamma^{(m)})t}.$$

Indépendance is essential: without it the product formula fails, and the sum of two dependent vecteurs gaussiens need not be Gaussian at all.

Corollary (Concatenation). *La concatenation de vecteurs gaussiens indépendants est un vecteur gaussien.*

Remark. La projection du vecteur formé par cette concatenation sur un vecteur quelconque est la somme de variables aléatoires gaussiennes indépendantes, one projection per bloc, which is normal by the previous theorem. Its matrice de covariance is diagonal by blocs, the blocs being the matrices de covariance of the pieces, which by the bloc form of the indépendance theorem is consistent: the blocs are independent of one another.

En particulier, un vecteur dont les composantes suivent des lois gaussiennes *et sont indépendantes* est gaussien ; sans la condition d'indépendance, le résultat est faux — that is exactly the counter-example above, whose components are normal, décorrélées, and not independent.

Example (A difference of two independent vecteurs gaussiens). Soit X et Y deux vecteurs gaussiens indépendants de mêmes espérance μ et matrice de covariance Γ . Then $-2Y \sim \mathcal{N}(-2\mu, 4\Gamma)$ by the affine

transformation theorem, the factor 4 being $(-2)\Gamma(-2)^T$, and X and $-2Y$ are independent, so by the sum theorem

$$X - 2Y \sim \mathcal{N}(-\mu, 5\Gamma).$$

The trap the factor 4 guards against is writing $\Gamma - 2\Gamma$ or $\Gamma + 2\Gamma$: covariance is quadratic, so a scalar multiplier enters squared.

Example (Two linear images of one standard vector). Soit Z un vecteur gaussien centré réduit de dimension 3. On note $X = AZ$ et $Y = BZ$ avec

$$A = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 0 & -1 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & -1 & 1 \end{pmatrix}.$$

Ce sont des vecteurs gaussiens comme transformations linéaires d'un vecteur gaussien — centrés, with matrices de covariance AA^T and BB^T :

$$X \sim \mathcal{N}\left(0, \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & -1 \\ 1 & -1 & 2 \end{pmatrix}\right), \quad Y \sim \mathcal{N}(0, 3).$$

For indépendance, stack them: le vecteur (X, Y) est lui-même gaussien comme transformation linéaire — the image of Z under the 4×3 matrix whose first three rows are A and whose last row is B — and the cross-covariance bloc is AB^T . Computing row by row, $(1, 1, 0) \cdot (1, -1, 1) = 0$, $(0, 1, 1) \cdot (1, -1, 1) = 0$ and $(1, 0, -1) \cdot (1, -1, 1) = 0$, so $AB^T = 0$ and les variables X et Y sont donc indépendantes — by the bloc form of the indépendance theorem applied to the stacked vecteur gaussien, which is the step that would be unavailable if the stack were not Gaussian.

Note in passing that $\det A = 0$, since the first row of A is the sum of the other two, so $X_1 = X_2 + X_3$ presque sûrement and X is a vecteur gaussien dégénéré with no densité on $\mathbb{R}^3$. Indépendance of X and Y is untouched by that: the indépendance theorem asks about the matrice de covariance only, never about a densité.

Example (Indépendance among three linear combinations). Let X, Y, Z be independent variables of loi normale centrée réduite, so that (X, Y, Z) is a vecteur gaussien centré réduit. Then $T = X + Y + Z \sim \mathcal{N}(0, 3)$, being a projection of it.

The pair $(T, X - Y)$ is a linear image of (X, Y, Z) , hence a vecteur gaussien, and its parameters are

$$(T, X - Y) \sim \mathcal{N}\left(0, \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix}\right),$$

the off-diagonal term being $\text{Cov}(X + Y + Z, X - Y) = \text{Var}(X) - \text{Var}(Y) = 0$. The matrice de covariance is diagonal, so T and $X - Y$ are independent; by symmetry of the roles of X, Y and Z the same holds for $Y - Z$ and for $Z - X$.

Now ask for which α the three variables $X + Y + Z$, $2X - Y - Z$ and $Y + \alpha Z$ are independent. The triple is again a linear image of (X, Y, Z) , so it is a vecteur gaussien centré, with matrice de covariance

$$\begin{pmatrix} 3 & 0 & 1 + \alpha \\ 0 & 6 & -1 - \alpha \\ 1 + \alpha & -1 - \alpha & 1 + \alpha^2 \end{pmatrix}.$$

Indépendance holds if and only if this is diagonal, that is if and only if $1 + \alpha = 0$, so $\alpha = -1$ is the only value. One scalar equation, no densités, no integrals — which is what the two theorems of this section buy.

Example (Conditioning one bloc of a vecteur gaussien on another). This is the shape behind every Gaussian conditioning question, and it is the affine transformation theorem followed by the indépendance theorem, in that order.

Let X and Y be vecteurs aléatoires of dimensions n and m such that the concatenation (X, Y) is a vecteur gaussien centré with matrice de covariance

$$\Gamma = \begin{pmatrix} A & C \\ C^T & B \end{pmatrix},$$

where the square blocs A and B have sizes $n \times n$ and $m \times m$, and A is invertible. Each bloc is a projection of a vecteur gaussien, so $X \sim \mathcal{N}(0, A)$ and $Y \sim \mathcal{N}(0, B)$, and by the bloc form of the indépendance theorem X and Y are independent if and only if $C = 0$.

For a general $m \times n$ matrix M , the vector $(X, Y - MX)$ is a linear image of (X, Y) , hence a vecteur gaussien centré, and its matrice de covariance is

$$\begin{pmatrix} A & C - AM^T \\ C^T - MA & B + MAM^T - MC - C^T M^T \end{pmatrix}.$$

The cross bloc vanishes exactly when $C^T - MA = 0$, that is for $M = C^T A^{-1}$ — this is where the invertibility of A is used, and it is the only place it is needed. For that M , the bloc form of the indépendance theorem makes X and $Y - MX$ independent, and the espérance conditionnelle follows without any further computation:

$$\mathbb{E}(Y \mid X = x) = \mathbb{E}(Y - MX \mid X = x) + \mathbb{E}(MX \mid X = x) = \mathbb{E}(Y - MX) + Mx = Mx,$$

since $Y - MX$ is independent of X and centré. The espérance conditionnelle of one bloc of a vecteur gaussien centré given another is *linear* in the conditioning value, with matrix $C^T A^{-1}$.

Concretely, in dimension $1 + 1$: soit X un vecteur gaussien centré de matrice de covariance

$$\Gamma = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}.$$

Here $A = 2$ is the variance of X_2 and $C^T = 1$ is the covariance, so $M = \frac{1}{2}$ and $X_1 - \frac{1}{2}X_2$ is independent of X_2 . Its variance is $\text{Var}(X_1) - \text{Cov}(X_1, X_2) + \frac{1}{4} \text{Var}(X_2) = 1 - 1 + \frac{1}{4} = \frac{1}{4}$, so

$$X_1 \mid X_2 = x_2 \sim \mathcal{N}\left(\frac{x_2}{2}, \frac{1}{4}\right), \quad \mathbb{E}(X_1 \mid X_2) = \frac{X_2}{2} \sim \mathcal{N}\left(0, \frac{1}{2}\right).$$

The conditional variance does not depend on x_2 — another feature peculiar to the Gaussian case. And conditioning on an événement rather than a value reduces to a one-dimensional integral: with $X_2 \sim \mathcal{N}(0, 2)$ and $\mathbb{E}(X_2 \mid X_2 \geq 0) = \sigma \sqrt{2/\pi} = 2/\sqrt{\pi}$,

$$\mathbb{E}(X_1 \mid X_2 \geq 0) = \frac{1}{2} \mathbb{E}(X_2 \mid X_2 \geq 0) = \frac{1}{\sqrt{\pi}}.$$

Example (Linear regression, and where the loi de Student comes from). This assembles the whole chapter, and it is the shape a long exam problem takes.

Let A be an $n \times d$ matrix with $n > d \geq 1$ and $A^T A$ invertible, let w be an unknown parameter vector of dimension d , and let Z be a vecteur gaussien centré of dimension n with matrice de covariance $\sigma^2 I_n$, $\sigma^2 > 0$. One observes

$$Y = Aw + Z \sim \mathcal{N}(Aw, \sigma^2 I_n),$$

by the affine transformation theorem. Write $P = A(A^T A)^{-1} A^T$ for the orthogonal projection onto the column space of A , so that $P^T = P$ and $P^2 = P$, and set

$$W = (A^T A)^{-1} A^T Y, \quad R = (I_n - P)Y.$$

The stacked vector (W, R) is a linear image of Y , hence a vecteur gaussien — that single sentence is the whole justification, and it is why the definition by linear combinations is the useful one. Its mean is $(w, 0)$, since $(A^T A)^{-1} A^T A w = w$ and $(I_n - P)Aw = Aw - Aw = 0$, and its matrice de covariance is diagonal by blocs:

$$\text{Cov} \begin{pmatrix} W \\ R \end{pmatrix} = \sigma^2 \begin{pmatrix} (A^T A)^{-1} & 0 \\ 0 & I_n - P \end{pmatrix},$$

the cross bloc being $\sigma^2(A^T A)^{-1} A^T (I_n - P) = \sigma^2(A^T A)^{-1} (A^T - A^T) = 0$ because $A^T P = A^T$. The bloc being zero, the bloc form of the indépendance theorem gives that the estimator W and the residual R are independent — and in particular so are the single component W_1 and the whole vector R .

Three consequences, each one of the theorems above. First, $W_1 \sim \mathcal{N}(w_1, \sigma^2[(A^T A)^{-1}]_{11})$, read off the diagonal. Second, R is a vecteur gaussien *dégénéré*: its matrice de covariance $\sigma^2(I_n - P)$ has rank $n - d$, so R has no densité on $\mathbb{R}^n$, exactly as the densité theorem predicts. Third, writing $\bar{Z} = Z/\sigma$ for the centré réduit part and using the spectral decomposition of the projection P ,

$$\frac{\|R\|^2}{\sigma^2} = \bar{Z}^T (I_n - P) \bar{Z}$$

is a sum of the squares of $n - d$ independent variables of loi normale centrée réduite, because $Q\bar{Z}$ is again a vecteur gaussien centré réduit for Q orthogonal — that is $QQ^T = I$ in the affine transformation theorem. It therefore follows a loi du χ^2 à $n - d$ degrés de liberté.

A variable of loi normale centrée réduite divided by the square root of an independent χ^2 over its degrees of freedom is by definition a variable of **loi de Student** (*Student distribution*), so with $c = \sqrt{[(A^T A)^{-1}]_{11}}$,

$$\frac{W_1 - w_1}{c \sqrt{\frac{\|R\|^2}{n - d}}}$$

follows a loi de Student with $n - d$ degrees of freedom. The unknown σ has cancelled between numerator and denominator, which is the point of the construction: the quantity can be computed from the data alone, and inverting it around w_1 turns the symmetry of the loi de Student into a confidence interval for the unknown parameter. Every step used only the two theorems of this section — an affine image of a vecteur gaussien is Gaussian, and a vanishing covariance bloc in a vecteur gaussien is indépendance.

Conclusion. One definition carries the chapter: a vecteur aléatoire is Gaussian when every linear combination of its components is a normal variable, and the counter-example shows why nothing weaker will do. From it, the fonction caractéristique $e^{it^T \mu} e^{-t^T \Gamma t/2}$ follows in a line, and with it the fact that μ and Γ determine the loi. The rest is arithmetic on those two objects. An affine image $AX + b$ is Gaussian with parameters $A\mu + b$ and $A\Gamma A^T$. A densité on $\mathbb{R}^n$ exists exactly when Γ is invertible, and when it is not the vector is a perfectly good Gaussian carried by an affine subspace. Components are independent exactly when Γ is diagonal, which makes this the one place in the course where zero covariance implies indépendance — and only because the vector, not merely each component, is Gaussian.

8 Théorèmes limites

Everything up to here has been about one variable aléatoire, or finitely many at a time: its loi, its moments, its fonction caractéristique, the loi of a vector built from it. Ce chapitre porte sur deux résultats fondamentaux de convergence de suites de variables aléatoires : la loi des grands nombres et le théorème central limite — the two results the whole construction was built for. The loi forte des grands nombres says that an empirical mean settles on the espérance, and the théorème central limite that the error it makes on the way there is Gaussian.

Both are statements that a sequence $X_1, X_2, \dots$ converges to something, so both need a notion of convergence

for variables aléatoires, and there is more than one. A variable aléatoire is a function on Ω , so one can ask for convergence of the functions — pointwise, for almost every ω — and that is the strongest thing to ask. Or one can forget Ω entirely and ask only that the *lois* converge, which is much weaker and is exactly what the théorème central limite delivers. Nous commençons par définir deux notions usuelles de convergence d'une suite de variables aléatoires : la convergence presque sûre et la convergence en loi. The first two subsections below set them up and relate them; the last three are the theorems.

Remark. D'autres notions de convergence existent, comme la convergence en probabilité, mais ne sont pas abordées dans ce cours — convergence in L^p is another. Convergence en probabilité is carried here anyway, marked as an addition, for the reason given at the end of the first subsection.

8.1 Convergence presque sûre

Two French abbreviations run through this chapter, both already in use. *p.s.* is the probabilistic name for *p.p.* from chapter 2, specialised to a measure that happens to be a probability — the exceptional set is $\mathbb{P}$ -négligeable rather than merely λ -négligeable, but nothing else changes.

For an i.i.d. sequence both halves of the abbreviation are used in the proofs below, and they are used differently — indépendance gives the factorisation of a fonction caractéristique or the vanishing of a cross term, and being identiquement distribuées gives the single loi that the limit is expressed in terms of. A sequence can have one without the other, and then neither theorem in this chapter applies.

Notation. Throughout, $X_1, X_2, \dots$ is a sequence of variables aléatoires réelles on a common espace de probabilité $(\Omega, \mathcal{F}, \mathbb{P})$, and $S_n = \sum_{i=1}^n X_i$ is its sequence of partial sums. That the space is common matters for convergence presque sûre, which compares $X_n(\omega)$ with $X(\omega)$ for the same ω , and not at all for convergence en loi, which never looks at ω .

Two Greek letters are kept apart: φ is a fonction caractéristique — φ_X , φ_n , or a bare φ for the limit's — and ϕ is always a fonction test, bounded and continuous where convergence en loi is being tested, mesurable and non-negative where the théorème de transfert is being applied. A continuous map applied to a sequence is written g .

La notion de convergence la plus forte est une convergence simple, valable pour presque toute réalisation ω : simple pointwise convergence of the functions $X_n : \Omega \rightarrow \mathbb{R}$, asked for not at every realisation but at almost every one.

Definition (Convergence presque sûre (*almost-sure convergence*)). On dit qu'une suite de variables aléatoires réelles $X_1, X_2, \dots$ converge **presque sûrement** vers une variable aléatoire réelle X si la suite $X_1(\omega), X_2(\omega), \dots$ converge vers $X(\omega)$ pour presque tout $\omega \in \Omega$:

$$\mathbb{P} \left(\left\{ \omega \in \Omega : \lim_{n \rightarrow +\infty} X_n(\omega) = X(\omega) \right\} \right) = 1.$$

Notation. On utilise la notation :

$$X_n \xrightarrow{\text{p.s.}} X.$$

The set appearing in the definition is mesurable — it is $\bigcap_{k \geq 1} \bigcup_{N \geq 1} \bigcap_{n \geq N} \{|X_n - X| \leq 1/k\}$, a countable combination of événements — so asking for its probability is legitimate. What the definition does *not* require is convergence at every ω , and in most applications there is a genuine exceptional événement: the binary-digit example below has one, and it contains the dyadic rationals, whose expansions are eventually constant. It is $\mathbb{P}$ -négligeable, but not for the cheap reason of being countable — it is not countable.

Proposition. Si $X_n \xrightarrow{\text{p.s.}} X$, alors $g(X_n) \xrightarrow{\text{p.s.}} g(X)$ pour toute fonction continue g .

Proof. Soit $\omega \in \Omega$ tel que $\lim_n X_n(\omega) = X(\omega)$. Pour toute fonction continue g , $\lim_n g(X_n(\omega)) = g(X(\omega))$, by continuity at the point $X(\omega)$. The événement on which $g(X_n)$ converges to $g(X)$ therefore contains the événement on which X_n converges to X . On a donc :

$$\mathbb{P} \left(\lim_n g(X_n) = g(X) \right) \geq \mathbb{P} \left(\lim_n X_n = X \right) = 1.$$

That one line is worth remembering as a move rather than as a result. Convergence presque sûre is convergence of numbers at a fixed ω , so anything true of convergent sequences of reals transfers to it by intersecting événements of probability 1 — countably many of which still intersect to an événement of probability 1. It is why the loi forte can be composed with a logarithm or an exponential below without further work.

Convergence en probabilité, un complément

The next definition is *not* part of the course. The course defines convergence presque sûre and convergence en loi, and names convergence en probabilité only to say that it is not treated — so nothing about it is ever defined or proved in it. It is carried here for one reason: it sits between the two modes the course does define, it is assumed wherever it turns up, and a problem on this syllabus may well supply the definition inline before asking for the implication below, precisely because the course does not.

Definition (Convergence en probabilité (*convergence in probability*) — hors programme). A sequence of variables aléatoires réelles $X_1, X_2, \dots$ converge **en probabilité** to a variable aléatoire réelle X if

$$\forall a > 0, \quad \lim_{n \rightarrow +\infty} \mathbb{P}(|X_n - X| > a) = 0.$$

This is written $X_n \xrightarrow{\mathbb{P}} X$.

Proposition (Hors programme). If $X_n \xrightarrow{p.s.} X$, then $X_n \xrightarrow{\mathbb{P}} X$.

Proof. Fix $a > 0$ and write the probability as an integral of an indicator:

$$\mathbb{P}(|X_n - X| > a) = \int_{\Omega} \mathbb{1}_{\{|X_n - X| > a\}} d\mathbb{P}.$$

On the événement of probability 1 where $X_n(\omega) \rightarrow X(\omega)$, one has $|X_n(\omega) - X(\omega)| \leq a$ for all n large enough, so the integrand tends to 0 *p.s.* It is bounded by the constant function 1, which is integrable because $\mathbb{P}(\Omega) = 1$ is finite, so convergence dominée applies and the integral tends to 0.

Remark. The domination is available only because the mesure is finite — the constant 1 is not integrable for the mesure de Lebesgue on $\mathbb{R}$ — so this is one of the few places where the normalisation $\mathbb{P}(\Omega) = 1$ does real work rather than bookkeeping.

Remark. The converse is false: a single indicator window of width $1/n$ sliding cyclically around $[0, 1]$ has $\mathbb{P}(|X_n| > a) = 1/n \rightarrow 0$, so $X_n \xrightarrow{\mathbb{P}} 0$, while every ω is hit infinitely often and $X_n(\omega)$ converges for no ω at all.

8.2 Convergence en loi

The second notion forgets the univers. Comme son nom l'indique, elle ne concerne que les *lois* des variables aléatoires impliquées, et non leur réalisation: the variables need not even be defined on the same espace de probabilité, and nothing is being compared ω by ω . What is compared is the sequence of fonctions de répartition.

Definition (Convergence en loi (*convergence in distribution*)). On dit qu'une suite de variables aléatoires réelles $X_1, X_2, \dots$ converge **en loi** vers une variable aléatoire réelle X si leurs fonctions de répartition $F_1, F_2, \dots$ convergent vers sa fonction de répartition F en tout point de continuité de celle-ci :

$$\forall x \text{ where } F \text{ is continuous,} \quad \lim_{n \rightarrow +\infty} F_n(x) = F(x).$$

Notation. On utilise la notation :

$$X_n \xrightarrow{\mathcal{L}} X.$$

Comme cette notion de convergence s'applique aux lois, on pourra également l'écrire comme tel, par exemple $X_n \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$: the right-hand side may be a loi rather than a variable, and this means that the loi limite is the loi normale centrée réduite.

The restriction to continuity points of F is not a technical nicety appended to make some proof work — it is the content of the definition. Requiring $F_n(x) \rightarrow F(x)$ at *every* x would break the two most natural examples of convergence to a constant, and a version of the definition without the restriction is simply wrong.

Example (A Gaussian collapsing onto a point). Soit une suite de variables aléatoires avec $X_n \sim \mathcal{N}(0, 1/n)$ pour tout $n \geq 1$. The variance shrinks to 0 and the loi concentrates at the origin:

$$\forall x, \quad \lim_{n \rightarrow +\infty} \mathbb{P}(X_n \leq x) = \begin{cases} 0 & \text{for } x < 0, \\ 1 & \text{for } x > 0, \end{cases}$$


which is the fonction de répartition of the constant variable aléatoire 0 at every $x \neq 0$. Cette suite converge donc en loi vers zéro: $X_n \xrightarrow{\mathcal{L}} 0$. At $x = 0$ itself the limit fails: by symmetry $F_n(0) = 1/2$ for every n , while $F(0) = 1$. The single point where the convergence breaks down is the single discontinuity of F , and the definition excludes exactly it.

Example (A deterministic sequence, converging en loi to a constant). The same phenomenon with no randomness at all. Let X_n be deterministic and equal to $1/n$, and X deterministic and equal to 0. Then

$$F_n(x) = \mathbb{1}_{\{x \geq 1/n\}}, \quad F(x) = \mathbb{1}_{\{x \geq 0\}},$$

and $X_n \rightarrow X$ in the most literal sense available — the numbers converge. For $x < 0$, $F_n(x) = 0 = F(x)$ for every n ; for $x > 0$, $F_n(x) = 1 = F(x)$ as soon as $n > 1/x$. But at $x = 0$, $F_n(0) = 0$ for every n , while $F(0) = 1$, and the sequence $F_n(0)$ does not converge to $F(0)$. Without the continuity-point restriction the definition would refuse to call $1/n \rightarrow 0$ a convergence en loi, which is absurd; with it, the one bad point is the one jump of F and is discarded.

The figure draws that second example. The two fonctions de répartition agree everywhere except on the interval $[0, 1/n)$, which shrinks to nothing, and the one point where they refuse to meet in the limit is the jump of F .



The two fonctions en escalier take the values 0 and 1; they are drawn at slightly different heights only to keep them apart.

Le résultat suivant, dont la preuve est omise, donne deux autres façons de caractériser la convergence en loi, and they are what make it usable: the first replaces fonctions de répartition by fonctions test, and the second replaces them by fonctions caractéristiques, which is the bridge back to the previous chapters and the engine of the théorème central limite.

Theorem (Trois caractérisations de la convergence en loi). Soit $X_1, X_2, \dots$ une suite de variables aléatoires réelles, de fonctions caractéristiques respectives $\varphi_1, \varphi_2, \dots$, et X une variable aléatoire réelle, de fonction caractéristique φ . Les propositions suivantes sont équivalentes :

1. La suite $X_1, X_2, \dots$ converge en loi vers X .
2. Pour toute fonction continue bornée ϕ ,

$$\lim_{n \rightarrow +\infty} \mathbb{E}(\phi(X_n)) = \mathbb{E}(\phi(X)).$$

3. Pour tout $t \in \mathbb{R}$,

$$\lim_{n \rightarrow +\infty} \varphi_n(t) = \varphi(t).$$

Remark. Both hypotheses on the fonction test in branch 2 are needed. Bounded, because $\mathbb{E}(\phi(X_n))$ must exist without any integrability assumption on X_n — and the theorem is stated for arbitrary sequences, with no moments assumed. Continuous, because the definition tolerates failure at the discontinuity points of F , and a discontinuous fonction test can be built to sit exactly on one of them: taking $\phi = \mathbb{1}_{(-\infty, 0]}$ in the deterministic example above gives $\mathbb{E}(\phi(X_n)) = 0$ for every n and $\mathbb{E}(\phi(X)) = 1$.

Remark. Branch 3 is the reason the fonction caractéristique chapter comes before this one. It converts a question about lois — objects with no arithmetic — into a question about pointwise convergence of a sequence of fonctions on $\mathbb{R}$, and fonctions caractéristiques of sums of independent variables multiply. Pointwise convergence, with no uniformity asked for anywhere, is all that is required. The full statement of the corresponding converse (Lévy's theorem, requiring the limit to be continuous at 0) is not part of this course: here the limit φ is always given in advance as the fonction caractéristique of an actual variable aléatoire, which is what branch 3 presupposes.

Convergence en loi can also be read off densités when they exist, and the proof is one application of convergence dominée followed by one application of the theorem above.

Proposition (Densités convergeant presque partout). *Soit $X_1, X_2, \dots$ une suite de variables aléatoires réelles, de densités respectives $f_1, f_2, \dots$, et X une variable aléatoire réelle, de densité f . Si la suite $(f_n)_{n \geq 1}$ converge presque partout vers f , alors la suite $X_1, X_2, \dots$ converge en loi vers X .*

Proof. Pour toute fonction continue bornée ϕ , the théorème de transfert gives

$$\mathbb{E}(\phi(X_n)) = \int \phi(x) f_n(x) dx \longrightarrow \int \phi(x) f(x) dx = \mathbb{E}(\phi(X)),$$

par convergence dominée: the integrands converge *p.p.*, since $f_n \rightarrow f$ *p.p.* and ϕ is fixed, and they are bounded in modulus by $\|\phi\|_\infty f_n$. Le résultat est alors une conséquence du théorème précédent — its branch 2.

Remark. The domination needs care: the bound $\|\phi\|_\infty f_n$ moves with n , so it is not a fixed dominating function and the argument as written is a sketch. The repair leans on a standard result the course neither states nor proves (Scheffé's lemma): $f_n \rightarrow f$ *p.p.*, all non-negative of integral 1, forces $\int |f_n - f| \rightarrow 0$, and then $|\mathbb{E}(\phi(X_n)) - \mathbb{E}(\phi(X))| \leq \|\phi\|_\infty \int |f_n - f| \rightarrow 0$, with no domination needed at all.

Remark. The implication runs one way only. Convergence en loi does not give convergence of densités, and the loi limite need not even have a densité: the two examples above converge en loi to a constant, whose loi is a mesure de Dirac with no densité at all. Convergence of densités is a genuinely stronger hypothesis, which is why it is stated as a sufficient condition and not as a characterisation.

The two notions of convergence are now related. La convergence presque sûre est plus forte que la convergence en loi :

Theorem (La convergence presque sûre implique la convergence en loi). *Soit $X_1, X_2, \dots$ une suite de variables aléatoires réelles :*

$$X_n \xrightarrow{p.s.} X \implies X_n \xrightarrow{\mathcal{L}} X.$$

Proof. Pour toute fonction continue bornée ϕ , on a par continuité (the stability of convergence presque sûre under a continuous map) :

$$\phi(X_n) \xrightarrow{p.s.} \phi(X).$$

La fonction ϕ étant bornée, the sequence $\phi(X_n)$ is dominated by the constant $\|\phi\|_\infty$, which is integrable for the finite mesure $\mathbb{P}$; on a donc par le théorème de convergence dominée :

$$\lim_{n \rightarrow +\infty} \mathbb{E}(\phi(X_n)) = \mathbb{E}(\phi(X)).$$

Le résultat découle du théorème des trois caractérisations — this is its branch 2 — so $X_n \xrightarrow{\mathcal{L}} X$.

Proposition. Si $X_n \xrightarrow{\mathcal{L}} X$, alors $g(X_n) \xrightarrow{\mathcal{L}} g(X)$ pour toute fonction continue g .

Proof. Pour toute fonction continue bornée ϕ , la fonction $\phi \circ g$ est elle-même continue bornée — bounded since ϕ is. Par le théorème des trois caractérisations (branch 2), applied to $X_n \xrightarrow{\mathcal{L}} X$,


$$\lim_{n \rightarrow +\infty} \mathbb{E}(\phi \circ g(X_n)) = \mathbb{E}(\phi \circ g(X)).$$

As this holds for every bounded continuous ϕ , l'application de ce même théorème, read in the other direction, implique que $g(X_n) \xrightarrow{\mathcal{L}} g(X)$.

Remark. Both stability results are used in the same shape: prove a convergence for the easiest transform of the sequence — usually a logarithm, which turns a product into a sum the limit theorems can reach — then push it through the exponential. The examples below do this twice.

Liens entre les modes de convergence

Collecting the implications, with the mode that is not part of the course drawn dashed:



the dashed box and the dashed arrow are the addition —
the course defines only the two solid modes

Remark. None of the arrows reverses. The sliding window above converges en probabilité and not presque sûrement; and with X of loi normale centrée réduite and $X_n = -X$ for every n , $X_n \xrightarrow{\mathcal{L}} X$ holds trivially while $|X_n - X| = 2|X|$ never gets small. The one partial converse worth knowing belongs to the addition and is stated, not proved, here: convergence en loi to a constant does imply convergence en probabilité to that constant.

8.3 Loi forte des grands nombres

La **loi forte des grands nombres** (*strong law of large numbers*) régit la limite de la moyenne empirique d'une suite de variables aléatoires i.i.d. La seule condition est que ces variables aléatoires aient une espérance — no variance, no higher moment, nothing else. On parle de loi *forte* car elle implique la convergence presque sûre: a weak law would conclude only convergence en probabilité.

Theorem (Loi forte des grands nombres). Pour toute suite $X_1, X_2, \dots$ de variables aléatoires réelles i.i.d. ayant une espérance,

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p.s.} \mathbb{E}(X_1).$$

Remark. The hypothesis is exactly “i.i.d. with an espérance”, that is, $\mathbb{E}(|X_1|) < +\infty$. It is *not* “with a finite variance”: that stronger hypothesis belongs to the weak law and to the proof carried below, and importing it into the statement would weaken the theorem for no gain. The distinction is not academic — the Cauchy example at the end of this subsection is a sequence with no espérance, and for it the theorem has nothing to say and the empirical mean genuinely fails to settle.

Proof. On donne une preuve partielle, dans le cas où les variables aléatoires ont un moment d'ordre 4.

Quitte à recentrer ces variables, on suppose que leur espérance est nulle, $\mathbb{E}(X_1) = 0$, et on note $S_n = \sum_{i=1}^n X_i$.

Step 1: a bound on the moment d'ordre 4 of S_n . Expand S_n^4 and take espérances. Indépendance

makes every term containing a factor X_i to the first power vanish, because $\mathbb{E}(X_1) = 0$ and the factors split; what survives are the terms X_i^4 , of which there are n , and the terms $X_i^2 X_j^2$ with $i \neq j$, of which there are $\binom{n}{2}$ pairs each arising with the multinomial coefficient $\binom{4}{2}$:

$$\mathbb{E}(S_n^4) = n \mathbb{E}(X_1^4) + \binom{n}{2} \binom{4}{2} \mathbb{E}(X_1^2 X_2^2).$$

Both espérances on the right are finite and do not depend on n , and $\binom{n}{2} \leq n^2/2$, so $\mathbb{E}(S_n^4)$ grows at most like n^2 .

Step 2: a summable series. Soit :

$$T = \sum_{n \geq 1} \left(\frac{S_n}{n} \right)^4,$$

a sum of non-negative terms, so the interchange of $\mathbb{E}$ and $\sum$ is legitimate — it is the Tonelli-type result for series of non-negative variables aléatoires from chapter 4, which needs no integrability hypothesis:

$$\mathbb{E}(T) = \sum_{n \geq 1} \frac{\mathbb{E}(S_n^4)}{n^4}.$$

By step 1 the general term is $O(n^{-2})$, so the series converges and $\mathbb{E}(T) < +\infty$.

Step 3: from an integrable sum to a vanishing term. A non-negative variable aléatoire with a finite espérance is finite *p.s.*: cette quantité étant finie, on en déduit que T est *p.s.* finie. A convergent series has a vanishing general term, so for almost every ω the terms $(S_n(\omega)/n)^4$ tend to 0. Ceci implique que :

$$\frac{S_n}{n} \xrightarrow{\text{p.s.}} 0,$$

which is the claim after undoing the recentring.

Remark. The technique of step 3 is the one to carry away, and it is more general than the theorem: to prove that a sequence of variables aléatoires converges presque sûrement to 0, it is enough to show that the *series* of some positive power of it has finite espérance. The fourth power is used rather than the second because the second is not summable — $\mathbb{E}(S_n^2)/n^2 = 1/n$ for unit-variance variables, and $\sum 1/n$ diverges. Going up to the fourth power buys the extra factor of n at the cost of a moment hypothesis that the full theorem does not need.

Example (Empirical frequency of a Bernoulli trial). Soit $X_1, X_2, \dots$ une suite de variables aléatoires i.i.d. suivant une loi de Bernoulli $\mathcal{B}(p)$ de paramètre $p \in [0, 1]$. Alors :

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\text{p.s.}} p.$$

The empirical frequency of an événement converges presque sûrement to its probability, which is the statement that makes the frequentist reading of $\mathbb{P}$ a theorem rather than a definition.

Example (Empirical mean of a centred normal sample). Soit $X_1, X_2, \dots$ une suite de variables aléatoires i.i.d. de loi normale centrée réduite $\mathcal{N}(0, 1)$. Alors :

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\text{p.s.}} 0.$$

Worth contrasting with the exact loi: $\frac{1}{n} S_n \sim \mathcal{N}(0, 1/n)$ for every n , the Gaussian collapsing onto a point from the earlier example. The loi forte says more than that collapse — it says the convergence holds ω by ω , not merely en loi.

Example (A loi with no espérance: Cauchy). Soit $X_1, X_2, \dots$ une suite de variables aléatoires i.i.d. de loi de Cauchy. Cette loi n'ayant pas d'espérance, la loi des grands nombres ne s'applique pas, and the empirical mean does not converge — in fact $\frac{1}{n}S_n$ has the same loi de Cauchy for every n , so it does not settle anywhere. On a par contre — the positive and negative parts both blow up :

$$\frac{1}{n} \sum_{i=1}^n X_i^+ \xrightarrow{\text{p.s.}} +\infty \quad \text{and} \quad \frac{1}{n} \sum_{i=1}^n X_i^- \xrightarrow{\text{p.s.}} +\infty,$$

two limits stated here without proof. The theorem above does not supply them: X_1^+ and X_1^- have infinite espérance, so they fall outside its hypothesis. What they need is the extension of the loi forte to non-negative variables of infinite espérance, obtained by truncation, which this course does not state. The empirical mean is then the difference of two sequences both going to $+\infty$, and the indeterminacy is real, not an artefact of the proof.

Example (Three means of a Beta sample). Soit $X_1, \dots, X_n$ des variables aléatoires i.i.d. de loi $\mathcal{B}(2, 1)$, whose densité is $2x$ on $[0, 1]$. Each of the three classical means has an almost-sure limit, and each is the loi forte applied to a different transform of the sample.

The arithmetic mean converges to $\mathbb{E}(X_1) = \int_0^1 2x^2 dx = 2/3$.

The geometric mean is handled by taking a logarithm, which turns it into an arithmetic mean:

$$\ln \left(\prod_{i=1}^n X_i \right)^{1/n} = \frac{1}{n} \sum_{i=1}^n \ln X_i \xrightarrow{\text{p.s.}} \mathbb{E}(\ln X_1) = \int_0^1 2x \ln x dx = -\frac{1}{2},$$

and pushing through the exponential, which is continuous, gives the geometric mean converging *p.s.* to $e^{-1/2}$. The harmonic mean is the reciprocal of the arithmetic mean of the reciprocals: $\frac{1}{n} \sum 1/X_i \xrightarrow{\text{p.s.}} \mathbb{E}(1/X_1) = \int_0^1 2 dx = 2$, and the reciprocal being continuous away from 0, the harmonic mean converges *p.s.* to $1/2$. The three limits satisfy $1/2 < e^{-1/2} \approx 0.607 < 2/3$, the usual ordering of means — a cheap check on the arithmetic.

Example (The digits of a uniform variable). Soit U une variable aléatoire uniforme sur $[0, 1]$, and write its binary expansion $U = \sum_{k \geq 1} b_k 2^{-k}$. The digits $b_1, b_2, \dots$ are i.i.d. of loi $\mathcal{B}(1/2)$ — each is determined by which half of a dyadic interval U falls in, and the halves are chosen independently by uniformity. By the loi forte, la fraction de 1 des n premiers bits de sa décomposition binaire tend presque sûrement vers un demi :

$$\frac{1}{n} \sum_{k=1}^n b_k \xrightarrow{\text{p.s.}} \frac{1}{2}.$$

The exceptional set is not empty: it contains the dyadic rationals, whose expansions are eventually constant. It is far larger than that — every u whose digit frequency is some other value lies in it too, and those form an uncountable family — so its negligibility comes from the loi forte itself and not from counting. That is exactly the licence the word *presque* gives.

Example (A random number of terms). Soit $X_1, X_2, \dots$ une suite de variables aléatoires i.i.d. de loi de Bernoulli $\mathcal{B}(p)$ de paramètre $p > 0$, with partial sums S_n . On note $Y_1, Y_2, \dots$ une suite de variables aléatoires i.i.d. de loi Poisson $\mathcal{P}(\lambda)$, independent of the first sequence. Then

$$\frac{1}{n} \sum_{k=1}^{S_n} Y_k \xrightarrow{\text{p.s.}} p\lambda.$$

Factor the quantity as $\frac{S_n}{n} \cdot \frac{1}{S_n} \sum_{k \leq S_n} Y_k$. The first factor tends *p.s.* to p by the loi forte. For the second, $p > 0$ forces $S_n \rightarrow +\infty$ *p.s.*, so it is the empirical mean of the Y sequence along indices tending to infinity and tends *p.s.* to $\mathbb{E}(Y_1) = \lambda$. The two almost-sure événements intersect in one of probability 1, on which the limits multiply.

Example (Équirépartition asymptotique). Soit $X_1, X_2, \dots$ une suite de variables aléatoires i.i.d. sur $\{1, \dots, K\}$ — a finite alphabet — et $p(k_1, \dots, k_n) = \mathbb{P}(X_1 = k_1, \dots, X_n = k_n)$, the probability of an observed word. Indépendance factorises it, so taking a logarithm turns it into a sum the loi forte reaches:

$$-\frac{1}{n} \ln p(X_1, \dots, X_n) = -\frac{1}{n} \sum_{i=1}^n \ln p_{X_i} \xrightarrow{\text{p.s.}} -\mathbb{E}(\ln p_{X_1}) = -\sum_{k=1}^K p_k \ln p_k,$$

where $p_k = \mathbb{P}(X_1 = k)$. Il s'agit de l'entropie de la loi de X_1 : $H = -\sum_k p_k \ln p_k$. Par continuité de la fonction exponentielle, on obtient

$$\sqrt[n]{p(X_1, \dots, X_n)} \xrightarrow{\text{p.s.}} e^{-H} :$$

almost every long word has probability close to e^{-nH} , so the K^n possible words split into roughly e^{nH} words of nearly equal probability and a remainder of négligeable total probability. This is the loi forte doing the work that information theory calls the **équirépartition asymptotique** (*asymptotic equipartition property*).

Example (A limiting geometric mean). Let $U_1, U_2, \dots$ be i.i.d. uniform on $(0, 1)$. First, $-\ln U_1$ follows the loi exponentielle $\mathcal{E}(1)$: for every mesurable $\phi \geq 0$, the changement de variable $v = -\ln u$ gives

$$\mathbb{E}(\phi(-\ln U_1)) = \int_0^1 \phi(-\ln u) du = \int_0^{+\infty} \phi(v) e^{-v} dv,$$

which identifies the loi by the théorème de transfert. Hence $\mathbb{E}(\ln U_1) = -1$. Writing $G_n = \sqrt[n]{U_1 U_2 \cdots U_n}$ and taking a logarithm,

$$\ln G_n = \frac{1}{n} \sum_{i=1}^n \ln U_i \xrightarrow{\text{p.s.}} -1,$$

by the loi forte, and the exponential being continuous,

$$G_n \xrightarrow{\text{p.s.}} \frac{1}{e}.$$

The geometric mean of uniform variables does not converge to the arithmetic mean $1/2$ but to $1/e \approx 0.368$, which is smaller, as it must be. The same sequence reappears in the next subsection, where the théorème central limite describes its fluctuations.

8.4 Théorème central limite

The loi forte says where the empirical mean goes. Le **théorème central limite** (*central limit theorem*) s'intéresse à la loi des écarts à la moyenne empirique, toujours pour une suite de variables aléatoires i.i.d.: it says how the mean gets there, describing the deviation from the limit once that deviation is magnified by the right factor. On suppose que ces variables ont un moment d'ordre 2 (donc d'espérance et de variance finies) — a hypothesis one notch stronger than the loi forte's — and the conclusion is one notch weaker, convergence en loi rather than convergence presque sûre. That trade is the whole content of the theorem.

Theorem (Théorème central limite). *Pour toute suite $X_1, X_2, \dots$ de variables aléatoires réelles i.i.d. d'espérance finie μ et de variance finie σ^2 ,*

$$\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n X_i - \mu \right) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2).$$

Remark. The $\sqrt{n}$ is not adjustable. The quantity in brackets tends to 0 *p.s.* by the loi forte, so any factor growing more slowly than $\sqrt{n}$ would give the constant 0 in the limit and any factor growing faster would give no limit at all; $\sqrt{n}$ is the unique scale at which the deviation has a loi limite non dégénérée, and it is dictated by the variance of the mean being σ^2/n . Note also what the loi limite does *not* depend on: the loi of X_1 enters only through σ^2 . That is the universality the theorem is famous for.

Proof. Reductions. Quitte à recentrer les variables aléatoires, on peut supposer que leur espérance est nulle, $\mu = 0$. Si leur variance est nulle, $\sigma^2 = 0$, le résultat est évident: the variables are *p.s.* constant and the left-hand side is *p.s.* zero; sinon, quitte à les renormaliser (by σ), on peut supposer que leur variance est égale à 1, $\sigma^2 = 1$. On note encore $S_n = \sum_{i=1}^n X_i$. On s'intéresse à la loi limite de la variable aléatoire $S_n/\sqrt{n}$.

Step 1: factorise the fonction caractéristique. The variables being indépendantes et identiquement distribuées, the fonction caractéristique of the sum is the product of the fonctions caractéristiques, and scaling the argument handles the $\sqrt{n}$:

$$\forall t \in \mathbb{R}, \quad \varphi_{S_n/\sqrt{n}}(t) = \varphi_{S_n}\left(\frac{t}{\sqrt{n}}\right) = \varphi_{X_1}\left(\frac{t}{\sqrt{n}}\right)^n.$$

Step 2: expand at the origin. X_1 has a moment d'ordre 2, so its fonction caractéristique is twice differentiable at 0 and the expansion from the fonction caractéristique chapter applies. Comme cette variable est supposée d'espérance nulle et de variance 1 (suite à l'étape initiale de recentrage et normalisation), that is $\mathbb{E}(X_1) = 0$ and $\text{Var}(X_1) = 1$, the first-order term vanishes and

$$\varphi_{X_1}(t) = 1 - \frac{t^2}{2} + o(t^2), \quad \text{so} \quad \varphi_{X_1}\left(\frac{t}{\sqrt{n}}\right) = 1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right).$$

Step 3: compare the n -th powers. Fix t . Pour n assez grand, on a $|1 - t^2/(2n)| \leq 1$ et donc, by the elementary bound $|a^n - b^n| \leq n|a - b|$ for complex a, b of modulus at most 1 :

$$\left| \varphi_{X_1}\left(\frac{t}{\sqrt{n}}\right)^n - \left(1 - \frac{t^2}{2n}\right)^n \right| \leq n \left| \varphi_{X_1}\left(\frac{t}{\sqrt{n}}\right) - \left(1 - \frac{t^2}{2n}\right) \right| = n \cdot o\left(\frac{t^2}{n}\right) \rightarrow 0.$$

Step 4: identify the limit. Since $(1 - t^2/(2n))^n \rightarrow e^{-t^2/2}$, on en déduit que :

$$\lim_{n \rightarrow +\infty} \varphi_{S_n/\sqrt{n}}(t) = \lim_{n \rightarrow +\infty} \varphi_{X_1}\left(\frac{t}{\sqrt{n}}\right)^n = e^{-t^2/2},$$

qui est la fonction caractéristique d'une loi normale centrée réduite, as computed in the fonction caractéristique chapter. Par le théorème des trois caractérisations (branch 3),


$$\frac{S_n}{\sqrt{n}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1).$$

Undoing the two reductions — multiplying back by σ and restoring μ — gives the statement.

Remark. Every hypothesis is visible in exactly one step. Being identiquement distribuées is what makes step 1 a single fonction caractéristique raised to a power rather than a product of n different ones. Indépendance is what makes it a product at all. The moment d'ordre 2 is what makes step 2 legitimate, and it is the only place any moment is used — there is no moment d'ordre 3 anywhere in the proof, and none is needed. Step 3 is a purely analytic estimate with no probability in it. The convergence obtained is pointwise in t , which is precisely what branch 3 asks for.

Remark. The specialisation $S_n/\sqrt{n} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$, obtained in step 4 for variables centrées of unit variance, is the form actually used in computations: it says that a sum of n i.i.d. variables centrées is of order $\sqrt{n}$, with Gaussian fluctuations. For variables of variance σ^2 the same statement reads $S_n/\sqrt{n} \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2)$, and for variables that are not centrées $(S_n - n\mu)/\sqrt{n} \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2)$, which is the theorem multiplied out.

The figure shows the convergence taking place for the least Gaussian-looking starting point available: the loi uniforme on $[0, 1]$. Each panel plots the exact densité of the standardised sum of n such variables against the densité of the loi normale centrée réduite. At $n = 1$ the two could hardly look less alike; at $n = 2$ the sum is triangular; by $n = 5$ the shape is already close; at $n = 30$ the two curves are indistinguishable at this scale.



Example (Fluctuations of a Bernoulli frequency). Soit $X_1, X_2, \dots$ une suite de variables aléatoires i.i.d. suivant une loi de Bernoulli $\mathcal{B}(p)$ de paramètre $p \in [0, 1]$. The variance is $p(1 - p)$, so

$$\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n X_i - p \right) \xrightarrow{\mathcal{L}} \mathcal{N}(0, p(1 - p)).$$

Autrement dit, pour n assez grand, la loi de l'écart de la moyenne empirique à la valeur limite p est proche d'une loi normale centrée et de variance $p(1 - p)/n$. This is the statement behind every confidence interval for a proportion.

Example (A loi du χ^2 is asymptotically normal). La loi du χ^2 à n degrés de liberté is by definition the loi of $Z_1^2 + \dots + Z_n^2$ with $Z_1, \dots, Z_n$ i.i.d. $\mathcal{N}(0, 1)$. The summands are i.i.d.; comme $\mathbb{E}(Z_1^2) = 1$ et $\text{Var}(Z_1^2) = \mathbb{E}(Z_1^4) - 1 = 3 - 1 = 2$, both finite, the théorème central limite applies to them. Formellement,

$$\frac{1}{\sqrt{n}} \left(\sum_{i=1}^n Z_i^2 - n \right) \xrightarrow{\mathcal{L}} \mathcal{N}(0, 2).$$

La loi $\chi^2(n)$ est donc proche de $\mathcal{N}(n, 2n)$, pourvu que n soit assez grand. The moment $\mathbb{E}(Z_1^4) = 3$ is the moment d'ordre 4 of the loi normale centrée réduite, read off the fourth-order expansion of $e^{-t^2/2}$ in the fonction caractéristique chapter.

Example (A Poisson sum cut at its mean). For $a, n > 0$ set $F(a, n) = \sum_{k=0}^{\lfloor an \rfloor} n^k / k!$. Since a sum of n i.i.d. $\mathcal{P}(1)$ variables follows $\mathcal{P}(n)$ — which the fonction génératrice settles in one line, $G_Y(s) = e^{n(s-1)} = (e^{s-1})^n$ — one may write $e^{-n} F(a, n) = \mathbb{P}(Y \leq an)$ with $Y \sim \mathcal{P}(n)$, that is, $Y = X_1 + \dots + X_n$ for i.i.d. $\mathcal{P}(1)$ variables. For $a \in (0, 1)$, the loi forte gives $\frac{1}{n}(X_1 + \dots + X_n) \xrightarrow{\text{p.s.}} 1$, hence convergence en loi to the constant 1, whose fonction de répartition is continuous at $a < 1$; therefore $e^{-n} F(a, n) = \mathbb{P}(\frac{1}{n} \sum X_i \leq a) \rightarrow 0$.

At the critical value $a = 1$ the loi forte says nothing, since 1 is the discontinuity point of the limit, and the théorème central limite takes over: $\sqrt{n}(\frac{1}{n} \sum X_i - 1) \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$ because $\mathcal{P}(1)$ has espérance and variance both equal to 1, and 0 is a continuity point of the fonction de répartition of the loi normale, so

$$e^{-n} F(1, n) = \mathbb{P}(\sqrt{n}(\frac{1}{n} \sum_i X_i - 1) \leq 0) \rightarrow \frac{1}{2}.$$

The example is the clearest illustration of the division of labour between the two theorems: away from the mean the loi forte decides, and exactly at the mean only the théorème central limite can.

Example (Fluctuations of the limiting geometric mean). Continuing the uniform example of the previous subsection, with $G_n = \sqrt[n]{U_1 \cdots U_n}$ and $\mathbb{E}(\ln U_1) = -1$. Set $Z_n = (cG_n)^{\sqrt{n}}$ and take a logarithm:

$$\ln Z_n = \sqrt{n} \left(\ln c + \frac{1}{n} \sum_{i=1}^n \ln U_i \right).$$

This is the théorème central limite's expression provided $\ln c$ cancels the espérance, that is $\ln c = -\mathbb{E}(\ln U_1) = 1$, so $c = e$. Since $-\ln U_1 \sim \mathcal{E}(1)$ has variance 1,

$$\ln Z_n \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1),$$

and the exponential being continuous, $Z_n \xrightarrow{\mathcal{L}} Z = e^X$ with $X \sim \mathcal{N}(0, 1)$. The densité of Z follows from the théorème de transfert and the changement de variable $z = e^x$. Pour toute fonction mesurable $\phi \geq 0$,

$$\mathbb{E}(\phi(Z)) = \int_{\mathbb{R}} \phi(e^x) \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = \int_0^{+\infty} \phi(z) \frac{1}{\sqrt{2\pi} z} e^{-(\ln z)^2/2} dz,$$

la densité est donc :

$$f_Z(z) = \frac{1}{\sqrt{2\pi} z} e^{-(\ln z)^2/2} \mathbb{1}_{\mathbb{R}_+}(z),$$

c'est une **loi log-normale** (*log-normal distribution*). Between them, this example and the one it continues use both stability results of the first two subsections, in the same shape — the presque sûre one there, the one for convergence en loi here: the logarithm turns the product into a sum, the limit theorem acts on the sum, the exponential carries the conclusion back.

Example (Excess of ones over zeros in a binary expansion). Soit U une variable aléatoire uniforme sur $[0, 1]$. On note X_n et Y_n les nombres de 0 et de 1 parmi les n premiers bits de sa décomposition binaire. With $b_1, b_2, \dots$ i.i.d. of loi $\mathcal{B}(1/2)$ as before, $Y_n = \sum_{k \leq n} b_k$ and $X_n = n - Y_n$, so

$$X_n - Y_n = \sum_{k=1}^n (1 - 2b_k).$$

The summands $1 - 2b_k$ are i.i.d., take the values ± 1 with probability $1/2$ each, and so have espérance 0 and variance 1. The specialised form of the théorème central limite applies directly:

$$\frac{X_n - Y_n}{\sqrt{n}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1).$$

The loi forte already said that the excess is $o(n)$; the théorème central limite says it is of order exactly $\sqrt{n}$, with Gaussian fluctuations.

Example (A rate the théorème central limite does not supply). The théorème central limite is a statement about a limit and gives no bound at any fixed n . When a bound is wanted — an **inégalité de déviation** (*deviation inequality*) — the route is the exponential moment, and it is worth carrying because the technique reappears whenever a rate is asked for.

Let $Y_1, Y_2, \dots$ be i.i.d. on $\{-1, +1\}$ with $\mathbb{P}(Y_1 = 1) = 1/2$, and $S_n = Y_1 + \cdots + Y_n$. Fix $a > 0$.

1. *Exponentiate, then apply Markov.* For every $x > 0$ the map $s \mapsto e^{xs}$ is increasing, so $\{S_n > a\} = \{e^{xS_n} > e^{xa}\}$, and the inégalité de Markov applied to the non-negative variable e^{xS_n} gives $\mathbb{P}(S_n > a) \leq e^{-ax} \mathbb{E}(e^{xS_n})$.
2. *Compute the exponential moment.* The variables being indépendantes et identiquement distribuées, $\mathbb{E}(e^{xS_n}) = \mathbb{E}(e^{xY_1})^n = \cosh(x)^n$, since $\mathbb{E}(e^{xY_1}) = \frac{1}{2}(e^x + e^{-x})$.
3. *Bound it.* Studying the sign of $x \mapsto x^2/2 - \ln \cosh(x)$, whose derivative $x - \tanh(x)$ is non-negative on $\mathbb{R}_+$ and which vanishes at 0, gives $\cosh(x) \leq e^{x^2/2}$, hence $\mathbb{E}(e^{xS_n}) \leq e^{nx^2/2}$ for $x > 0$.

4. *Optimise.* The bound is now $e^{-ax+nx^2/2}$; minimising the exponent over $x > 0$ gives $x = a/n$ and $\mathbb{P}(S_n > a) \leq e^{-a^2/(2n)}$.

5. *Symmetrise.* The loi of S_n is symétrique, so the borne de l'union gives $\mathbb{P}(|S_n| > a) \leq 2e^{-a^2/(2n)}$.

Two things to notice. The bound holds at every n , not asymptotically, which is what the limit theorems never give. And taking $a = \varepsilon n$ gives $\mathbb{P}(|S_n/n| > \varepsilon) \leq 2e^{-\varepsilon^2 n/2}$, an exponential rate for a convergence that the loi forte, read through the implication of the first subsection, gives without any rate at all.

8.5 Cas des vecteurs aléatoires

La loi des grands nombres et le théorème central limite s'étendent sans difficulté au cas vectoriel. The empirical mean is taken coordinate by coordinate, the espérance becomes a vector, and the variance becomes a matrice de covariance Γ .

Theorem (Loi forte des grands nombres – cas vectoriel). *Pour toute suite $X_1, X_2, \dots$ de vecteurs aléatoires réels i.i.d. ayant une espérance,*

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p.s.} \mathbb{E}(X_1).$$

Theorem (Théorème central limite – cas vectoriel). *Pour toute suite $X_1, X_2, \dots$ de vecteurs aléatoires réels i.i.d. d'espérance finie μ et de matrice de covariance finie Γ ,*

$$\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n X_i - \mu \right) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \Gamma).$$

Remark. The loi forte in the vector case is the scalar one applied to each coordinate, together with the fact that a finite intersection of événements of probability 1 has probability 1 — which is why it costs nothing. The théorème central limite in the vector case is genuinely more than its coordinates: convergence en loi of each coordinate does not give convergence en loi of the vector, since the loi jointe is not determined by the lois marginales. What repairs this is the fonction caractéristique of a vecteur aléatoire, which does determine the loi jointe, together with the vector form of branch 3: pointwise convergence of fonctions caractéristiques on $\mathbb{R}^d$, d being the dimension of the vectors, gives convergence en loi. That vector form is the missing ingredient and is stated, not proved, here — the characterisation theorem above is for variables aléatoires réelles, and this course states the vector case without supplying it. The matrice de covariance Γ carries the dependence between coordinates that the lois marginales lose.

Remark. “Matrice de covariance finie” means every entry finite, that is, a moment d'ordre 2 for every coordinate. No invertibility of Γ is required anywhere: a Γ that is dégénérée gives a vecteur gaussien supported on a proper subspace, which is a perfectly good limit en loi even though it has no densité on $\mathbb{R}^d$.

Example (Uniform points on the unit disc). Soit $X_1, X_2, \dots$ une suite de vecteurs aléatoires réels i.i.d. (in $\mathbb{R}^2$) de loi uniforme sur le disque unité. Their espérance is 0 by symmetry, and leur matrice de covariance est $I/4$, où I désigne la matrice identité en dimension 2: writing $X_1 = (X, Y)$ for the two coordinates of one point, the off-diagonal entry $\mathbb{E}(XY)$ vanishes by symmetry, and in polar coordinates the diagonal entry is

$$\mathbb{E}(X^2) = \frac{1}{\pi} \int_0^{2\pi} \int_0^1 r^2 \cos^2 \theta \cdot r \, dr \, d\theta = \frac{1}{\pi} \cdot \frac{1}{4} \cdot \pi = \frac{1}{4}.$$

Alors, by the théorème central limite in the vector case,

$$\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n X_i \right) \xrightarrow{\mathcal{L}} \mathcal{N}\left(0, \frac{I}{4}\right).$$

The limit is a rescaled vecteur gaussien centré réduit, so its level sets are circles: the isotropy of the disc survives into the limit.

Example (The barycentre of random points). Soit G_n le barycentre de n points aléatoires indépendants de même loi uniforme sur le disque unité. Then $G_n = \frac{1}{n} \sum_{i \leq n} X_i$ is exactly the empirical mean of the previous example, so $G_n \xrightarrow{\text{p.s.}} 0$ by the loi forte in the vector case, and

$$\sqrt{n} G_n \xrightarrow{\mathcal{L}} \mathcal{N}\left(0, \frac{I}{4}\right).$$

The barycentre of many random points is near the centre, at distance of order $1/\sqrt{n}$, and its fluctuation is isotropic Gaussian.

Example (Order statistics of two uniform variables). Soient U, V deux variables aléatoires indépendantes de loi uniforme sur $[0, 1]$. On note le vecteur $Z = (X, Y)$ avec $X = \min(U, V)$ et $Y = \max(U, V)$, et $Z_1, Z_2, \dots$ une suite de vecteurs aléatoires i.i.d. de même loi que Z .

The loi of Z . The pair (U, V) has densité $\mathbb{1}_{[0,1]^2}$, and (X, Y) is obtained by folding the square along its diagonal — the two points (u, v) and (v, u) give the same (x, y) — so

$$f_Z(x, y) = 2 \mathbb{1}_{\{0 < x < y < 1\}}.$$

The almost-sure limit. The lois marginales have densités $2(1-x)$ and $2y$ on $[0, 1]$, so $\mathbb{E}(X) = 1/3$ and $\mathbb{E}(Y) = 2/3$, and the loi forte in the vector case gives

$$\frac{1}{n} \sum_{k=1}^n Z_k \xrightarrow{\text{p.s.}} \mu = \left(\frac{1}{3}, \frac{2}{3}\right).$$

The fluctuations. The second moments are $\mathbb{E}(X^2) = 1/6$ and $\mathbb{E}(Y^2) = 1/2$, so $\text{Var}(X) = \text{Var}(Y) = 1/18$; and since $XY = UV$ with U, V independent, $\mathbb{E}(XY) = 1/4$ and $\text{Cov}(X, Y) = 1/4 - 2/9 = 1/36$. Hence

$$\Gamma = \frac{1}{36} \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}, \quad \sqrt{n} \left(\frac{1}{n} \sum_{k=1}^n Z_k - \mu \right) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \Gamma).$$

The off-diagonal entry is positive and non-zero, as it must be — the minimum and the maximum of the same pair move together — and this is exactly the information that treating the two coordinates separately would have thrown away.

Conclusion. Two notions of convergence, two theorems, one bridge between them. Convergence presque sûre is pointwise convergence on an événement of probability 1, and everything true of convergent sequences of reals transfers to it by intersecting such événements. Convergence en loi looks only at the lois, through fonctions de répartition at continuity points of the limit, and is equivalently tested on bounded continuous functions or, decisively, on fonctions caractéristiques — which lets a loi limite be identified by a computation with no univers in it. Convergence presque sûre implies it, through convergence en probabilité if that mode is carried, and nothing implies convergence presque sûre.

The loi forte needs an espérance and delivers an almost-sure limit; the théorème central limite needs a variance as well, delivers only a limit en loi, and in exchange describes the deviation at the scale $\sqrt{n}$ with a Gaussian whose covariance is the only trace the underlying loi leaves. In practice the two are used in sequence and on transformed sequences: take a logarithm to turn a product into a sum, apply the loi forte for the location and the théorème central limite for the fluctuation, and push both conclusions back through a continuous map.

9 Annexes

This last chapter is the one to open with an exam paper in front of you. It carries three pieces of reference material — the lemme de classe monotone, the table of lois discrètes and the table of lois à densité — and adds to them a summary the course gives nowhere, a single page on the modes of convergence.

Two things are worth saying before the tables. The first is that the lemme de classe monotone is not

decoration: chapter 2's théorème d'unicité for mesures is proved by building a classe monotone and invoking the lemma, and without the lemma that proof has a hole in the middle. It is stated and proved here in full, hypotheses included.

The second is that the two tables of lois are *not* a bare list of definitions. Such a list gives a name, the parameters, the notation, the support and the loi; the tables below add the espérance, the variance and the fonction caractéristique on both sides, and — for the lois discrètes only — the fonction génératrice, from which their fonction caractéristique is read off directly. Those added columns are computed in chapters 1, 6 and 7, and they are the reason to have the tables at all: the first five columns alone tell you nothing you could not read off a definition.

9.1 Classe monotone

On se donne un ensemble Ω ; all the families considered in this subsection are families of subsets of Ω .

Definition (Classe monotone). Une famille $\mathcal{M}$ de sous-ensembles de Ω est appelée classe monotone sur Ω si elle vérifie les propriétés suivantes :

- $\Omega \in \mathcal{M}$;
- pour tous $A, B \in \mathcal{M}$ tels que $A \subseteq B$, $B \setminus A \in \mathcal{M}$;
- pour tous $A_1, A_2, \dots \in \mathcal{M}$ tels que $A_n \uparrow A$, $A \in \mathcal{M}$.

Remark (Why the first condition is needed). The first condition is $\Omega \in \mathcal{M}$, membership in the family $\mathcal{M}$ itself, and it has to be: the second condition produces complements only by subtracting from a set already in the family, so without Ω in $\mathcal{M}$ the family need not contain a single complement and the proposition below would be false.

Il est facile de vérifier que toute tribu est une classe monotone: a tribu contains Ω ; it is stable under proper difference, since $B \setminus A = B \cap A^c$; and it is stable under increasing limits, since an increasing limit is a countable union. L'inverse n'est pas vrai en général — a classe monotone need not be stable under intersection, and then it is not a tribu. Une condition nécessaire et suffisante pour qu'une classe monotone soit une tribu est qu'elle soit stable par intersection finie: the gap between the two notions is exactly that stability, which is the content of the next statement.

Proposition (Classe monotone qui est une tribu). Une classe monotone $\mathcal{M}$ est une tribu si et seulement si elle est stable par intersection finie.

Proof. If $\mathcal{M}$ is a tribu then it is stable par intersection finie, since $A \cap B = (A^c \cup B^c)^c$ and a tribu is stable under complement and under countable — hence finite — union.

Conversely, suppose the classe monotone $\mathcal{M}$ is stable par intersection finie. It contains Ω by the first axiom. It is stable under complement: for $A \in \mathcal{M}$ one has $A \subseteq \Omega$ and both sets lie in $\mathcal{M}$, so $A^c = \Omega \setminus A \in \mathcal{M}$ by the second axiom. Par passage au complémentaire, on obtient donc la stabilité par réunion finie, since

$$A \cup B = (A^c \cap B^c)^c,$$

the intersection on the right being in $\mathcal{M}$ by hypothesis. There remains countable union. Pour montrer la stabilité par réunion dénombrable, on considère une suite $(A_n)_{n \geq 1}$ dans $\mathcal{M}$. Put $B_n = \bigcup_{k=1}^n A_k$: each B_n lies in $\mathcal{M}$ by stability under finite union. Alors la suite $(B_n)_{n \geq 1}$ est croissante, si bien que sa limite

$$\bigcup_{n \geq 1} A_n = \lim_{n \rightarrow +\infty} \uparrow B_n$$

appartient à $\mathcal{M}$, by the third axiom. So $\mathcal{M}$ contains Ω and is stable under complement and countable union: it is a tribu.

Remark. The finite-union step is where stability under intersection is spent, and it is spent only there. That is the shape of every application: one wants a countable union, the third axiom delivers increasing limits only, and the gap is closed by turning an arbitrary countable union into an increasing one — which costs finite unions, which cost complements and finite intersections.

Comme pour les tribus, toute intersection de classes monotones sur Ω est une classe monotone: each of the three conditions is stable under intersecting the families, because each is a condition of the form “these sets belong to the family”. Since $\mathcal{P}(\Omega)$ is itself a classe monotone containing any collection whatsoever, the intersection below is taken over a non-empty family, ce qui permet de définir la notion de classe monotone engendrée.

Definition (Classe monotone engendrée). Soit $\mathcal{C} \subseteq \mathcal{P}(\Omega)$ une collection d’ensembles. L’intersection de toutes les classes monotones contenant $\mathcal{C}$ est une classe monotone, appelée la **classe monotone engendrée** (*generated monotone class*) par $\mathcal{C}$. On la note $\mathcal{M}(\mathcal{C})$.

The classe monotone engendrée is contained in the tribu engendrée, since a tribu is a classe monotone. La classe monotone engendrée n’est pas la tribu engendrée en général. C’est le cas dès que la collection $\mathcal{C}$ est stable par intersection finie. C’est le **lemme de classe monotone** (*monotone class lemma*).

Lemma (Lemme de classe monotone). Soit $\mathcal{C} \subseteq \mathcal{P}(\Omega)$ une collection d’ensembles stable par intersection finie. Alors

$$\mathcal{M}(\mathcal{C}) = \sigma(\mathcal{C}).$$

Proof. Puisque toute tribu est une classe monotone — $\sigma(\mathcal{C})$ is one, and it contains $\mathcal{C}$ —, on a nécessairement $\mathcal{M}(\mathcal{C}) \subseteq \sigma(\mathcal{C})$.

Pour montrer l’autre inclusion, il suffit de montrer que $\mathcal{M}(\mathcal{C})$ est une tribu — it then contains $\sigma(\mathcal{C})$, the smallest tribu containing $\mathcal{C}$ —, c’est-à-dire, d’après la proposition, qu’elle est stable par intersection finie: being a tribu amounts to that for a classe monotone, and that is what is proved, in two steps.

First step: one set in $\mathcal{C}$. Soit $A \in \mathcal{C}$. On définit :

$$\mathcal{M} = \{B \in \mathcal{M}(\mathcal{C}) : A \cap B \in \mathcal{M}(\mathcal{C})\}.$$

Comme $\mathcal{C}$ est stable par intersection finie — $A \cap B$ lies in $\mathcal{C} \subseteq \mathcal{M}(\mathcal{C})$ for every $B \in \mathcal{C}$ —, on a $\mathcal{C} \subseteq \mathcal{M}$. On vérifie par ailleurs que $\mathcal{M}$ est une classe monotone :

- $\Omega \in \mathcal{M}$, because $A \cap \Omega = A \in \mathcal{C} \subseteq \mathcal{M}(\mathcal{C})$;
- pour tous $A', B' \in \mathcal{M}$ tels que $A' \subseteq B'$,

$$A \cap (B' \setminus A') = (A \cap B') \setminus (A \cap A') \in \mathcal{M}(\mathcal{C}),$$

the two sets on the right being in $\mathcal{M}(\mathcal{C})$ by definition of $\mathcal{M}$ and nested because $A' \subseteq B'$, donc $B' \setminus A' \in \mathcal{M}$;

- pour tous $A'_1, A'_2, \dots \in \mathcal{M}$ tels que $A'_n \uparrow A'$, one has $A \cap A'_n \uparrow A \cap A'$, an increasing limit of sets of $\mathcal{M}(\mathcal{C})$, whence $A \cap A' \in \mathcal{M}(\mathcal{C})$, de sorte que $A' \in \mathcal{M}$.

Comme $\mathcal{M}$ — a classe monotone — contient $\mathcal{C}$, on a $\mathcal{M}(\mathcal{C}) \subseteq \mathcal{M}$. Unwinding the definition of $\mathcal{M}$, on a donc montré que :

$$\forall A \in \mathcal{C}, \forall B \in \mathcal{M}(\mathcal{C}), \quad A \cap B \in \mathcal{M}(\mathcal{C}).$$

Second step: both sets in $\mathcal{M}(\mathcal{C})$. Pour conclure, on fixe $B \in \mathcal{M}(\mathcal{C})$ et on définit :

$$\mathcal{M}' = \{A \in \mathcal{M}(\mathcal{C}) : A \cap B \in \mathcal{M}(\mathcal{C})\}.$$

On sait que $\mathcal{C} \subseteq \mathcal{M}'$: it is exactly the conclusion of the first step. Par les mêmes arguments que précédemment — the same three verifications as above, with B now playing the role A played there —, on montre que $\mathcal{M}'$ est une classe monotone, si bien que $\mathcal{M}(\mathcal{C}) \subseteq \mathcal{M}'$. On a donc :

$$\forall A, B \in \mathcal{M}(\mathcal{C}), \quad A \cap B \in \mathcal{M}(\mathcal{C}).$$

Ce qui prouve que $\mathcal{M}(\mathcal{C})$ est stable par intersection finie. Being a classe monotone, it is therefore a tribu, which completes the proof.

Remark (Why the two steps). The asymmetry is the whole proof. The hypothesis on $\mathcal{C}$ gives intersections of two sets of $\mathcal{C}$; the first step upgrades one of the two arguments to an arbitrary element of $\mathcal{M}(\mathcal{C})$, and the second step upgrades the other, using the first step's conclusion as the seed $\mathcal{C} \subseteq \mathcal{M}'$. Dropping stability of $\mathcal{C}$ under finite intersection kills the first step at its first line, and the lemma is false without it — as is chapter 2's théorème d'unicité, which is why that theorem carries the same hypothesis, alongside its own second condition that Ω be covered by countably many elements of $\mathcal{C}$ of finite mesure. Both are load-bearing there: the first buys this lemma, the second is what lets the equality be passed to the limit along an increasing exhaustion of Ω .

9.2 Lois usuelles

The two tables below list the usual lois with columns added — four to the table of lois discrètes, three to the table of lois à densité. Name, parameters, notation, support and loi define each entry; the espérance, the variance and the transforms are computed elsewhere in these notes and are gathered here. Read the notation column first: it fixes which meaning each of the overloaded symbols carries, and the closing note of this chapter lists the overloads.

Lois discrètes

Nom	Paramètre(s)	Notation	Support	Loi	$\mathbb{E}(X)$	$\text{Var}(X)$
Bernoulli	$p \in [0, 1]$	$\mathcal{B}(p)$	$\{0, 1\}$	$\begin{cases} p & k = 1 \\ 1 - p & k = 0 \end{cases}$	p	$p(1 - p)$
Binomiale	$n \in \mathbb{N}, p \in [0, 1]$	$\mathcal{B}(n, p)$	$\{0, 1, \dots, n\}$	$\binom{n}{k} p^k (1 - p)^{n-k}$	np	$np(1 - p)$
Poisson	$\lambda > 0$	$\mathcal{P}(\lambda)$	$\mathbb{N}$	$e^{-\lambda} \frac{\lambda^k}{k!}$	λ	λ
Géométrique	$p \in]0, 1]$	$\mathcal{G}(p)$	$\mathbb{N}^*$	$(1 - p)^{k-1} p$	$\frac{1}{p}$	$\frac{1 - p}{p^2}$
Uniforme	$n \in \mathbb{N}^*$	$\mathcal{U}(1, \dots, n)$	$\{1, \dots, n\}$	$\frac{1}{n}$	$\frac{n+1}{2}$	$\frac{n^2 - 1}{12}$

Nom	Notation	$G_X(t) = \mathbb{E}(t^X)$	$\varphi_X(t) = G_X(e^{it})$
Bernoulli	$\mathcal{B}(p)$	$1 - p + pt$	$1 - p + pe^{it}$
Binomiale	$\mathcal{B}(n, p)$	$(1 - p + pt)^n$	$(1 - p + pe^{it})^n$
Poisson	$\mathcal{P}(\lambda)$	$e^{\lambda(t-1)}$	$e^{\lambda(e^{it}-1)}$
Géométrique	$\mathcal{G}(p)$	$\frac{pt}{1 - (1-p)t}$	$\frac{pe^{it}}{1 - (1-p)e^{it}}$
Uniforme	$\mathcal{U}(1, \dots, n)$	$\frac{t(1-t^n)}{n(1-t)}$	$\frac{1}{n} e^{it} \frac{e^{int} - 1}{e^{it} - 1}$

The first table gives the definitions plus the two moment columns; the second carries the fonction génératrice computed in chapter 1 and, beside it, the fonction caractéristique of chapter 6. The two are the same object: for a variable with values in $\mathbb{N}$,

$$\varphi_X(t) = \mathbb{E}(e^{itX}) = \mathbb{E}\left((e^{it})^X\right) = G_X(e^{it}),$$

so the right-hand column is the middle one evaluated on the unit circle and nothing new has to be memorised. The entry for the loi uniforme is written for $t \neq 1$ and, in the characteristic form, for $t \notin 2\pi\mathbb{Z}$; at the excluded points every term of the sum is 1 and the value is 1.

Remark (The geometric support is a convention, and it moves). The table supports the loi géométrique on $\mathbb{N}^*$: X counts the trials up to and including the first success, so $\mathbb{E}(X) = 1/p$. Many sources, and some exercises, instead use $\tau = X - 1$, the number of failures *before* the first success, supported on $\mathbb{N}$, with $\mathbb{E}(\tau) = (1 - p)/p$ and the same variance $(1 - p)/p^2$. The table above follows the course's convention. Check which of the two a question means before quoting a mean.

Lois à densité

Nom	Paramètre(s)	Notation	Support	Densité	$\mathbb{E}(X)$	$\text{Var}(X)$
Exponentielle	$\lambda > 0$	$\mathcal{E}(\lambda)$	$\mathbb{R}_+$	$\lambda e^{-\lambda x} \mathbb{1}_{\mathbb{R}_+}(x)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Gamma	$a, \lambda > 0$	$\Gamma(a, \lambda)$	$\mathbb{R}_+$	$\frac{\lambda^a}{\Gamma(a)} x^{a-1} e^{-\lambda x} \mathbb{1}_{\mathbb{R}_+}(x)$	$\frac{a}{\lambda}$	$\frac{a}{\lambda^2}$
Uniforme	$a < b$	$\mathcal{U}([a, b])$	$[a, b]$	$\frac{1}{b-a} \mathbb{1}_{[a, b]}(x)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Beta	$a, b > 0$	$\mathcal{B}(a, b)$	$[0, 1]$	$\frac{1}{B(a, b)} x^{a-1} (1-x)^{b-1} \mathbb{1}_{[0, 1]}(x)$	$\frac{a}{a+b}$	$\frac{ab}{(a+b)^2(a+b+1)}$
Normale	$\mu \in \mathbb{R}, \sigma^2 > 0$	$\mathcal{N}(\mu, \sigma^2)$	$\mathbb{R}$	$\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	μ	σ^2

Each support is the set on which the densité's indicator does not vanish; the densité of the loi normale carries no indicator, and its support is all of $\mathbb{R}$. The fonctions caractéristiques, computed in chapter 6, are:

Nom	Notation	$\varphi_X(t) = \mathbb{E}(e^{itX})$
Exponentielle	$\mathcal{E}(\lambda)$	$\frac{\lambda}{\lambda - it}$
Gamma	$\Gamma(a, \lambda)$	$\left(\frac{\lambda}{\lambda - it}\right)^a$
Uniforme	$\mathcal{U}([a, b])$	$\frac{e^{itb} - e^{ita}}{it(b-a)}$ for $t \neq 0$, and 1 at $t = 0$
Beta	$\mathcal{B}(a, b)$	$\sum_{k \geq 0} \left(\prod_{r=0}^{k-1} \frac{a+r}{a+b+r} \right) \frac{(it)^k}{k!}$
Normale	$\mathcal{N}(\mu, \sigma^2)$	$e^{i\mu t} e^{-\sigma^2 t^2 / 2}$

Remark (The loi normale row is an addition). The loi normale is developed with the vecteurs gaussiens in chapter 7 rather than alongside the lois exponentielle, Gamma, uniforme and Beta. The row above is added anyway — its fonction caractéristique is chapter 6's, and the reason for wanting it in a reference table at all is chapter 7's Gaussian development — and it is worth having here, because it is the one loi an exam is certain to use and the one row a revision sheet built from those four lois alone would lack.

Remark (Which entries are computed, and where). The moments of the lois exponentielle and Gamma come from the fonction caractéristique by the moment expansion of chapter 6, and the Gamma line at $a = 1$ reproduces the Exponentielle line as a check. The moments of the loi uniforme are chapter 6's unit-interval computation $\mathbb{E} = 1/2$, $\text{Var} = 1/12$ transported by the affine map $x \mapsto a + (b-a)x$, which shifts the mean to $(a+b)/2$ and scales the variance by $(b-a)^2$. The moments of the loi Beta come from the moment formula $\mathbb{E}(X^k) = \prod_{r=0}^{k-1} \frac{a+r}{a+b+r}$ of the same chapter, at $k = 1$ and $k = 2$. The Normale row's fonction caractéristique is chapter 6's; its mean and variance are its parameters, as chapter 7 defines them.

Remark (The beta fonction caractéristique has no elementary closed form). Four of the five lois above have a fonction caractéristique in closed form; the loi Beta does not, and the series recorded in the table is the honest answer rather than an omission. It converges everywhere — the support is bounded, so every moment exists and the partial sums are dominated by $e^{|t|}$ times the densité — and it is the confluent hypergeometric function $M(a, a+b, it)$. On an exam a question about the loi Beta asks for a moment, not for φ_X .

9.3 Notions de convergence


The course defines two modes of convergence for variables aléatoires and names a third only to say that it is not treated. They are collected here with the implications between them, because the two theorems of chapter 8 deliver different ones and saying which is half of a correct answer.

La notion de convergence la plus forte — the strongest of the three — est une convergence simple, valable pour presque toute réalisation ω : the numbers $X_n(\omega)$ converge, and the set of ω at which $X_n(\omega) \rightarrow X(\omega)$ has probability 1. On parle de convergence presque sûre. On utilise la notation $X_n \xrightarrow{\text{p.s.}} X$. It composes

freely with continuous maps, as convergence en loi also does.

La convergence en loi forgets the univers entirely: elle ne concerne que les lois des variables aléatoires impliquées, et non leur réalisation. They are compared through the fonctions de répartition, and $F_n(x) \rightarrow F(x)$ is required at the continuity points of F alone. On utilise la notation $X_n \xrightarrow{\mathcal{L}} X$; comme cette notion de convergence s'applique aux lois, on pourra également l'écrire comme tel, par exemple $X_n \xrightarrow{\mathcal{L}} \mathcal{N}(0,1)$. The restriction to continuity points is the content of the definition and not a technicality: without it the deterministic sequence $1/n$ would fail to converge en loi to 0.

La convergence en probabilité requires $\mathbb{P}(|X_n - X| > a) \rightarrow 0$ for every $a > 0$, and is written $X_n \xrightarrow{\mathbb{P}} X$. *The course does not define it.* D'autres notions de convergence existent, comme la convergence en probabilité, mais ne sont pas abordées dans ce cours: the course names it only to say so, and proves nothing about it. It is carried in these notes as an addition, because it sits between the two modes the course does define, and a problem on this syllabus may well supply its definition inline before asking for an implication — which is itself a sign that the course does not supply it.



the dashed box and the dashed arrow are the addition —
the course defines only the two solid modes

Remark (No arrow reverses). Convergence presque sûre implies convergence en probabilité — proved in chapter 8 — and convergence en probabilité implies convergence en loi, an implication carried here without proof; neither converse holds. An indicator window of width $1/n$ sliding cyclically around $[0, 1]$ has $\mathbb{P}(|X_n| > a) = 1/n \rightarrow 0$, so $X_n \xrightarrow{\mathbb{P}} 0$, while every ω is hit infinitely often and $X_n(\omega)$ converges for no ω at all. And with X of loi normale centrée réduite and $X_n = -X$ for every n , the lois are equal so $X_n \xrightarrow{\mathcal{L}} X$ holds trivially, while $|X_n - X| = 2|X|$ never gets small. The one partial converse worth knowing belongs to the addition and is stated, not proved, in these notes: convergence en loi *to a constant* does imply convergence en probabilité to that constant.

The practical criterion for convergence en loi is not the definition but the fonction caractéristique, and it comes from two results used together. Chapter 6 proves that the fonction caractéristique determines the loi: $\mathbb{P}_X = \mathbb{P}_Y$ if and only if $\varphi_X = \varphi_Y$. Chapter 8's theorem on the three characterisations of convergence en loi then upgrades that from lois to sequences of lois.

Theorem (Trois caractérisations de la convergence en loi). *Soit $X_1, X_2, \dots$ une suite de variables aléatoires réelles, de fonctions caractéristiques respectives $\varphi_1, \varphi_2, \dots$, et X une variable aléatoire réelle, de fonction caractéristique φ . Les propositions suivantes sont équivalentes :*

1. $X_n \xrightarrow{\mathcal{L}} X$;
2. $\mathbb{E}(\phi(X_n)) \rightarrow \mathbb{E}(\phi(X))$ pour toute fonction continue bornée ϕ ;
3. $\varphi_n(t) \rightarrow \varphi(t)$ pour tout $t \in \mathbb{R}$.

The third characterisation is the one that gets used: to prove a convergence en loi, compute the fonction caractéristique of the n -th term, take its pointwise limit, and recognise the result. That is exactly how the théorème central limite is proved.

Two hypotheses inside the criterion are worth keeping in view. The fonctions test of the second characterisation must be bounded *and* continuous — boundedness alone is what makes convergence dominée available, and continuity alone is what lets convergence presque sûre be pushed through. And the pointwise convergence of the third is convergence at every real t , not on a neighbourhood of 0 and not uniformly.

Which mode does each theorem deliver? The two results of chapter 8 answer differently, and confusing them is the standard error.

Theorem (Loi forte des grands nombres). *Pour toute suite $X_1, X_2, \dots$ de variables aléatoires réelles i.i.d. ayant une espérance,*

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p.s.} \mathbb{E}(X_1).$$

Theorem (Théorème central limite). *Pour toute suite $X_1, X_2, \dots$ de variables aléatoires réelles i.i.d. d'espérance finie μ et de variance finie σ^2 ,*

$$\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n X_i - \mu \right) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2).$$

Remark (The hypotheses are not interchangeable either). The loi forte asks for an espérance, that is $\mathbb{E}(|X_1|) < +\infty$, and *not* for a finite variance; the finite variance belongs to the weak law and to one proof of the loi forte, and importing it into the statement weakens the theorem for nothing. The théorème central limite does need a finite variance, since σ^2 appears in its conclusion. So the loi forte delivers the strongest mode under the weaker hypothesis, and the théorème central limite the weakest mode under the stronger one — which is not a paradox: they say different things, one about where the mean goes and one about how large the error is on the way.

Conclusion. Five symbols in these notes carry more than one meaning, because the course's notation is kept as exams use it, collisions included, and each time the meaning is fixed by what sits in the parentheses. $\mathcal{P}$ is the ensemble des parties $\mathcal{P}(\Omega)$ and the loi de Poisson $\mathcal{P}(\lambda)$. $\mathcal{B}$ is the tribu de Borel $\mathcal{B}(\mathbb{R})$, the loi de Bernoulli $\mathcal{B}(p)$, the loi binomiale $\mathcal{B}(n, p)$ and the loi Beta $\mathcal{B}(a, b)$. λ is the mesure de Lebesgue and the parameter of the loi exponentielle and the loi de Poisson. Γ is the loi Gamma $\Gamma(a, \lambda)$ and the matrice de covariance of a vecteur gaussien, $\mathcal{N}(\mu, \Gamma)$ — and, in the densité of the loi Gamma, also the gamma function. $\mathcal{E}$ is a generic tribu, as in $(E, \mathcal{E})$, and the loi exponentielle $\mathcal{E}(\lambda)$. All five appear in the tables above in their meaning as a loi, and two of them collide there on a single page: $\mathcal{B}$ carries the loi de Bernoulli, the loi binomiale and the loi Beta in the same two tables, and the Gamma row prints the loi Gamma and the gamma function side by side. That is why the notation column is the one to read first.